存算一体非线性失真的读出适配
——进展摘要与当前状况（2026-10-19）

黄奕皓　中国科学院大学计算机科学与技术　huangyihao24@mails.ucas.ac.cn

方法与此处的每个数字见 *paper/journal/*（期刊稿，*33* 页）与 *paper/technical-report/*（技术报告，*31* 页）；全部数字可追溯到仓库内的产物文件。

一、这个工作在问什么

存算一体芯片把乘法和加法放在存储阵列里完成，省电、速度快；代价是模拟电路不完美，误差会直接进入计算。比赛给的失真模型是：每个输入先按自己的最大绝对值归一化，再经过一个三次函数，参数 α 控制失真强度。注意：归一化后最大分量恒为 ± 1，所以 $\alpha > 0$ 时端点不变、中间段被压向零；$\alpha < 0$ 时中间段被放大。这个失真不是随机的，它跟各分量相对该层最大值的比例有关，而且会一层一层累积。

工程上有两个限制：第一，部署阶段不更新阵列里的权重（重写代价高，寿命和能耗也不允许）；第二，本文只考虑数字域可改的部分。所以本文问的不是“怎么让网络更抗失真”，而是 **“权重不动的时候，到底改哪一层最有用”**。所有结果都来自这个参数化模型的计算机仿真，没有在真实芯片上测过。

二、主要结论

先说定位：**只重训最后一层不是本文发明的方法**。它在迁移学习里叫线性探针；在存算一体里，Nature 2020 的混合训练也在硬件侧做过微调，近年的 AHWA-LoRA、DoRA 校准、只调 BatchNorm 等工作也属于“冻结阵列、只更新少量参数”这一族。本文的贡献是：诊断瓶颈在哪、还能恢复多少、损伤在特征空间里是什么形态、哪个架构变量不增加可训练参数、修复的边界在哪。

在 SimpleCNN 与 VGG-11 的最严重正向失真（$\alpha = +0.3$）下，网络丢的主要是“维度/散布尺度”；类中心结构没有同步变差（类间与类内散布都在缩，类内缩得更快），不是简单的“类间距缩小”。把特征提取部分冻住，在最后的特征上重新训练一个线性分类器，并假定失真强度已知（oracle 口径），准确率能到 **48.35%**（CIFAR-100/SimpleCNN），而原分类层只有 **28.09%**，差 **20.26 个百分点**。**48.35% 是诊断上界，不是可部署读数**；真正部署时不知道 α，只重训最后一层线性分类器能拿到 **43.31%**，是上界的 **89.6%**。换成普通高斯噪声，差距只有 **7.50 个百分点**；但高斯噪声其实更狠（clean 3.98% 对 28.09%），只是可恢复空间更小。

为了确认这不是测量方法造成的，我做了四个对照实验（随机标签、激活噪声下精度崩塌的临界点、重新划分训练/测试集、以及与网络训练集完全不相交的划分）。四个都没有推翻结论；其中只有“临界点”一项提供了独立的第二读数，而且只在大方向上一致。把分类器的训练样本加到 50000 后，oracle 口径的读数升到 **27.63 个百分点**（按不相交校正约 **25.4**）；真实可解码性至少 25.4 个百分点，仍未饱和。

修复办法是：冻住整个特征提取网络，只重训最后那一层线性分类器。三个网络（SimpleCNN/VGG-11/ResNet-18）上，最严重失真时的准确率从 28.09/15.98/6.22 提升到 **43.31/47.79/26.82**；训练需要约 2 万条带标签的失真特征，训练时间 12–30 分钟，是重训整个网络的 1/5–1/16。在本文比较的全部全网络鲁棒训练配方中，这是最好的结果；但“最好”只限本文测过的路径和设置。网络结构上还有一个办法：把最大池化层从 2 个增加到 5 个（SimpleCNN），参数量不变、不增加额外训练成本，但必须在设计阶段选定；同设置同种子下提高 **15.52 个百分点**（单 seed；3 seed 复核同向 +12.20，基线协议不同）。两个办法可以一起用，合起来 +21.09，约为单独增益之和 +29.60 的七成（架构侧单 seed、读出侧 3 seed）。

反过来，训练端的五条路——采样预算分配、对抗训练、课程式采样、训练范围外推、解冻微调——**没有一条改善最严重失真**；最后一条反而明显变差。还要说明：正侧最严重只在 SimpleCNN 和 VGG-11 上成立；ResNet-18 的负侧更严重，这是架构依赖的。

三、主要证据一览

量	取值	说明
oracle 探针能多恢复（CIFAR-100/SimpleCNN）	**+20.26**	高斯对照 +7.50；样本加到 5 万后 +27.63（oracle 读数；校正约 +25.4；未饱和）
可部署只重训分类层（三网络）	**43.31/47.79/26.82**	各 3 seed；约 2 万带标签失真特征；训练 12–30 分钟
最大池化 2 → 5（SimpleCNN）	**+15.52**	同设置同 seed，单 seed；3 seed 复核 +12.20（基线异协议）；不增加可训练参数
训练端五条路径	无一改善	采样预算 / 对抗 / 课程 / 外推四条无效；解冻微调反而变差
有效维度减少 → 恢复比例	$r = -0.934$（四点）	有效维度减少**不是**唯一因素

四、哪些方向已经试过、不行

已被实验否定，不建议再试：四条训练端路径（采样预算分配、对抗训练、课程式采样、训练范围外推）；先训分类层再解冻微调（三个网络都明显变差，说明微调破坏了预训练特征）；“只要少量样本就能恢复全部特征”；部署前让门控自检；“分类层容量不够”（试过 k-NN 和两种多层感知机，在本文的模型和训练预算下没有发现容量不足的证据；其中一种多层感知机落在可分辨门槛内，不能裁决）。

五、还没解决的问题

- **所有结果都是计算机仿真，没有在真实芯片上测过。**如果真实器件的失真形式和模型不一样，这个结论还成不成立，现在不知道。
- **除了“特征的有效维度减少”以外，还有一个我们没找到的因素：**两个网络的有效维度只差 0.7 个百分点，恢复比例却差 4.0 个百分点。
- **两套代码实现之间有 5.55 个百分点的差异，**三次干预仍未找到原因；找到原因前，不把两套实现的精度数字直接比较。
- 只重训分类层这个办法，只在 $|\alpha| \le 0.3$ 的范围内试过；更严重的失真还没测。

六、还剩多少工作

主要实验已完成；剩下的主要是：换一种失真形式做对照（约 10 小时）、查清两套代码实现差异（要改训练循环）、找出有效维度之外的因素（约 6 小时）、按失真强度切换两个分类层（约 6 小时）、试一组不同形状的失真模型（约 12 小时）、系统搜索架构改进（约 10 小时）。还有一项实验需要新数据集，按项目规则先确认；全部需要 GPU，只能一个接一个跑。

这些结论可信吗：每条结论跑前先写死判据、跑后不改；阴性结果全部保留，包括三次“先归因、后被自己的数据推翻”。所有数字可追溯到仓库产物。目前正文已引的文献已做过核对；这次新补的先行工作已补到摘要级（Kong ISCAS 2026 已从 Semantic Scholar 取到逐字摘要），尚未逐字精读全文。