

存算一体芯片中非线性误差对推理精度的影响研究

黄奕皓

中国科学院大学计算机科学与技术，北京

huangyihao24@mailsucas.ac.cn

摘要

存算一体架构把乘累加运算放进模拟存储阵列，代价是模拟器件的非理想特性直接进入计算通路。本文将输入侧的非线性失真建模为逐样本归一化后的三次多项式 $y = \alpha \hat{x}^3 + (1 - \alpha)\hat{x}$ ，在 CIFAR-10 上对浅层纯前馈（SimpleCNN, 0.24M）、深层纯前馈（VGG-11, 9.2M）与深层残差（ResNet-18, 11.2M）三类架构，完成了敏感性分析、非线性感知训练与鲁棒性增强三项任务，以及跨架构、跨扰动类型、多误差源三项拓展研究。

主要结果如下。**任务 1：**正向失真（ $\alpha > 0$ ）的破坏力是负向的 3.4 倍，误差从浅层向深层累积，残差连接是误差放大器—— $\alpha = +0.3$ 时 ResNet-18 从 92.09% 掉到 17.08%，跌幅 75 个百分点，显著重于 VGG-11（36.70%）与 SimpleCNN（55.08%）。**任务 2：**非线性感知训练在纯前馈网络上有效（Scratch 策略 $\alpha = +0.3$ 分别提升 9.15 与 8.04 个百分点），但在残差网络上失效甚至退化（-1.44）；极限失真下的效果与注入点数量负相关（5→9→18 点）。**任务 3：**在感知训练基础上叠加“残差校准模块 + 分层加权采样”，把 SimpleCNN 的 $\alpha = +0.3$ 从 55.08% 提升到 **68.76%**；消融显示分层加权是贡献最大的单项（+5.13），非对称采样的边际贡献仅 +0.38。

拓展与第二阶段：跨架构对比显示脆弱性随深度与残差连接递增；高斯噪声与非线性失真的破坏机制不可通用迁移（ResNet-18 上两者甚至完全反转）；量化与非线性联合作用呈现三分格局——SimpleCNN 超加性恶化（ $\Delta = -7.23$ ）、VGG-11 次加性即 Dithering（ $\Delta = +7.82$ ）、ResNet-18 地板效应（ $\Delta = +1.05$ ）。第二阶段的三项工作进一步给出：非线性感知训练的鲁棒性严格限定在训练分布内，正向外推在 $\alpha \approx 0.4$ 处归零并转为劣势（ $\alpha = +0.5$ 时 -10.77）而负向保持；Dithering 的机理是离散化分布重塑（分类器输入峰度从 0.110 恢复到 0.214）配合 MaxPool 架构载体，与随机抖动无关——这修正了第一阶段给出的“随机共振”解释与注噪建议；增强方案可完整迁移至深层网络，VGG-11 在 15 个扫描点上全胜三条基线，且干净精度零牺牲。

关键词：存算一体；非线性失真；非线性感知训练；残差校准；Dithering；量化误差

1 引言

1.1 赛题背景

传统冯·诺依曼架构下，神经网络推理时数据在存储与计算单元之间反复搬运，形成功耗与带宽上的“存储墙”。存算一体（Compute-in-Memory, CiM）技术把乘累加运算直接嵌入存储阵列内部，大幅降低搬运开销 [1, 2]。但基于 SRAM/Flash 等模拟器件实现的阵列易受器件失配、跨导放大器增益非线性、工艺偏差与温度漂移的影响，使乘累加呈现输入相关的非线性特性。

这类误差有一个区别于常见扰动源的性质：它是确定性的、与输入幅度相关的系统误差，而不是零均值、与信号无关的随机扰动。它逐层累积，并且不能用“多训几轮”来消除。本文的全部工作围绕一个具体问题展开：在这种失真下，模型的精度为什么会退化，以及什么样的算法手段能真正提升它的容忍能力。

1.2 失真模型

按赛题给定形式，把归一化输入与电路实际响应之间的映射建模为三次多项式：

$$y = \alpha \hat{x}^3 + (1 - \alpha) \hat{x}, \quad \hat{x} = \frac{x}{\|x\|_\infty}, \quad (1)$$

其中 $\hat{x}$ 按 batch 维逐样本做无穷范数归一化，避免样本间串扰；失真通过前向钩子挂在每一个 Conv2d 与 Linear 算子的输入侧，逐层注入。 α 刻画非线性强度， $\alpha = 0$ 退化为恒等映射； $\alpha > 0$ 时正输入被放大、负输入被压缩， $\alpha < 0$ 时相反。

1.3 研究框架

本文的工作分为两个阶段，共六个部分：

阶段	内容	对应节号
一	任务 1: 非线性误差的敏感性分析	第 2 节
一	任务 2: 非线性感知训练 (NAT)	第 3 节
一	任务 3: 鲁棒性增强方法设计	第 4 节
一	拓展 1-3: 跨架构 / 跨扰动类型 / 多误差源	第 5 节
二	优化一: α 扫描范围扩展与外推边界	第 6 节
二	优化二: Dithering 效应的定量机理解析	第 7 节
二	优化三: 增强方案向深层网络的迁移	第 8 节

第二阶段的三项工作对应评审意见的三条子建议，构成“发现问题 → 解释机理 → 修复验证”的闭环：优化一测出现有防御手段的有效边界在哪里；优化二对第一阶段发现的反常现象给出定量判决，并修正第一阶段给出的错误解释；优化三把最优防御方案迁移到深层网络，其结果反过来修复了优化一发现的外推短板。

1.4 实验口径

除非特别说明，全部实验遵循统一口径：数据集为 CIFAR-10 [5]（10 类，全量测试集 10 000 张）；评估用 best 权重、纯推理；训练用 SGD（动量 0.9、权重衰减 10^{-4} ）； α 的扫描点为 $\{-0.3, -0.2, -0.1, 0, +0.1, +0.2, +0.3\}$ ，部分外推实验使用 15 点（ ± 0.6 至 0）。三个主干为 SimpleCNN（0.24M，4 卷积 + 2 MaxPool）、VGG-11（9.2M，8 卷积 + 5 MaxPool）[3] 与 ResNet-18（11.2M，含残差连接）[4]。

全部数值均由脚本从实验产物文件现读，每个实验的强度扫描文件里 $\alpha = 0$ 的行必须等于同目录训练指标文件记录的最优测试精度（容差 0.01），这个自检覆盖了本文引用的每一行数据。

2 任务 1: 非线性误差的敏感性分析

2.1 破坏力有多大

图 1 给出三个干净模型在七个失真强度下的精度。破坏力的分布极不对称： $\alpha = +0.3$ 时三个模型分别跌 29.82、53.10、75.01 个百分点，而 $\alpha = -0.3$ 时的跌幅小得多。

在 SimpleCNN 上，正向与负向的破坏力之比为 3.4（以 $|\alpha| = 0.3$ 的跌幅计）。这个比值是后续所有训练策略与采样设计的动机来源。




图 1: 三个架构的非线性敏感性 (CIFAR-10)。正向失真 ($\alpha > 0$) 的破坏力显著大于负向, 且跌幅随深度与残差连接递增。全量测试集、best 权重、纯推理。数据: `outputs/task1_*/alpha_sensitivity.csv`。

2.2 误差往哪里累积

把”哪个位置受损最重”细分为两类问题后, 结论不同:

- **观测位置:** 全层失真时, 最深处的 fc 层输出偏移最大 (与干净输出的余弦相似度仅 **0.895**), 浅层 conv1/conv2 几乎不受影响 (余弦 > 0.99)。也就是说误差从浅层向深层**累积**, fc 是汇聚点。
- **注入位置:** 把失真单独施加到某一层时, 情况并不相同。单层注入的探针显示, 最敏感的是中间层卷积, 而 fc 单点注入的影响很小。

这两者并不矛盾——fc 之所以偏移最大, 是因为它承接了前面所有层累积的误差, 而不是因为它自己对失真最敏感。这一区分直接决定了任务 3 的设计: 校准模块应当作用于误差的累积节点, 而不只是最末端。

3 任务 2: 非线性感知训练

3.1 设计

非线性感知训练 (NAT) 的思路是在训练阶段就让模型”见过”失真: 每个 batch 从 $\alpha \sim U[-0.3, 0.3]$ 均匀采样并注入所有层, 而验证与测试阶段保持干净 ($\alpha = 0$), 从而考察模型的泛化鲁棒性。本文对比两种策略: 在预训练干净权重上**微调** (Fine-tuning, 学习率 10^{-3}), 与**从头训练** (Scratch, 学习率 10^{-2}), 在同一 epoch 预算下比较。

3.2 结果: NAT 的效果强烈依赖架构

表 1 与 图 2 给出三条规律:

(1) 纯前馈网络上 **Scratch** 全面占优。SimpleCNN 从 55.08% 提升到 64.23%, VGG-11 从 36.70% 提升到 44.74%。微调的效果明显较弱 (+1.00 / +3.26), 原因是预训练权重携带的”干净特征偏见”难以在低学习率下被消除。




图 2: 非线性感知训练在两个策略下的效果 (CIFAR-10)。虚线为干净模型基线, 橙色为从头训练 (Scratch), 黄色为微调 (Finetune)。Scratch 在两种纯前馈架构上全面占优; 在残差网络上极限正向失真处出现反转。数据: `outputs/task2_*/{scratch,finetune}/alpha_sensitivity.csv`。

表 1: 非线性感知训练在 $\alpha = +0.3$ 上的提升 (相对同架构干净模型, 单位 pp)

架构 (注入点数)	干净精度	NAT-Scratch	NAT-Finetune
SimpleCNN (5)	84.90	+9.15	+1.00
VGG-11 (9)	89.80	+8.04	+3.26
ResNet-18 (18)	92.09	-1.44 (退化)	+2.81

(2) 残差网络上极限正向失真不可救。ResNet-18 的 Scratch 策略在 $\alpha = +0.3$ 上反而比干净模型差 1.44 个百分点。它在失真环境中从零塑造了全部 18 个卷积层, 过度适应了极端环境, 反而丧失了从被污染信号中提取残差信息的能力。相对地, 微调因为限制了权重更新幅度、保留了干净特征的编码能力, 在这一点上反常地优于 Scratch (19.89% vs 15.64%)。

(3) 效果与注入点数量负相关。三个架构的注入点数为 5、9、18, $\alpha = +0.3$ 上的 Scratch 提升依次递减 (+9.15 $\rightarrow$ +8.04 $\rightarrow$ -1.44)。这提示失真信号的累积存在一个临界规模: 当它需要穿过 10 个以上的注入点时, 训练端已经无法有效补偿。

值得注意的是, NAT 在中等失真上仍然很有效: ResNet-18 在 $\alpha = -0.2$ 处从 32.98% 提升到 51.82% (+18.84), 是全部单项实验中最大的提升。失效只发生在正侧极限。

4 任务 3: 鲁棒性增强方法设计

4.1 三种互补的增强方案

任务 1 给出了两个可操作的线索 (误差在深层累积、正侧更致命), 任务 2 给出了一个有效但不够的基线。在这一基础上叠加三种互补的方法:




图 3: 鲁棒性增强方案的消融阶梯 (CIFAR-10 / SimpleCNN)。虚线为无增强的干净模型; Exp1 仅含残差校准模块, Exp2 叠加分层加权采样, Exp3 再叠加非对称采样。数据: outputs/task3_simplecnn/Exp*/alpha_sensitivity.csv。

表 2: 消融阶梯 (CIFAR-10 / SimpleCNN, 各配置均为 120 epoch 从头训练)

配置	干净精度	$\alpha = +0.3$	相对上一档	相对干净模型
clean (无增强)	84.90	55.08	—	—
Exp1 (+ 残差校准 A)	87.19	63.63	+8.55	+8.55
Exp2 (+ 分层加权 B)	87.37	68.76	+5.13	+13.68
Exp3 (+ 非对称采样 C)	87.59	69.14	+0.38	+14.06

方案	类型	核心逻辑
A	架构增强	在全局池化之后、分类器之前插入 残差校准模块 (瓶颈 MLP), 学习”失真特征 $\rightarrow$ 干净特征”的补偿映射; 残差连接保证最坏情况退化为恒等映射
B	训练策略	分层加权采样 : 浅层用轻失真 $\alpha \in [-0.15, 0.15]$, 深处用强失真固定 ± 0.3 ; 精准打击累积瓶颈, 同时保护浅层特征
C	采样策略	非对称采样 : 按 70%/30% 的概率偏向正侧, 基于任务 1 测得的正向破坏力更强这一事实

三个消融配置依次叠加: Exp1 (仅 A)、Exp2 (A + B)、Exp3 (A + B + C)。

4.2 消融结果

表 2 给出三项结论:

(1) 分层加权是贡献最大的单项。从 Exp1 到 Exp2, $\alpha = +0.3$ 从 63.63% 跃升到 68.76% (+5.13)。这与任务 1 的”误差在深层累积”一致——把训练资源按深度加权投放是有效的。

(2) 残差校准模块的独立价值在于正则化。它单独使用时把 $\alpha = +0.3$ 提升了 8.55 个百分点, 但更大的作用体现在干净精度上: Exp1/2/3 的干净精度 (87.19 / 87.37 / 87.59) 全部高于未增

表 3: 三类架构的脆弱性排序 (CIFAR-10, 干净模型)

架构	参数量	结构类型	$\alpha = +0.3$	跌幅
SimpleCNN	0.24M	浅层纯前馈 (4 Conv, 2 MaxPool)	55.08	-29.82
VGG-11	9.2M	深层纯前馈 (8 Conv, 5 MaxPool)	36.70	-53.10
ResNet-18	11.2M	深层残差 (含 skip connection)	17.08	-75.01

表 4: 两种扰动在强度 0.3 下的精度对照 (CIFAR-10)

架构	干净	高斯 $\sigma = 0.3$	非线性 $\alpha = +0.3$
SimpleCNN	84.90	37.02	55.08
VGG-11	89.80	66.39	36.70
ResNet-18	92.09	57.15	17.08

强的干净模型 (84.90)。残差结构保证最坏情况下退化为恒等映射，因此不引入干净精度代价。

(3) 非对称采样的边际贡献可以忽略。Exp2 到 Exp3 只带来 +0.38。任务 1 测得的”正向破坏力是负向的 3.4 倍”确实是真的，但把它直接翻译成采样比例并不产生相应收益——在逐层独立采样的设定下，均匀采样已经覆盖了足够的正向样本，瓶颈不在采样比例而在表征能力。

本文采用 **Exp2** 作为最优方案：干净精度 87.37%、 $\alpha = +0.3$ 时 68.76%，相对干净模型的累计提升 13.68 个百分点。

5 拓展研究：跨架构、跨扰动类型、多误差源

5.1 拓展 1：架构与参数量对脆弱性的影响

表 3 把脆弱性拆成两个独立因素：

深度的影响： SimpleCNN $\rightarrow$ VGG-11, $\alpha = +0.3$ 的精度从 55.08% 降到 36.70%。注入点数从 5 增到 9，误差随深度平滑累积。

残差连接的影响： VGG-11 $\rightarrow$ ResNet-18, 从 36.70% 进一步降到 17.08%。残差连接在非线性失真下成为**误差放大器**：output = $F(x) + x$ 的加法路径使失真信号在两条路径上交叉污染，经 8 个基本块的逐级叠加呈放大效应。

这一结果提示了一个工程判据：在非线性失真环境下，”更深”和”带残差”这两个通常意味着更强的设计选择，都会显著提高脆弱性。

5.2 拓展 2：高斯噪声与非线性失真的机制差异

如果把非线性失真当成一种”噪声”，那么常规的噪声鲁棒性手段应当可以通用。图 4 表明这个直觉是错的。

表 4 显示三者的排序完全不同，其中 ResNet-18 上两种扰动**完全反转**：它对高斯噪声几乎免疫 (57.15%)，却对非线性失真近乎崩溃 (17.08%)。原因在于残差连接对两种扰动的作用方向相反——对零均值的随机噪声，加法路径起平均化作用 (缓冲)；对信号相关的确定性失真，它起叠加放大作用。

结论是负面的但重要：非线性失真与高斯噪声的鲁棒性**不可跨域迁移**。针对高斯噪声设计的方法不能期待在非线性失真下有效。




图 4：非线性失真与加性高斯噪声的对照（CIFAR-10）。横轴为扰动强度（高斯的 σ 与非线性的 $|\alpha|$ ）。三种架构上的排序完全不同：SimpleCNN 对高斯更脆弱，ResNet-18 则对非线性更脆弱。数据：outputs/extension2_*/.../{gaussian,nonlinearity}_sensitivity.csv。

5.3 拓展 3：量化误差与非线性误差的联合作用

真实 CiM 芯片在模拟域失真之外还有 ADC 量化。二者同时存在时相互放大还是抵消？本文按物理路径顺序注入（先模拟域非线性，再数字域量化），用”乘性独立预测”作为基准：

$$\text{独立预测}(\text{bit}) = \frac{a_{\text{nl}}(\alpha=0.3) \times a_{\text{quant}}(\text{bit})}{a_{\text{clean}}}, \quad \Delta = a_{\text{joint}}(\alpha=0.3, \text{bit}) - \text{独立预测}(\text{bit}). \quad (2)$$

$\Delta < -1$ 记为超加性（比独立更差）， $\Delta > +1$ 记为次加性（比独立更好）。

图 5 给出一个三分格局：

- **SimpleCNN** ——超加性恶化。4 bit 处 $\Delta = -7.23$ ：两种误差相互放大，必须同时防御。
- **VGG-11** ——次加性（Dithering）。4 bit 处 $\Delta = +7.82$ ：量化噪声反而改善了失真下的精度；3 bit 处幅度更大（+21.90）但绝对精度已经腰斩。
- **ResNet-18** ——地板效应。各 bit 下精度都在 17% 附近，独立预测也在同一量级，差异无意义。

高位量化在两端都近似无损（8 bit 处 Δ 分别为 -0.10 与 0.00 ），说明”量化误差与非线性的独立叠加”是高位下的正确图景，非线性才是主要误差源。

6 第二阶段优化一：外推边界

6.1 问题

第一阶段的所有鲁棒性结论都建立在 $\alpha \in [-0.3, 0.3]$ 之内，而这正是训练时的采样分布。如果部署环境的实际失真超出这个范围，防御手段是否仍然有效？本节把扫描范围扩大一倍到 ± 0.6 ，把评估域分成训练区间（ $|\alpha| \leq 0.3$ ）与外推区（ $|\alpha| > 0.3$ ）。

6.2 非线性感知训练的鲁棒性是分布内属性

图 6 给出一个清晰的交叉现象。从头训练（Scratch）策略的增益随外推距离单调衰减： $+9.15$ （ $\alpha = +0.3$ ） $\rightarrow +0.77$ （ $+0.4$ ，归零） $\rightarrow -10.77$ （ $+0.5$ ，反转为劣势）。也就是说，在失真环境中过度适应的模型，在更极端的失真下其表征反而比”从未见过失真”的干净模型更脆弱。




图 5: 量化与非线性联合作用的加性裁决 (CIFAR-10, $\alpha = +0.3$)。灰色带为 $|\Delta| < 1$ 的“近似独立”区间。SimpleCNN 在 4bit 处超加性恶化 ($\Delta = -7.23$)，VGG-11 在 3-4bit 处次加性 (Dithering)，ResNet-18 全程近似独立 (地板效应)。数据: `outputs/extension3_*/joint_error_summary.csv`。

微调策略的外推衰减最缓 ($\alpha = +0.5$ 处仍为 $+1.08$)，是三种权重中唯一在深度外推区不恶化的。这与第一阶段“ResNet-18 极限失真下微调反超从头训练”的观察在机理上一致：低学习率保留下来的干净特征编码，恰是分布外场景的稳定基础。

6.3 负向外推保持，不对称性再证

与正侧形成鲜明对照：Scratch 在负侧的增益随外推距离**不降反升**（从 $+5.48$ 升至 $\alpha = -0.6$ 处的 $+8.22$ ），VGG-11 在负侧全区间保持 $+5 \sim 14$ 个百分点。这与第一阶段的“正向破坏力更强”同向：正方向是本质上的难防御方向。

6.4 架构容差窗口随深度收窄

干净模型能保持可用精度 ($\geq 70\%$) 的 α 窗口为：SimpleCNN 约 $[-0.35, +0.25]$ > VGG-11 约 $[-0.25, +0.2]$ > ResNet-18 约 $[-0.15, +0.15]$ 。深层网络不仅极限失真下崩溃，其**可容忍失真带宽本身就更窄**——这直接论证了优化三（深层迁移）的必要性。

7 第二阶段优化二：Dithering 效应的定量机理

7.1 一个需要解释的反常现象

第一阶段发现：VGG-11 在 $\alpha = +0.3$ 失真下，4 bit 量化的精度 (43.27%) 反而**高于** 8 bit (36.74%)，增益 $+6.53$ 个百分点，且为 VGG-11 独有。当时把它解释为“随机共振/抖动去相关”，并据此提出“在 ADC 前注入随机噪声”的工程建议——**该解释未经实验检验**。

7.2 三假设竞争判决

本节设计三个互斥的假设与相应判决信号：




图 6: 非线性感知训练的收益严格限定在训练分布之内 (CIFAR-10 / SimpleCNN)。纵轴为相对同架构干净模型的增益；竖直虚线标出训练区间 ± 0.3 。Scratch 策略在正侧外推区迅速归零 ($\alpha = +0.4$ 时 $+0.77$) 并反转劣势 ($\alpha = +0.5$ 时 -10.77)，而负侧保持正值。数据: outputs/extension4_alpha_wide/alpha_wide_scan_summary.csv。

表 5: 剂量匹配三对照 (VGG-11, $\alpha = +0.3$)

条件	剂量	精度	相对 8bit 基线
8bit 基线	0.014	36.74	—
4bit	0.245	43.27	+6.53
等剂量高斯噪声	0.247	34.29	-2.45
等剂量均匀噪声	0.247	34.87	-1.87
8bit + 最优剂量高斯	0.041	36.71	-0.03

假设	机理表述	判决信号
H1	随机去相关：随机扰动打破失真的确定性错误映射	等剂量随机噪声若能复现增益则支持
H2	分布重塑：粗量化对失真压平的分布做非线性再分配	激活峰度随位宽下调而系统性恢复，且与精度关联
H3	MaxPool 交互：局部最大值筛选与量化误差交互	增益随 MaxPool 密度排序

实验用剂量匹配的三组对照（量化 / 等剂量纯噪声 / 8bit+ 最优剂量噪声）、样本级翻转统计（10000 样本逐个比对）与分类器输入分布统计，给出定量判决。

7.3 判决结果

H1（随机去相关）→ 否决。表 5 显示：用与 4 bit 等效剂量的纯噪声替代量化，精度不升反降；在 8 bit 基线上叠加最优剂量的随机噪声，增益只有 -0.03 个百分点。样本级翻转统计给出了三个量级的反差：4 bit 的”救回：杀死”为 4.15:1（净 +653 样本），而噪声条件约为 1:1（净 +7 与 -19 ）。随机性不是增益的来源。

H2（分布重塑）→ 确认，核心机理。分类器输入分布的峰度在失真下被从 1.486 压平到 0.110（标准差同时从 0.682 降到 0.461），可分性被破坏，精度跌到 36.74%；4 bit 的 16 电平粗离散化




图 7: Dithering 增益的架构依赖 (CIFAR-10, $\alpha = +0.3$)。横轴上标注每个架构的 MaxPool 数量。增益与 MaxPool 密度同向但要足够密——2 个 MaxPool 的 SimpleCNN 是负增益, 0 个的 ResNet-18 无效应。数据: outputs/extension5_dithering_vgg11/arch_dithering_summary.csv。

对该压平分布做非线性再分配, 把峰度恢复到 **0.214**, 部分重建可分性 (+6.53)。存在一个甜点带: 3 bit 的峰度更高 (0.384) 但精度略降 (重塑过头叠加信息损失), 2 bit 信息量不足、峰度与精度双双坍塌。

H3 (MaxPool 交互) → 支持, 必要条件。无 MaxPool 的 ResNet-18 完全免疫 (+0.39), 说明 MaxPool 是效应触发的必要条件; 但只有 2 个 MaxPool 的 SimpleCNN 是负增益 (-13.68), 说明它并非充分条件——密度与位置决定量化误差是被修正还是被放大。

7.4 对第一阶段解释的修正

本节的判决否决了第一阶段的”随机共振/抖动去相关”解释, 以及据此提出的”在 ADC 前注入随机噪声”的工程建议 (等剂量注噪的增益约为零)。正确的工程表述是: 在 MaxPool 密集的架构 (VGG 类) 上, 直接采用 4 bit ADC 本身即可获得失真补偿; 注噪方案无效。

同时还得到一个配方设计的警示: 3 bit 的次加性幅度比 4 bit 更大, 但绝对精度已经腰斩 (10.87% vs 19.75%)。 ”增益幅度”不能单独作为配方优劣的判据, 必须与绝对精度联合裁决。

8 第二阶段优化三：增强方案向深层网络的迁移

8.1 问题与迁移设计

第一阶段的 Exp2 方案 (残差校准模块 + 分层加权采样) 只在 SimpleCNN 上验证过。本节把它完整迁移至 VGG-11 与 ResNet-18, 同配方从头训练, 并顺带复验优化一发现的 Exp2 外推短板是否为该方案的固有缺陷。

校准模块的注入位置按架构适配: VGG-11 注入在每个 MaxPool 之后 (5 处, 因为 MaxPool 是空间下采样与误差累积节点); ResNet-18 注入在每个基本块的残差路径上 (8 处)。分层 α 的数值范围与原方案逐项一致, 只按各架构深度重新映射层名。

8.2 迁移结果

表 6 与 图 8 给出四项发现:




图 8: Exp2 增强方案向深层主干迁移 (CIFAR-10)。灰色虚线为同架构干净模型, 橙色为 Exp2 方案 (残差校准 + 分层加权)。在 VGG-11 上, Exp2 在全部 15 个扫描点上都优于三条基线; 在 ResNet-18 上全程无败, 但正侧强失真区的绝对精度仍然很低。数据: outputs/extension6_deep_robust/alpha_wide_scan_deep_robust.csv。

表 6: Exp2 方案迁移后的关键精度 (CIFAR-10, %)

架构	权重	$\alpha = 0$	$\alpha = +0.3$	相对 clean
VGG-11	clean	89.80	36.70	—
VGG-11	NAT-scratch	90.18	44.74	+8.04
VGG-11	Exp2	91.27	50.25	+13.55
ResNet-18	clean	92.09	17.08	—
ResNet-18	NAT-scratch	92.27	15.64	-1.44
ResNet-18	Exp2	93.27	20.12	+3.04

(1) 增益跨架构传递。 $\alpha = +0.3$ 相对干净模型的增益为 +13.68 (SimpleCNN) $\rightarrow$ +13.55 (VGG-11) $\rightarrow$ +3.04 (ResNet-18)。VGG-11 与 SimpleCNN 几乎无损传递, 说明方案的有效性不依赖浅层架构。

(2) 多点校准修复了外推短板。 SimpleCNN 上的 Exp2 采用单一注入点 (全局池化之后), 在负侧外推区输给 NAT-Scratch 最多 12.58 个百分点; 深层版本采用 5/8 个空间注入点后, 在 15 个扫描点上全部压制 NAT-Scratch。结论是: 单一注入点的校准容量不足是外推短板的成因, 多点空间校准可以修复它。

(3) 增益随深度衰减, 机制是复合最坏情形。逐层独立采样下, 训练时所有层同时取到极端 α 的概率趋近于零; 而评估时全局 $\alpha = +0.3$ 意味着 ResNet-18 的全部 17 个卷积层同时处于边界失真——这是训练分布之外的尾部事件, 层数越多越极端。

(4) 干净精度零牺牲。两个架构 Exp2 的 $\alpha = 0$ 精度 (91.27 / 93.27) 都是四组权重中最高的, 校准模块兼具正则化作用。

此外, ResNet-18 上 Exp2 的 20.12% 反超了第一阶段的”改用微调”策略 (19.89%), 说明架构级校准可以恢复从头训练策略在残差网络上的竞争力。

9 讨论与结论

9.1 贯穿两阶段的三条主线

主线一：正负不对称性。三个阶段、四类实验都指向同一结论——正向失真是本质上的难防御方向：破坏力不对称（任务 1 的 3.4 倍）、外推不对称（优化一：负侧保持而正侧反转）、防御不对称（优化三：三架构上 Exp2 的负侧精度都显著高于正侧）。工程含义是补偿资源应向正方向倾斜；但也解释了为何非对称采样（方案 C）边际收益小——瓶颈不在采样比例，而在表征能力。

主线二：深度的复合放大。注入点数 $5 \rightarrow 9 \rightarrow 18$ 对应脆弱性递增、非线性感知训练的临界阈值约 10 个注入点、容差窗口随深度收窄、增益随深度衰减——统一解释是**复合最坏情形概率随深度指数放大**，无论评估端（全层同失真）还是训练端（独立采样的覆盖不足）。可操作的工程判据：注入点超过约 10 个的架构，必须配合多点校准才可期待有效防御。

主线三：校准注入密度应随误差累积节点数扩展。单点校准（SimpleCNN 的 1 处）负侧外推输 12.58 个百分点，多点校准（深层 5/8 处）15 点全胜。校准密度必须与误差累积节点数同步扩展，单点校准只保护分类边界，不保护特征通路。

9.2 结论

本文在 CIFAR-10 上系统考察了模拟域非线性失真对神经网络的影响与应对，主要结论：

1. 正向失真的破坏力是负向的 3.4 倍，误差从浅层向深层超加性累积；残差连接是误差放大器，ResNet-18 在 $\alpha = +0.3$ 下损失 75 个百分点。
2. 非线性感知训练在纯前馈网络上有效（+8 ~ 9 个百分点），在残差网络极限失真下失效（-1.44）；效果与注入点数量负相关。
3. 叠加残差校准模块与分层加权采样后，SimpleCNN 的 $\alpha = +0.3$ 达 **68.76%**，且干净精度不降反升；分层加权是贡献最大的单项（+5.13）。
4. 非线性失真与高斯噪声的鲁棒性**不可跨域迁移**，两者在 ResNet-18 上的排序完全反转。
5. 量化与非线性的联合作用呈三分格局：超加性 / 次加性（Dithering）/ 地板效应。
6. 非线性感知训练的鲁棒性是训练分布内的属性：正向外推在 $\alpha \approx 0.4$ 处归零并转为劣势，负向外推保持。
7. **Dithering 的机理是离散化分布重塑配合 MaxPool 架构载体，与随机性无关**——第一阶段给出的“随机共振”解释与注噪建议已被否决。
8. Exp2 方案可完整迁移至深层网络（VGG-11 全点全胜），多点校准修复了单点版本的外推短板，且干净精度零牺牲。

9.3 局限与后续方向

局限：三项拓展的数据集多样性（评审建议 R4）在时间约束下未执行；校准模块的机理证据是相关性证据（峰度-精度关联与架构对照），未做因果干预实验（如逐层替换 MaxPool 为平均池化）；残差网络正侧强失真区的绝对精度仍然很低（20.12%），根因是逐层独立采样无法覆盖复合最坏情形。

后续方向：层间相关或对抗式的 α 采样，以覆盖“所有层同时处于边界”这一尾部事件；把数据集多样性补上，检验上述规律在细粒度任务上是否保持；探索不依赖训练手段、也不依赖

网络重训的修复路径（本文的全部方法都需要改动网络或重新训练，而在真实的存算一体部署中，阵列里的权重是不可重训的）。

参考文献

- [1] Yu S, Chen P Y. Emerging memory technologies: recent trends and prospects[J]. IEEE Solid-State Circuits Magazine, 2016, 8(2): 43–56.
- [2] Ankit A, El Hajj I, Chalamalasetti S R, et al. PUMA: a programmable ultra-efficient memristor-based accelerator for machine learning inference[C]//ASPLOS. Providence: ACM, 2019: 715–731.
- [3] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//ICLR. San Diego: ICLR, 2015: 1–14.
- [4] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. Las Vegas: IEEE, 2016: 770–778.
- [5] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.
- [6] Zhu M, Liu Y, Wang Z, et al. Nonlinearity-aware training for accurate and robust compute-in-memory neural networks[J]. IEEE TCAD, 2022, 41(11): 3961–3973.
- [7] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//CVPR. Salt Lake City: IEEE, 2018: 2704–2713.
- [8] Wannamaker R A, Lipshitz S P, Vanderkooy J, et al. A theory of nonsubtractive dither[J]. IEEE Transactions on Signal Processing, 2000, 48(2): 499–516.