逐层非线性失真下神经网络精度退化的成因
读出瓶颈与两个修复杠杆

黄奕皓

中国科学院大学计算机科学与技术，北京

huangyihao24@mails.ucas.ac.cn

摘要

存算一体（compute-in-memory, CiM）芯片把乘累加运算放进存储阵列里完成，省掉了数据搬运；代价是模拟器件的非理想性直接进入计算通路。本文研究其中一种失真：每个输入先按自身最大绝对值归一化，再做三次多项式变换 $y = \alpha\hat{x}^3 + (1-\alpha)\hat{x}$，$\hat{x} = x/\|x\|_\infty$。这种失真不是零均值的随机噪声，而是确定性的、与输入幅度有关的，并且会逐层累积。本文在 CIFAR-10 与 CIFAR-100 上，用五个网络配置（三个架构族：SimpleCNN、VGG-11、ResNet-18）考察它的破坏形态、oracle-α 诊断上界（即“若失真强度已知、读出可自由重训，线性解码最多能到多少”，它是对可部署读数的上界）与修复边界。**全部结果都来自该参数化模型的仿真，没有硬件实测。**主要结论有四条。

第一，在本文主要分析的 SimpleCNN 与 VGG-11 上，最严重的正向失真（$\alpha = +0.3$）损坏的主要不是特征里的信息，而是最后分类层把信息读出来的能力。这里说的“读出来”，是指冻结特征之后，还能不能用一个简单的线性分类器把类别分开。在冻结特征上重训线性探针，并假定失真强度已知（oracle-α 口径），CIFAR-100/SimpleCNN 可达 48.35%，而原分类层只有 28.09%，差 20.26 个百分点；同样条件下换成加性高斯噪声，差距只有 7.50 个百分点（高斯噪声本身更狠：同一干净模型在 $\sigma = 0.3$ 下只剩 3.98%，而 $\alpha = +0.3$ 下还有 28.09%；只是高斯的可恢复空间更小）。需要强调：**48.35% 是诊断上界，不是部署读数**；部署时 α 未知，只重训最后一层线性分类器能拿到 43.31%，是上界的 89.6%。作为对照，只把同一个头在干净分布上重训，增益为零。这个读数经过四项对照检验，四个对照实验都不能够证明它错误；其中只有一项（在激活上逐步加噪声、看读数何时崩溃）提供了独立的第二个读数，但只在大方向上一致。把探针样本增加到 50000 后，同一 oracle 口径下的读数升到 27.63 个百分点（按不相交校正约 25.4），仍未饱和。用 k-NN 与两种 MLP 替换线性头，两种明显低于线性头、差距超过本文自订的可分辨门槛，一种落在门槛内；因此没有发现容量不足的证据，其中一种 MLP 不能裁决。补充一句机制：有效维度下降 20.6%–58.7%，但类中心结构没有同步变差——同强度下 Fisher 判别比不低于负侧（$\alpha < 0$），不过沿正侧 $\alpha = +0.3$ 的 Fisher 仍低于干净条件。类间散布与类内散布都在缩，类内散布缩得更快；所以丢的主要是维度和散布尺度，不能简单说成“类间距缩小”。

第二，在部署阶段不更新阵列权重的约束下，只重训最后一层线性分类器是本文测试路径中最稳定有效的修复。冻结全部主干权重，只重训最后一层线性分类器；三个网络上 $\alpha = +0.3$ 的准确率从 28.09/15.98/6.22 提升到 43.31/47.79/26.82（各 3 个种子），一致超过本文测过的所有全网络鲁棒训练配方。训练需要约 2 万条带标签的失真特征，耗时 12–30 分钟，为主干重训的 1/5–1/16。**这个方法本身不是本文提出的：**线性探针在迁移学习中已有理论与实证；在 CiM 中，2020 年 Nature 的忆阻器 CNN 采用混合训练：权重先在软件中训练，再在硬件侧微调；近年的 AHWA-LoRA、DoRA 校准、BN-only 等工作也属于“只更新少量参数”这一族。本文的贡献是给出该场景下的 oracle-α 诊断上界、损伤机制与修复边界。训练端的五条路径——采样预算分配、对抗训练、课程式采样、训练范围外推、解冻微调——没有一条改善最严重失真；最后一条反而明显变差（三个主干分别下降 11.85/33.83/12.88 个百分点）。

第三，最大池化层的数量是一个不增加可训练参数的架构变量。把 SimpleCNN 的最大池化层从 2 个增加到 5 个，参数量不变，不增加额外训练成本，但必须在设计阶段选定；在同设置、同种子的配对上，$\alpha = +0.3$ 提高 15.52 个百分点（单 seed；3 seed 复核同向 +12.20，基线协议不同）。它的保护主要来自降维。两个手段可以同时使用，但效果不能简单相加：合计提高 21.09 个百分点，约为单独增益之和 29.60 的七成（架构侧单 seed、读出侧 3 seed）。此外，失真强度可以用读出特征的岭回归在线估计（R^2 0.83–0.98），使两个分类层的门控可以接近 oracle；但门控有效需要两个前提同时成立，边界由本文给出。

第四，为一种失真做的鲁棒训练不会顺带保护另一种。非线性失真与加性高斯噪声之间的正迁移接近零；但存在单向负迁移：σ 训练使 α 侧下降 6.08 个百分点，联合训练下降 12.82；两种扰动同时存在时，最优配方是 σ-only，不是联合训练。另外，正侧最严重只在 SimpleCNN 与 VGG-11 上成立；ResNet-18 的负侧更严重。

最后是一条方法学观察：同一份权重在两条评估路径下读数逐位相同，而两套训练脚本产出的权重稳定相差 5.55 个百分点；经过三次干预仍未归因。**在找到原因之前，本文不跨代码实现（包括与文献）引用精度数字。**本文还给出一个三级可分辨性尺度（种子噪声 / 同一实现内的过程自由度 / 跨实现），并给出初步证据：过程自由度的主要来源是“训练多久”，而不是“用哪个优化器”。

关键词：存算一体；非线性失真；读出瓶颈；有效秩；鲁棒性杠杆；测量纪律

1 引言

1.1 问题

存算一体（Compute-in-Memory, CiM）架构把乘累加运算放在存储阵列里完成：权重存在阵列中，输入送进阵列后直接得到结果，不需要在存储和计算单元之间反复搬数据 [1, 2]。好处是能耗和延迟；代价是模拟电路的不理想特性直接进入计算通路。器件失配、跨导放大器增益非线性、工艺偏差和温度漂移，都会让输入和输出偏离理想的线性关系。这类误差和常见扰动源有一个关键区别：**它是确定性的，而且和输入幅度有关**，不像高斯噪声或随机 Dropout 那样零均值、与信号无关。

本文采用赛题给定的参数化模型：

$$y = \alpha\,\hat{x}^3 + (1-\alpha)\,\hat{x}, \qquad \hat{x} = \frac{x}{\|x\|_\infty}, \tag{1}$$

其中 $\hat{x}$ 按样本做无穷范数归一化：每个输入除以它自己最大的绝对值，避免样本之间互相干扰。失真通过前向钩子挂在每一个 `Conv2d` 与 `Linear` 算子的**输入端**，逐层注入。α 表示失真强度，$\alpha = 0$ 时没有失真；$|\alpha|$ 越大失真越强，α 的符号决定失真方向。归一化后最大分量恒为 ± 1，所以 $\alpha > 0$ 时两端不变、中间段被压向零；$\alpha < 0$ 时中间段被放大。

从工程角度看，约束是硬的：**部署阶段不更新阵列里的权重**。重写权重代价高，器件寿命和能耗也不允许。因此本文不问“如何训练一个更抗失真的网络”，而问：**在权重不更新的前提下，鲁棒性的着手点到底在哪一层。**

1.2 本文的发现与贡献

本文报告四条相互衔接的结论，以及一条方法学结论。

1. **定位：在本文主要分析的 SimpleCNN 与 VGG-11 上，最严重的正向失真损坏的主要是“读出”，不是“表征”。**这里说的“读出”，是指冻结特征之后，最后的分类层还能不能把类别分开。在冻结特征上重训一个线性探针，并假定失真强度已知（下称 oracle-α 口径），$\alpha = +0.3$ 时 CIFAR-100/SimpleCNN 可达 48.35%，而模型自带的分类头只有 28.09%，相差 20.26 个

百分点；同样条件下换成加性高斯噪声，差距只有 7.50 个百分点（高斯噪声本身更狠：同一干净模型在 $\sigma = 0.3$ 下只剩 3.98%，而 $\alpha = +0.3$ 下还有 28.09%）。这个读数经过四项对照检验：随机标签、激活上逐步加噪声、换训练/测试划分、以及与主干训练集完全不相交的划分。**这四个对照实验都不能够证明它错误**，但其中只有“激活上加噪声”这一项给出了独立的第二个读数，**而且只在大方向上一致**。在最严口径下，差距仍有 +16.23 个百分点，是常规口径的八成。把探针样本从 8000 增加到 50000，同一 oracle 口径下的读数升到 +27.63 个百分点（按不相交校正约 +25.4），仍未饱和。用 k-NN 与两种 MLP 替换线性头，两种明显低于线性头、差距超过本文自订的可分辨门槛，一种落在门槛内；因此没有发现容量不足的证据，其中一种 MLP 不能裁决。需要强调口径：**48.35% 是诊断上界，不是部署读数**；部署时 α 未知，只重训最后一层线性分类器能拿到 43.31%，是上界的 89.6%。作为对照，只把同一个头在干净分布上重训，增益为零。

2. **修复：在部署阶段不更新阵列权重的约束下，只重训最后一层线性分类器是本文测试路径中最稳定有效的修复。**冻结全部主干权重，只重训最后一层线性分类器（即迁移学习中的 linear probing 一族），在三个主干上把 $\alpha = +0.3$ 的准确率提高 15.2∼31.8 个百分点（CIFAR-100，24 ep/20k，各 3 seed），成本约为主干重训的 1/5 ∼ 1/16；训练需要约 2 万条带标签的失真特征，耗时 12∼30 分钟。**这个方法本身不是本文的贡献**：当预训练特征好、分布偏移大时线性探针可以胜过全量微调，这是已有理论与十数据集实证的结论 [9]；在 CiM 中，2020 年 Nature 的忆阻器 CNN 采用混合训练：权重先在软件中训练，再在硬件侧微调 [15]，近年的 AHWA-LoRA [17]、DoRA 校准 [18]、BN-only [20] 等工作也属于“只更新少量参数”这一族。**本文的贡献是给出该场景下的 oracle-α 诊断上界、损伤机制与修复边界。**训练端的五条路径——采样预算分配、对抗训练、课程式采样、训练范围外推、解冻微调——在本文测试的设置内没有一条改善最严重失真；最后一条反而主动放大损伤（三个主干上分别下降 11.85/33.83/12.88 个百分点）。

3. **第二个着手点：最大池化层的数量是一个不增加可训练参数的架构变量。**把 SimpleCNN 的最大池化层从 2 个增加到 5 个，参数量不变，不增加额外训练成本，但必须在设计阶段选定；在同设置、同种子的配对上，$\alpha = +0.3$ 提高 15.52 个百分点（单 seed；3 seed 复核同向 +12.20，基线协议不同）。它的保护主要来自降维，而不是池化算子本身。两个手段可以同时使用，但效果不能简单相加：合计提高 21.09 个百分点，约为单独增益之和 29.60 的七成（架构侧单 seed、读出侧 3 seed）。工程落地有一个结构前提：读出层必须位于数字域，或者可以重写；其余假设列入局限。

4. **边界：为一种失真做的鲁棒训练不会顺带保护另一种。**非线性失真与加性高斯噪声之间的正迁移接近零；但存在单向负迁移：σ 训练使 α 侧下降 6.08 个百分点，联合训练下降 12.82；两种扰动同时存在时，最优配方是 σ-only，不是联合训练。另外，正侧最严重只在 SimpleCNN 与 VGG-11 上成立；ResNet-18 的负侧更严重，这是架构依赖的。

5. **方法学：跨代码实现的精度数字不能直接比较。**同一份权重在两条评估路径下逐位相同，而两套训练脚本产出的权重稳定相差 5.55 个百分点；经过三次干预仍未归因。**在归因之前，本文不跨实现（包括与文献）引用精度数字。**本文进一步给出一个三级可分辨性尺度（随机种子噪声 / 同一实现内的过程自由度 / 跨实现），并给出初步证据：过程自由度的主要来源是“训练多久”，而不是“用哪个优化器”。

第 2 节给出方法与协议；第 3 节按科学问题组织结果；第 4 节综合讨论；第 5 节给出局限与未来工作。

1.3 相关工作

非线性感知训练。已有工作（如 NEAT [3]）通过**约束权重范围**让器件工作在晶体管的线性区，从而**避开**模拟域的非线性。本文的场景不同：这里的失真**无法靠权重约束避开**，因为它由模拟域算子在**每一层输入端**产生，和权重值无关。因此本文的问题不是“如何避免进入失真区”，而是“在失真区内，可解码性还剩多少、能从读出侧拿回多少”。就本文测过的训练端路径而言，收益严格限定在训练分布之内，而且不触及本文关心的正侧最严重失真（图 5）。

量化。量化是 CiM 的另一条主要误差通路 [4]。本文考察了失真与量化联合作用的场景，并复现了一个反直觉现象：在池化密集的架构上，低位量化反而提升失真下的精度，其机理与随机抖动无关（图 10）。这与经典的非减性抖动理论 [5] 有本质区别。

架构。残差连接 [6] 与纯 3×3 卷积堆叠的深层前馈结构 [7] 在本文的扰动下表现出显著不同的脆弱性；数据集为 CIFAR [8]。

测试时适配与无源域适应。“冻结主干、只更新极少量参数”在分布偏移下已被证明是有效范式：Tent 在测试时只最小化预测熵、在线重估归一化统计量并只更新其仿射参数，主干与分类器都不动 [13]；SHOT 处理不访问源数据的域适应，它冻结源模型的分类器、只学目标域的特征提取器 [14]。本文与这一支共享“只动极少量参数”的取向，但**动的对象正好相反**：本文冻结的是特征（主干在部署阶段不更新），更新的是分类头。三条差异：**①偏移的性质不同**——TTA/DA 处理的是数据分布偏移，而本文的失真是确定性的、逐层累积的、与输入幅度有关的系统误差，换一批测试数据或匹配分布都不能消除它；**②可动参数的性质不同**——TTA 的“只动少数参数”是一种设计选择（主干在原理上仍可训练），而在本文的 CiM 场景下，部署阶段不更新权重是研究对象给定的约束；**③给出的量不同**——上述工作报告的是准确率，本文给出的是该约束下的 oracle-α 诊断上界、损伤的几何形态与代价的定量权衡（两个杠杆可同时受益但次可加、门控的两个前提）。

线性探针。“冻结主干、只重训最后的线性层”与全量微调的对比，在迁移学习里是一条有理论和大规模实证支撑的已知结论：当预训练特征足够好、分布偏移足够大时，线性探针的分布外精度反而高于全量微调，原因是微调在学分类头的同时扭曲了底层特征 [9]。本文的读出适配属于同一族做法，**本文的贡献不在于这条规律本身**，而在于：①把它搬到一个新场景——失真是确定性的、逐层累积的输入侧系统误差，而不是统计意义上的分布偏移；②在该场景下主干在部署阶段不更新，读出适配不是“更优选择”，而是本文测试路径内可行的修复；③给出该场景特有的上界、机制与边界。

CiM 中的部分重训与数字域补偿。“冻结阵列、只更新少量参数”在 CiM 里已有先例，但形态不同：2020 年 Yao 等的忆阻器 CNN 采用混合训练，权重先在软件中训练，再在硬件侧微调 [15]；另有一篇中文硕士论文报告了“最后一层全连接层软件训练再映射”（检索摘要级，未逐字核实，故未作正式引用）；IBM 的硬件感知训练系统评估了多种网络的重训 [16]；MTJ 工作用离线标定与自适应量化实现免片上训练 [10]；AHWA-LoRA 冻结模拟阵列上的预训练权重、只训练 LoRA 适配器 [17]；DoRA 校准用少量校准参数（2.34% 参数、10 个校准样本） [18]；ISCAS 2026 的原位校准用 LoRA + 逐层蒸馏（<5% 可更新权重、<5 个校准样本） [19]；BN-only 工作冻结卷积权重、只微调 BatchNorm 参数 [20]；此外还有高效重训 [21]、噪声无关的一次性训练与重训 [22]、VeRA+ [23] 等。**这些工作回答的是“怎么做”；本文回答的是“为什么读出层是瓶颈、还能恢复多少、损伤在特征空间里是什么形态、哪个架构变量不增加可训练参数、修复的边界在哪”。**在我们能核实的文献中，与本文方向最接近的是 Yao 2020 的混合训练；本文与它的区别在于研究问题和证据形态，而不是“首次提出只重训最后一层”。

关于本文最依赖的测量手段。本文的中心结论建立在线性探针的读数上。这一手段近年正受到系统质疑：探针精度饱和并不意味着信息在场，探针失灵也不意味着信息不在场——已有工作报告过探针精度 0.871、有效秩指标全部健康的表征，在检索任务上却只恢复了 14.4 bit 中的 0.00 bit，作者因此警告秩、探针与其他指标都可能在无支撑的评测上虚假饱和 [11]。本文对此做了主

表 1： 主干与参数量（按类别数分列）。

主干	参数量（CIFAR-10 / CIFAR-100）	卷积层数	MaxPool 数
SimpleCNN	242 474 / 254 084	4	2
SimpleCNN+3×MaxPool（后文简称 **mp** 主干）	242 474 / 254 084	4	5
Wide-CNN†	1 353 258 / 1 399 428	4	2
VGG-11	9 231 114 / 9 277 284	8	5
ResNet-18	11 173 962 / 11 220 132	17	0

† 仅用于 图 7 的第 4 个容量档，不参与正文其余各节。与 SimpleCNN 的差异有**两个变量**：容量（1.40M 对 0.25M）与**第二次下采样位置**（SimpleCNN 的 conv4 在 16×16、本主干在 8×8），后者是 MACs 约束下的取舍。

参数量口径：本表为**主干本体，不含**各实验所用配方里的 **特征校准模块**（`FeatureCalibration`）。**含**校准模块时，VGG-11 与 ResNet-18 分别为 9 889 796（9.89 M）与 11 919 332（11.92 M），第 4 个容量档为 1 662 340（1.66 M）——复现者按模型定义实例化得到的是后者。

动加固：为探针读数配第二读法（激活噪声下的临界崩塌点）与多组对照，详见第 3.2 节。

2 方法

2.1 度量口径

全阶段统一使用四个标量指标，定义如下：

指标	定义
`clean`	$\alpha = 0$ 时的测试精度
`drop@0.3`	`clean` 减去 $\alpha = +0.3$ 时的精度
`mid_band`	$\alpha \in \{-0.2, -0.1, +0.1, +0.2\}$ 四点的平均精度
`mean7`	$\{-0.3, -0.2, -0.1, 0, +0.1, +0.2, +0.3\}$ 七点的平均精度

用日常的话说：`clean` 是完全没有失真时的精度；`drop@0.3` 是最严重的正向失真让精度掉了多少；`mid_band` 和 `mean7` 分别看中等失真和整条失真曲线上的平均表现。本文最关心 $\alpha = +0.3$ 这个最严重的正侧点，因此多数结论直接报该点的精度或 `drop@0.3`。

评估协议固定为：全量测试集（10 000 张）、best 权重、纯推理。每个实验的强度扫描文件里 $\alpha = 0$ 的行必须等于同目录 `metrics.json` 的 `best_test_acc`（容限 0.01）。这个自检结果记在全局台账的 `pairing_check` 列中。台账 152 行里 **58 行通过**该自检，**无一行 FAIL**；其余 **94 行**（读出适配 74 行、复用权重的扫描 20 行）该自检**不适用**。

种子纪律：最严重失真指标的比较原则上使用 ≥ 3 个种子；单种子下的差值小于 3 个百分点不作为结论（理由见第 3.13 节）。个别实验只有单 seed（池化密度配对、CIFAR-10 侧读出），正文在报数处逐条注明。

2.2 数据集、主干与协议

数据集为 CIFAR-10（10 类）与 CIFAR-100（100 类）。五个主干及其参数量见表 1。它们属于三个架构族：SimpleCNN、VGG-11 和 ResNet-18；SimpleCNN 另有一个把最大池化层从 2 个增加到 5 个的配置（后文简称 **mp**），用来单独考察池化密度。所有主干都先在干净条件下训练 100∼200 个 epoch，优化器为 SGD（动量 0.9、权重衰减 10^{-4}），学习率采用余弦退火。

失真注入：逐层、逐样本，同一个 α 施加到所有层（除非特别说明）。训练时的 α 采样区间为 $U[-0.3, +0.3]$，采样粒度在正文中注明。

2.3 读出适配方法

本文的主要修复方法（内部代号 readout-NAT）很直接：**把主干全部冻结**——关闭主干参数的梯度，一个参数都不更新——只重训最后那个 `nn.Linear` 分类头。训练数据是在 $\alpha \sim U[\pm 0.3]$ 上采样得到的失真样本，评估仍在干净条件和各 α 点上进行。默认配置为 24 个 epoch、20 000 个特征样本。对 SimpleCNN，读出层占全模型参数的 5.04%；对 VGG-11 只有 0.55%。这里要把代价说清楚：它**不增加可训练参数**，但**需要约 2 万条带标签的失真特征和 12∼30 分钟训练时间**。“训练成本为零”只适用于最大池化层这个架构变量，不适用于读出层重训。

“信息仍线性可达”这一结论不只有探针读数背书。冻结主干、只重训一个线性头，在 $\alpha = +0.3$ 上**实际达到 43.31**（SimpleCNN，3 seed，24 ep 协议；原始自带头 28.09）——**这是一个真实可部署的分类器**，而不只是用于测量的探针。同口径的 **oracle-α** 探针读数为 48.35，即**部署物取到了该上界的 89.6%**（43.31/48.35）。（口径提醒：探针是 oracle-α 诊断量——它假定失真强度已知；因此 89.6% 是“部署物对 oracle 上界”的比值，**不是部署时能达到的绝对水平**。）

2.4 其他探针

信息探针：在冻结主干的末端特征上重训一个线性分类器，和模型自带的分类头比较，差值就是可恢复空间（本文有时叫 headroom）。“模型自带头”后文也叫**原始头 / 冻结头 / 自带头**，都指同一个东西；它在第 3.10 节的门控里叫**干净头**——就是产物列名 `acc_clean_head` 的那一层，即模型自带、冻结不动的那一层，和“在干净分布上重训出来的头”（读出适配一节的 b 臂）不是同一个东西。这个探针**逐 α 训练**：在每一个被评估的失真强度上，探针都只用该强度**自己**的特征训练（$n = 8000$，另有 $n = 50000$ 档）。所以它是一个 **oracle-α 诊断量**：回答“如果失真强度已知、读出可以自由重训，线性解码还能拿回多少”，**不是可部署读数**。作为对照，只喂干净特征、与 α 无关的另一列探针在 $\alpha = +0.3$ 上只有 18.1%，反而低于模型自带头；这一列记录在同一个产物文件里，本文不用它作可恢复空间。**秩探针**：对末端特征做奇异值分解（SVD），有效维度定义为 $\exp(-\sum_i p_i \ln p_i)$，其中 p_i 为归一化奇异值；同时记录 99% 能量条件数 κ_{99} 与 Fisher 判别比（类间可分性指标）。**交叉评估**：把 A 脚本训练出的权重放到 B 脚本的评估函数下扫描，反之亦然；两条路径都从各自脚本原样导入，不复制、不改写。

3 结果

3.1 正向失真通常更伤，但网络越深这个方向性越弱——最深的 ResNet-18 上甚至反过来

图 1 给出三个主干在 CIFAR-100 上的七点扫描。$\alpha > 0$ 叫正侧，$\alpha < 0$ 叫负侧；正侧的破坏力通常大于负侧，但“正侧跌幅是负侧的几倍”这个倍数会随主干变深而变小（$|\alpha| = 0.3$ 处依次为 1.87 / 1.18 / 1.01，见图注）。与此同时，**绝对跌幅**随容量和深度变大：$\alpha = +0.3$ 时 SimpleCNN 从 59.99 掉到 28.09，VGG-11 从 67.09 掉到 16.92，ResNet-18 从 72.09 掉到 2.70。在同一数据集内，干净精度越高的主干，最严重失真下的跌幅也越大。

我们进一步区分两个位置：**失真加在哪一层**，以及**我们在哪一层看到损伤**。一个反直觉的结果是：在单层注入的探针里，最敏感的是中间层的卷积（conv2 跌幅 −12.43、conv3 −7.56），而一直被当作瓶颈的 fc 层单点注入只有 −0.68。五层同时注入时跌幅 31.90，而把五层单独注入的跌幅直接相加只有 23.33——实际损伤比简单相加还多 8.57 个百分点，说明损伤在层与层之间会**放大**。fc 层是误差汇聚和观测的地方，不是注入最敏感的地方。

还要强调：$\alpha > 0$ 与 $\alpha < 0$ 的破坏力之比**不是常数**。在 CIFAR-10/SimpleCNN/$|\alpha| = 0.3$ 这一个点上是 3.4，而 CIFAR-100 的同一模型上只有 1.87；跨条件引用这个倍数会出错。连**方向**本

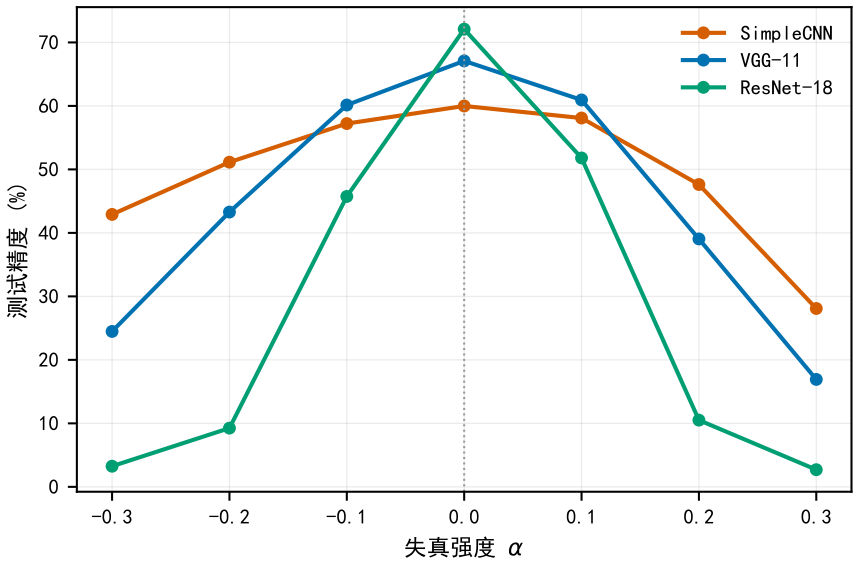


图 1：失真的方向性与容量依赖。三个主干在 CIFAR-100 上的七点扫描；全量测试集、best 权重、纯推理。正侧（$\alpha > 0$）的跌幅大于负侧，但**这个不对称的倍数随容量递减**：$|\alpha| = 0.3$ 处“正侧跌幅 ÷ 负侧跌幅”在 SimpleCNN / VGG-11 / ResNet-18 上依次为 1.87 / 1.18 / 1.01——**方向性在浅层明显，在最深的主干上几乎消失**。数据：`outputs_cifar100/task1_*/alpha_sensitivity.csv`。

身也不是跨架构常数——CIFAR-10 的三个主干依次为 3.4 / 1.40 / 0.94，到了最深的 ResNet-18 上，正侧反而没有负侧伤得重。

3.2 最严重失真下，信息还在特征里，坏的是最后分类层读不出来

这是全文的关键。如果最严重的正侧失真把特征本身摧毁了，那么任何修复都必须改动主干；如果信息还在、只是最后分类层读不出来，那么修复的着手点就在读出侧。图 2 用线性探针把这两种可能分开：在**冻结主干**的末端特征上重训一个线性分类器，再和模型自带的分类头在**同一 α 条件**下比较。注意探针是**逐 α 训练**的（见第 2 节）：它在每个失真强度上都用该强度自己的特征训练，所以这个差值是一个 **“假定失真强度已知”的诊断上界**，它说明“线性解码还剩多少余量”，而不是“部署时能直接拿到多少”。这个结论由三个对照夹住：①与 α 无关的干净探针在 $\alpha = +0.3$ 上只有 18.1%，反而低于模型自带头；②真正可部署的那条路径——在 $\alpha \sim U[\pm 0.3]$ 上重训同一个线性头——在三个主干上拿到 43.31 / 47.79 / 26.82（3 seed，见 图 3）；③只把同一个头在**干净分布**上重训，增益是零（+0.26 / −0.17 / −0.84，见下文的第二项自我校验）。$\Rightarrow$ 起作用的既不是“换了一个更强的读出”（α 无关的探针更差），也不是“换了一个头”（干净分布重训零增益），而是**这个头是在哪条分布上训练的**。

$\alpha = +0.3$ 时探针达 48.35%，自带头只有 28.09%，两者相差 **20.26** 个百分点（即可恢复空间）[1]；$\alpha = +0.4$ 时 30.90、$\alpha = +0.5$ 时 30.82。失真越强，这个差距越大——这与“信息差被拉大”一致，而与“信息被摧毁”不一致。要说准一点：**放大只到 $\alpha = +0.4$ 为止**（+0.3 为 20.26、+0.4 为 30.90），$\alpha = +0.5$ 时微降到 30.82——即**信息差在 +0.4 之后不再被拉大**。

高斯噪声对照给出了这条测量的分辨力：同样的探针在加性高斯噪声 $\sigma = 0.3$ 下只差 7.50 个

[1]两项均取自**全量测试集**（10 000 张），并与项目的规范口径逐位一致：冻结头在 $\alpha = +0.3$ 的 28.09 等于 `task1` 扫描的同名行，清洁模型在 $\alpha = 0$ 的 59.99 等于 `metrics.json` 的 `best_test_acc`。（早期版本的探针表曾用 8000 样本子集，给出 27.76 / 59.60 与 headroom +20.12；内部的 M0c 审计已在同一设备上重跑全量口径并替换，全案见 `docs/IMPL_AUDIT.md`。）

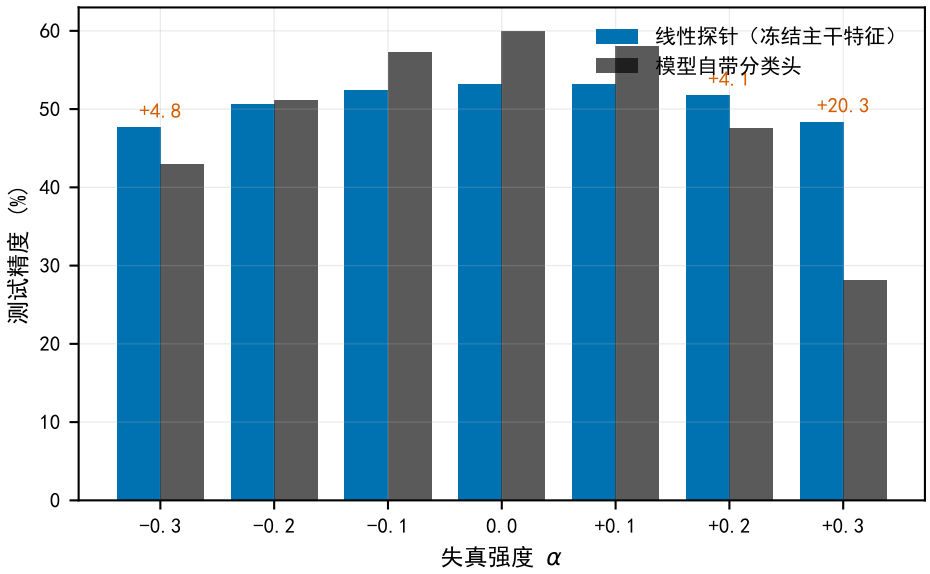


图 2: 最严重失真下，标签信息仍然可以用线性分类器读出来。在同一冻结主干的末端特征上，线性探针（实心）与模型自带分类头（空心）的精度对比；7 个 α 点，CIFAR-100 **全量测试集**（10 000 张）、best 权重、单种子。$\alpha = +0.3$ 时两者相差 20.26 个百分点；这个差距随失真增强先变大、后趋平（+0.4 为 30.90、+0.5 为 30.82）。作为对照，同一套探针在加性高斯噪声（$\sigma = 0.3$）上只有 7.50 个百分点。数据：`outputs_cifar100/v7_probe_audit/ra_onprotocol_main.csv`。

百分点。随机扰动与确定性系统误差在“信息还剩多少”这个量上清楚地分开，说明“先测这个差值”这个动作本身有判别价值。

3.3 这个探针读数可信吗：四组对照与一次主动加固

上面那个差值来自**单个探针设定**，而线性探针近年正受到系统质疑：探针精度饱和，不代表信息一定在场；探针失灵，也不代表信息一定不在场。已有工作报告过：探针精度 0.871、有效秩指标全部健康，但在检索任务上只恢复了 14.4 bit 中的 **0.00** bit （见第 1.3 节）。本文因此做了四组对照实验，逐一检查这个读数会不会是假象。

对照一：随机标签。 把探针的训练标签打乱后重训。9 个条件全部落在 $[0.85, 1.11]\%$，而 CIFAR-100 的随机水平是 1.0%，**最大偏离 0.15 个百分点**。这说明探针管线没有泄漏。

对照二：给激活加噪声，看读数何时崩溃。 单点精度之外再取一个读数：给**评估侧**的激活逐步加噪，测“探针精度跌到一半时”的噪声水平 σ^*。噪声只加在评估侧；训练侧也加噪测的是解码器的抗噪补偿能力，是另一个量。这个指标及其用法取自已有工作 [12]——它报告的正是“探针精度持平时，fragility 仍能给出结构化回答”，本文借它作第二条独立读数。

结果：正侧 σ^* 从 clean 的 **0.4188** 一路降到 $\alpha = +0.5$ 的 **0.1221**（−71%；只有 $\alpha = +0.1$ 一点略高于 clean，0.4273，此后严格单调下降）。**但在同一 $|\alpha| = 0.3$ 上，正负两侧几乎一样：** σ^* 为 **0.3230** 与 **0.3310**，相对 clean 分别是 **−22.9**% 与 **−21.0**%（约 1.1 : 1）。负侧只测到 −0.3——产物里没有 $\alpha = -0.4/-0.5$ 两档，所以“负侧平缓”是**未测**，不是测出来。

⇒ **第二条读数在最关心的那一点上，没有复现 headroom 的不对称：** 同一 $|\alpha| = 0.3$ 处，headroom 是 20.26 对 4.76（4.3 : 1），而 fragility 只有 1.1 : 1。两条读数**一致的地方只有“失真使读出更脆”这个方向；“正侧特别脆”这件事对指标敏感**——这是本文对这条加固论证的**限定**。

要判定 fragility 在大失真处是否也分正负，须把负侧测到 -0.5。

一个必须避开的陷阱。 σ^* 的**单位**是关键：若用**绝对**噪声水平，会得出**符号相反**的结论。

α	激活 RMS	绝对 σ^* vs clean	**RMS 归一** σ^* vs clean
clean	2.166	—	—
-0.3	**4.055**（1.87×）	+48%（**显得更鲁棒**）	−21%（**更脆弱**）
$+0.3$	0.914（0.42×）	−67%（更脆弱）	−23%（更脆弱）

表中两列分别取自 `v7_probe_audit/c2_fragility.csv` 的 `critical_noise_abs` 与 `critical_sigma_rms_norm`；“vs clean”以该文件的 clean 行为基准；两行都已与上文 σ^* 的正负对照对齐：负侧基准是 clean，不是 $\alpha = -0.1$。

原因：$\alpha < 0$ 把深层激活的幅度**抬高到 1.87 倍**，固定绝对噪声相对就更“小”，于是失真组**虚假地显得更鲁棒**。归一化到该条件自身的 RMS 之后，符号才正确。因此**负侧的结论完全依赖这一步归一化**。本文一律使用 RMS 归一化的 σ^*，并在正侧 $\alpha \in \{+0.1, \ldots, +0.5\}$ 这 5 个点上两两比较：共 10 对，其中 9 对的变化方向与 headroom 相反，唯一同向的是 $+0.4 \to +0.5$ 这一对。**这只说明两条读数沿 α 轴的变化方向同构，不说明正负不对称一致**——后者见上文的限定（$|\alpha| = 0.3$ 处 fragility 是 1.1 : 1，而 headroom 是 4.3 : 1）。

这个陷阱并非本文首见：[12] 自己就把它列为该指标的适用条件（跨层比较须用 RMS 归一化的临界噪声，层内比较才用原始值）。本文在本场景下**独立复现**了它，而且这里的尺度差达 1.87×，所以这一步在本文里是**判决性的**，不是可选项。

对照三与四：划分与不相交性。 换 decoder 的随机种子与训练/测试划分（5 个划分 + 3 次 bootstrap）：读数稳定，划分间标准差 0.17 ∼ 0.47、bootstrap ≤ 0.38，单条件总标准差 0.56 ∼ 1.33（总极差 ≤ 3.42）。更强的一项是把探针的训练与评估都放在**与主干训练集完全不相交**的样本上：$\alpha = +0.3$ 的差值为 $\mathbf{+16.23}$，即规范口径 +20.26 的 **80%**。

小结。 四组对照实验**都不能够证明它错误**；其中**只有对照二提供了第二条独立读数**，而它只与 headroom 在“方向”上一致。**这个结论在更严的口径下存活，但幅度会缩水到约八成。**我们把它作为本文中心结论的**下界**：即使在“探针从没见过的样本上训练”这一最严设定下，$\alpha = +0.3$ 处仍有一个约 16 个百分点的可解码性缺口（也就是线性读出还能多拿的百分点）。

这个缺口不是“只有线性读出才存在”的假象。 上面用的全是线性读出，所以“瓶颈在读出”有一个明显的反驳：也许瓶颈只是在线性。为排除它，在同一批冻结特征上比较六种读出（$\alpha = +0.3$，CIFAR-100）：

读出	精度	相对线性（同族公平锚）
逻辑回归，强 L2（$C = 0.01$）	49.23	−2.24
逻辑回归（sklearn 默认，跨优化器参考臂）	48.25	−3.22
k-NN（$k = 20$）	38.12	−13.35
线性头（torch，公平锚）	**51.47**	—
瓶颈 MLP（$128 \to 32 \to 100$）	43.38	−8.09
两层 MLP（$128 \to 256 \to 100$）	48.62	−2.85

三种非线性读出没有一个超过线性头。按本文的可分辨门槛（$\Delta_{\text{proc}} = 3.45$ pp，见第 3.13 节）分开说：k-NN（−13.35）与瓶颈 MLP（−8.09）**远超门槛**；两层 MLP 只差 2.85，**落在门槛之内**，

按本文自订规则这一臂**不能裁决**，只能说方向上仍劣于线性头。**参数越多反而越差**（瓶颈 MLP 43.38 < 两层 MLP 48.62 < 线性 51.47），是典型的过拟合序（$n = 8000$、100 类）。因此“信息仍线性可达”这句话，从“只测过线性”升级为“测过 k-NN 与两种 MLP 之后，线性头仍是最优读出”。**在本文的模型和训练预算下，没有发现容量不足的证据；其中一种 MLP 落在门槛内，不能裁决。**（出处：`outputs_cifar100/v7_readout_capacity/capacity_ladder.csv`；两个 torch 臂各在自己的最优轮数上取值，取值已记在产物里。）

换一种归纳偏置，也没有增益。 上面六种读出都是“自由”的头，一个自然的反驳是“换成带结构先验的读出会不会更好”。在同一批冻结特征上再测三种：最近类均值，以及两种强度的原型正则化线性头（把类中心拉向等角紧框架，$\lambda = 0.1$ 与 1.0）。以同一实现、同一 seed 下的线性头（$\alpha = +0.3$ 处 50.37）为基准：最近类均值为 36.50（−13.87）；原型两臂为 50.39（+0.02）与 50.67（+0.30）。按预登记门槛（≥ 1 pp **且超过该臂优化器噪声的 2 倍**，即约 0.10），**两臂都不达标**：前者连噪声都没超过，后者超过了噪声但幅度远小于 1 pp；干净精度下降 0.07 / 0.09。因此与容量阶梯合起来，“信息仍线性可达”有了**两条平行的排除线**：既不是“头不够大”，也不是“头缺少结构先验”。（出处：`outputs_cifar100/v7_etf_readout/etf_readout.csv`。）

表里两个“线性读出”不是同一个数。 本文的 headroom（第 3.2 节）用的探针是 sklearn 的 `LogisticRegression(max_iter=1000)`（默认 $C = 1$、lbfgs），与表中“逻辑回归（sklearn 默认，跨优化器参考臂）”是**同一族**：两者在 $\alpha = +0.3$ 上是 **48.35** 与 **48.25**，差 0.10，来自**设备口径**（headroom 那一次的探针是 CUDA run，这张梯子是 CPU run）。表中加粗的“线性头（torch，公平锚）”是**另一个实现**（Adam，取最优轮数，3 seed 均值），它与本文探针的差 $51.47 - 48.35 = \mathbf{3.12}$，与第 3.13 节的 $\Delta_{\text{proc}} = 3.45$ 同量级。注意这一对同时含拟合过程、设备与种子三重差，不宜当作 Δ_{proc} 本身；Δ_{proc} 表里的 Adam 50 轮 = 51.57 是单 seed。**结论不变**：同一个线性读出、同一批冻结特征，换个拟合方式就能差 3 个百分点。

这个下界还可以再抬高：差值取决于读出怎么训。 上面四组对照都在同一个探针设定（$n = 8000$ 训练样本）下做。把训练样本加到 50000（训练集全量，**同为 oracle-α 口径**），$\alpha = +0.3$ 的探针精度从 48.35 升到 **55.72**，差值从 +20.26 升到 +27.63，**且仍未饱和**（对数刻度上的增量斜率从 5.02 降到 3.06，比值 0.61，仍高于预登记的“已接近饱和”阈值 0.5）。按第 3.2 节的“不相交划分”**只扣这一项**校正（$\alpha = +0.3$ 处为 −2.19；出处 `v7_probe_audit/c5_private_decompose_agg.csv` 的 `d_disjoint` 列；同一张表里“探针样本量 5000 对 8000”另计 −1.98，本文不扣），折合约 +25.4（$27.63 - 2.19 = 25.44$），**仍远高于** +20.26。干净端也更清楚：$n = 8000$ 时探针比冻结头低 6.42，$n = 50000$ 时只低 **0.99**。

这条观测的含义比数字本身重要：+20.26 不是表征的某个固定属性，**它是“探针只喂了 8000 个样本”下的读数**。因此**差值取决于读出训练方式**——与第 3.13 节那条“过程自由度 3.45 pp”是同一件事的两个侧面，都指向同一个判断：**读出这一层不是免费的，它的读数取决于你训得多好**。本文因此把 +20.26 作为**已审计的规范值**引用，同时声明它是**下界**；真实可解码性**至少**为 +25.4。

（出处：`outputs_cifar100/v7_readout_samplesize/samplesize_ext.csv`。$n = 50000$ 档三个种子的标准差为 0——该档即训练集全量，各 seed 用同一批数据，故无采样变异。）

3.4 冻结主干、只重训最后一层线性分类器，就能用低一个数量级的成本把最严重失真的精度拿回来

这一节看修复效果。方法很简单：把主干全部冻住，只重训最后那个线性分类器。图 3 给出它在三个主干上的效果。

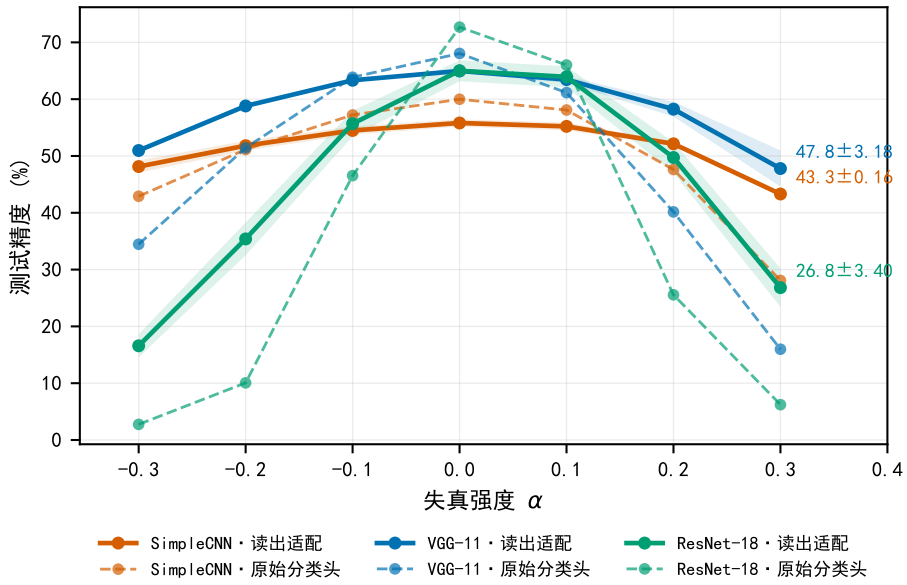


图 3: 读出适配跨三个主干一致抬升最严重失真下的精度。实线为 readout-NAT（冻结主干、只重训线性读出，可训练参数占全模型 5.04%/0.55%）；**每个主干的原始分类头用与该主干同色的虚线**；每个主干为 3 个种子的逐点均值，阴影为该点上 3 个种子的 ±1 总体标准差。$\alpha = +0.3$ 处的标注为均值 ± 总体标准差。数据：`outputs_cifar100/v3_readout_repair/*ep24*.csv`。

表 2: 读出适配与全网络鲁棒训练的对照（CIFAR-100，$\alpha = +0.3$，精度%）

方法	可训练参数	训练成本	SimpleCNN	VGG-11	ResNet-18
原始头（读出适配所依附的主干）	—	—	28.09	15.98	6.22
本文读出适配（24ep，3 seed）	12.8k / 51.2k	12∼30 min	**43.31**±0.16	**47.79**±3.18	**26.82**±3.40
全网络鲁棒训练（最好）	全部	1∼6.5 h	29.89	24.69	6.22

表 2 的口径。 这张表容易被读错，先把三件事说清。

- **第一行不是另一批干净模型**，而是本表读出适配所依附的那三块主干自带的分类头：SimpleCNN 依附干净主干，VGG-11 依附 Exp2 配方主干（120 ep），ResNet-18 依附 Exp3 配方主干（200 ep）。三块主干的身份由一条恒等式核验：读出文件 `a_original_fc` 行的 $\alpha = 0$ 列必须等于该主干 `metrics.json` 的 `best_test_acc`（实测 59.99 / 68.05 / 72.69 对 59.99 / 68.05 / 72.70，**最大差 0.01**，即 10 000 张测试样本中的 1 张）。
- **ResNet-18 一列的第一行与第三行是同一块主干**（都是 Exp3），第二行是在它之上再训读出；把两行并列成“两个选项”会读错。VGG-11 一列的读出依附 Exp2（15.98），与第三行的 Exp3（24.69）也不是同一模型。ResNet-18 两格取值相同，是因为读出适配所依附的 Exp3 主干本身就是该主干上全网络鲁棒训练的最优结果；所以那一列的对照是“同一块主干内：原始头 6.22 → 读出适配 26.82”，**不含任何主干升级**。另两列恰好相反——读出适配依附的主干**弱于**各自的全网络最优（SimpleCNN 28.09 对 29.89、VGG-11 15.98 对 24.69），故那两列的对照对读出侧是**保守**的。
- **读出适配自身的增益只由第一行到第二行给出**（+15.22 / +31.81 / +20.60，见下文第二项自我校验）。第三行的三格是各列上已知最优的全网络配方，来自两个不同的 harness（SimpleCNN 为 `task3` 的 Exp3 配方，VGG-11 / ResNet-18 为 `ext6` 的 Exp3），且都是**单次运行**；SimpleCNN

上同协议的 3 seed 均值是 26.57，低于 29.89，故本行取 29.89。读出适配相对该行的领先为 +13.42 / +23.10 / +20.60。

- **成本比逐主干配对**：读出 12 / 25 / 30 min 对全网络 1 / 6.5 / 6.5 h，即 1/5、1/16、1/13，约低一个数量级（读出侧 24 ep，全网络侧 120∼200 ep）。
- **第二行的 ± 是“读出种子”口径**（固定该主干、只换 3 个读出种子）。若换成“主干种子”口径（读出侧固定 seed 42、3 个主干种子），深层的最严重失真均值为 VGG-11 46.82 ± 0.25、ResNet-18 22.91 ± 2.61——后者低于本表的 26.82，差额来自主干之间的散布。两组口径只有一格重合（s42 主干 + 读出 seed 42 = 22.26），是同一张 3×3 表的两条不同边缘，不可相减或互替（见第 5 节的局限 (2)）。

（另一批干净主干 `task1` 的 VGG-11 / ResNet-18 在 $\alpha = +0.3$ 上是 16.92 / 2.70，与前两行的读数不同源，故不列入本表。）

表 2 把两类方法并列。读出适配在三个主干上一致超过“全网络重训”这一整类配方，而可训练参数只有 5.04%/0.55%，训练时间低约一个数量级。代价是干净精度下降 **3.08∼7.69** 个百分点（$\alpha = 0$ 处读出适配的三 seed 均值为 55.81 / 64.97 / 65.00，对各自主干的原始头 59.99 / 68.05 / 72.69）——这一点在第 3.10 节里处理。

自我校验一：不是“拆东墙补西墙”。 把读出专门拟合到 $\alpha = +0.3$ 单点，该点确实从 28.09 涨到 52.79（+24.70），但干净精度掉 20.36、$\alpha = -0.3$ 掉 25.71，七点均值反而低于基线。起作用的这一版是在 $\alpha \sim U[\pm 0.3]$ 上分布的：它在每个扫描点都不显著劣化，最严重失真和中等失真同时提升。同一层参数、两种训练方式给出质上不同的结果，说明起作用的不是“读出被放开了”这件事本身。

自我校验二：增益不是“多训了一个分类器”的通用效应。 读出适配的全部改动只有最后一层。一个自然的怀疑是：任何重训过的线性头都会带来类似增益，与“在哪种分布上训练”无关。这个对照本来就在数据里——`v3_readout_repair` 的产物文件里每个权重都带有多个读出臂，其中 `b_clean_fit_linear` 是**在干净分布上重训同一个线性头**：

主干	原始头	**在干净分布上重训**	Δ	本文方法	Δ
SimpleCNN	28.09	**28.35**	+0.26	43.31	+15.22
VGG-11	15.98	**15.81**	−0.17	47.79	+31.81
ResNet-18	6.22	**5.38**	−0.84	26.82	+20.60

（$\alpha = +0.3$ 精度，CIFAR-100，各 3 seed，24 epoch 读出；出处：`outputs_cifar100/v3_readout_repair/*ep24*.csv` 的 `a_original_fc` 与 `b_clean_fit_linear` 两行。**表中为 3 个种子的均值**——CSV 存的是逐 seed 的行，均值需自行合成，算式登记在 `docs/DERIVED_VALUES.md`。）

b 臂在三个主干上**全部零增益，其中两个还是负的**（+0.26 / −0.17 / −0.84）。因此起作用的不是“换了一个头”，而是**头是在哪种分布上训练的**。

同一批文件里还有一个 `c_dist_fit_linear` 臂——把读出拟合到失真的窄分布上。它在 $\alpha = +0.3$ 上更高（52.16 / 58.98 / 47.40，同为主干内 3 seed 均值），但**干净精度崩掉**：ResNet-18 从 72.69 掉到 **15.53**。这是“再分配”的极端形态，也正是本文方法选择在整个 $\alpha \sim U[\pm 0.3]$ 区间上训练的原因。**注意**：该臂是 24 ep / 3 seed 口径，与上文引用的单点适配读数 52.79 来自不同轮次，两者**不可直接相比**。

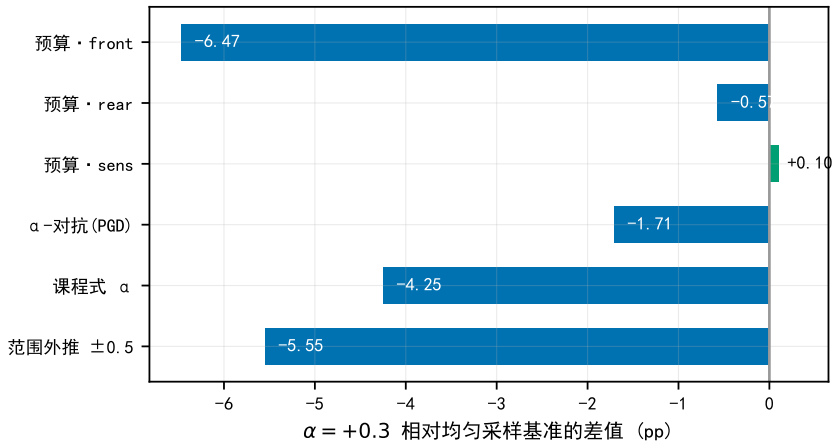


图 4: 训练端的补救路径在 $\alpha = +0.3$ 上没有一条**显著**优于均匀采样基准（最好的一条为 +0.10 pp）。差值以基准（均匀采样，$\alpha = +0.3$ 时 26.03%）为零线；**绿 = 高于基准、蓝 = 低于基准**；预算分配三种轮廓、α 空间对抗训练（PGD）、课程式采样、训练范围外推至 ±0.5。CIFAR-100 / SimpleCNN / 120 epoch / 单种子。数据：`outputs_cifar100/v3_methods/*/alpha_sensitivity.csv`。

同一套做法在更简单的任务上更强（提示性）。 把读出适配原样搬到 CIFAR-10（10 类，比 CIFAR-100 容易）：

主干	原头 @+0.3	读出适配 @+0.3	clean 代价	**恢复率（C10）**	恢复率（C100）
SimpleCNN	55.08	**72.51**	−0.84	**85.4%**	72.2%
VGG-11	36.71	**79.64**	−0.58	**88.7%**	70.2%
ResNet-18	17.09	**44.37**	−0.71	**48.2%**	36.9%

（24 epoch 读出，全量测试集；恢复率 = 读出适配 @+0.3 的精度 ÷ 原头 @$\alpha = 0$ 的精度。CIFAR-100 的对应值取自 图 7 所在小节。出处：`outputs/v3_readout_repair/*ep24*.csv` 与 `outputs_cifar100/v3_readout_repair/*ep24*.csv`。）

两件事同时成立：**恢复率在三个主干上一致更高**（85.4 / 88.7 / 48.2 对 72.2 / 70.2 / 36.9），**干净代价也小得多**（−0.58 ∼ −0.84 对 −3.08 ∼ −7.69）。因此读出适配的收益**随“可用头部空间”缩放**：任务越难，能被读出捞回来的越少。这与第 3.2 节的逻辑一致——可恢复量由“信息还剩多少”决定，而更难的任务在同样的失真下损耗更多。注：CIFAR-10 侧的读出为**单 seed**，CIFAR-100 侧为 3 seed；这一点记在第 5 节的局限 (7) 里，它正落在本文自订的 Δ_{proc} 不可裁决区间内。

3.5 训练端的五条补救路径没有一条改善最严重失真：前四条无效，第五条反而放大损伤

如果最严重失真下的精度损失只是“训练还不够适应”，那么更聪明的采样或更宽的分布应该能救它。图 4 给出前四条独立路径的结果，全部在同一 harness 下与均匀采样基准对比。

前四条路径的结果如下（同一 harness、与均匀采样基准对比）：

- 采样预算分配（三种轮廓，最好 26.13）：+0.10，与基准同级。
- α 空间对抗训练（PGD）：24.32，−1.71，落在门槛内，不可分辨。
- 课程式采样：21.78，−4.25，显著劣于基准。

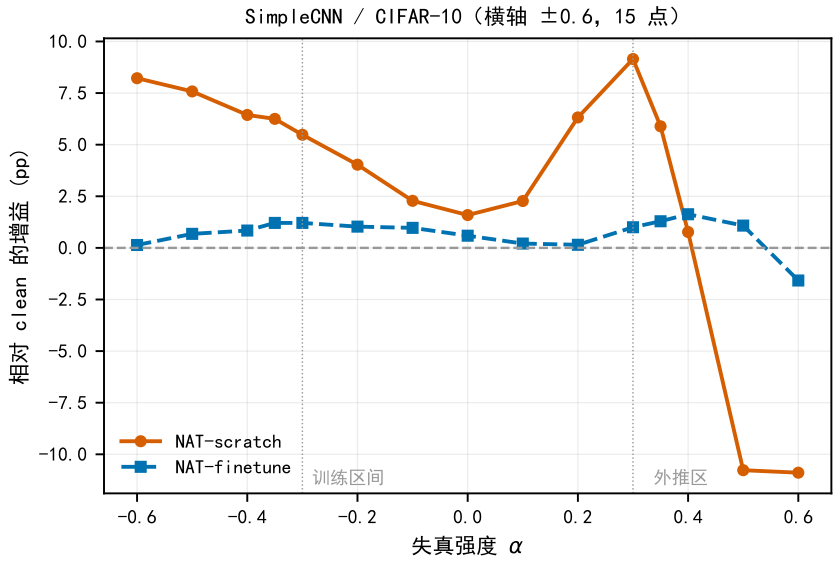


图 5：非线性感知训练的收益是训练分布内的属性。SimpleCNN 上两种训练策略相对干净模型的增益沿 α 轴的变化。横轴 ±0.6（15 点），**范围大于正文其余各图的 ±0.3（7 点）**；竖直虚线标出训练区间 ±0.3，其外为外推区。**NAT-scratch（实线圆点）**：正侧在 $\alpha \approx 0.4$ 处归零（+0.77）、$\alpha = +0.5$ 反转为 −10.77；负侧在外推区保持正值并略有上升（−0.4 时 +6.44 → −0.6 时 +8.22）。**NAT-finetune（虚线方点）**：正侧在整个外推区基本平坦（$|\Delta| < 1.7$，到 $\alpha = +0.6$ 才转为 −1.58）；负侧随外推距离缓慢衰减（+1.21 → +0.14）。**注意：本图数据集为 CIFAR-10**（干净精度 84.90），与正文其余各图的 CIFAR-100 不同，跨图不可直接比较绝对值。数据：`outputs/extension4_alpha_wide/alpha_wide_scan_summary.csv`。

- 训练范围外推至 ±0.5：20.48，−5.55，显著劣于基准。

按本文自订的种子纪律（第 2 节：单种子下的差值小于 3 个百分点不作为结论），后两条显著劣于基准，对抗训练不可分辨，预算分配与基准同级。因此**没有一条改善最严重失真**。

其中“训练范围外推”这一条最能说明问题：**模型已经在 ±0.5 上训练过**，但测试到 $\alpha = +0.5$ 时仍只有 2.71%，同期负侧 −0.5 有 31.19%，相差 28.5 个百分点。正侧的这个损失不是采样覆盖问题；在本文测试的训练端路径内，它是训练分布之外的一块区域，换更聪明的采样也进不去。

这一边界不是“训练不够”造成的，而是“训练分布之外”造成的。图 5 给出一个直接对照：把非线性感知训练的增益沿 α 轴外推，正侧在 $\alpha \approx 0.4$ 处归零并迅速转为劣势，而负侧随外推距离**不降反升**。也就是说，训练端手段的收益被它自己的训练分布框住；这与 图 4 的四条路径互为印证。

第五条路径：解冻主干微调（LP-FT）。 前四条都在“冻结主干、只改采样分布”的框架内。第五条动的是**主干本身**：先按上文读出适配把线性头训好（linear probing, LP），**再解冻主干**与该头联合微调（fine-tuning, FT）——即 Kumar 等提出的 LP-FT 配方 [9]。它的要点是**先把头训好再解冻**：直接全量微调时，随机初始化的头会在早期产生大梯度、把预训练特征扭曲掉；先做 LP 可以避免这一点。该配方在分布偏移场景下比全量微调好约 10 个百分点（**ID 高 1% / OOD 高 10%**，同一文献 [9]）。注意这是“LP-FT 对全量微调”，与第 1.3 节那组“全量微调对线性探针”（2%/7%）**不是同一个对照**，两组数不可混。如果它在失真场景下同样成立，“训练端无效”这一说法就必须加上限定。

判据在跑前写死：**LP-FT 在 $\alpha = +0.3$ 上相对同一次运行内的纯读出适配提升 ≥ 3 pp**（本项目自订的种子噪声分辨门槛）即算成立。表 3 给出结果：**三个主干一致大幅下降**——不是“没有提升”，而是**净损伤**，最深的主干上掉了 33.83 个百分点。

表 3: 第五条路径（解冻主干微调）在三个主干上都显著劣于纯读出适配

主干	纯读出 @+0.3	LP-FT @+0.3	最严重失真变化
SimpleCNN	43.40	31.55	−11.85
VGG-11（Exp2）	47.92	14.09	−33.83
ResNet-18（Exp3）	20.79	7.91	−12.88

两臂在同一次运行内、同一评估路径下测量（读出侧 seed 42）；LP 阶段 24 ep、lr 10^{-2}，FT 阶段 30 ep、lr 10^{-3}。**FT 的 batch 在 ResNet-18 一臂为 128、另两臂为 512**——512 是为“冻结主干前向 / 从头训练”选的，做**全模型反传**时该主干实测 >13 min/epoch，故改小。这是**修配置**（lr 与 ep 保持预登记值），但读者应知道**这一格与另两格不同源**。数据：`outputs_cifar100/v7_m8c_lpft/`。

口径提醒。 表 3 的“纯读出”列取自**同一次运行的 LP 臂（单 seed）**，与 表 2 第二行的“读出适配”（**3 seed 均值**）同名但不同源、不可互替。ResNet-18 那一格 20.79 对 26.82 的 6.03 个百分点里，**约 4.6 来自“单 seed 对 3 seed 均值”**（该主干读出侧的种子标准差本就是 3.40），**约 1.5 来自脚本内的 RNG 路径差**（LP 阶段 `nn.Linear` 的初始化走全局 torch RNG，与既有产物不同）。**本表的判据是同一次运行内的前后对比，不受此影响。**

机制。 FT 阶段的**训练精度一路上涨**（SimpleCNN 88.9%、VGG-11 96.9%，在混合 α 的训练分布上），说明模型在**训练分布上确实变好了**；而**各 α 的测试读数全线变差、且最严重失真降幅远大于干净精度降幅**（VGG-11：−33.83 对 −10.38）。⇒ 这是第 1.3 节所述“微调在学头的同时扭曲底层特征”在失真场景下的直接复现：**在一个不包含修复方向的梯度场里继续优化，只会把解推离预训练点**。前四条路径的失败是“没有改善”，这一条是“主动破坏”——两者合起来说明：在本文测试的训练路径内，损伤落在主干参数能到达的范围之外。

3.6 损伤的形态是维度丢失，而不是类中心结构改变

既然信息还在（图 2）而训练救不回（图 4），损伤的形态是什么？图 6 给出答案。

$\alpha = +0.3$ 时有效秩下降 20.6%（SimpleCNN）、33.3%（VGG-11）、58.7%（ResNet-18）；负侧同强度下降 **2.0% / 17.9% / 67.3%**。**“负侧几乎不动”只在浅层主干上成立**——VGG-11 的负侧掉近两成，而 **ResNet-18 的负侧（67.3%）比正侧（58.7%）掉得更多**。

先限定适用域。 这一点必须说清，因为它限定了下面这个机制叙述的适用范围：**有效秩下降与精度损失在 ResNet-18 上是两侧对称的**——它的 +0.3 与 −0.3 精度分别是 2.70 与 3.25，同样是两侧都崩。因此**“正侧更致命”这条（第 3 节 R1）在 ResNet-18 上并不成立**；它在本文全部证据里成立的场合是**浅层与中等深度主干**（SimpleCNN / VGG-11），以及**训练端**那前四条路径（全部在 SimpleCNN 上做的）。**有效秩下降解释“正侧特殊”这条链，只在有效秩下降本身不对称的主干上才连得起来。**

Fisher 判别比怎么读。 更关键的是，**同强度下正侧的 Fisher 判别比反而高于负侧**：$\mathrm{Fisher}(+\alpha) > \mathrm{Fisher}(-\alpha)$ 在 $|\alpha| \in \{0.1, \ldots, 0.5\}$ 上**五点全成立**（例如 $|\alpha| = 0.3$ 时 0.45669 对 0.39062，出处 `v7_nc_geometry/nc_geometry.csv`；同一对数在秩统计产物 `rank_stats*.csv` 里是 0.39061，差最后一位，为两个产物的精度口径差）。类间可分性没有变差，丢失的是**维度**。注意措辞：这里说的是**跨正负的比较**，不是“正侧的 Fisher 随失真单调升高”——沿正侧看它是**先升后降**的，只有 $\alpha = +0.1$ 那一点高于 clean （0.50124 vs 0.49096），此后单调下降。

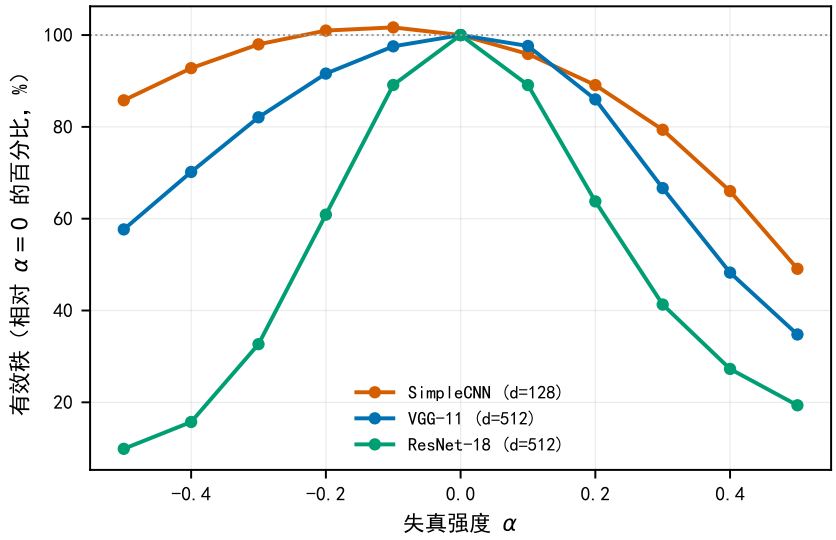


图 6: 失真使末端特征的有效秩明显下降，但**两侧的形态按主干分化**。纵轴为按各模型 $\alpha = 0$ 归一化后的有效秩（$\exp(-\sum p_i \ln p_i)$，p_i 为归一化奇异值）；横轴 11 个 α 点。三个主干的特征维数分别为 128 / 512 / 512。$\alpha = \pm 0.3$ 处的秩损失分别为 20.6% / 2.0%（SimpleCNN）、33.3% / 17.9%（VGG-11）、58.7% / **67.3%**（ResNet-18）——**负侧“几乎不动”只在浅层的 SimpleCNN 上成立；ResNet-18 的负侧比正侧掉得更多**。数据：`outputs_cifar100/v5_rank_collapse/rank_stats*.csv`。

这个不对称是什么：类内散布缩得更快。 把 Fisher 判别比写成 S_b/S_w（类间 / 类内散布），看失真沿哪个因子推动它。在 5 个 $|\alpha|$ 上，两类散布**都**随失真收缩（$\Delta \log S_b$ 与 $\Delta \log S_w$ 全为负），但**类内那一个收缩得更快**：5/5 上 $|\Delta \log S_w| > |\Delta \log S_b|$，故 log(Fisher 比) 为正（$|\alpha| = 0.3$ 时三者依次为 -2.2318、-2.3881、$+0.1563$；分解含一条恒等自检，残差在机器精度量级）。因此 **Fisher 的正负不对称，是约掉公共幅度之后剩下的残差**：正侧的 S_b 与 S_w 都远小于负侧（比 9.32 与 10.89），而 S_b 的比基本就是“$\alpha > 0$ 压低幅度”这一个已知效应（幅度平方之比 9.07，差 3%），**类内散布比类间多缩了约** 17%——这一份才是 Fisher 在正侧反而更高的来源。这与本节“类间可分性没有变差、丢失的是维度”一致：变的是**散布的尺度**，不是类中心的结构。（出处：`outputs_cifar100/v7_nc_geometry/fisher_decompose.csv`。）

与幅度统计对上了。 $\alpha > 0$ 把深层特征的幅度向中段压缩（fc 与 conv1 的 L2 范数比从 0.45 降到 0.23），端点不变而中段被压低。这就解释了“信息还在但训练救不回”这个表面矛盾：信息仍存在于剩余的维度里，但这些维度在主干参数的可达域之外；只有换一个读出才能在新的几何下重新找到判别方向。

3.7 读出能拿回多少与秩损失强相关——但它不是唯一因素

如果上一节的机制成立，那么“秩掉得越多，读出能拿回的越少”应当成立。图 7 把四个容量档的秩损失与各自的读出恢复率配对。

整体趋势成立，但不是单调关系。 秩损失 19.9% / 20.6% / 33.3% / 58.7% 对应恢复率 68.2% / 72.2% / 70.2% / 36.9%（$r = -0.934$），**整体趋势成立**。但**“有效秩下降即不可恢复”**不成立：ResNet-18 掉了 58.7% 的有效秩，读出仍拿回 36.9%（相对自带头 6.22 仍有 +20.60），所以**下降不等于不可恢复**。

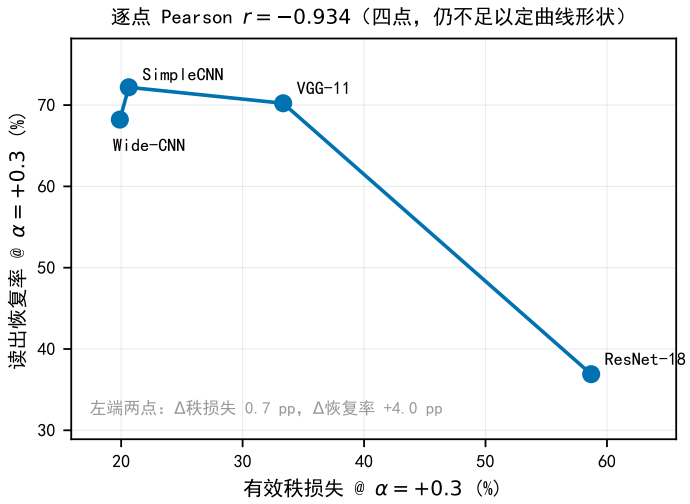


图 7: 秩损失与读出可恢复量的关系（四点）。恢复率定义为读出适配在 $\alpha = +0.3$ 的精度除以同一读出文件里原始头在 $\alpha = 0$ 的精度。四点整体趋势向下（逐点 Pearson $r = -0.934$），但**已经不是单调关系**：最左两点秩损失只差 0.7 个百分点，恢复率却差 4.0 个百分点。**四点仍不足以定曲线形状**，形状提示为“先平后塌”。数据：`rank_stats*.csv` 与 `v3_readout_repair/*ep24*.csv`。

第 4 个容量档没有补上中间段。 第 4 个容量档（Wide-CNN：1.40M 参数，MACs 为 VGG-11 的 0.87 倍）的干净精度 65.97% 正好落在 SimpleCNN（59.99）与 VGG-11（68.05）之间，**但它的秩损失 19.9% 与 SimpleCNN 的 20.6% 几乎重合**，没有落进中间段。因此按预登记判据，**四点仍不足以判定曲线形状**——“先平后塌”仍只是提示、不是证据。

一个比判据更重要的发现。 最左两点秩损失只差 **0.7** 个百分点，恢复率却相差 **4.0** 个百分点（72.2 − 68.2）——**超过本文自订的 3 个百分点分辨门槛**，且两点出自同一读出流程、同一秩统计口径、同为 3 seed。因此**秩损失不是恢复率的唯一决定因素**：存在秩损失之外的变量在起作用。须写明的代价：Wide-CNN 与前三点的差异**不纯是容量**，它还含“第二次下采样位置”这一个变量，是 MACs 约束下的取舍。这条开口正是第 5 节局限 (4) 所记，也是本文开放问题里最值得追的一条。

3.8 池化密度是第二个独立杠杆，它的保护主要来自降维

读出侧的杠杆要求读出层可写。有没有不依赖这一点的、纯架构的杠杆？图 8 给出一个不增加可训练参数、也不增加额外训练成本的答案。

主口径：同协议、同 seed 配对。 $\alpha = +0.3$ 从 26.03 提升到 **41.55**（+15.52）——两臂同出 `v3_methods`、同为 120 epoch 的逐层独立采样、seed 相同，**只改了池化层数**；这是与“架构杠杆”这个说法严格对应的对照（各单 seed）。

干净训练臂只作锚点。 干净训练臂给出同向的读数（28.09 → 42.47，+14.38），但它**不构成同协议对照**：基线 28.09 取自第一阶段的另一个训练脚本（无增强配方），与 `v3_methods` 异协议，故**只作锚点**。该臂自身有 3 个同协议的种子——$\alpha = +0.3$ 为 42.47 / 38.77 / 39.64，均值 **40.29 ± 1.58**，即在该臂内部增益应记为 +12.20（基线仍为异协议的单次运行）。**42.47 是这三个种子里最高的一个**，不宜单独引用。

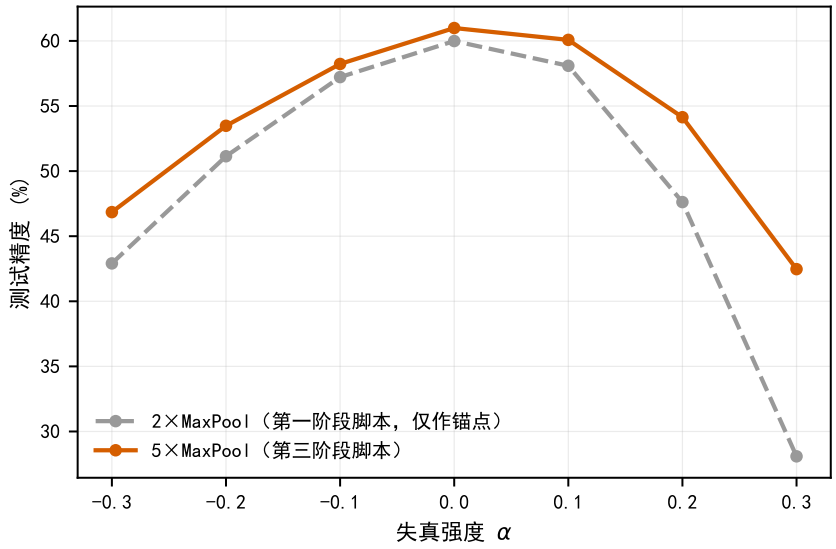


图 8: 池化密度是独立的架构级杠杆。把 SimpleCNN 的最大池化层从 2 个增加到 5 个——参数量不变、不增加额外训练成本。**同协议同 seed 配对（120 epoch、逐层独立采样）的读数是** $\alpha = +0.3$ **从 26.03 提升到 41.55**（+15.52，**各单 seed**）。图中灰色虚线为**第一阶段脚本**的产物，与实线的 `v3_methods` 分属两个阶段、**不同协议，仅作锚点、不参与任何同协议对比**（正文若引用 28.09 → 42.47，即横跨这两条曲线，须显式注明其跨协议性；该臂自身三个同协议种子的均值为 40.29 ± 1.58，见正文）。数据：`outputs_cifar100/v3_methods/simple_cnn_mp_clean_uniform/alpha_sensitivity.csv` 与 `task1_simplecnn/alpha_sensitivity.csv`。

七点均值。 七点均值提升 **3.6∼4.9** 个百分点——**区间两端是两种口径，不可当成同一个量**：下界 3.6 取自干净臂的 **3 seed 均值**（52.88 对基线 49.29）；上界 4.9 取自同协议配对的 NAT 臂（54.09 对 49.24），为**单 seed**。而干净精度不降。增益与读出适配同级，但不增加可训练参数与额外训练成本。

保护从哪里来。 四个候选机制被逐一检验：三条被否证，一条判为不可分辨。

第四条是唯一没被否证的，但也没能证实。 表 4 的前三条排除线都没有排掉一个更基本的原因：ReLU 把池化输入限制在**非负域**，而在那里归一化三次映射与 max 精确可交换（第一行实测）。若保护来源于这个非负性，那么**削弱非负性的激活应当让保护变弱**。实测（SimpleCNN，2× 与 5× 两种池化密度 × 两种激活，每格 3 seed）：定义池化保护 $P = (\text{2-pool 的 drop}) - (\text{5-pool 的 drop})$，得 $P(\text{ReLU}) = +11.81$、$P(\text{GELU}) = +14.71$，差 -2.91 个百分点，落在预登记的 ± 4（2σ）不可分辨带之内。⇒ **判为不可分辨——既不判成立，也不判否证。**

这里还要说明为什么不能把它当成“接近显著”：**方向本身不稳定**——单 seed 时该差值为 +2.57（与假说同向），3 seed 均值时变成 −2.91（**反向**）。**这不是“接近显著”，而是“这个量级的效应在本协议下判不了”**；它的噪声主要来自 2×max 一侧（种子标准差 3.03 / 2.89，而 5×max 一侧只有 1.54 / 0.26，相差一个量级）。

唯一显著的差异：空间元素数。 三条排除线之后，唯一显著的差异是**空间元素数从 256 降到 16**。进一步做同协议 3 种子对照：5×max 的 `drop@0.3` 为 20.60 ± 1.54、5×avg 为 21.78 ± 0.91，差 +1.17。该差值落在预登记的 1∼2 个百分点区间（差值的标准误 1.03，$z \approx 1.1$）。因此 **“降维：非均值聚合”的定量比例不予裁决**，只能给出方向性结论：**保护主要来自降维**。

表 4: 池化保护的四个候选解释与检验结果

候选解释	检验	结论
池化“吸收”了失真	归一化三次映射与 max 在非负域是否可交换	在池化输入（post-ReLU，非负）上**精确可交换**，$\max\|\Delta\| = 0.000\text{e+}00$；但可交换却非成因——交换律成立时保护并未因此产生
质量向恒等区集中	5-pool 与 2-pool 的易感度 S 与不变区占比	5-pool 的 S **反而更高**（conv4：0.1527 vs 0.1134），不变区占比几乎不变
max 的选择性或可交换性	换成 top-2 池化（与 f_α 不可交换）	保护与 max 等同（42.98 vs 42.47，单种子）
ReLU 的非负性（使池化输入落在正卦限）	换成 GELU（破坏非负性）后池化保护是否变弱	$P(\text{ReLU}) = +11.81$ 对 $P(\text{GELU}) = +14.71$（SimpleCNN，两种池化密度 × 3 seed），差 -2.91，**落在预登记的 ±4 不可分辨带内；方向还随种子翻转 ⇒ 不可裁决**

3.9 两个杠杆在最严重失真上可以同时受益，但不独立相加；失真强度可以在线估计

叠加：可以同时受益，但次可加。 图 8 的架构杠杆与 图 3 的读出杠杆是否互斥？把两者叠起来（5×MaxPool 主干 + readout-NAT），$\alpha = +0.3$ 达 **49.18**（三个读出种子：49.12 / 48.82 / 49.59），比架构单独（42.47）高 6.71、比读出单独（43.31）高 5.87。**但两个杠杆并不独立相加**：架构单独增益 +14.38、读出单独增益 +15.22，单独之和的预期是 +29.60，实际只拿到 +21.09——**次可加**，合起来拿到约七成（21.09/29.60）、损失约三成。准确的表述是：**两个手段在最严重失真上可以同时受益，但它们不独立相加**。

口径核对：架构一侧必须用 42.47。 上述数字取自连续均匀 α 头、24 ep/20k、同一条评估路径；读出侧取 3 seed 均值。叠加实验是在 seed 42 那一块主干上做的，“架构单独”与“叠加”只能在同一块主干内相减，所以这里是**同实例配对**，而不是上一节的跨主干 3 seed 均值 40.29。若把架构一侧换成 40.29，预期变为 +27.42、缺口 6.33、实得占预期的 77%——**“次可加”的结论在两个口径下都成立**。

在线估计：从特征里把 α 读回来。 部署时还有一个信息问题：现场并不知道失真有多强。用读出层的特征做岭回归即可恢复它：在四个主干 × 数据集组合上，R^2 为 **0.827∼0.935**、MAE **0.036∼0.061**，$\hat{\alpha}$ 在 ±0.3 区间上近乎无偏。

主干越深，估计越准。 VGG-11（Exp2 主干）$R^2 = \mathbf{0.9516}$ / MAE 0.0324，ResNet-18（Exp3 主干）$R^2 = \mathbf{0.9778}$ / MAE 0.0219。（出处：`outputs_cifar100/v5_full_recipe/recipe_robust_*.csv` 的 `ridge_R2` / `ridge_MAE` 两列。）这与直觉一致——深层特征的维度更高（512 对 128），承载的失真强度信息更完整；而浅层里 MaxPool 会把一部分 α 信息压掉（CIFAR-100 上 5×MaxPool 主干的 R^2 为 0.8323，低于 2×MaxPool（plain）主干的 0.935）。这意味着可以按估计值在多个头之间调度，且**在深层上这个调度信号比浅层更可靠**。

3.10 门控能把读出的干净精度代价收回来——但有清晰的门槛

问题：干净精度代价能不能收回来。 读出适配付出了干净精度代价：上文读出适配一节的三个主干（24 ep、各 3 seed）为 **3.08∼7.69** 个百分点。这里要提醒口径：本节以下七个点取自**另一批**

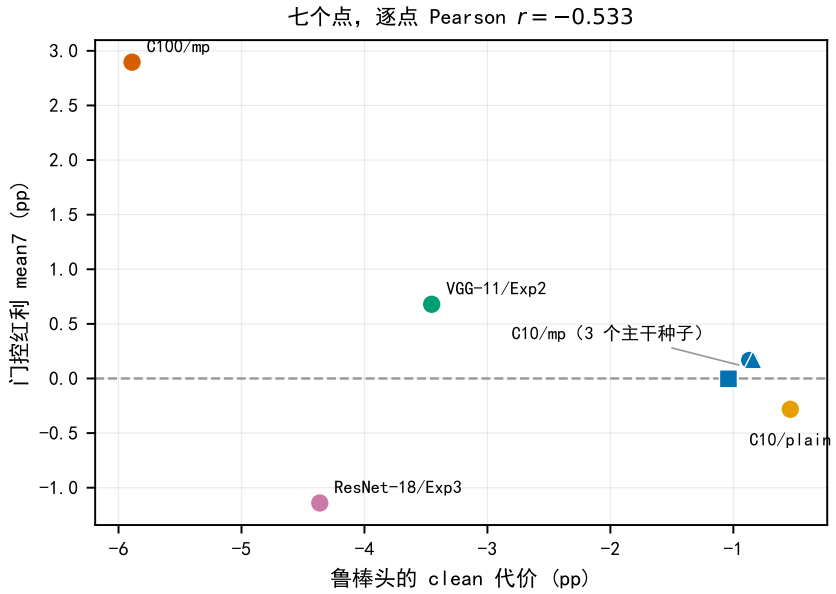


图 9: 门控红利不随鲁棒头代价单调增长。横轴为鲁棒头相对干净头在 $\alpha = 0$ 的精度损失（负值 = 鲁棒头更差），纵轴为门控相对单用鲁棒头在 `mean7` 上的增益。七个点取自四个主干配置与两个数据集，各 3 个种子。（C10/mp 的三个主干种子在图中以三种标记画出、共用同一标签。）逐点 Pearson $r = -0.533$；去掉 CIFAR-100 远点后 $n = 6$ 时符号反转为 $+0.351$。数据：`v5_full_recipe/recipe*.csv`。

产物（`v5_full_recipe`）——主干配置与读出训练都与那一批不同，故其代价与上面这个区间**不逐位对应**。

既然 α 可以估计，一个自然的做法是同时保留两个头：**干净头**就是模型自带的那个分类头（第 3.2 节的“原始头”），它冻结不动、可以固化在 ROM 里；**鲁棒头**即读出适配头，是在 $\alpha \sim U[\pm 0.3]$ 上重训出来的那个读出（沿用产物列名 `acc_robust_head`）。按 $w = \mathrm{clip}(|\hat{\alpha}|/0.3, 0, 1)$ 在两个头的 logits 之间插值。图 9 把七个 (代价, 红利) 点画在一起，结论与直觉相反。

结果：代价更大，红利没有跟着变大。 在 CIFAR-100/mp 上，鲁棒头的干净代价是 -5.89，门控收回 $+2.90$，七个扫描点里有三个超过两头中较优者。但当把深层主干加进来，代价落进了此前空白的 2∼5 个百分点区间（VGG-11 -3.45、ResNet-18 -4.36），**红利却没有跟着变大**：分别是 $+0.68$ 与 $\mathbf{-1.14}$——在 ResNet-18 上门控比单用鲁棒头还差 1.14 个百分点。

原因在逐 α 曲线上看得很清楚：ResNet-18 的自带分类头在**负侧是崩的**（$\alpha = -0.2$ 只有 10.27%）。软门控按 $w = |\hat{\alpha}|/0.3$ 插值，在真实 $\alpha = -0.2$ 处 $w \approx 0.67$，于是三分之一权重的坏头把 45.64 拖到 39.21。插值没有任何机制知道“其中一个头在这个 α 上是坏的”。

两个前提。 因此门控有效需要**两个前提同时成立**：

1. 鲁棒头的干净代价足够大（有东西可回收）；
2. 两个头在整个 α 轴上都不能崩掉（否则插值会把一个头在该点的灾难带进来）。

跨数据集自检：强主张未复现。 上述机制是在 CIFAR-100 上事后发现的。为检验它，在**尚无任何配方结果**的 CIFAR-10 上锁定了全部超参、并在跑之前写死了五条判据（C1–C5）。结果：形式判据成立，但强主张**未复现**——“插值超过 oracle”的判据由 3/7 降到 **1/7** [2]，门控相对 oracle

[2] **但这个计数不稳健，本节的结论不挂在它上面。**内部复核发现：CIFAR-10 侧有一个 α 点的“软门控减 oracle”只有 -0.0100 pp （$\alpha = -0.2$），而 CPU 与 CUDA 的**设备差异单独就能把它翻成** $+0.0033$ ——也就是说 **3/7 与 1/7**

由 +0.12 变成 −0.07，门控红利由 +2.90 缩到 +0.17。复现的是**弱支配**（不差于任一头），不是集成增益。机制因此被改写成更保守的形式：**门控红利 = 鲁棒头干净代价的回收量**；当干净代价小于 1 个百分点时，直接用单鲁棒头即可。

为什么它只能“弱支配”：一个机制级的回答。 上面那条“没有复现”是**跨数据集的经验事实**。它后来有了一个**机制级的解释**，而这个解释同时把那个主张**永久关闭**了。

两个头的错误是否互补，可以直接测：取两个头在同一批样本上的 0/1 错误指示向量，算它们的 ϕ 相关。**只有当两头的错误负相关时，插值才可能“集成”出比两头都好的结果。**

实测（7 个 α 点 × 3 个种子 = 每个数据集 21 格）：

	CIFAR-100	CIFAR-10
ϕ 范围	$+0.594 \sim +0.706$	$+0.519 \sim +0.830$
两头都错 / 独立基线	$1.50 \sim 1.98$	$2.76 \sim 6.58$

（**口径**：表中范围取**按 α 点先做 3 seed 平均**后的逐点极值；若不平均、直接在 21 格上取极值，则 ϕ 依次为 $+0.581 \sim +0.712$ 与 $+0.475 \sim +0.842$、“两头都错”倍数为 $1.49 \sim 1.99$ 与 $2.61 \sim 6.68$。**两个口径的定性结论相同**——逐行极值是对“ϕ 处处强正”这一主张的保守下界，按 α 平均后的极值则刻画各 α 处的典型值。）

结论：错误高度正相关，互补性不存在。 ϕ **在两个数据集上都是强正**——两个头的错误**正相关**，它们在同一批样本上**一起错**。⇒ **“插值即集成”所依赖的互补性，在两个数据集上都不存在。**

由此两条：

1. **那个机制是被否证，不是“未能分辨”。**本文因此把“插值即集成”**永久关闭**——不是“没复现”，是它依赖的前提不成立。
2. **收益的上界由此变得可解释：**没有互补性可利用，插值的增益注定有限。实测“软门控减 oracle”的极差，CIFAR-100 为 **1.60** pp、CIFAR-10 只有 **0.71** pp，与“两头错误高度正相关”一致。

被关闭的是机制解释，不是效应本身。 CIFAR-100 上软门控确有若干点超过两个头，那个效应仍然存在、也仍未被完全解释——本节给出的机制只说明了**它的上界为什么不高**，没有说明**它为什么不为零**。（出处：`outputs_cifar100/v7_gate_mechanism/gate_errors.csv`。该诊断含一条恒等自检：soft − oracle = (rescue − hurt) × 100，通过。）

裕度是不是碰巧：补到 3 个主干种子。 上面的 CIFAR-10 检验只用了**一个主干种子**——3 个种子变的是鲁棒头与估计器，不是主干本身。为判断裕度是否稳健，把 CIFAR-10 的 mp 主干补到 3 个种子，每个主干各跑一次完整配方：

主干种子	mean7（干净头）	mean7（鲁棒头）	mean7（软门控）	m
42	82.68	85.02	85.19	+0.169
43	82.19	84.90	84.90	**−0.003**
44	82.61	85.00	85.17	+0.171

之差可以只由设备口径造成。（CIFAR-100 侧对应点的最小裕度是 0.1567 pp，是稳的。）⇒ 本节的结论一律挂在**幅度**上，不挂在计数上。

（$m = \text{mean7(软门控)} - \max(\text{mean7 干净头, mean7 鲁棒头})$。判据跑前写死：**任一 $m \le 0$ 则 C1 改判“不可分辨”**。）

主干种子 43 的 $m = -0.003$，判据命中 $\Rightarrow$ C1 由“弱通过”改判 **“不可分辨”**，软门控在 CIFAR-10 上的定性定为**“与单头不可区分”**。更准确的说法是：**差值在 $0 \sim +0.17$ 之间飘，三个主干种子里有一个正好落在 0 上**（平均 +0.112，全部远小于主干级的 mean7 噪声）。**部署推荐不变**——CIFAR-10 一直推荐单鲁棒头。

被替代的配置也要记录。 按本项目的纪律，预登记未达标的记录必须留下：最早预登记的完整配方用的是**硬** τ 路由，端到端实测三项判据里 mean7 54.49（达标）、clean 60.92（达标）、但 $\alpha = +0.3 =$ **47.90**（**未达标**，阈值 48.5，差 0.60）。**软门控是在看到这次失败之后才引入的**——这正是上文所有“事后变体”措辞的来源，也是为什么本文对它的每一个主张都要求跨数据集复现。

两前提不能做成装前自检。 门控的两前提**无法**做成装前的量化自检：把“崩”定义为两头在 7 个 α 点上的最小精度，或定义为最坏相对缺口，两种定义在已有的 7 个点上**都不分离**红利的符号（VGG-11 的最小精度只有 15.73 却红利为正；CIFAR-10/mp 主干 43 的最小精度有 69.23 却红利为 -0.003）。该判据作为事后机制解释保留，不作为预测规则。

分布漂移：按六种分布重新加权。 上面所有比较都在训练分布 $U[\pm 0.3]$ 上做。真实芯片的失真分布未必如此，于是按六种分布对**已有的逐 α 结果重新加权**（5×MaxPool 主干，CIFAR-100，各 3 seed 均值；表内指标为 `mean7`；权重固定、τ 不重选，零 GPU 成本；出处 `outputs_cifar100/v5_alpha_drift/drift_stress.csv`）：

评估分布	clean 头	robust 头	硬路由	**软门控**	oracle
① $U[\pm 0.3]$（训练分布，参照）	54.12	52.19	54.49	**55.08**	54.96
②仅正向	54.53	52.85	55.49	**56.07**	55.87
③仅负向	55.43	52.25	55.10	**55.50**	55.56
④双峰（± 0.2 各半）	53.71	52.03	53.25	**54.40**	54.02
⑤尾部集中（± 0.3 各半）	45.63	**48.57**	48.10	**49.11**	48.57
⑥单峰 $N(+0.3, 0.05)$	44.51	49.08	48.57	**49.83**	49.24

软门控在 6/6 种分布下都最好。 其中 **5** 种还超过 oracle。唯一不超过的是③仅负向：55.50 对 55.56，差 0.06——这是全表最小的裕度，其余五行的裕度分别是 +0.12 / +0.20 / +0.38 / +0.54 / +0.59。它不需要知道真实分布是什么——因为插值权重 $w = |\hat{\alpha}|/0.3$ 是**逐样本**算的，分布的形状不影响它。

硬路由在漂移下会退化。 在⑤（尾部集中）处，硬路由只有 48.10，**反而低于单用鲁棒头的 48.57**（差 -0.47）；⑥（单峰）处同样如此（$48.57 < 49.08$，差 -0.51）。原因是硬路由在 $|\hat{\alpha}|$ 的阈值附近做二值选择，而尾部集中时 $\hat{\alpha}$ 大量落在阈值两侧，选错的代价被放大。

但红利不是无条件的。 同一组实验在**池化稀疏**（plain，2 个 MaxPool）主干上做，⑤处软门控 47.70 对鲁棒头 47.71——**红利消失**（-0.01）。这与第 3.10 节的边界条件一致：**软门控的价值取决于主干自身在最严重失真下的可用性**，分布漂移只是让它更明显或更不必要。

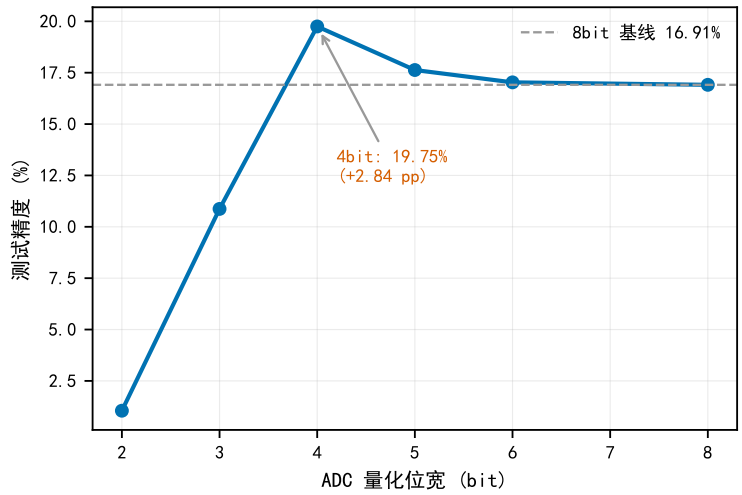


图 10: 低位量化在池化密集架构上反转成增益。VGG-11、固定 $\alpha = +0.3$、CIFAR-100，扫描 ADC 位宽；虚线为 8 bit 基线。4 bit 时精度最高，比 8 bit 高 2.84 个百分点。数据：`outputs_cifar100/extension5_dithering_vgg11/group_a_bits_scan.csv`。

3.11 失真与量化联合作用时，低位量化在池化密集架构上会反转成增益

真实芯片在模拟域失真之外还有 ADC 量化。两者同时存在时相互放大还是抵消？图 10 给出一个反直觉的答案。

反直觉的结果。 在 VGG-11（5 个 MaxPool）上，4 bit 量化的精度**高于** 8 bit（CIFAR-100：+2.84；CIFAR-10：+6.53）。三个候选假设通过剂量匹配的三组对照、样本级翻转统计与激活分布统计判决。

先分清楚数据来自哪个数据集。 图 10 的扫描是 CIFAR-100 的；而下面 H1–H3 的**机理量取自 CIFAR-10 侧**（`outputs/extension5_dithering_vgg11/`，与 CIFAR-100 侧同一脚本、同一协议，只换数据集与主干权重）。CIFAR-100 侧的对应量平行列在附录表 7 中——两数据集的**定性结论一致**，这正是这一节结论的稳健性证据。

- **H1 随机去相关——否决。**用与 4 bit 等效剂量的纯高斯/均匀噪声替代量化，精度不升反降（**CIFAR-10**：−2.45 / −1.87；CIFAR-100 同号，−3.12 / −2.48）；8 bit 基线上叠加最优剂量噪声的增益为 −0.03（CIFAR-10；CIFAR-100 为 −0.07）。样本级翻转统计给出三个量级的反差：**CIFAR-10** 上 4 bit 的救回: 杀死为 4.15:1（净 +653 样本），而噪声条件约为 1:1（净 +7 / −19）；CIFAR-100 上同向（1.77:1，净 +284）。
- **H2 分布重塑——确认（核心机理）。****CIFAR-10** 上分类器输入分布的峰度在失真下从 1.486 被压平到 0.110，4 bit 的粗离散化把它恢复到 **0.214**，部分重建可分性（CIFAR-100：2.541 → 0.847 → 0.980，同向）。存在甜点带：3 bit 峰度更高（0.384）但**在 CIFAR-10 口径下**精度略降（43.27 → 42.97），2 bit 信息量不足、峰度与精度双双坍缩。（CIFAR-100 口径下 3 bit 不是“略降”而是大幅下降，19.75 → 10.87，见附录表 7。）
- **H3 MaxPool 交互——支持（必要条件）。****CIFAR-10** 上无 MaxPool 的 ResNet-18 完全免疫（+0.39）；但只有 2 个 MaxPool 的 SimpleCNN 是**负增益**（−13.68）。CIFAR-100 上定性相同（ResNet-18 −0.21、SimpleCNN −14.71）——**这条定性结论在第二个数据集上复现。**因此 MaxPool 是必要而非充分条件，其密度决定量化误差是被修正还是被放大。

分层答案。 这条结果对“数字域后处理能救多少”给出了分层答案：同一个 4 bit ADC，在池化密集架构上是补偿，在池化稀疏架构上是负担。

3.12 为一种失真做的鲁棒性训练，不会顺带保护另一种

问题：两种扰动能不能互相迁移。 前十节讨论的都是同一类扰动：确定性的、输入相关的非线性失真。现实中的模拟域还有另一类误差源——零均值、与信号无关的**加性随机噪声**。一个自然的问题是：**为其中一种训练出的鲁棒性，能不能迁移到另一种？**如果不能，那么两类误差必须分别对待；如果能，联合训练就够。

迁移：两种扰动几乎互不影响，但幅度依赖架构。 把一条通路上训好的权重拿到另一条通路上扫，测“扰动敏感性”的变化幅度 $\max|\Delta_\sigma|$（超过 1.2 个百分点判为非零迁移）：

架构	配方对	$\max\|\Delta_\sigma\|$
SimpleCNN	Exp2（校准）vs 原始	1.16
SimpleCNN	NAT-scratch vs clean	2.43
SimpleCNN + 3×MaxPool	NAT vs clean	0.98
VGG-11	**Exp2（校准）vs clean**	**5.26**
ResNet-18	Exp2（校准）vs clean	1.41

⇒ “两种扰动互不影响、迁移为零”这条结论**是架构依赖的**：在 SimpleCNN 与 ResNet-18 上成立（$\leq$1.41），但在 **MaxPool 密集的 VGG-11 上被打破**（5.26）。值得注意的是，加三个 MaxPool 反而**降低**了迁移（2.43 → 0.98），所以“MaxPool 密度”本身不是迁移的成因——更可能是校准模块作用于空间特征图的方式（§1.3 的讨论）。

训练端：不是零迁移，而是单向强干扰。 迁移幅度小，容易被读成“两者互不影响”。但训练端的对照否证了这个读法。在同一个 harness 上做 2×2（是否注入 α × 是否注入 σ）：

训练条件	clean	$\alpha=+0.3$	$\sigma=0.30$	双扰动最坏点均值
无训练（clean 模型）	59.99	28.09	3.98	16.04
α-only	**60.85**	26.03	4.40	15.22
σ-only	55.79	22.01	**27.19**	**24.60**
$\alpha+\sigma$（联合）	55.20	15.27	**31.31**	23.29

三件事同时成立：

1. **α 训练对 σ 几乎零收益**（4.40 vs 3.98）——这一侧确实是正交的。
2. **但 σ 训练使 α 侧付出代价**：$\alpha=+0.3$ 从 28.09 掉到 22.01（−6.08），干净精度也掉 4.20。联合训练更糟：α 侧 15.27（相对 clean 模型 −12.82，相对只做 α 训练的 26.03 又低 −10.76）。
3. **双扰动并存时的最优配方是 σ-only，不是联合训练**：joint 里的 α 注入是**净负担**——它在 σ 侧只多拿 4.12，却付出 α 侧 −6.74。

⇒ 正确表述不是“两种扰动互不影响”，而是「**迁移接近零，但训练端存在单向干扰**——只在一个方向上有代价（$\sigma\to\alpha$ 有代价、$\alpha\to\sigma$ 无收益）」。

表 5: 5.55 个百分点差异的三次归因尝试与结果

轮次	当时的归因	结果
1	最严重失真**种子噪声** ±3.1	**否证**。三个种子来自两个脚本，同协议下标准差只有 ±0.39；混协议把标准差估高约 6 倍
2	α 采样**粒度**（每批共享 vs 逐层独立）	**否证**。在同一脚本内只切换粒度：26.55 vs 26.57，差 +0.02（$z = 0.08$）；而同粒度跨脚本差 +5.52（$z = 9.4$；口径 $26.55 - 21.03$，两臂**同为 shared 粒度**——与正文“相差 5.55”的口径不同：后者是 $26.58 - 21.03$，B 侧为 6 个 run 的合并均值）。效应跟着脚本走，不跟着粒度走
3	随机数**消耗位置**（每批消耗 1 个 vs 5 个随机数）	**否证**。同脚本把消耗数从 5 改成 1：26.66 vs 26.55，差 +0.11

这条结论的工程含义。 如果部署环境同时存在两类误差，**不应把两种扰动一起塞进训练**——应该先显式训 σ 鲁棒性（它是必须显式训练的，且收益大：$\sigma = 0.3$ 处 $3.98 \to 27.19$），然后**在读出侧**单独处理非线性失真（第 3.2 节的方法正好不碰主干，因此不会与 σ 训练互相干扰）。换言之，本节的结论与本文的主线是一致的：**训练端做的事越少越好，剩下的交给读出。**

3.13 这些效应有多大：用错协议会把标准差估高六倍

先给一个误差尺度。 上面所有差值都需要一个误差尺度。本文的不确定度标定给出三个数值，其中一个足以改变结论。

第一：最严重失真指标的种子标准差远大于干净精度。 同协议实测：浅层鲁棒训练在最严重失真上的标准差为 ±0.39、架构变体为 $\pm 0.95 \sim 1.58$、深层读出为 $\pm 3.18 \sim 3.40$；而同组的干净精度只有 $\pm 0.07 \sim 1.85$。更麻烦的是干净精度**不能外推**：ResNet-18 按 2 个种子报的 ±0.15 在补上第 3 个种子后变成 ±1.85（第 3 个种子的干净精度为 67.61，比另两个高 2.6~4.1 个百分点）。三个容量的干净标准差跨度达 26 倍。

第二：混用协议会把标准差估高约 6 倍。 一组 3 seed 的鲁棒训练的最严重失真读数，若三个种子来自两个脚本，标准差是 ±2.561；补跑同脚本的第三个种子后，同协议标准差只有 ±0.392。进一步的定量分解显示，那 2.56 里绝大部分**不是随机噪声，而是两种训练配方之间的系统差**（组内两个数相差 5.32，与实测的脚本级处理效应 5.52 几乎相等）。也就是说，把处理效应误读成了噪声。

第三：跨训练实现的数字对不上，且原因未定。 这一条是**本文的观测**，不是一条普遍定律：一个未归因的差异，既可能是实现层的普遍不可移植，也可能是其中一个脚本里还有没找到的具体差别——本文没有排除后者。两个脚本（记为 A 与 B）在数据加载、归一化、优化器、batch、epoch、调度器、增强、钩子机制、采样位置与评估口径上逐项一致，同 seed 的逐 epoch 训练损失全程贴合（差 ≤ 0.016，无分叉），但 A 训出的鲁棒权重在最严重失真上稳定落在 21.03 ± 1.00，B 训出的**六个** run 全部落在 26.58 ± 0.29，两者相差 **5.55** 个百分点（$z = 9.4$）。

为定位原因做了三次独立的干预，全部失败：

已排除的解释累计为：种子噪声、α 采样粒度、随机数消耗数、评估路径（图 11，8 个权重 × 2 条路径逐位相同）、训练动力学（逐 epoch 损失差 ≤ 0.016）。**该差异仍未归因，按已知未知**

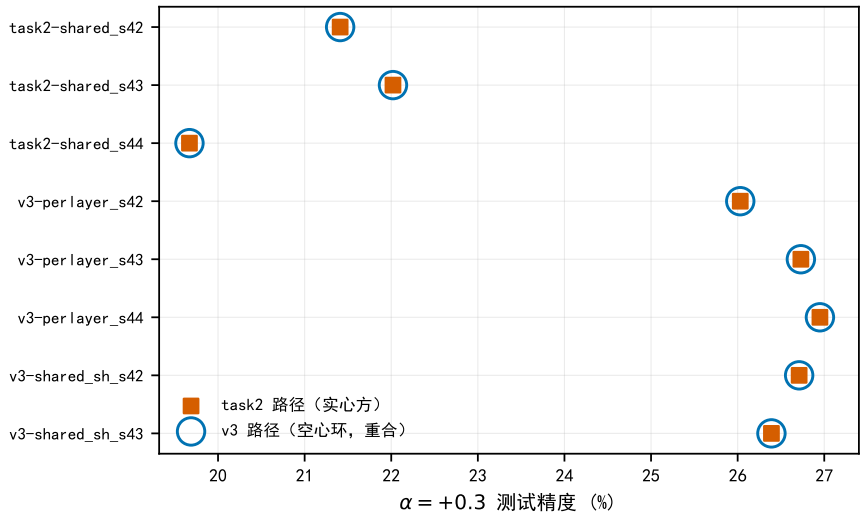


图 11：交叉评估：差异不在评估路径。把 8 个权重分别在另一脚本原样导入的评估函数下重扫，两条路径给出**逐位相同**的读数（含干净精度）——（图中每条读数由**重合的两枚标记**表示：实心方 = task2 路径、空心环 = v3 路径；两者逐位相同故完全重合）；但两组权重稳定分成两簇（A 脚本 19.7∼22.0，B 脚本 26.0∼27.0）。数据：outputs_cifar100/v6_p4e_crosspath/crosspath.csv。

记录。

这条观察的实践含义是硬的：**本文的做法是让部署校准与部署训练同实现、同路径**；在归因之前，跨实现引用精度数字——包括与文献对比——都不可靠，本文不引用。

一个更实用的刻度：三级可分辨性。 上面那条跨实现差异是一个**已知未知**，无法直接当门槛用。但它旁边有两级**可以测准**的散布，合起来给出一个可操作的判断尺度：

层级	变的是什么	实测幅度
①种子噪声	同一过程重复	最严重失真 ±0.16 ∼ 3.40；clean ±0.07 ∼ 1.85
②过程自由度	**同数据、同特征、同架构，只换拟合过程**	**3.45 pp**
③跨实现	同超参同种子，实现不同	5.55 pp（**未归因**）

第①级：种子噪声。它含两类种子：读出种子（固定主干，最严重失真 ±0.16 ∼ 3.40——0.16 来自 SimpleCNN、3.40 来自 ResNet-18）与主干种子（固定读出，最严重失真 ±0.25 ∼ 2.61，见第 5 节的局限 (2)）。

第②级：过程自由度。它是在**同一批冻结特征**上训同一个线性头，只换六种拟合过程（sklearn 的 lbfgs / saga；torch 的 Adam 在 50 / 150 / 400 轮；SGD+ 动量 150 轮），$\alpha = 0$ 与 $+0.3$ 上各跑一遍。结果：

拟合过程	sklearn lbfgs	sklearn saga	Adam 50	Adam 150	Adam 400	SGD+mom 150
$\alpha = 0$	53.22	54.91	**56.31**	54.89	**52.85**	53.27
$\alpha = +0.3$	48.25	50.75	**51.57**	50.37	48.55	**48.12**

⇒ **极差** $\Delta_{\mathbf{proc}} = 3.45 \sim 3.46$ **pp**。同数据、同特征、同架构、同一个线性头，**只换“怎么把它拟合出来”，就能差 3.45 个百分点。**

一个反直觉的细节。 $\alpha = 0$ 的最大值与最小值**都来自同一个优化器的不同轮数**（Adam 50 轮最高 56.31、Adam 400 轮最低 52.85）。⇒ **在** $\alpha = 0$ **上，过程自由度的主要来源是“训多久”，不是**

“用哪个”。（$\alpha = +0.3$ 上两个因子**同量级**，不能只归给轮数：轮数在 Adam 内部跨 3.02（51.57 → 48.55），而全距 3.45 是由**跨优化器**的那一对跨出来的（Adam 50 轮 51.57 对 SGD+ 动量 48.12）；同轮数下换优化器（Adam 150 对 SGD+mom 150）只跨 2.25。该论断是本文的单主干单特征集观测，未进预登记判据。）

判断规则。任何“读出类”效应（换头、加正则、改容量）的可分辨门槛 **必须同时以 $\Delta_{\mathbf{proc}}$ 为参照，不能只用种子噪声**——因为种子噪声测的是“同一过程重复”的散布，而 Δ_{proc} 测的是“换一个过程”的散布，**后者才是接收端口真正面对的那种不确定性**。本文第 3.10 节关于门控增益的每一个比较，其效应量都远大于种子噪声，但与 Δ_{proc} 同量级——这一点读者在解释那些差值时应当一并考虑。

4 讨论

4.1 为什么修复的对象不是参数而是解码

三条证据并置。 把 图 2、图 3、图 4 三条并置：信息仍在（探针可线性取用）、换读出即取到（最严重失真上 +15.2 ∼ +31.8）、而参数空间的五条路径没有一条改善最严重失真，其中第五条还主动放大了损伤。这三条单独看都可以被别的解释吸收——探针可能过强、“训练不够久”、读出适配可能是再分配——但并置之后“再分配”这个解释被排除，因为分布式读出适配在每个扫描点都不显著劣化。

为什么不是“扰动被参数吸收”。 常规对抗鲁棒性的直觉是“扰动在参数空间里被吸收”：对抗训练之所以有效，是因为训练分布覆盖了测试分布。但本文的扰动性质不同——它是确定性的、输入相关的系统误差，逐层累积且与信号幅度挂钩。图 6 表明这类误差不摧毁信息，它改变信息的**几何**：把深层表征的有效维度压下去；同强度下 Fisher 判别比不低于负侧，但正侧 $\alpha = +0.3$ 的 Fisher 仍低于干净条件。在一个丢维度的子空间里，“把参数训得更适应”不会增加维度；换一个读出却可以在剩余的维度里重新找到判别方向。图 7 把这个直觉接上了定量：可恢复量随秩损失整体下降。但它**不是唯一的决定因素**——最左两点秩损失相差 0.7 个百分点，恢复率却相差 4.0 个百分点，说明在那个子空间的几何里，还有秩之外的量在起作用。

4.2 一个我们建议的测量顺序（在一族卷积主干上验证过）

原理。 更一般地，当失真同时具有“确定性、逐层累积、且权重不可重训”三个性质时，**鲁棒性的杠杆位置由信息在哪一层被破坏决定，而不是由“哪一层参数多”或“哪一层最脆弱”决定**。这条原理可以落成一个测量顺序，而不是一个方法——**本文只在一族卷积主干（0.25M∼11.2M 参数，以 CIFAR-100 计；全部为卷积 + BatchNorm + ReLU + 池化的堆叠）上验证过它，适用范围见第 5 节的局限 (10)：**

1. **先测 headroom**：在冻结主干的末端特征上重训线性探针，与自带头比较。headroom 小 → 信息真的没了，只能动表征，回到常规鲁棒训练；headroom 大 → 杠杆在读出，训练端的投入大概率是浪费。
2. **若杠杆在读出，再测秩损失**：它给可恢复量一个上界提示（本文：秩损失 19.9∼58.7% 对应恢复率 68.2∼36.9%）——但要注意**它只是主要相关量、不是唯一决定因素**（见 图 7）。
3. **再看架构端有没有不增加可训练参数的降维空间**（本文：池化密度）。

第一步本身有区分力。 本文给出 headroom 的两个对照值：非线性失真 +20.26、加性高斯噪声 +7.50。随机扰动与确定性系统误差在这个量上清楚地分开——前者需要的是表征层面的平滑，后者需要的是解码层面的重定向。

4.3 若要落到真实器件的数字后端

本节把上面的结论映射到存内计算的实际约束上：模拟阵列负责乘累加、权重**固化**，阵列输出经 ADC 回到数字域，失真发生在模拟域的输入侧。判定分三档——**可行** / **需改动** / **不可行**：

组件	判定	依据
读出适配	**需改动**	要求读出层位于数字域、或阵列里那一小块可重写。读出层只占全模型参数的 **5.04%**（SimpleCNN）/ **0.55%**（VGG-11），挪出阵列对面积影响很小
在线 α 估计	**可行**	一次 d 维点积（$d = 128/512$），算力占主干前向的 **3.8e-4%** / 2.4e-4%
软门控	**可行**（前提同第一条）	数字域逐元素运算，每次推理约 **400** 次操作；干净头是冻结不动的那一个，正好可以固化在 ROM 里
冻结主干	**可行**	就是“不训练主干”，天然符合权重固化
MaxPool 密集主干	**设计阶段不增加可训练参数** / 部署后不可行	它是网络定义的改动，只能在投片前决定；好消息是它不增加可训练参数与额外训练成本
全网络重训	**不可行**	阵列权重是烧录/固化的；而且训练端的五条路本来就救不了最严重失真（第 3.5 节）

推荐的落地顺序。 三步，前两步都有实测支撑：

1. **架构端先上**：MaxPool 密集主干。不增加可训练参数与额外训练成本，最严重失真上 +15.52 个百分点（同协议同 seed 配对）——但它只能在投片前决定，所以这一条要最先定。
2. **读出端再训**：α-混合鲁棒头（即上文的读出适配；24 epoch，约 12 分钟）。最严重失真上再抬升一截，代价是干净精度下降——**代价的大小决定了第三步要不要做**。
3. **门控按需加**：仅当鲁棒头的干净代价足够大时（CIFAR-100 式细粒度任务，代价 -5.89）才加，且先查两个头的逐 α 曲线（第 3.10 节的前提②）。代价 $\lesssim$1 pp 时直接用单鲁棒头。

一个必须说清的结构性前提。 以上全部依赖**读出层可写**。若某款 CIM 把读出层也固化在阵列里，本方法整体不成立——这不是精度问题，是可行性问题，因此它出现在第 5 节的局限 (6) 里。

本节的边界。 以上是**推演**，不是实测。没有硬件实测、没有 RTL 或功耗仿真、也没有写出“读出层挪到数字域”的接口约定（时序、位宽、与 ADC 的对接）。面积、延迟、功耗的绝对值本文没有算过。

4.4 打开的问题空间

按重要性排序，四个问题如下。

1. **秩损失到可恢复量的曲线是什么形状？**四点提示“先平后塌”，但四点仍定不了形状（图 7）。**更关键的是秩损失之外还有什么**：最左两点秩损失相差 0.7 个百分点、恢复率却差 4.0 个百

分点，说明存在一个尚未识别的变量（候选：下采样位置、特征几何）。这直接影响能否把可恢复量写成一个由秩损失预测的上界——在找到那个变量之前，这样的上界即使画出来也是不完备的。

2. **若失真形态不是三次多项式，headroom 还剩多少？**高斯对照给了下界；更高阶、带温度漂移或器件失配的形态族未测。
3. **α-无关读出的可达上界在哪？**本文的读出适配在**不知道** α 的情况下只拿到 43.31（3 seed），而 oracle-α 探针为 48.35，两者相差 **5.04** 个百分点（$48.35 - 43.31$，同一 $\alpha = +0.3$ 点）。这个缺口里有多少是“不知道 α”的代价、有多少是优化不足，本文未分离。
4. **多头扩展：**把 α 与噪声强度 σ 同时估出来、三头调度，是否优于单训 σ 的配方？（本文的联合扰动数据已显示 σ-only 最优、α 注入是净负担，但未做三头路由。）

5 局限与未来工作

下面 12 条限制，每一条都让某个由本文发现引出的问题处于未决状态。

(1) 失真模型是参数化假设，且无硬件实测。 全部收益都测在 式 (1) 这一族上。若真实 CiM 的非线性更接近高阶多项式、带温度依赖、或器件间失配有随机成分，headroom 还有多大、读出杠杆是否成立，本文无法回答。已知的下界来自高斯对照（headroom 从 20.26 降到 7.50）。**下一步：**结合真实 CiM 宏的实测特性标定失真参数，在形态族上重测 headroom。

(2) 深层差值的可裁决性（已补测，原判断部分保留）。 这条原先写的是“深层主干是单次训练产物……涉及深层的所有差值是否在主干种子方差内无法裁决”。现每个深层主干已补训到 3 个种子（读出侧固定 seed 42）。最严重失真（$\alpha = +0.3$）的**主干级**标准差为 VGG-11 0.25、ResNet-18 2.61，**均小于对应的读出级标准差**（3.18 / 3.40）——即此前印出的 $\pm$ 值没有低估总不确定度。读出适配线上的深层差值因此可以裁决（判决为“合格，但须写明在已测主干上成立”）；而 图 9 上 ResNet-18 的 -1.14 仍落在主干级散布 2.61 之内，**这一条仍然不可裁决**——理由从“没有测”变成了“测了，方差确实盖得住它”。

(3) 池化保护的机制分解没有定下来。 两个子问题都没有结论。**①定量分解：**同协议 3 种子下 avg 与 max 的差值只有 $+1.17$，落在 1∼2 个百分点区间，差值的标准误 1.03（$z \approx 1.1$）。本文只能给出方向（保护主要来自降维），无法裁决“降维: 非均值聚合”的比例。这条路的根本瓶颈是 avg 与 max 本身的差距太小。**②非负性：**把 ReLU 换成 GELU 后，池化保护之差为 -2.91 个百分点，落在预登记 ± 4 的不可分辨带内，**且方向随种子翻转**（单 seed $+2.57$、3 seed -2.91），只能记为不可分辨（表 4 末行）。**下一步：**①换效应量更大的对照（池化窗口 2×2 vs 4×4，或池化层的位置分布），或补到 ≥ 8 个种子每组；②本实验的噪声已定位到 2×max 一侧（其种子标准差一个量级大于 5×max），追加预算应集中在那一侧。

(4) 秩-恢复关系仍不足以定形状，且秩损失不是唯一决定因素（见 图 7）。 第 4 个容量档已补齐，但它落在与 SimpleCNN 几乎相同的秩损失上（19.9% 对 20.6%），没有为中间段提供新信息，故**曲线形状仍未判定**；同时它暴露出一条更重要的事实——**秩损失相同的主干，恢复率可以差 4.0 个百分点**，说明存在秩损失之外的变量。**这个变量是什么，本文未识别。下一步：**①再补一个秩损失落在 33∼58% 之间的容量档以定形状；②更值得做的是找出秩损失之外那个变量——下采样位置与特征几何是两个候选。

(5) 跨实现的 5.55 个百分点差异未归因（见 表 5）。 已验证无效的路径是换评估路线；必须动训练循环。**下一步：**逐行对齐两个训练循环做二分。

(6) 读出适配要求读出层可写，且本文未评估其硬件代价。 读出层占全模型参数的 5.04%（SimpleCNN）/ 0.55%（VGG-11），结构条件是“读出层位于数字域或可重写”。但面积、延迟、功耗的真实代价需要 RTL 或流片验证，超出本文范围。若某款 CiM 把读出层也固化在阵列里，本文的方法整体不成立。

(7) CIFAR-10 侧的读出只有单 seed，跨数据集的“恢复率标度律”因此是提示性的。 上文的 CIFAR-10 读出表为**单 seed**（CIFAR-100 侧为 3 seed），而“恢复率在更简单的任务上更高”这条跨数据集对比（85.4 / 88.7 / 48.2% 对 72.2 / 70.2 / 36.9%）正建立在这一对比之上。两个量要说清：恢复率差（11.3∼18.5 个百分点）是本文实测的**读出层过程自由度** $\Delta_{\mathrm{proc}} = 3.45$ pp 的**三到五倍**，所以**主效应远大于“换个方式拟合读出”**；但 CIFAR-10 侧只有一次运行，**因此无法把“数据集差”与“那一次训练的运气”分开。下一步：**把 CIFAR-10 侧的读出补到 3 seed（成本与已有的读出实验同级）。

(8) 读出杠杆只在 $|\alpha| \le 0.3$ 上评估过。 本文全部读出适配产物的 α 网格只有 $\{-0.3, \ldots, +0.3\}$ 七个点（CIFAR-10 与 CIFAR-100 两侧皆然）。而探针显示更远处缺口**反而更大：**$\alpha = +0.4$ 时自带头已降到 12.32、线性探针仍有 43.22 （headroom +30.90）；$\alpha = +0.5$ 时是 6.09 对 36.91（+30.82）。⇒ **读出杠杆在那两处还能兑现多少，本文无法回答**——现有每一条读出结论都只在 $|\alpha| \le 0.3$ 窗口内取得，而这个窗口之外恰好是自带头最需要被救的地方。**下一步：**把读出适配的评估扩到 ± 0.5（成本与已有的 24 ep 读出同级）。

(9) 架构杠杆在不含池化的主干上没有旋钮。 “池化密度是独立架构杠杆”这一结论在本文三个主干上成立，但**三者都含池化层**；本文所用的 ResNet-18 已按 CIFAR 适配**去掉了 ImageNet 版的初始 MaxPool**，其 MaxPool 数为 0 （见表 1）。⇒ 对**本身不含池化**的架构（含注意力主干），这条杠杆**无对应旋钮**，而“架构端先上”正是本文落地顺序的第一步。**下一步：**测一种不依赖 MaxPool 的降维方式（把残差主干的 stride 下采样改为池化、或把平均池换成最大池——两者都是不增加可训练参数的网络定义改动）。

(10) 全部证据来自 CIFAR 上的小型卷积主干。 五个主干的参数量跨度 0.25M∼11.2M（以 CIFAR-100 计），架构形态全部是 **卷积 + BatchNorm + ReLU + 池化**的堆叠——**无注意力主干，也没有以归一化层为主体的设计**；但须说明，**五个主干全部含 BatchNorm**，本文未考察归一化方式（BatchNorm / LayerNorm / 无）对上述结论的影响，数据集只有 CIFAR-10/100。⇒ 本文建议的**测量顺序**（先测 headroom、再测秩损失、再看架构端）是否对**注意力架构与更大规模**成立，本文未验证；异构架构的读出层形态（是否线性、是否共享权重）也可能改变 headroom 的可测性。**下一步：**在一个有清晰“末端特征”的注意力主干上重做第一步。

(11) 缺一条与部署同构的读出臂：“不知道 α”到底值多少。 本文的探针读数是 **oracle-α** 的（假定失真强度已知），而与部署同构的读出（在 $\alpha \sim U[\pm 0.3]$ 上训练、α 未知）与之相差 5.04 个百分点（48.35 对 43.31，见第 3 节开放问题第 3 条）。⇒ **这 5.04 里有多少是“不知道 α”的代价、多少是协议差（含读出训练不足）**，需要一条**与探针同协议**（同特征提取、同划分、同拟合过程）但**用 α 混合数据训练**的第三臂才能分开——现有的读出适配臂虽同为 α 混合数据训练，但它与探针在拟合过程（24 ep Adam 对一次拟合）、训练样本量（20k 对 8k）与评估路径上都不同

构，两者之差因此混入了协议差；**本文缺这一臂**，开放问题第 3 条只能停在“缺口有多大”。**下一步**：补该臂（与探针同协议，只换训练分布）。

(12) 低位量化与读出适配从未组合测量。 本文关于“低位量化在池化密集架构上反转为增益”的证据，取自**未施加读出适配**的原始分类头，且固定在 $\alpha = +0.3$。两条杠杆（量化位宽、读出适配）**从未在同一份产物上同时改变**。⇒ **二者的收益是可加的、还是互相挤占同一个机制（对失真的补偿）**，本文无法判定；本文给出的是“分层答案”（哪种架构该用哪一类手段），它对需要**同时**使用两种手段的读者不成立。**下一步**：在池化密集主干上做 2×2（读出适配 $\times$ 4 bit / 8 bit）。

6 结论

在逐层三次多项式非线性失真下，在本文主要分析的 SimpleCNN 与 VGG-11 上，最严重的正向失真（$\alpha = +0.3$）损坏的主要是读出的可解码性，而不是类中心结构：48.35% 是 oracle-α 诊断上界（假定失真强度已知），可部署读数是 43.31%；ResNet-18 的负侧更严重。这一诊断直接给出了修复路径：冻结全部主干权重、只重训最后一层线性分类器，在三个主干上把 $\alpha = +0.3$ 提升 15.2∼31.8 个百分点；训练需要约 2 万条带标签的失真特征，训练时间为主干重训的 1/5∼1/16；读出适配的准确率一致超过本文测过的所有全网络鲁棒训练配方；而训练端的五条补救路径没有一条改善最严重失真——前四条无效，第五条（解冻主干微调）反而主动放大损伤，机制是微调扭曲了预训练特征。架构端的池化密度提供一个不增加可训练参数与额外训练成本的第二杠杆（同设置同种子配对 +15.52 个百分点；单 seed，3 seed 复核同向 +12.20，基线协议不同），其保护主要来自降维。两个杠杆在最严重失真上可以同时受益，但不独立相加。失真强度可由岭回归在线恢复，使门控可以逼近 oracle，但门控有效需两个前提同时成立，其边界由本文给出。最后，本文报告一条方法学观察：同一份权重在两条评估路径下读数逐位相同，而不同训练脚本产出的权重稳定相差 5.55 个百分点且原因未明——**在归因之前，精度数字不应跨训练实现引用（本文不引用）**。

A 关键数值汇总

表 6: 本文引用的主要数值与出处

数值	取值	出处
探针 headroom @+0.3（非线性 / 高斯）	+20.26 / +7.50	`v7_probe_audit/ra_onprotocol_main.csv`（全量 10k 口径；旧 8k 为 +20.12/+7.00）
读出适配 @+0.3（三主干，3 seed）	43.31 / 47.79 / 26.82	`v3_readout_repair/*ep24*.csv`
全网络鲁棒训练 @+0.3（最好）	29.89 / 24.69 / 6.22	`task3_simplecnn/Exp3_FullRobust/`; `extension6_deep_robust/*_exp3/`
池化密度 2 → 5 @+0.3（同协议配对）	26.03 → 41.55（+15.52）	`v3_methods/*_uniform/`
池化密度 2 → 5 @+0.3（干净臂，3 seed）	40.29 ± 1.58	`simple_cnn_mp_clean_uniform{,_s43,_s44}/`
有效秩损失 @+0.3（四主干）	19.9% / 20.6% / 33.3% / 58.7%	`v5_rank_collapse/rank_stats*.csv`
秩损失 → 恢复率（四点，r）	−0.934	同上一行 + `v3_readout_repair/`
池化保护 P：ReLU / GELU（3 seed）	+11.81 / +14.71（差 −2.91，不可分辨）	`v3_methods/*m14b*/alpha_sensitivity.csv`
LP-FT 相对纯读出 @+0.3（三主干）	−11.85 / −33.83 / −12.88	`v7_m8c_lpft/*.csv`
池化同协议 3 seed 差（avg−max）	+1.17（SE 1.03；未舍入 = 1.1733——三个逐 seed 的 `drop` 各取均值后再相减）	台账 §13.8
过程自由度 Δ_{proc}（$\alpha = 0$ / +0.3）	3.46 / 3.45	`v7_etf_readout/proc_sensitivity.csv`
门控红利（C100/mp）	−5.89 → +2.90	`recipe_simple_cnn_mp.csv`
门控红利（ResNet-18/Exp3）	−4.36 → −1.14	`recipe_robust_resnet18_exp3resnet18.csv`
α 估计器（6 组：4 浅 2 深）	R^2 0.827∼0.978	`v5_full_recipe/recipe*.csv`
Dithering 增益（C100 / C10）	+2.84 / +6.53	`extension5_dithering_vgg11/`
跨实现最严重失真差	5.55（$z = 9.4$；$26.58 - 21.03$，3 对 6 个 run）	台账 §14.6
同协议方差 / 混协议方差	±0.392 / ±2.561	台账 §13.10

B 低位量化机理的跨数据集平行对照

正文第 3 节 H1–H3 的机理量取自 CIFAR-10 侧；下表把 CIFAR-100 侧的对应量平行列出。两侧由同一脚本、同一协议产出（固定 $\alpha = +0.3$），唯一差别是数据集与主干权重。（α 固定为 $+0.3$，故表中“clean”指 $\alpha = 0$ 的未量化基线。）

表 7: 低位量化机理的量：CIFAR-10 与 CIFAR-100 的平行对照

量	条件	CIFAR-10	CIFAR-100
(a) 精度（VGG-11，固定 $\alpha = +0.3$，%）			
8 bit（基线）	—	36.74	16.91
4 bit	—	43.27	19.75
3 bit	—	42.97	10.87
4 bit − 8 bit	—	+6.53	+2.84
(b) 分类器输入峰度（H2）			
	clean	1.486	2.541
	8 bit	0.110	0.847
	4 bit	0.214	0.980
	3 bit	0.384	1.023
	2 bit	0.069	0.088
(c) 样本级翻转（H1，VGG-11，4 bit 相对 8 bit）			
4 bit 救回 / 杀死	计数（比值）	860 / 207（4.15:1）	655 / 371（1.77:1）
4 bit 净增	计数	+653	+284
8 bit + 最优剂量噪声	高斯 / 均匀（净增）	+7 / −19	−20 / −9
剂量匹配的纯噪声	高斯 / 均匀	−2.45 / −1.87	−3.12 / −2.48
(d) 架构对照（H3）：4 bit − 8 bit			
ResNet-18（0 MaxPool）	—	+0.39	−0.21
SimpleCNN（2 MaxPool）	—	−13.68	−14.71

出处:`outputs/extension5_dithering_vgg11/` 与 `outputs_cifar100/extension5_dithering_vgg11/` 下的 `group_a_bits_scan.csv`（(a)(d) 的精度）、`activation_stats.csv`（(b) 的峰度）、`flip_statistics.csv`（(c)）与 `group_c_pure_noise.csv`（(c) 末行的剂量匹配噪声）。两点读数：**机理的定性结论在两个数据集上一致**（H1 否决、H2 确认、H3 支持）；而**幅度不可跨数据集搬运**——同一条“3 bit 比 4 bit 更尖”，在 CIFAR-10 上只是 0.30 个点的代价，在 CIFAR-100 上却是 8.88 个点。

参考文献

[1] Yu S, Chen P Y. Emerging memory technologies: recent trends and prospects[J]. IEEE Solid-State Circuits Magazine, 2016, 8(2): 43–56.

[2] Ankit A, El Hajj I, Chalamalasetti S R, et al. PUMA: a programmable ultra-efficient memristor-based accelerator for machine learning inference[C]//ASPLOS. Providence: ACM, 2019: 715–731.

[3] Bhattacharjee A, Bhatnagar L, Kim Y, et al. NEAT: nonlinearity aware training for accurate, energy-efficient, and robust implementation of neural networks on 1T-1R crossbars[J]. IEEE TCAD, 2022, 41(8): 2625–2637.

[4] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//CVPR. Salt Lake City: IEEE, 2018: 2704–2713.

[5] Wannamaker R A, Lipshitz S P, Vanderkooy J, et al. A theory of nonsubtractive dither[J]. IEEE Transactions on Signal Processing, 2000, 48(2): 499–516.

[6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. Las Vegas: IEEE, 2016: 770–778.

[7] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//ICLR. San Diego: ICLR, 2015: 1–14.

[8] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.

[9] Kumar A, Raghunathan A, Jones R, et al. Fine-tuning can distort pretrained features and underperform out-of-distribution[C]//International Conference on Learning Representations. 2022. arXiv:2202.10054.

[10] Xiao Z, Naik V B, Lim J H, et al. Adapting magnetoresistive memory devices for accurate and on-chip-training-free in-memory computing[J]. Science Advances, 2024, 10(38): eadp3710.

[11] Rabby G, Auer S. When Graph-JEPA learns the wrong thing: diagnosing and repairing category-conditional collapse[R]. 2026. arXiv:2608.20516.

[12] Reblitz-Richardson O. When probing accuracy saturates, fragility resolves: a complementary metric for LLM pre-training analysis[R]. 2026. arXiv:2606.11375.

[13] Wang D, Shelhamer E, Liu S, et al. Tent: fully test-time adaptation by entropy minimization[C]//International Conference on Learning Representations. 2021. arXiv:2006.10726.

[14] Liang J, Hu D, Feng J. Do we really need to access the source data? Source hypothesis transfer for unsupervised domain adaptation[C]//International Conference on Machine Learning. 2020: 6028–6039. arXiv:2002.08546.

[15] Yao P, Wu H, Gao B, et al. Fully hardware-implemented memristor convolutional neural network[J]. Nature, 2020, 577(7792): 641–646. DOI: 10.1038/s41586-020-1942-4.

[16] Rasch M J, Mackin C, Le Gallo M, et al. Hardware-aware training for large-scale and diverse deep learning inference workloads using in-memory computing-based accelerators[J]. Nature Communications, 2023, 14: 5282. DOI: 10.1038/s41467-023-40770-4.

[17] Li C, Ferro E, Lammie C, et al. Efficient transformer adaptation for analog in-memory computing via low-rank adapters[J]. Neuromorphic Computing and Engineering, 2026, 6(1): 014011. DOI: 10.1088/2634-4386/ae405e. arXiv:2411.17367.

[18] Dong W, Zhou K, Kong Z, et al. Efficient calibration for RRAM-based in-memory computing using DoRA[R]. 2025. arXiv:2504.03763.

[19] Kong Z, Dong W, He J, et al. Mitigating conductance drift via in-situ calibration for reliable RRAM-based CIM edge inference[C]//IEEE International Symposium on Circuits and Systems (ISCAS). 2026: 4212–4216. DOI: 10.1109/ISCAS66217.2026.11562039.

[20] Bhattacharjee A, Moitra A, Kim Y, et al. Examining the role and limits of batchnorm optimization to mitigate diverse hardware-noise in in-memory computing[C]//ACM Great Lakes Symposium on VLSI (GLSVLSI). 2023: 619–624. DOI: 10.1145/3583781.3590241.

[21] Klein B, Kuhn L, Weis J, et al. Towards addressing noise and static variations of analog computations using efficient retraining[C]//ECML PKDD 2021 Workshops. CCIS 1524/1525. 2021: 409–420. DOI: 10.1007/978-3-030-93736-2_32.

[22] Bommana A R, Feinberg B, Xiao P, et al. Noise-agnostic one-shot training and retraining for robust DNN inferencing on analog compute-in-memory systems[C]//Asia and South Pacific Design Automation Conference (ASP-DAC). 2026: 1463–1469. DOI: 10.1109/ASP-DAC66049.2026.11420230.

[23] Dong W, Zhou K, Kong Z, et al. VeRA+: vector-based lightweight digital compensation for drift-resilient RRAM in-memory computing[C]//Design Automation Conference (DAC). 2026. arXiv:2603.26016.