

逐层非线性失真下神经网络精度退化的成因

读出瓶颈与双杠杆修复

黄奕皓

中国科学院大学计算机科学与技术，北京

huangyihao24@mailsucas.ac.cn

摘要

存算一体芯片的模拟域乘累加存在输入相关的非线性失真，通常建模为逐样本归一化后的三次多项式 $y = \alpha \hat{x}^3 + (1 - \alpha)\hat{x}$ 。本文在 CIFAR-10 与 CIFAR-100 上，用四个主干（参数量 0.25M~11.2M，以 CIFAR-100 计；CIFAR-10 侧略小，见表 1）系统考察了这种失真的破坏形态、可达边界与修复路径。主要结论有四条。全部结果来自该参数化失真模型的仿真，没有硬件实测。第一，灾难尾的瓶颈不在表征而在读出。在冻结主干的末端特征上重训线性探针， $\alpha = +0.3$ 时可达 48.35%，而模型自带分类头只有 28.09%，headroom 为 20.26 个百分点；同一套探针在加性高斯噪声这条对照通路上只有 7.50 个百分点。需先说明口径：探针逐 α 训练，因此 headroom 是 oracle- α 诊断量——它给出的是“若失真强度已知、且读出可自由重训”时的线性可解码性，不是可部署读数。真正与 α 无关的部署路径见第二条——它在同一 α 点上拿到 43.31；而只把同一个头在干净分布上重训，增益为零。这条读数经四路主动加固（随机标签、激活噪声下的临界崩塌点、划分与重采样、以及与主干训练集完全不相交的划分）——四路都未能否定它，但其中只有对照二给出独立的第二条读数——在最严口径下仍存活（+16.23，为规范口径的八成）；它是下界——把探针样本加到 50000 后升至 +27.63（按不相交校正约 +25.4），且仍未饱和。用三种非线性读出（k-NN 与两种 MLP）替换线性头，没有一个能超过它——容量不是这里的瓶颈。第二，因此最省力的修复动作在读出侧。冻结全部主干权重、只重训最后一个线性层（训练成本 12~30 分钟，为主干重训的 1/5~1/16），尾部精度从 28.09/15.98/6.22 提升到 43.31/47.79/26.82（三个主干，各 3 个种子），一致超过所有全网络鲁棒训练配方；而训练端四条补救路径（采样预算分配、 α 空间对抗训练、课程式采样、训练范围外推至 ± 0.5 ）没有一条改善尾部（后两条显著劣于基准，另两条落在门槛内或与基准同级）。第三，架构端存在一个零训练成本的第二杠杆。把主干的最大池化层从 2 个增加到 5 个（参数量不变、训练成本为零），在同协议同 seed 配对下 $\alpha = +0.3$ 从 26.03 提升到 41.55（+15.52；单 seed，见第 3 节的口径说明）；机制上，这一保护主要来自降维而非池化算子本身——三条独立的排除线（可交换性、不变区集中、max 的选择性）逐一否定了候选解释。两个杠杆在尾部可以同时受益，但不独立相加（合起来拿到单独增益之和的六到七成）。此外，失真强度可由读出特征的岭回归在线恢复（ R^2 0.83~0.98：浅层四个组合 0.827~0.935、深层两个组合 0.95~0.98），使双头门控可以逼近 oracle；但门控有效需要两个前提同时成立，其边界由本文给出。第四，为一种失真做的鲁棒性训练不会顺带保护另一种。非线性与加性高斯之间的迁移近正交（但在 MaxPool 密集的 VGG-11 上被打破），然而训练端存在单向强干扰—— σ 训练使 α 侧掉 6.08 个百分点，联合训练使它掉 12.82；双扰动并存时的最优配方是 σ -only，不是联合训练。

最后，本文报告一条方法学观察：本文观测到一个同超参、同种子、跨实现稳定的 5.55 个百分点尾部差异，经三次干预仍未归因——同一模型在两条评估路径下逐位相同，而两个训练脚本产出的权重稳定相差 5.55 个百分点，按已知未知记录。在归因之前，本文的做法是不跨实现（含与文献）引用精度数字。本文进一步把这个已知未知旁边的两级散布测准，给出一个三级可分辨性尺度（种子噪声 / 过程自由度 / 跨实现），并表明过程自由度的主要来源是“训多久”而非“用哪个优化器”。

关键词：存算一体；非线性失真；读出瓶颈；有效秩；鲁棒性杠杆；测量纪律

1 引言

1.1 问题

在存算一体（Compute-in-Memory, CiM）架构中，乘累加运算在模拟域完成，权重固化在存储阵列里 [1, 2]。这消除了数据搬运开销，但也把模拟器件的非理想特性直接引入了计算通路：器件失配、跨导放大器增益非线性、工艺偏差与温度漂移，共同使输入-输出关系偏离理想的线性映射。这一类误差有一个区别于常见扰动源的关键性质——它是**确定性的、且与输入幅度相关的**，而不是像高斯噪声或随机 Dropout 那样零均值且与信号无关。

本文采用赛题给定的参数化模型：

$$y = \alpha \hat{x}^3 + (1 - \alpha) \hat{x}, \quad \hat{x} = \frac{x}{\|x\|_\infty}, \quad (1)$$

其中 $\hat{x}$ 按 batch 维**逐样本**做无穷范数归一化（避免样本间串扰），失真通过前向钩子挂在每一个 Conv2d 与 Linear 算子的**输入侧**，逐层注入。 α 刻画非线性强度， $\alpha = 0$ 退化为恒等映射； $|\alpha|$ 越大失真越强， α 的符号决定失真的方向。

从工程角度看，这个问题的约束条件是硬的：**阵列里的权重不可重训**。这既是 CiM 省功耗的前提，也意味着所有“重新训练网络以适应失真”的方案在部署阶段都不成立。本文的出发点正是：在这个约束下，鲁棒性的杠杆究竟在哪里。

1.2 本文的发现与贡献

本文报告四条相互衔接的结论，以及一条方法学结论。

- 定位：**灾难尾（ $\alpha = +0.3$ ）损失的是读出的**可解码性**，而不是表征中的信息。直接用探针测量 headroom： $\alpha = +0.3$ 时为 20.26 个百分点，且随失真增强放大后**趋平**（ $+0.3$ 时 20.26、 $+0.4$ 时 30.90、 $+0.5$ 时 30.82——最后两个点几乎持平，“信息差被拉大”这一解读自 $+0.4$ 起饱和）。**这条读数经过四路主动加固**——随机标签、激活噪声下的临界崩塌点、划分与重采样、以及与主干训练集完全不相交的划分（见第 3.2 节）；**四路都未能否认它**，在最严口径下结论仍存活，幅度为规范口径的八成（ $+16.23$ ）。
- 修复：**据此得到的读出适配方法（冻结主干、只重训线性读出——即迁移学习中的 linear probing 一族）在三个主干上把尾部提升 $+15.2 \sim +31.8$ 个百分点（CIFAR-100, 24 ep/20k, 各 3 seed），成本低约一个数量级。**该做法本身不是本文的贡献：**当预训练特征好、偏移大时线性探针可胜过全量微调，这是已有理论与十数据集实证的结论（见第 1.3 节）；在存内计算领域，“冻结阵列、只在数字域补偿”也有先例，但那是标量或查找表级的校正。**本文的贡献是给出读出适配在本场景下的上界、机制与边界**，并指出在主干物理不可重训的约束下，它是**投片后唯一可行的一类修复**（架构端那个零成本杠杆只能在投片前决定，见第三条）。与之对照，训练端的四条独立路径没有一条改善尾部（后两条显著劣于基准，另两条分别落在门槛内与基准同级），其中“把训练范围扩到 ± 0.5 ”这条最能说明问题的性质：模型在 $\alpha = +0.5$ 上仍只有 2.71%，而同期负侧有 31.19%。
- 第二个杠杆：**架构端的池化密度是一个**零训练成本**的独立杠杆；其保护主要来自降维。两个杠杆在尾部可以同时受益，但**不独立相加**。本文据此给出一条**三步落地顺序**（第 4.3 节），并指出全部结论只依赖一个结构前提——读出层位于数字域或可重写。

4. **失真通路的边界**：为一种失真做的鲁棒性训练不会顺带保护另一种。非线性与加性高斯之间的迁移近正交（但在 MaxPool 密集的 VGG-11 上被打破），然而训练端存在单向强干扰—— σ 训练使 α 侧掉 6.08 个百分点，联合训练使它掉 12.82；双扰动并存时的最优配方是 σ -only，不是联合训练。
5. **方法学**：本文所有涉及深层主干或跨实现的比较都附带了方差标定与交叉评估，由此得到一条对同领域有直接约束力的观察——同一份权重在不同评估路径下读数逐位相同，而不同训练脚本产出的权重稳定相差 5.55 个百分点，且该差异经三次干预实验仍未归因。在归因完成前，跨实现（含与文献）引用精度数字是不可靠的，本文的做法是不引用。本文进一步把这个“已知未知”旁边的两级散布测准，给出一个三级可分辨性尺度（种子噪声 / 过程自由度 / 跨实现），并表明：在本文测过的这一个特征集上，过程自由度的主要来源是“训多久”而非“用哪个优化器”（第 3.13 节）。

第 2 节给出方法与协议；第 3 节按科学问题组织结果；第 4 节综合讨论；第 5 节给出局限与未来工作。

1.3 相关工作

非线性感知训练（NAT）把失真注入训练过程，让网络在失真分布内学习，是在此之前的范式 [3]。本文的结果表明该类方法的收益严格限定在训练分布之内，且不触及本文关心的正侧尾部（图 5）。

量化是 CiM 的另一条主要误差通路 [4]。本文考察了失真与量化联合作用的场景，并复现了一个反直觉现象：在池化密集的架构上，低位量化反而提升失真下的精度，其机理与随机抖动无关（图 10）。这与经典的非减性抖动理论 [5] 有本质区别。

架构层面，残差连接 [6] 与纯 3×3 卷积堆叠的深层前馈结构 [7] 在本文的扰动下表现出显著不同的脆弱性；数据集为 CIFAR [8]。

本文的方法属于哪一支：**测试时适配与无源域适应**。”冻结主干、只更新极少量参数”在分布偏移下已被证明是有效范式：Tent 在测试时只最小化预测熵、在线重估归一化统计量并只更新其仿射参数，主干与分类器都不动 [13]；SHOT 处理不访问源数据的域适应，它冻结源模型的分层器、只学目标域的特征提取器 [14]。本文与这一支共享”只动极少量参数、也不需要源数据”的取向，但动的对象正好相反——本文冻结的是特征（主干物理上不可重训），更新的是分类头。三条差异：**偏移的性质不同**——TTA / DA 处理的是数据分布偏移（协变量或域偏移），而本文的失真**是确定性的、逐层累积的、输入相关的系统误差**，由模拟域算子的非线性引起，不随测试样本分布变化，因此换一批测试数据或匹配分布都不能消除它；**可动参数的性质不同**——TTA 的”只动少数参数”是一种设计选择（主干在原理上仍可训练），而在 CiM 场景下主干**因硬件原因物理上不可重训**，冻结不是选择而是约束；**给出的量不同**——上述工作报告的是准确率，本文给出的是该约束下的可恢复量上界（探针 headroom）、损伤的几何形态（有效秩塌陷）与代价的定量权衡（两个杠杆可同时受益但次可加、门控的两个前提）。

与本文方法最接近的一条已有结论。「冻结主干、只重训最后的线性层」（linear probing）与全量微调的对比，在迁移学习里是一条有理论与大规模实证支撑的已知结论：当预训练特征足够好、且分布偏移足够大时，线性探针的分布外精度反而高于全量微调（在 10 个偏移数据集上平均，全量微调相对线性探针 ID 高 2%、OOD 低 7%），原因是微调在学头的同时**扭曲了底层特征（feature distortion）** [9]。本文的读出适配属于同一族做法。本文的贡献不在此规律本身，而在于：**把它搬到一个新场景——失真是确定性的、逐层累积的输入侧系统误差，而非统计意义上的分布偏移**；在该场景下主干**物理上不可重训**，故读出适配不是”更优选择”，而是在权重层

面唯一的选择：给出该场景特有的上界（探针 headroom 与可恢复量）、机制（有效秩塌陷）与边界（门控的两前提）。

与 CIM 数字域补偿的关系。在存内计算领域，「冻结阵列、只在数字域补偿」已有先例，但形态是标量或查找表级的校正：例如用器件特定的电导漂移查找表配合自适应量化，在不做片上训练的前提下达到软件基线精度 [10]。本文动的对象不同——不是调一个缩放因子，而是重训整个线性读出层。代价相应更大：它要求读出层位于数字域或可重写（见第 5 节）。换言之，已有工作回答的是“能不能用数字域的便宜手段把阵列误差压下去”，本文回答的是“误差到底损伤了哪一层、损伤了多少、以及修复的边界在哪”。

关于本文最依赖的测量手段。本文的中心结论建立在线性探针的读数上。这一手段近年正受到系统质疑：探针精度饱和并不意味着信息在场，探针失灵也不意味着信息不在场——已有工作报告过探针精度 0.871、有效秩指标全部健康的表征，在检索任务上却只恢复了 14.4 bit 中的 0.00 bit，作者因此警告「秩、探针与其他指标都可能在无支撑的评测上虚假饱和」[11]。本文对此的处理是主动加固：为探针读数配第二读法（激活噪声下的临界崩塌点）与多组对照，详见第 3.2 节与第七阶段的审计记录。

2 方法

2.1 度量口径

全阶段统一使用四个标量指标，定义如下：

指标	定义
clean	$\alpha = 0$ 时的测试精度
drop@0.3	clean 减去 $\alpha = +0.3$ 时的精度
mid_band	$\alpha \in \{-0.2, -0.1, +0.1, +0.2\}$ 四点的平均精度
mean7	$\{-0.3, -0.2, -0.1, 0, +0.1, +0.2, +0.3\}$ 七点的平均精度

评估协议固定为：全量测试集（10 000 张）、best 权重、纯推理。每个实验的强度扫描文件里 $\alpha = 0$ 的行必须等于同目录 metrics.json 的 best_test_acc（容限 0.01）。这个自检结果记在全局台账的 pairing_check 列中。台账 152 行里 58 行通过该自检，无一行 FAIL；其余 94 行（读出适配 74 行、复权重重的扫描 20 行）该自检不适用。

种子纪律：凡涉及尾部指标的比较均使用 ≥ 3 个种子；单种子的尾部差值小于 3 个百分点不作为结论（理由见第 3.13 节）。

2.2 数据集、主干与协议

数据集为 CIFAR-10（10 类）与 CIFAR-100（100 类）。四个主干及其参数量见表 1。所有主干均在干净条件下训练 100~200 个 epoch，优化器为 SGD（动量 0.9、权重衰减 10^{-4} ），余弦退火调度。

失真注入：逐层、逐样本，同一个 α 施加到所有层（除非特别说明）。训练时的 α 采样区间为 $U[-0.3, +0.3]$ ，采样粒度在正文中注明。

2.3 读出适配方法

本文的主要方法（下称 readout-NAT）极为简单：主干全部冻结——把主干参数的梯度开关全部关闭、一个参数都不更新——只重训最后那个 nn.Linear 分类头，训练数据为在 $\alpha \sim U[\pm 0.3]$

表 1: 主干与参数量（按类别数分列）。

主干	参数量（CIFAR-10 / CIFAR-100）	卷积层数	MaxPool 数
SimpleCNN	242 474 / 254 084	4	2
SimpleCNN+3×MaxPool（后文简称 mp 主干）	242 474 / 254 084	4	5
VGG-11	9 231 114 / 9 277 284	8	5
ResNet-18	11 173 962 / 11 220 132	17	0

上采样的失真样本，评估仍在干净与各 α 点上进行。默认配置为 24 个 epoch、20 000 个特征样本。对 SimpleCNN 而言读出层占全模型参数的 5.04%，对 VGG-11 为 0.55%。

”信息仍线性可达”这一结论不只有探针读数背书。冻结主干、只重训一个线性头，在 $\alpha = +0.3$ 上实际达到 **43.31**（SimpleCNN，3 seed，24 ep 协议；原始自带头 28.09）——这是一个真实可部署的分类器，而不只是用于测量的探针。同口径的 **oracle- α** 探针读数为 48.35，即部署物取到了该上界的 **89.6%**（43.31/48.35）。（口径提醒：探针是 oracle- α 诊断量——它假定失真强度已知；因此 89.6% 是”部署物对 oracle 上界”的比值，不是部署时能达到的绝对水平。）

2.4 其他探针

信息探针：在冻结主干的末端特征上重训一个线性分类器，与模型自带头比较，差值记为 headroom（”模型自带头”后文亦称**原始头** / **冻结头** / **自带头**，均指同一个头；它在第 3.10 节门控里叫**干净头**——就是产物列名 `acc_clean_head` 的那一个，即模型自带、冻结不动的那一层，与”在干净分布上重训出来的头”（下文读出适配一节的 b 臂）不是同一个东西）。该探针逐 α 训练——每一个被评估的失真强度上，探针都训在该强度自己的特征上（ $n = 8000$ ，另有 $n = 50000$ 档），因此 headroom 是一个 **oracle- α 诊断量**：它回答的是”若失真强度已知、且读出可自由重训，线性解码还能取回多少”，不是可部署读数。（作为对照，只喂干净特征、与 α 无关的另一列探针在 $\alpha = +0.3$ 上只有 18.1%，反而低于模型自带头；这一列记录在同一个产物文件里，本文不用它作 headroom。）**秩探针**：对末端特征做 SVD，有效秩定义为 $\exp(-\sum_i p_i \ln p_i)$ ，其中 p_i 为归一化奇异值；同时记录 99% 能量条件数 κ_{99} 与 Fisher 判别比。**交叉评估**：把 A 脚本训出的权重在 B 脚本的评估函数下扫描，反之亦然，两条路径均从各自脚本原样导入，不复制、不改写。

3 结果

3.1 正向失真更致命，且这个方向性跨架构稳定——但倍数不是常数

图 1 给出三个主干在 CIFAR-100 上的七点扫描。 $\alpha > 0$ （正侧）的破坏力大于 $\alpha < 0$ （负侧），但不对称的倍率随主干递减（ $|\alpha| = 0.3$ 处 1.87 / 1.18 / 1.01，见图注），而跌幅本身随容量与深度单调放大： $\alpha = +0.3$ 时 SimpleCNN 从 59.99 掉到 28.09，VGG-11 从 67.09 掉到 16.92，ResNet-18 从 72.09 掉到 2.70。按容量排序，`clean` 越高、`drop@0.3` 越大，这条反相关关系在同数据集内跨容量单调。

把”最脆弱的位置”进一步区分为**注入位置**与**观测位置**后，一个反直觉的结果出现：在单层注入的探针中，最敏感的是中间层的卷积（conv2 跌幅 -12.43、conv3 -7.56），而一直被当作瓶颈的 fc 层单点注入只有 -0.68。全 5 层同时注入时跌幅 31.90，而按单层跌幅线性累加只有 23.33，超加性达 -8.57。也就是说，损伤在层间**超加性累积**，而 fc 是误差的汇聚与观测点，不是注入敏感点。

需要强调的是， $\alpha > 0$ 与 $\alpha < 0$ 的破坏力之比**不是常数**：在 CIFAR-10/SimpleCNN/ $|\alpha| = 0.3$




图 1: 失真的方向性与容量依赖。三个主干在 CIFAR-100 上的七点扫描；全量测试集、best 权重、纯推理。正侧 ($\alpha > 0$) 的跌落大于负侧，但不对称倍率随容量递减： $|\alpha| = 0.3$ 处”正侧跌幅 ÷ 负侧跌幅”在 SimpleCNN / VGG-11 / ResNet-18 上依次为 1.87 / 1.18 / 1.01——方向性在浅层显著，在最深的主干上几乎消失。数据：outputs_cifar100/task1_*/alpha_sensitivity.csv。

这一个点上是 3.4，而 CIFAR-100 的同一模型上只有 1.87。跨条件引用这个倍数会出错；跨阶段稳定成立的只有方向。

3.2 灾难尾丢的不是信息，而是读出的可解码性

这是全文的枢纽。若正侧尾部是表征被摧毁，那么任何修复都必须改动主干；若信息仍在、只是读不出来，则杠杆在读出侧。图 2 用探针把两者分开：在冻结主干的末端特征上重训线性分类器，与模型自带分类头在同一 α 条件下比较。注意探针是逐 α 训练的（见第 2 节）：headroom 因此是 **oracle- α 诊断量**，它标定”线性解码还剩多少余量”，而不是”部署时能直接拿到多少”。这一点由三个对照夹住：与 α 无关的干净探针在 $\alpha = +0.3$ 上只有 18.1%，反而低于模型自带头；真正可部署的那条路径——在 $\alpha \sim U[\pm 0.3]$ 上重训同一个线性头——在三个主干上拿到 43.31 / 47.79 / 26.82（3 seed，见图 3）；而只把同一个头在干净分布上重训，增益是零（+0.26 / -0.17 / -0.84，见下文的第二项自我校验）。起作用既不是”换了一个更强的读出”（ α 无关的探针更差），也不是”换了一个头”（干净分布重训零增益），而是头是在哪条分布上训练的。

$\alpha = +0.3$ 时探针达 48.35%，自带头只有 28.09%，headroom 为 **20.26** 个百分点¹； $\alpha = +0.4$ 时 30.90、 $\alpha = +0.5$ 时 30.82。失真越强，headroom 越大——这与”信息差被拉大”一致，而与”信息被摧毁”不一致。要说准一点：放大只到 $\alpha = +0.4$ 为止（+0.3 为 20.26、+0.4 为 30.90）， $\alpha = +0.5$ 时微降到 30.82——即信息差在 +0.4 之后不再被拉大。

对照通路给出了这条测量的分辨力：同样的探针在加性高斯噪声 $\sigma = 0.3$ 下 headroom 只有 7.50 个百分点。随机扰动与确定性系统误差在”信息还剩多少”这个量上清楚地分开，说明”先测 headroom”这个动作本身有判别价值。

¹两项均取自全量测试集（10000 张），并与项目的规范口径逐位一致：冻结头在 $\alpha = +0.3$ 的 28.09 等于 task1 扫描的同名行，清洁模型在 $\alpha = 0$ 的 59.99 等于 metrics.json 的 best_test_acc。（早期版本的探针表曾用 8000 样本子集，给出 27.76 / 59.60 与 headroom +20.12；第七阶段 M0c 已在同一设备上重跑全量口径并替换，全案见 docs/IMPL_AUDIT.md。）




图 2：灾难尾的标签信息仍然线性可达。在同一冻结主干的末端特征上，线性探针（实心）与模型自带分类头（空心）的精度对比；7 个 α 点，CIFAR-100 全量测试集（10000 张）、best 权重、单种子。 $\alpha = +0.3$ 时两者相差 20.26 个百分点；该差距随失真增强先放大、后趋平（+0.4 为 30.90、+0.5 为 30.82）。作为对照，同一套探针在加性高斯噪声（ $\sigma = 0.3$ ）上只有 7.50 个百分点。数据：outputs_cifar100/v7_probe_audit/ra_onprotocol_main.csv。

3.3 这条探针读数可信吗：一次主动加固

上面那个 headroom 是单点探针读数，而线性探针近年正受到系统质疑：探针精度饱和并不意味着信息在场，探针失灵也不意味着信息不在场；已有工作报告过探针精度 0.871、有效秩指标全部健康的表征，在检索任务上却只恢复了 14.4 bit 中的 0.00 bit（见第 1.3 节）。本文因此做了一组主动加固，四路对照如下。

对照一：随机标签。 把探针的训练标签打乱后重训。9 个条件全部落在 [0.85, 1.11]%，而 CIFAR-100 的随机水平是 1.0%，最大偏离 0.15 个百分点。探针管线没有泄漏。

对照二：fragility（激活噪声下的临界崩塌点）。单点精度之外再取一个读数：给评估侧的激活加噪，测“探针精度跌到半程时的噪声水平” σ^* 。该指标及其用法取自已有工作 [12]——它报告的正是“探针精度持平时，fragility 仍能给出结构化回答”，本文借用它作第二条独立读数。（噪声只加在评估侧——训练侧也加噪测的是解码器的抗噪补偿能力，是另一个量。）结果：正侧 σ^* 从 clean 的 0.4188 一路降到 $\alpha = +0.5$ 的 0.1221（-71%；只有 $\alpha = +0.1$ 一点略高于 clean, 0.4273，此后严格单调下降）。但在同一 $|\alpha| = 0.3$ 上，正负两侧几乎一样： σ^* 为 0.3230 与 0.3310，相对 clean 分别是 -22.9% 与 -21.0%（约 1.1 : 1）。（负侧只测到 -0.3——产物里没有 $\alpha = -0.4 / -0.5$ 两档，所以“负侧平缓”是未测，不是测出来。）第二条读数在最关心的那一点上没有复现 headroom 的不对称：同一 $|\alpha| = 0.3$ 处，headroom 是 20.26 对 4.76（4.3 : 1），而 fragility 只有 1.1 : 1。两条读数一致的地方只有“失真使读出更脆”这个方向；“正侧特别脆”这件事对指标敏感——这是本文对这条加固论证的限定，要判定 fragility 在大失真处是否也分正负，须把负侧测到 -0.5。

一个必须避开的陷阱（我们在本项目内实测到了它）。 σ^* 的单位是关键：若用绝对噪声水平，会得出符号相反的结论：

α	激活 RMS	绝对 σ^* vs clean	RMS 归一 σ^* vs clean
clean	2.166	—	—
-0.3	4.055 (1.87 $\times$)	+48% (显得更鲁棒)	-21% (更脆弱)
+0.3	0.914 (0.42 $\times$)	-67% (更脆弱)	-23% (更脆弱)

(表中两列分别取自 v7_probe_audit/c2_fragility.csv 的 critical_noise_abs 与 critical_sigma_rms_noise_vs_clean。"vs clean" 是以该文件的 clean 行为基准；两行都已与上文 σ^* 的正负对照对齐：负侧基准是 clean，不是 $\alpha = -0.1$ 。)

原因： $\alpha < 0$ 把深层激活的幅度抬高到 **1.87 倍**，固定绝对噪声相对就更"小"，于是失真组虚假地显得更鲁棒。归一化到该条件自身的 RMS 之后符号才正确。负侧的结论完全依赖这一步归一化。本文一律使用 RMS 归一化的 σ^* ，并在正侧 $\alpha \in \{+0.1, \dots, +0.5\}$ 这 5 个点上按两两成对计票（共 10 对，其中 9 对的变化方向与 headroom 相反；唯一同向的是 $+0.4 \rightarrow +0.5$ 这一对）。这^只说明两条读数沿 α 轴的变化方向同构，不说明正负不对称一致——后者见上文的限定 ($|\alpha| = 0.3$ 处 fragility 是 1.1 : 1，而 headroom 是 4.3 : 1)。这一陷阱并非本文首见：[12] 自己就把它列为该指标的适用条件（跨层比较须用 RMS 归一化的临界噪声，层内比较才用原始值），本文在本场景下独立复现了它——而且这里的尺度差达 1.87 $\times$ ($\alpha < 0$ 把深层激活抬高到 1.87 倍)，所以这一步在本文里是判决性的，不是可选项。

对照三与四：划分与不相交性。 换 decoder 的随机种子与训练/测试划分（5 个划分 + 3 次 bootstrap）：读数稳定，划分间标准差 0.17 ~ 0.47、bootstrap ≤ 0.38 ，单条件总标准差 0.56 ~ 1.33（总极差 ≤ 3.42 ）。更强的一项是把探针的训练与评估都放在与主干训练集完全不相交的样本上： $\alpha = +0.3$ 的 headroom 为 **+16.23**，即规范口径 +20.26 的 **80%**。

小结。 四路对照都未能否证 headroom；其中只有对照二（fragility）提供了第二条独立读数，而它只与 headroom 在"方向"上一致（见上）。headroom 这个结论在更严的口径下存活，但幅度会缩水到约八成。我们把它作为本文中心结论的下界：即使在"探针从没见过的样本上训练"这一最严设定下， $\alpha = +0.3$ 处仍有一个约 16 个百分点的可解码性缺口。

而且这个缺口不是"线性读出"的假象。上面用的全是线性读出，所以"瓶颈在读出"有一个明显的反驳：也许瓶颈只是在线性。为排除它，在同一批冻结特征上比较六种读出 ($\alpha = +0.3$, CIFAR-100)：

读出	精度	相对线性（同族公平锚）
逻辑回归，强 L2 ($C = 0.01$)	49.23	-2.24
逻辑回归 (sklearn 默认，跨优化器参考臂)	48.25	-3.22
k-NN ($k = 20$)	38.12	-13.35
线性头 (torch, 公平锚)	51.47	—
瓶颈 MLP (128 $\rightarrow$ 32 $\rightarrow$ 100)	43.38	-8.09
两层 MLP (128 $\rightarrow$ 256 $\rightarrow$ 100)	48.62	-2.85

三种非线性读出没有一个超过线性头。按本文立的可分辨门槛 ($\Delta_{\text{proc}} = 3.45$ pp，见第 3.13 节) 分开说：k-NN (-13.35) 与瓶颈 MLP (-8.09) 远超门槛；而两层 MLP 只差 2.85，落在门槛之内，按本文自订规则这一臂不可裁决——只能说方向上仍劣于线性头。参数越多反而越差（瓶颈 MLP 43.38 < 两层 MLP 48.62 < 线性 51.47），是典型的过拟合序 ($n = 8000, 100$ 类)。「信息仍线性可达」这句话，从"只测过线性"升级为「测过 k-NN 与两种 MLP 之后，线性头仍是最优读出」。容

表 2: 读出适配与全网络鲁棒训练的对照 (CIFAR-100, $\alpha = +0.3$, 精度%)

方法	可训练参数	训练成本	SimpleCNN	VGG-11	ResNet-18
原始头 (读出适配所依附的主干)	—	—	28.09	15.98	6.22
本文读出适配 (24ep, 3 seed)	12.8k / 51.2k	12~30 min	43.31±0.16	47.79±3.18	26.82±3.40
全网络鲁棒训练 (最好)	全部	1~6.5 h	29.89	24.69	6.22

量不是这里的瓶颈。(出处: `outputs_cifar100/v7_readout_capacity/capacity_ladder.csv`; 两个 torch 臂各在自己的最优轮数上取值, 取值已记在产物里。)

表里有两个”线性读出”, 与本文 `headroom` 用的探针不是同一个数, 这里对齐一下: 本文的 `headroom` (第 3.2 节) 用的探针是 `sklearn` 的 `LogisticRegression(max_iter=1000)` (默认 $C = 1$, `lbfgs`), 与表中”逻辑回归 (`sklearn` 默认, 跨优化器参考臂)”是同一族——两者在 $\alpha = +0.3$ 上是 **48.35** 与 **48.25** (差 0.10, 来自设备口径: `headroom` 那一次的探针是 CUDA run, 这张梯子 CPU run)。而表中被加粗的”线性头 (torch, 公平锚)”是另一个实现 (Adam, 取最优轮数, 3 seed 均值), 它与本文探针的差 $51.47 - 48.35 = 3.12$, 与第 3.13 节的 $\Delta_{\text{proc}} = 3.45$ 同量级 (注意这一对里同时含拟合过程、设备与种子口径三重差, 不宜当作 Δ_{proc} 本身; Δ_{proc} 表里的 Adam 50 轮 = 51.57 是单 seed)。结论不变: 同一个线性读出、同一批冻结特征, 换个拟合方式就能差 3 个百分点。

这个下界还可以再抬高: `headroom` 依赖读出怎么训。上面四路对照都在同一个探针设定 ($n = 8000$ 训练样本) 下做。把探针的训练样本加到 50000 (训练集全量; 同为 `oracle- $\alpha$` 口径), $\alpha = +0.3$ 的探针精度从 48.35 升到 **55.72**, `headroom` 从 +20.26 升到 +27.63——且仍未饱和 (对数刻度上的增量斜率从 5.02 降到 3.06, 比值 0.61, 仍高于预登记的”已接近饱和”阈值 0.5)。按第 3.2 节的”不相交划分”只扣这一项校正 ($\alpha = +0.3$ 处为 -2.19; 出处 `v7_probe_audit/c5_private_decompose_agg.csv` 的 `d_disjoint` 列, 同一张表里”探针样本量 5000 对 8000”另计 -1.98, 本文不扣), 折合约 +25.4 ($27.63 - 2.19 = 25.44$), 仍远高于 +20.26。clean 端也更清楚: $n = 8000$ 时探针比冻结头低 6.42, $n = 50000$ 时只低 **0.99**。

这条观测的含义比数字本身重要: +20.26 不是表征的某个固定属性, 它是”探针只喂了 8000 个样本”下的读数。`headroom` 是读出训练方式的函数——与第 3.13 节那条”过程自由度 3.45 pp”是同一件事的两个侧面, 都指向同一个判断: 读出这一层不是免费的, 它的读数取决于你训得多好。本文因此把 +20.26 作为已审计的规范值引用, 同时声明它是下界: 真实可解码性至少为 +25.4。

(出处: `outputs_cifar100/v7_readout_samplesize/samplesize_ext.csv`。 $n = 50000$ 档三个种子的标准差为 0——该档即训练集全量, 各 seed 用同一批数据, 故无采样变异。)

3.4 冻结主干、只重训线性读出, 就能以一个数量级更低的成本拿回尾部

图 3 给出读出适配在三个主干上的效果。

表 2 的口径: 第一行不是另一批干净模型, 而是本表读出适配所依附的那三块主干自带的分类头——SimpleCNN 依附干净主干, VGG-11 依附 Exp2 配方主干 (120 ep), ResNet-18 依附 Exp3 配方主干 (200 ep)。三块主干的身份由一条恒等式核验: 读出文件 `a_original_fc` 行的 $\alpha = 0$ 列必须等于该主干 `metrics.json` 的 `best_test_acc` (实测 59.99 / 68.05 / 72.69 对 59.99 / 68.05 / 72.70, 最大差 **0.01**, 即 10 000 张测试样本中的 1 张)。由此有两点必须说明: **ResNet-18** 一列的第一行与第三行是同一块主干 (都是 Exp3), 第二行是在它之上再训读出——把两行并列成”两个选项”会读错; VGG-11 一列的读出依附 Exp2 (15.98), 与第三行的 Exp3 (24.69) 也不是




图 3: 读出适配跨三个主干一致抬升尾部。实线为 readout-NAT (冻结主干、只重训线性读出, 可训练参数占全模型 5.04%/0.55%); 每个主干的原始分类头用与该主干同色的虚线; 每个主干为 3 个种子的逐点均值, 阴影为该点上 3 个种子的 ± 1 总体标准差。 $\alpha = +0.3$ 处的标注为均值 $\pm$ 总体标准差。数据: outputs_cifar100/v3_readout_repair/*ep24*.csv。

同一模型。ResNet-18 一列两格取值相同的原因正是这个: 它读出适配所依附的 **Exp3** 主干, 本身就是该主干上全网络鲁棒训练的最优结果, 所以那一列的对照是”同一块主干内: 原始头 6.22 $\rightarrow$ 读出适配 26.82”, 不含任何主干升级。另两列恰好相反——读出适配依附的主干弱于各自的全网络最优 (SimpleCNN 28.09 对 29.89、VGG-11 15.98 对 24.69), 故那两列的对照对读出侧是保守的。三种情形下读出适配都大幅领先, 其中一种还是在最强主干的基底上取得的。读出适配自身的增益只由第一行 $\rightarrow$ 第二行给出 (+15.22 / +31.81 / +20.60, 见下文第二项自我校验)。第三行的三格是各列上已知最优的全网络配方, 来自两个不同的 harness (SimpleCNN 为 task3 的 Exp3 配方, VGG-11 / ResNet-18 为 ext6 的 Exp3), 且都是单次运行; SimpleCNN 上同协议的 3 seed 均值是 26.57, 低于 29.89, 故本行取 29.89。读出适配相对该行的领先为 +13.42 / +23.10 / +20.60。(另一批干净主干 task1 的 VGG-11 / ResNet-18 在 $\alpha = +0.3$ 上是 16.92 / 2.70, 与前两行的读数不同源, 故不列入本表。)成本比逐主干配对: 读出 12 / 25 / 30 min 对全网络 1 / 6.5 / 6.5 h $\Rightarrow$ 1/5、1/16、1/13, 即约低一个数量级 (读出侧 24 ep, 全网络侧 120~200 ep)。

表 2 把两类方法并列。读出适配在三个主干上一致地超过”全网络重训”这一整类配方, 而可训练参数只有 5.04%/0.55%, 训练时间低约一个数量级。代价是干净精度下降 3.19~6.67 个百分点——这一点在第 3.10 节里被处理。

一个必要的自我校验: 读出适配不是”再分配”。把读出专门拟合到 $\alpha = +0.3$ 单点, 该点确实从 28.09 涨到 52.79 (+24.70), 但干净精度掉 20.36、 $\alpha = -0.3$ 掉 25.71, 七点均值反而低于基线。而起作用的这一版是在 $\alpha \sim U[\pm 0.3]$ 上分布的——它在每个扫描点都不显著劣化, 尾部与中带同时提升。同一层参数、两种训练方式给出质上不同的结果, 说明起作用的不是”读出被放开了”这件事本身。

第二项自我校验: 增益不是”多训了一个分类器”的通用效应。读出适配的全部改动只有最后一层。一个自然的怀疑是: 任何重训过的线性头都会带来类似增益, 与”在哪种分布上训练”无关。这个对照本来就在数据里——v3_readout_repair 的产物文件里每个权重都带有多个读出臂, 其中 b_clean_fit_linear 是在干净分布上重训同一个线性头:

主干	原始头	在干净分布上重训	Δ	本文方法	Δ
SimpleCNN	28.09	28.35	+0.26	43.31	+15.22
VGG-11	15.98	15.81	-0.17	47.79	+31.81
ResNet-18	6.22	5.38	-0.84	26.82	+20.60

($\alpha = +0.3$ 精度, CIFAR-100, 各 3 seed, 24 epoch 读出; 出处: `outputs_cifar100/v3_readout_repair/*ep24` 的 `a_original_fc` 与 `b_clean_fit_linear` 两行。表中为 3 个种子的均值——CSV 存的是逐 seed 的行, 均值需自行合成, 算式登记在 `docs/DERIVED_VALUES.md`。)

b 在三个主干上全部零增益, 其中两个还是负的 (+0.26 / -0.17 / -0.84)。起作用的不是“换了一个头”, 而是头是在哪种分布上训练的。

(同一批文件里还有一个 `c_dist_fit_linear` 臂——把读出拟合到失真的窄分布上。它在 $\alpha = +0.3$ 上更高 (52.16 / 58.98 / 47.40, 同为主干内 3 seed 均值), 但干净精度崩掉: ResNet-18 从 72.69 掉到 **15.53**。这是“再分配”的极端形态, 也正是本文方法选择在整个 $\alpha \sim U[\pm 0.3]$ 区间上训练的原因。注意: 该臂是 24 ep / 3 seed 口径, 与上文引用的单点适配读数 52.79 来自不同轮次, 两者不可直接相比。)

同一套做法在更简单的任务上更强——一条标度律。把读出适配原样搬到 CIFAR-10 (10 类, 比 CIFAR-100 容易):

主干	原头 @+0.3	读出适配 @+0.3	clean 代价	恢复率 (C10)	恢复率 (C100)
SimpleCNN	55.08	72.51	-0.84	85.4%	72.2%
VGG-11	36.71	79.64	-0.58	88.7%	70.2%
ResNet-18	17.09	44.37	-0.71	48.2%	36.9%

(24 epoch 读出, 全量测试集; 恢复率 = 读出适配 @+0.3 的精度 $\div$ 原头 @ $\alpha = 0$ 的精度。CIFAR-100 的对应值取自图 7 所在小节。出处: `outputs/v3_readout_repair/*ep24*.csv` 与 `outputs_cifar100/v3_readout_repair/*ep24*.csv`。)

两件事同时成立: 恢复率在三个主干上一致更高 (85.4 / 88.7 / 48.2 对 72.2 / 70.2 / 36.9), 干净代价也小得多 (-0.58 ~ -0.84 对 -3.19 ~ -6.67)。读出适配的收益随“可用头部空间”缩放: 任务越难, 能被读出捞回来的越少。这与本文第 3.2 节的逻辑一致——可恢复量由“信息还剩多少”决定, 而更难的任务在同样的失真下损耗更多。(注: CIFAR-10 侧的读出为单 seed; CIFAR-100 侧为 3 seed。这一点记在第 5 节的局限 (7) 里——它正落在本文自订的 Δ_{proc} 不可裁决区间内。)

3.5 训练端的四条补救路径没有一条改善尾部, 因为损伤落在参数空间之外

如果尾部是“训练不够适应”, 那么更聪明的采样或更宽的分布应该能救它。图 4 给出四条独立路径的结果, 全部在同一 harness 下与均匀采样基准对比。

四条路径分别为: 采样预算分配 (三种轮廓, 最好 26.13)、 α 空间对抗训练 (24.32, -1.71)、课程式采样 (21.78, -4.25)、训练范围外推至 ± 0.5 (20.48, -5.55)。按本文自订的种子纪律 (第 2 节: 单种子的尾部差值小于 3 个百分点不作为结论), 这四条要分开说: 后两条 (-4.25 / -5.55) 显著劣于基准; 对抗训练的 -1.71 落在门槛之内, 记为不可分辨; 预算分配的 +0.10 与基准同级。没有一条改善尾部。

其中最后一条最能说明问题的性质: 模型已经在 ± 0.5 上训练过, 但测试到 $\alpha = +0.5$ 时仍只有 2.71%, 同期负侧 -0.5 有 31.19%, 相差 28.5 个百分点。正侧尾部不是采样覆盖问题, 而是结构性的不可训练区。




图 4: 训练端的补救路径在 $\alpha = +0.3$ 上没有一条显著优于均匀采样基准 (最好的一条为 $+0.10$ pp)。差值以基准 (均匀采样, $\alpha = +0.3$ 时 26.03%) 为零线; 绿 = 高于基准、蓝 = 低于基准; 预算分配三种轮廓、 α 空间对抗训练 (PGD)、课程式采样、训练范围外推至 ± 0.5 。CIFAR-100 / SimpleCNN / 120 epoch / 单种子。数据: `outputs_cifar100/v3_methods/*/alpha_sensitivity.csv`。

这一边界不是“训练不够”造成的, 而是“训练分布之外”造成的。图 5 给出一个直接对照: 把非线性感知训练的增益沿 α 轴外推, 正侧在 $\alpha \approx 0.4$ 处归零并迅速转为劣势, 而负侧随外推距离不降反升。也就是说, 训练端手段的收益被它自己的训练分布框住; 这与图 4 的四条路径互为印证。

3.6 损伤的形态是维度丢失, 而不是类间距缩小

既然信息还在 (图 2) 而训练救不回 (图 4), 损伤的形态是什么? 图 6 给出答案。

$\alpha = +0.3$ 时有效秩下降 20.6% (SimpleCNN)、33.3% (VGG-11)、58.7% (ResNet-18); 负侧同强度下降 2.0% / 17.9% / 67.3%。“负侧几乎不动”只在浅层主干上成立——VGG-11 的负侧掉近两成, 而 ResNet-18 的负侧 (67.3%) 比正侧 (58.7%) 掉得更多。

这一点必须说清, 因为它限定了下面这个机制叙述的适用域: 秩塌陷与精度损失在 ResNet-18 上是两侧对称的——它的 $+0.3$ 与 -0.3 精度分别是 2.70 与 3.25, 同样是两侧都崩。“正侧更致命”这条 (第 3 节 R1) 在 ResNet-18 上并不成立, 它在本文全部证据里成立的场合是浅层与中等深度主干 (SimpleCNN / VGG-11), 以及训练端那四条路径 (全部在 SimpleCNN 上做的)。秩塌陷解释“正侧特殊”这条链, 只在秩塌陷本身不对称的主干上才连得起来。更关键的是, 同强度下正侧的 Fisher 判别比反而高于负侧—— $\text{Fisher}(+\alpha) > \text{Fisher}(-\alpha)$ 在 $|\alpha| \in \{0.1, \dots, 0.5\}$ 上五点全成立 (例如 $|\alpha| = 0.3$ 时 0.45669 对 0.39062, 出处 `v7_nc_geometry/nc_geometry.csv`; 同一对数在秩统计产物 `rank_stats*.csv` 里是 0.39061, 差最后一位, 为两个产物的精度口径差)。类间可分性没有变差, 丢失的是维度。

(注意措辞: 这里说的是跨正负的比较, 不是“正侧的 Fisher 随失真单调升高”——沿正侧看它是先升后降的, 只有 $\alpha = +0.1$ 那一点高于 clean (0.50124 vs 0.49096), 此后单调下降。上文早期版本写作“正侧失真下 Fisher 反而升高”, 丢了比较对象, 是可被本文表格否证的错误表述, 已更正。)这与前文的幅度统计一致: $\alpha > 0$ 把深层特征的幅度向中段压缩 (fc 与 conv1 的 L2 范数比从 0.45 降到 0.23), 端点不变而中段被压低。

这就解释了“信息还在但训练救不回”这个表面矛盾: 信息仍存在于剩余的维度里, 但这些维度在主干参数的可达域之外; 只有换一个读出才能在新的几何下重新找到判别方向。




图 5: 非线性感知训练的收益是训练分布内的属性。SimpleCNN 上两种训练策略相对于干净模型的增益沿 α 轴的变化。横轴 ± 0.6 (15 点), 范围大于正文其余各图的 ± 0.3 (7 点); 竖直虚线标出训练区间 ± 0.3 , 其外为外推区。**NAT-scratch** (实线圆点): 正侧在 $\alpha \approx 0.4$ 处归零 (+0.77)、 $\alpha = +0.5$ 反转为 -10.77; 负侧在外推区保持正值并略有上升 (-0.4 时 +6.44 $\rightarrow$ -0.6 时 +8.22)。**NAT-finetune** (虚线方点): 正侧在整个外推区基本平坦 ($|\Delta| < 1.7$, 到 $\alpha = +0.6$ 才转为 -1.58); 负侧随外推距离缓慢衰减 (+1.21 $\rightarrow$ +0.14)。注意: 本图数据集为 **CIFAR-10** (干净精度 84.90), 与正文其余各图的 CIFAR-100 不同, 跨图不可直接比较绝对值。数据: outputs/extension4_alpha_wide/alpha_wide_scan_summary.csv。

3.7 读出能拿回多少, 由表征的秩损失决定

如果上一节的机制成立, 那么”秩掉得越多, 读出能拿回的越少”应当成立。图 7 把三个容量档的秩损失与各自的读出恢复率配对。

秩损失 20.6% / 33.3% / 58.7% 对应恢复率 72.2% / 70.2% / 36.9% ($r = -0.960$), 趋势成立。但反向不成立: ResNet-18 掉了 58.7% 的秩, 读出仍拿回 36.9% (相对自带头 6.22 仍有 +20.60), 所以塌陷不等于不可恢复。三点也定不了曲线形状——逐点看前两点只差 2.0 个百分点, 第三点比第二点低 33.3, 更像”先平后塌”而非直线。这一点作为提示记录, 需第 4 个容量档才能判定。

3.8 池化密度是第二个独立杠杆, 它的保护主要来自降维

读出侧的杠杆要求读出层可写。有没有不依赖这一点的、纯架构的杠杆? 图 8 给出一个零训练成本的答案。

主口径是同协议、同 seed 配对: $\alpha = +0.3$ 从 26.03 提升到 **41.55** (+15.52) ——两臂同出 v3_methods、同为 120 epoch 的逐层独立采样、seed 相同, 只改了池化层数, 这是与”架构杠杆”这个说法严格对应的对照 (各单 seed)。

干净训练臂给出同向的读数 (28.09 $\rightarrow$ 42.47, +14.38), 但它不构成同协议对照: 基线 28.09 取自第一阶段的另一个训练脚本 (无增强配方), 与 v3_methods 异协议, 故只作锚点。该臂自身有 3 个同协议的种子—— $\alpha = +0.3$ 为 42.47 / 38.77 / 39.64, 均值 **40.29 $\pm$ 1.58**, 即在该臂内部增益应记为 +12.20 (基线仍为异协议的单次运行)。**42.47** 是这三个种子里最高的一个, 不宜单独引用。

七点均值提升 3.6~4.9 个百分点 (干净臂用 3 seed 均值 52.88 对基线 49.29; 同协议配对的 NAT 臂为 54.09 对 49.24), 而干净精度不降。增益与读出适配同级, 但训练成本为零。




图 6: 失真使末端特征的有效秩塌陷, 但两侧的形态按主干分化。纵轴为按各模型 $\alpha = 0$ 归一化后的有效秩 ($\exp(-\sum p_i \ln p_i)$, p_i 为归一化奇异值); 横轴 11 个 α 点。三个主干的特征维数分别为 128 / 512 / 512。 $\alpha = \pm 0.3$ 处的秩损失分别为 20.6% / 2.0% (SimpleCNN)、33.3% / 17.9% (VGG-11)、58.7% / 67.3% (ResNet-18)——“负侧”几乎不动”只在浅层的 SimpleCNN 上成立; ResNet-18 的负侧比正侧掉得更多。数据: outputs_cifar100/v5_rank_collapse/rank_stats*.csv。

表 3: 池化保护的三个候选解释与排除依据

候选解释	检验	结论
池化”吸收”了失真	归一化三次映射与 max 在非负域是否可交换	在池化输入 (post-ReLU, 非负) 上精确可交换, $\max \Delta = 0.000e+00$; 但可交换却非成因——交换律成立时保护并未因此产生
质量向恒等区集中	5-pool 与 2-pool 的易感度 S 与不变区占比	5-pool 的 S 反而更高 (conv4: 0.1527 vs 0.1134), 不变区占比几乎不变
max 的选择性或可交换性	换成 top-2 池化 (与 f_α 不可交换)	保护与 max 等同 (42.98 vs 42.47, 单种子)

保护从哪里来? 三个候选机制被逐一检验, 全部否定:

三条排除之后, 唯一显著的差异是空间元素数从 256 降到 16。进一步做同协议 3 种子对照: $5 \times \max$ 的 $\text{drop}@0.3$ 为 20.60 ± 1.54 、 $5 \times \text{avg}$ 为 21.78 ± 0.91 , 差 +1.17。该差值落在预登记的 1~2 个百分点区间 (差值的标准误 1.03, $z \approx 1.1$), 因此”降维: 非均值聚合”的定量比例不予裁决, 只能给出方向性结论: 保护主要来自降维。

3.9 两个杠杆在尾部可以同时受益但不独立相加, 且失真强度可以在线估计

图 8 的架构杠杆与图 3 的读出杠杆是否互斥? 把两者叠 ($5 \times \text{MaxPool}$ 主干 + readout-NAT) 后, $\alpha = +0.3$ 达 49.18 (三个读出种子: 49.12 / 48.82 / 49.59), 比架构单独 (42.47) 高 6.71、比读出单独 (43.31) 高 5.87。但两个杠杆并不独立相加: 架构单独增益 +14.38、读出单独增益 +15.22, 单独之和的预期是 +29.60, 实际只拿到 +21.09——次可加, 合起来拿到约七成 (21.09/29.60)、损失约三成。准确的表述是: 两个手段在尾部可以同时受益, 但它们不独立相加。(口径: 连续均匀 α 头、24ep/20k、同一条评估路径; 读出侧取 3 seed 均值。架构一侧必须用 42.47: 叠加实




图 7: 秩损失与读出可恢复量的关系 (三点)。恢复率定义为读出适配在 $\alpha = +0.3$ 的精度除以同一读出文件里原始头在 $\alpha = 0$ 的精度。三点在 $\alpha = +0.3$ 上单调, 逐点 Pearson $r = -0.960$ 。三点不足以定曲线形状, 形状提示为“先平后塌”。数据: rank_stats*.csv 与 v3_readout_repair/*ep24*.csv。

验是在 seed 42 那一块主干上做的, “架构单独”与“叠加”只能在一块主干内相减, 所以这里是同实例配对, 而不是上一节的跨主干 3 seed 均值 40.29。若把架构一侧换成 40.29, 预期变为 +27.42、缺口 6.33、实得占预期的 77%——“次可加”的结论在两个口径下都成立。)。

部署时还有一个信息问题: 现场并不知道失真有多强。用读出层的特征做岭回归即可恢复它: 在四个主干 $\times$ 数据集组合上, R^2 为 **0.827~0.935**、MAE **0.036~0.061**, $\hat{\alpha}$ 在 ± 0.3 区间上近乎无偏。

主干越深, 估计越准: VGG-11 (Exp2 主干) $R^2 = 0.9516$ / MAE 0.0324, ResNet-18 (Exp3 主干) $R^2 = 0.9778$ / MAE 0.0219。(出处: outputs_cifar100/v5_full_recipe/recipe_robust*.csv 的 ridge_R2 / ridge_MAE 两列。)这与直觉一致——深层特征的维度更高 (512 对 128), 承载的失真强度信息更完整; 而浅层里 MaxPool 会把一部分 α 信息压掉 (CIFAR-100 上 $5 \times$ MaxPool 主干的 R^2 为 0.8323, 低于 $2 \times$ MaxPool (plain) 主干的 0.935)。

这意味着可以按估计值在多个头之间调度, 且在深层上这个调度信号比浅层更可靠。

3.10 门控能把读出的 clean 代价收回来——但有清晰的门槛

读出适配付出了 3.19~6.67 个百分点的干净精度代价。既然 α 可以估计, 一个自然的做法是同时保留干净头与鲁棒头 (干净头就是模型自带的那个分类头 (第 3.2 节的“原始头”)——它冻结不动、可以固化在 ROM 里; 鲁棒头即读出适配头, 是在 $\alpha \sim U[\pm 0.3]$ 上重训出来的那个读出, 此处沿用产物列名 acc_robust_head), 按 $w = \text{clip}(|\hat{\alpha}|/0.3, 0, 1)$ 在两个头的 logits 之间插值。图 9 把七个 (代价, 红利) 点画在一起, 结论与直觉相反。

在 CIFAR-100/mp 上, 鲁棒头的干净代价是 -5.89, 门控收回 +2.90, 七个扫描点里有三个超过两头中较优者。但当把深层主干加进来, 代价落进了此前空白的 2~5 个百分点区间 (VGG-11 -3.45、ResNet-18 -4.36), 红利却没有跟着变大: 分别是 +0.68 与 -1.14——在 ResNet-18 上门控比单用鲁棒头还差 1.14 个百分点。

原因在逐 α 曲线上看得很清楚: ResNet-18 的自带分类头在负侧是崩的 ($\alpha = -0.2$ 只有 10.27%)。软门控按 $w = |\hat{\alpha}|/0.3$ 插值, 在真实 $\alpha = -0.2$ 处 $w \approx 0.67$, 于是三分之一权重的坏头把 45.64 拖到 39.21。插值没有任何机制知道“其中一个头在这个 α 上是坏的”。

因此门控有效需要两个前提同时成立:




图 8: 池化密度是独立的架构级杠杆。把 SimpleCNN 的最大池化层从 2 个增加到 5 个——参数量不变、训练成本为零。同协议同 seed 配对 (120 epoch、逐层独立采样) 的读数是 $\alpha = +0.3$ 从 26.03 提升到 41.55 (+15.52, 各单 seed)。图中灰色虚线为第一阶段脚本的产物, 与实线的 v3_methods 分属两个阶段、不同协议, 仅作参考点、不参与任何同协议对比 (正文若引用 28.09 $\rightarrow$ 42.47, 即横跨这两条曲线, 须显式注明其跨协议性; 该臂自身三个同协议种子的均值为 40.29 ± 1.58 , 见正文)。数据: outputs_cifar100/v3_methods/simple_cnn_mp_clean_uniform/alpha_sensitivity.csv 与 task1_simplecnn/alpha_sensitivity.csv。

1. 鲁棒头的干净代价足够大 (有东西可回收);
2. 两个头在整个 α 轴上都不能崩掉 (否则插值会把一个头在该点的灾难带进来)。

一个多数据集的自我检验值得一提。上述机制是在 CIFAR-100 上事后发现的。为检验它, 在尚无任何配方结果的 CIFAR-10 上锁定了全部超参、并在跑之前写死了五条判据 (C1–C5)。结果: 形式判据成立, 但强主张未复现——“插值超过 oracle”的判据由 3/7 降到 1/7², 门控相对 oracle 由 +0.12 变成 -0.07, 门控红利由 +2.90 缩到 +0.17。复现的是弱支配 (不差于任一头), 不是集成增益。机制因此被改写成更保守的形式: 门控红利 = 鲁棒头干净代价的回收量; 当干净代价小于 1 个百分点时, 直接用单鲁棒头即可。

为什么它只能“弱支配”: 一个机制级的回答。上面那条“没有复现”是跨数据集的经验事实。它后来有了一个机制级的解释, 而这个解释同时把那个主张永久关闭了。

两个头的错误是否互补, 可以直接测: 取两个头在同一批样本上的 0/1 错误指示向量, 算它们的 ϕ 相关。只有当两头的错误负相关时, 插值才可能“集成”出比两头都好的结果。

实测 (7 个 α 点, 每个数据集 21 格):

	CIFAR-100	CIFAR-10
ϕ 范围	+0.594 ~ +0.706	+0.519 ~ +0.830
两头都错 / 独立基线	1.50 ~ 1.98	2.76 ~ 6.58

²但这个计数不稳健, 本节的结论不挂在它上面。第七阶段复核发现: CIFAR-10 侧有一个 α 点的“软门控减 oracle”只有 -0.0100 pp ($\alpha = -0.2$), 而 CPU 与 CUDA 的设备差异单独就能把它翻成 +0.0033 ——也就是说 3/7 与 1/7 之差可以只由设备口径造成。(CIFAR-100 侧对应点的最小裕度是 0.1567 pp, 是稳的。) 本节的结论一律挂在幅度上, 不挂在计数上。




图 9: 门控红利不随鲁棒头代价单调增长。横轴为鲁棒头相对干净头在 $\alpha = 0$ 的精度损失（负值 = 鲁棒头更差），纵轴为门控相对单用鲁棒头在 mean7 上的增益。七个点取自四个主干配置与两个数据集，各 3 个种子。（C10/mp 的三个主干种子在图中以三种标记画出、共用同一标签。）逐点 Pearson $r = -0.533$ ；去掉 CIFAR-100 远点后 $n = 6$ 时符号反转为 $+0.351$ 。数据：v5_full_recipe/recipe*.csv。

ϕ 在两个数据集上都是强正——两个头的错误正相关，它们在同一批样本上一起错。「插值即集成」所依赖的互补性，在两个数据集上都不存在。

由此两条：

1. 那个机制是被否认，不是“未能分辨”。本文因此把「插值即集成」永久关闭——不是“没复现”，是它依赖的前提不成立。
2. 收益的上界由此变得可解释：没有互补性可利用，插值的增益注定有限。实测“软门控减 oracle”的极差，CIFAR-100 为 1.60 pp、CIFAR-10 只有 0.71 pp，与“两头错误高度正相关”一致。

这里要分清：被关闭的是机制解释，不是那个效应本身。CIFAR-100 上软门控确有若干点超过两个头，那个效应仍然存在、也仍未被完全解释——本节给出的机制只说明了它的上界为什么不高，没有说明它为什么不为零。

（出处：outputs_cifar100/v7_gate_mechanism/gate_errors.csv。该诊断含一条恒等自检：soft - oracle = (rescue - hurt) $\times$ 100，通过。）

再补一步：那个 +0.17 的裕度是不是碰巧？上面的 CIFAR-10 检验只用了一个主干种子——3 个种子变的是鲁棒头与估计器，不是主干本身。为判断裕度是否稳健，把 CIFAR-10 的 mp 主干补到 3 个种子，每个主干各跑一次完整配方：

主干种子	mean7 (干净头)	mean7 (鲁棒头)	mean7 (软门控)	m
42	82.68	85.02	85.19	+0.169
43	82.19	84.90	84.90	-0.003
44	82.61	85.00	85.17	+0.171

（ $m = \text{mean7}(\text{软门控}) - \max(\text{mean7 干净头}, \text{mean7 鲁棒头})$ 。判据跑前写死：任一 $m \leq 0$ 则 C1 改判“不可分辨”。）

主干种子 43 的 $m = -0.003$ ，判据命中 C1 由”弱通过”改判”不可分辨”，软门控在 CIFAR-10 上的定性定为”与单头不可区分”。更准确的说法是：差值在 $0 \sim +0.17$ 之间飘，三个主干种子里有一个正好落在 0 上（平均 $+0.112$ ，全部远小于主干级的 mean7 噪声）。部署推荐不变——CIFAR-10 一直推荐单鲁棒头。

最后记一笔被替代掉的配置。按本项目的纪律，预登记未达标的记录必须留下：最早预登记的完整配方用的是硬 τ 路由，端到端实测三项判据里 mean7 54.49（达标）、clean 60.92（达标）、但 $\alpha = +0.3 = 47.90$ （未达标，阈值 48.5，差 0.60）。软门控是在看到这次失败之后才引入的——这正是上文所有”事后变体”措辞的来源，也是为什么本文对它的每一个主张都要求跨数据集复现。

另外，门控的两前提无法做成装前的量化自检：把”崩”定义为两头在 7 个 α 点上的最小精度，或定义为最坏相对缺口，两种定义在已有的 7 个点上都分离红利的符号（VGG-11 的最小精度只有 15.73 却红利为正；CIFAR-10/mp 主干 43 的最小精度有 69.23 却红利为 -0.003 ）。该判据作为事后机制解释保留，不作为预测规则。

部署时的失真分布会漂移——门控扛得住吗？上面所有比较都在训练分布 $U[\pm 0.3]$ 上做。真实芯片的失真分布未必如此，于是按六种分布对已有的逐 α 结果重新加权（ $5 \times \text{MaxPool}$ 主干，CIFAR-100，各 3 seed 均值；表内指标为 mean7；权重固定、 τ 不重选，零 GPU 成本；出处 `outputs_cifar100/v5_alpha_drift/drift_stress.csv`）：

评估分布	clean 头	robust 头	硬路由	软门控	oracle
$U[\pm 0.3]$ （训练分布，参照）	54.12	52.19	54.49	55.08	54.96
仅正向	54.53	52.85	55.49	56.07	55.87
仅负向	55.43	52.25	55.10	55.50	55.56
双峰（ ± 0.2 各半）	53.71	52.03	53.25	54.40	54.02
尾部集中（ ± 0.3 各半）	45.63	48.57	48.10	49.11	48.57
单峰 $N(+0.3, 0.05)$	44.51	49.08	48.57	49.83	49.24

两件事：

(1) 软门控在 6/6 种分布下都是最好的（其中 5 种还超过 oracle。唯一不超过的是 仅负向：55.50 对 55.56，差 0.06——这是全表最小的裕度，其余五行的裕度分别是 $+0.12 / +0.20 / +0.38 / +0.54 / +0.59$ ）。它不需要知道真实分布是什么——因为插值权重 $w = |\hat{\alpha}|/0.3$ 是逐样本算的，分布的形状不影响它。

(2) 硬路由在漂移下会退化：在（尾部集中）处，硬路由只有 48.10，反而低于单用鲁棒头的 **48.57**（差 -0.47 ）；（单峰）处同样如此（ $48.57 < 49.08$ ，差 -0.51 ）。原因是硬路由在 $|\hat{\alpha}|$ 的阈值附近做二值选择，而尾部集中时 $\hat{\alpha}$ 大量落在阈值两侧，选错的代价被放大。

但这条红利不是无条件的：同一组实验在池化稀疏（plain，2 个 MaxPool）主干上做，处软门控 47.70 对鲁棒头 47.71——红利消失（ -0.01 ）。这与第 3.10 节的边界条件一致：软门控的价值取决于主干自身的尾部可用性，分布漂移只是让它更明显或更不必要。

3.11 失真与量化联合作用时，低位量化在池化密集架构上会反转成增益

真实芯片在模拟域失真之外还有 ADC 量化。两者同时存在时相互放大还是抵消？图 10 给出一个反直觉的答案。

在 VGG-11（5 个 MaxPool）上，4 bit 量化的精度高于 8 bit（CIFAR-100: $+2.84$ ；CIFAR-10: $+6.53$ ）。三个候选假设通过剂量匹配的三组对照、样本级翻转统计与激活分布统计判决。




图 10: 低位量化在池化密集架构上反转成增益。VGG-11、固定 $\alpha = +0.3$ 、CIFAR-100，扫描 ADC 位宽；虚线为 8 bit 基线。4 bit 时精度最高，比 8 bit 高 2.84 个百分点。数据：outputs_cifar100/extension5_dithering_vgg11/group_a_bits_scan.csv。

先标注数据集：图 10 的扫描是 CIFAR-100 的；而下面 H1-H3 的机理量取自 **CIFAR-10** 侧 (outputs/extension5_dithering_vgg11/)，与 CIFAR-100 侧同一脚本、同一协议，只换数据集与主干权重)。CIFAR-100 侧的对应量平行列在附录表 6 中——两数据集的定性结论一致，这正是这一节结论的稳健性证据。

- **H1 随机去相关——否决。**用与 4 bit 等效剂量的纯高斯/均匀噪声替代量化，精度不升反降 (**CIFAR-10**: $-2.45 / -1.87$; **CIFAR-100** 同号, $-3.12 / -2.48$); 8 bit 基线上叠加最优剂量噪声的增益为 -0.03 (**CIFAR-10**; **CIFAR-100** 为 -0.07)。样本级翻转统计给出三个量级的反差: **CIFAR-10** 上 4 bit 的救回: 杀死为 4.15:1 (净 +653 样本)，而噪声条件约为 1:1 (净 +7 / -19); **CIFAR-100** 上同向 (1.77:1, 净 +284)。
- **H2 分布重塑——确认 (核心机理)。****CIFAR-10** 上分类器输入分布的峰度在失真下从 1.486 被压平到 0.110, 4 bit 的粗离散化把它恢复到 **0.214**, 部分重建可分性 (**CIFAR-100**: $2.541 \rightarrow 0.847 \rightarrow 0.980$, 同向)。存在甜点带: 3 bit 峰度更高 (0.384) 但在 **CIFAR-10** 口径下精度略降 ($43.27 \rightarrow 42.97$), 2 bit 信息量不足、峰度与精度双双坍塌。(CIFAR-100 口径下 3 bit 不是“略降”而是大幅下降, $19.75 \rightarrow 10.87$, 见附录表 6。)
- **H3 MaxPool 交互——支持 (必要条件)。****CIFAR-10** 上无 MaxPool 的 ResNet-18 完全免疫 ($+0.39$); 但只有 2 个 MaxPool 的 SimpleCNN 是负增益 (-13.68)。CIFAR-100 上定性相同 (ResNet-18 -0.21 、SimpleCNN -14.71)——这条定性结论在第二个数据集上复现。因此 MaxPool 是必要而非充分条件，其密度决定量化误差是被修正还是被放大。

这条结果对“数字域后处理能救多少”给出了分层答案：同一个 4 bit ADC，在池化密集架构上是补偿，在池化稀疏架构上是负担。

3.12 为一种失真做的鲁棒性训练，不会顺带保护另一种

前九节讨论的都是同一类扰动：确定性的、输入相关的非线性失真。现实中的模拟域还有另一类误差源——零均值、与信号无关的加性随机噪声。一个自然的问题是：为其中一种训练出的鲁棒性，能不能迁移到另一种？如果不能，那么两类误差必须分别对待；如果能，联合训练就够。

迁移：近正交，但幅度依赖架构。 把一条通路上训好的权重拿到另一条通路上扫，测”扰动敏感性”的变化幅度 $\max |\Delta_\sigma|$ （超过 1.2 个百分点判为非零迁移）：

架构	配方对	$\max \Delta_\sigma $
SimpleCNN	Exp2（校准）vs 原始	1.16
SimpleCNN	NAT-scratch vs clean	2.43
SimpleCNN + 3×MaxPool	NAT vs clean	0.98
VGG-11	Exp2（校准）vs clean	5.26
ResNet-18	Exp2（校准）vs clean	1.41

「两通路正交、迁移为零」这条结论是架构依赖的：在 SimpleCNN 与 ResNet-18 上成立（ ≤ 1.41 ），但在 **MaxPool 密集的 VGG-11 上被打破（5.26）**。值得注意的是，加三个 MaxPool 反而降低了迁移（2.43 $\rightarrow$ 0.98），所以”MaxPool 密度”本身不是迁移的成因——更可能是校准模块作用于空间特征图的方式（§1.3 的讨论）。

训练端：不是零迁移，而是单向强干扰。 迁移幅度小，容易被读成”两者互不影响”。但训练端的对照否证了这个读法。在同一个 harness 上做 2×2 （是否注入 $\alpha \times$ 是否注入 σ ）：

训练条件	clean	$\alpha = +0.3$	$\sigma = 0.30$	双扰动最坏点均值
无训练（clean 模型）	59.99	28.09	3.98	16.04
α -only	60.85	26.03	4.40	15.22
σ -only	55.79	22.01	27.19	24.60
$\alpha + \sigma$ （联合）	55.20	15.27	31.31	23.29

三件事同时成立：

(1) α 训练对 σ 几乎零收益（4.40 vs 3.98）——这一侧确实是正交的。(2) 但 σ 训练使 α 侧付出代价： $\alpha = +0.3$ 从 28.09 掉到 22.01（ -6.08 ），干净精度也掉 4.20。联合训练更糟： α 侧 15.27（相对 clean 模型 -12.82 ，相对只做 α 训练的 26.03 又低 -10.76 ）。(3) 双扰动并存时的最优配方是 σ -only，不是联合训练：joint 里的 α 注入是净负担——它在 σ 侧只多拿 4.12，却付出 α 侧 -6.74 。

正确表述不是”两条通路正交”，而是「迁移近正交，但训练端存在单向强干扰（ $\sigma \rightarrow \alpha$ 有代价、 $\alpha \rightarrow \sigma$ 无收益）」。

这条结论的工程含义。 如果部署环境同时存在两类误差，不应把两种扰动一起塞进训练——应该先显式训 σ 鲁棒性（它是必须显式训练的，且收益大： $\sigma = 0.3$ 处 $3.98 \rightarrow 27.19$ ），然后在读出侧单独处理非线性失真（第 3.2 节的方法正好不碰主干，因此不会与 σ 训练互相干扰）。换言之，本节的结论与本文的主线是一致的：训练端做的事越少越好，剩下的交给读出。

3.13 这些效应有多大：用错协议会把方差估高六倍

上面所有差值都需要一个误差尺度。本文的方差标定给出两个数值，其中一个足以改变结论。

第一，尾部指标的种子方差远大于干净精度。同协议实测：浅层鲁棒训练尾部 ± 0.39 、架构变体 $\pm 0.95 \sim 1.58$ 、深层读出 $\pm 3.18 \sim 3.40$ ；而同组的干净精度只有 $\pm 0.07 \sim 1.85$ 。更麻烦的是干净精度不能外推：ResNet-18 按 2 个种子报的 ± 0.15 在补上第 3 个种子后变成 ± 1.85 （第 3 个种子的干净精度为 67.61，比另两个高 2.6~4.1 个百分点）。三个容量的干净方差跨度达 26 倍。

第二，混用协议会把方差估高约 6 倍。一组 3 seed 的鲁棒训练尾部读数，若三个种子来自两个脚本，标准差是 ± 2.561 ；补跑同脚本的第三个种子后，同协议标准差只有 ± 0.392 。进一步的




图 11: 交叉评估: 差异不在评估路径。把 8 个权重分别在另一脚本原样导入的评估函数下重扫, 两条路径给出逐位相同的读数 (含干净精度) —— (图中每条读数由重合的两枚标记表示: 实心方 = task2 路径、空心环 = v3 路径; 两者逐位相同故完全重合); 但两组权重稳定分成两簇 (A 脚本 19.7~22.0, B 脚本 26.0~27.0)。数据: `outputs_cifar100/v6_p4e_crosspath/crosspath.csv`。

定量分解显示, 那 2.56 里绝大部分不是随机噪声, 而是两种训练配方之间的系统差 (组内两个数相差 5.32, 与实测的脚本级处理效应 5.52 几乎相等)。也就是说, 把处理效应误读成了噪声。

第三, 也是最难处理的一条: 本文观测到跨训练实现的精度数字对不上, 且原因未定。(这一条是本文的观测, 不是一条普遍定律: 一个未归因的差异, 既可能是实现层的普遍不可移植, 也可能是其中一个脚本里还有没找到的具体差别——本文没有排除后者。) 两个脚本 (记为 A 与 B) 在数据加载、归一化、优化器、batch、epoch、调度器、增强、钩子机制、采样位置与评估口径上逐项一致, 同 seed 的逐 epoch 训练损失全程贴合 (差 ≤ 0.016 , 无分叉), 但 A 训出的鲁棒权重尾部稳定落在 21.03 ± 1.00 , B 训出的六个 run 全部落在 26.58 ± 0.29 , 两者相差 **5.55** 个百分点 ($z = 9.4$)。

为定位原因做了三次独立的干预, 全部失败:

已排除的解释累计为: 种子噪声、 α 采样粒度、随机数消耗数、评估路径 (图 11, 8 个权重 $\times$ 2 条路径逐位相同)、训练动力学 (逐 epoch 损失差 ≤ 0.016)。该差异仍未归因, 按已知未知记录。

这条观察的实践含义是硬的: 本文的做法是让部署校准与部署训练同实现、同路径; 在归因之前, 跨实现引用精度数字——包括与文献对比——都不可靠, 本文不引用。

一个更实用的刻度: 三级可分辨性。上面那条跨实现差异是一个已知未知, 无法直接当门槛用。但它旁边有两级可以测准的散布, 合起来给出一个可操作的判断尺度:

层级	变的是什么	实测幅度
种子噪声	同一过程重复	尾部 $\pm 0.39 \sim 3.40$; clean $\pm 0.07 \sim 1.85$
过程自由度	同数据、同特征、同架构, 只换拟合过程	3.45 pp
跨实现	同超参同种子, 实现不同	5.55 pp (未归因)

第 级是这样测的: 在同一批冻结特征上训同一个线性头, 只换六种拟合过程 (sklearn 的 lbfgs / saga; torch 的 Adam 在 50 / 150 / 400 轮; SGD+ 动量 150 轮), $\alpha = 0$ 与 $+0.3$ 上各跑一遍。结果:

表 4: 5.55 个百分点差异的三次归因尝试与结果

轮次	当时的归因	结果
1	尾部种子噪声 ± 3.1	否定。三个种子来自两个脚本，同协议下标准差只有 ± 0.39 ；混协议把方差估高约 6 倍
2	α 采样粒度（每批共享 vs 逐层独立）	否定。在同一脚本内只切换粒度：26.55 vs 26.57，差 +0.02 ($z = 0.08$)；而同粒度跨脚本差 +5.52 ($z = 9.4$ ；口径 26.55 – 21.03，两臂同为 shared 粒度——与正文”相差 5.55”的口径不同：后者是 26.58 – 21.03，B 侧为 6 个 run 的合并均值)。效应跟着脚本走，不跟着粒度走
3	随机数消耗位置（每批消耗 1 个 vs 5 个随机数）	否定。同脚本把消耗数从 5 改成 1：26.66 vs 26.55，差 +0.11

拟合过程	sklearn lbfgs	sklearn saga	Adam 50	Adam 150	Adam 400	SGD+mom 150
$\alpha = 0$	53.22	54.91	56.31	54.89	52.85	53.27
$\alpha = +0.3$	48.25	50.75	51.57	50.37	48.55	48.12

极差 $\Delta_{\text{proc}} = 3.45 \sim 3.46$ pp。同数据、同特征、同架构、同一个线性头，只换”怎么把它拟合出来”，就能差 3.45 个百分点。

这里有一个反直觉的细节值得单独记： $\alpha = 0$ 的最大值与最小值 都来自同一个优化器的不同轮数（Adam 50 轮最高 56.31、Adam 400 轮最低 52.85）。在 $\alpha = 0$ 上，过程自由度的主要来源是”训多久”，不是”用哪个”。（ $\alpha = +0.3$ 上两个因子同量级，不能只归给轮数：轮数在 Adam 内部跨 3.02（51.57 $\rightarrow$ 48.55），而全距 3.45 是由跨优化器的那一对跨出来的（Adam 50 轮 51.57 对 SGD+ 动量 48.12）；同轮数下换优化器（Adam 150 对 SGD+mom 150）只跨 2.25。该论断是本文的单主干单特征集观测，未进预登记判据。）

由此得到一条判断规则：任何”读出类”效应（换头、加正则、改容量）的可分辨门槛 必须同时以 Δ_{proc} 为参照，不能只用种子噪声——因为种子噪声测的是”同一过程重复”的散布，而 Δ_{proc} 测的是”换一个过程”的散布，后者才是接收端口真正面对的那种不确定性。本文第 3.10 节关于门控增益的每一个比较，其效应量都远大于种子噪声，但与 Δ_{proc} 同量级——这一点读者在解释那些差值时应当一并考虑。

4 讨论

4.1 为什么修复的对象不是参数而是解码

把图 2、图 3、图 4 三条并置：信息仍在（探针可线性取用）、换读出即取到（尾部 +15.2 ~ +31.8）、而参数空间的四条路径没有一条改善尾部。这三条单独看都可以被别的解释吸收——探针可能过强、”训练不够久”、读出适配可能是再分配——但并置之后”再分配”这个解释被排除，因为分布式读出适配在每个扫描点都不显著劣化。

常规对抗鲁棒性的直觉是”扰动在参数空间里被吸收”：对抗训练之所以有效，是因为训练分布覆盖了测试分布。但本文的扰动性质不同——它是确定性的、输入相关的系统误差，逐层累积且与信号幅度挂钩。图 6 表明这类误差不摧毁信息，它改变信息的几何：把深层表征的有效秩压下去，而 Fisher 判别比在正侧反而高于同强度的负侧。在一个丢维度的子空间里，”把参数训得

更适应”不会增加维度；换一个读出却可以在剩余的维度里重新找到判别方向。图 7 把这个直觉接上了定量：可恢复量随秩损失单调下降。

4.2 一个我们建议的测量顺序（在一族卷积主干上验证过）

更一般地，当失真同时具有”确定性、逐层累积、且权重不可重训”三个性质时，鲁棒性的杠杆位置由信息在哪一层被破坏决定，而不是由”哪一层参数多”或”哪一层最脆弱”决定。这条原理可以落成个测量顺序，而不是一个方法——本文只在一族卷积主干（0.25M~11.2M 参数，以 CIFAR-100 计；全部为 ReLU + 卷积/池化堆叠）上验证过它，适用范围见第 5 节的局限 (10)：

1. 先测 **headroom**：在冻结主干的末端特征上重训线性探针，与自带头比较。headroom 小 → 信息真的没了，只能动表征，回到常规鲁棒训练；headroom 大 → 杠杆在读出，训练端的投入大概率是浪费。
2. 若杠杆在读出，再测秩损失：它给可恢复量一个上界提示（本文：秩损失 20~59% 对应恢复率 72~37%）。
3. 再看架构端有没有零成本的降维空间（本文：池化密度）。

本文给出 headroom 的两个对照值，说明第一步本身有区分力：非线性失真 +20.26、加性高斯噪声 +7.50。随机扰动与确定性系统误差在这个量上清楚地分开——前者需要的是表征层面的平滑，后者需要的是解码层面的重定向。

4.3 若要落到真实器件的数字后端

本节把上面的结论映射到存内计算的现实约束上：模拟阵列负责乘累加、权重固化，阵列输出经 ADC 回到数字域，失真发生在模拟域的输入侧。判定分三档——可行 / 需改动 / 不可行：

组件	判定	依据
读出适配	需改动	要求读出层位于数字域、或阵列里那一小块可重写。读出层只占全模型参数的 5.04% (SimpleCNN) / 0.55% (VGG-11)，挪出阵列对面积影响很小
在线 α 估计	可行	一次 d 维点积 ($d = 128/512$)，算力占主干前向的 3.8e-4% / 2.4e-4%
软门控	可行（前提同第一条）	数字域逐元素运算，每次推理约 400 次操作；干净头是冻结不动的那一个，正好可以固化在 ROM 里
冻结主干	可行	就是”不训练主干”，天然符合权重固化
MaxPool 密集主干	设计阶段零成本 / 部署后不可行	它是网络定义的改动，只能在投片前决定；好消息是它零训练成本
全网络重训	不可行	阵列权重是烧录/固化的；而且训练端的四条路本来就救不了尾部（第 3.5 节）

推荐的落地顺序（三步，前两步都有实测支撑）：

1. 架构端先上：MaxPool 密集主干。零训练成本，尾部 +15.52 个百分点（同协议同 seed 配对）——但它只能在投片前决定，所以这一条要最先定。

2. 读出端再训： α -混合鲁棒头（即上文的读出适配；24 epoch，约 12 分钟）。尾部再抬升一截，代价是干净精度下降——代价的大小决定了第三步要不要做。
3. 门控按需加：仅当鲁棒头的干净代价足够大时（CIFAR-100 式细粒度任务，代价 -5.89 ）才加，且先查两个头的逐 α 曲线（第 3.10 节的前提）。代价 $\lesssim 1$ pp 时直接用单鲁棒头。

一个必须说清的结构性前提：以上全部依赖读出层可写。若某款 CIM 把读出层也固化在阵列里，本方法整体不成立——这不是精度问题，是可行性问题，因此它出现在第 5 节的局限 (6) 里。

本节的边界：以上是推演，不是实测。没有硬件实测、没有 RTL 或功耗仿真、也没有写出“读出层挪到数字域”的接口约定（时序、位宽、与 ADC 的对接）。面积、延迟、功耗的绝对值本文没有算过。

4.4 打开的问题空间

1. 秩损失到可恢复量的曲线是什么形状？三点提示”先平后塌”，但三点定不了形状。这直接影响能否把可恢复量写成一个由秩损失预测的上界。
2. 若失真形态不是三次多项式，headroom 还剩多少？高斯对照给了下界；更高阶、带温度漂移或器件失配的形态族未测。
3. α -无关读出的可达上界在哪？本文的读出适配在不知道 α 的情况下只拿到 43.31（3 seed），而 oracle- α 探针为 48.35，两者相差 5.04 个百分点（48.35 - 43.31，同一 $\alpha = +0.3$ 点）。这个缺口里有多少是”不知道 α ”的代价、有多少是优化不足，本文未分离。
4. 多头扩展：把 α 与噪声强度 σ 同时估出来、三头调度，是否优于单训 σ 的配方？（本文的联合扰动数据已显示 σ -only 最优、 α 注入是净负担，但未做三头路由。）

5 局限与未来工作

以下几项限制各自导致了一个由本文发现引出的重要问题处于未决状态。

(1) 失真模型是参数化假设，且无硬件实测。全部收益都测在式 (1) 这一族上。若真实 CiM 的非线性更接近高阶多项式、带温度依赖、或器件间失配有随机成分，headroom 还有多大、读出杠杆是否成立，本文无法回答。已知的下界来自高斯对照（headroom 从 20.26 降到 7.50）。下一步：结合真实 CiM 宏的实测特性标定失真参数，在形态族上重测 headroom。

(2) 深层主干是单次训练产物。VGG-11 与 ResNet-18 的主干各只训了一次；读出侧的 3 个种子只反映读出训练的数据顺序与采样随机性，不含主干训练方差。而深层上已知的方差已经不小（固定主干换读出种子，干净精度从 63.54 摆到 67.61）。因此涉及深层的所有差值——包括图 9 上 ResNet-18 的 -1.14 ——是否在主干种子方差内无法裁决。下一步：每个深层主干重训 2 个种子（约 16 小时）。

(3) 池化保护的定量分解没有定下来。同协议 3 种子下 avg 与 max 的差值只有 $+1.17$ ，落在 1~2 个百分点区间，差值的标准误 1.03（ $z \approx 1.1$ ）。本文只能给出方向（保护主要来自降维），无法裁决”降维：非均值聚合”的比例。这条路的根本瓶颈是 avg 与 max 本身的差距太小。下一步：换效应量更大的对照（池化窗口 2×2 vs 4×4 ，或池化层的位置分布），或补到 ≥ 8 个种子每组。

(4) 秩-恢复关系只有三个点（见图 7）。下一步：补第 4 个容量档。

(5) 跨实现的 5.55 个百分点差异未归因（表 4）。已验证无效的路径是换评估路线；必须动训练循环。下一步：逐行对齐两个训练循环做二分。

(6) 读出适配要求读出层可写，且本文未评估其硬件代价。读出层占全模型参数的 5.04%（SimpleCNN）/ 0.55%（VGG-11），结构条件是”读出层位于数字域或可重写”。但面积、延迟、功耗

的真实代价需要 RTL 或流片验证，超出本文范围。若某款 CiM 把读出层也固化在阵列里，本文的方法整体不成立。

(7) CIFAR-10 侧的读出只有单 seed，跨数据集的”恢复率标度律”因此是提示性的。上文的 CIFAR-10 读出表为单 seed (CIFAR-100 侧为 3 seed)，而”恢复率在更简单的任务上更高”这条跨数据集对比 (85.4 / 88.7 / 48.2% 对 72.2 / 70.2 / 36.9%) 正建立在这一对比之上。两个量要说清：恢复率差 (11.3~18.5 个百分点) 是本文实测的读出层过程自由度 $\Delta_{\text{proc}} = 3.45 \text{ pp}$ 的三到五倍，所以主效应远大于”换个方式拟合读出”；但 CIFAR-10 侧只有一次运行，因此无法把”数据集差”与”那一次训练的运气”分开。下一步：把 CIFAR-10 侧的读出补到 3 seed (成本与已有的读出实验同级)。

(8) 读出杠杆只在 $|\alpha| \leq 0.3$ 上评估过。本文全部读出适配产物的 α 网格只有 $\{-0.3, \dots, +0.3\}$ 七个点 (CIFAR-10 与 CIFAR-100 两侧皆然)。而探针显示更远处缺口反而更大： $\alpha = +0.4$ 时自带头已降到 12.32、线性探针仍有 43.22 (headroom +30.90)； $\alpha = +0.5$ 时是 6.09 对 36.91 (+30.82)。读出杠杆在那两处还能兑现多少，本文无法回答——现有每一条读出结论都只在 $|\alpha| \leq 0.3$ 窗口内取得，而这个窗口之外恰好是自带头最需要被救的地方。下一步：把读出适配的评估扩到 ± 0.5 (成本与已有的 24ep 读出同级)。

(9) 架构杠杆在不含池化的主干上没有旋钮。”池化密度是独立架构杠杆”这一结论在本文三个主干上成立，但三者都含池化层；本文所用的 ResNet-18 已按 CIFAR 适配去掉了 ImageNet 版的初始 MaxPool，其 MaxPool 数为 0 (见表 1)。对本身不含池化的架构 (含注意力主干)，这条杠杆无对应旋钮，而”架构端先上”正是本文落地顺序的第一步。下一步：测一种不依赖 MaxPool 的降维方式 (把残差主干的 stride 下采样改为池化、或把平均池换成最大池——两者都是零训练成本的网络定义改动)。

(10) 全部证据来自 CIFAR 上的小型卷积主干。四个主干的参数量跨度 0.25M~11.2M (以 CIFAR-100 计)，架构形态全部是 ReLU + 卷积/池化堆叠 (无注意力主干、无归一化层主干)，数据集只有 CIFAR-10/100。本文建议的测量顺序 (先测 headroom、再测秩损失、再看架构端) 是否对注意力架构与更大规模成立，本文未验证；异构架构的读出层形态 (是否线性、是否共享权重) 也可能改变 headroom 的可测性。下一步：在一个有清晰”末端特征”的注意力主干上重做第一步。

(11) 缺一条与部署同构的读出臂：”不知道 α ”到底值多少。本文的探针读数是 oracle- α 的 (假定失真强度已知)，而与部署同构的读出 (在 $\alpha \sim U[\pm 0.3]$ 上训练、 α 未知) 与之相差 5.04 个百分点 (48.35 对 43.31，见第 3 节开放问题第 3 条)。这 5.04 里有多少是”不知道 α ”的代价、多少是读出训练不足，需要一条同样用 α 混合数据训练、但按”不知道 α ”评估的对照臂才能分开；本文缺这一臂，因此开放问题第 3 条只能停在”缺口有多大”。下一步：补该臂 (与已有的读出实验同构，只换训练分布)。

(12) 低位量化与读出适配从未组合测量。本文关于”低位量化在池化密集架构上反转为增益”的证据，取自未施加读出适配的原始分类头，且固定在 $\alpha = +0.3$ 。两条杠杆 (量化位宽、读出适配) 从未在同一份产物上同时改变。二者的收益是可加的、还是互相挤占同一个机制 (对失真的补偿)，本文无法判定；本文给出的是”分层答案” (哪种架构该用哪一类手段)，它对需要同时使用两种手段的读者不成立。下一步：在池化密集主干上做 2×2 (读出适配 $\times 4 \text{ bit} / 8 \text{ bit}$)。

6 结论

在逐层三次多项式非线性失真下，神经网络在灾难尾损失的是读出的可解码性而非表征中的信息 (headroom 20.26 个百分点，而同一探针在高斯噪声下只有 7.50)。这一诊断直接给出了修复路径：冻结全部模拟权重、只重训最后的线性层，在三个主干上把 $\alpha = +0.3$ 提升 $+15.2 \sim +31.8$

个百分点，成本为主干重训的 $1/5 \sim 1/16$ ，并一致超过所有全网络鲁棒训练配方；而训练端的四条补救路径没有一条改善尾部。架构端的池化密度提供一个零成本的第二杠杆（同协议同 seed 配对 +15.52 个百分点），其保护主要来自降维。两个杠杆在尾部可以同时受益，但不独立相加。失真强度可由岭回归在线恢复，使门控可以逼近 oracle，但门控有效需两个前提同时成立，其边界由本文给出。最后，本文报告一条方法学观察：同一份权重在两条评估路径下读数逐位相同，而不同训练脚本产出的权重稳定相差 5.55 个百分点且原因未明——在归因之前，精度数字不应跨训练实现引用（本文不引用）。

A 关键数值汇总

表 5: 本文引用的主要数值与出处

数值	取值	出处
探针 headroom @+0.3（非线性 / 高斯）	+20.26 / +7.50	v7_probe_audit/ra_onprotocol
读出适配 @+0.3（三主干，3 seed）	43.31 / 47.79 / 26.82	v3_readout_repair/*ep24*.cs
全网络鲁棒训练 @+0.3（最好）	29.89 / 24.69 / 6.22	task3_simplecnn/Exp3_FullRo
池化密度 $2 \rightarrow 5$ @+0.3（同协议配对）	26.03 $\rightarrow$ 41.55 (+15.52)	v3_methods/*_uniform/
池化密度 $2 \rightarrow 5$ @+0.3（干净臂，3 seed）	40.29 $\pm$ 1.58	simple_cnn_mp_clean_uniform
有效秩损失 @+0.3（三主干）	20.6% / 33.3% / 58.7%	v5_rank_collapse/rank_stats
秩损失 $\rightarrow$ 恢复率（三点， r ）	-0.960	同上一行 + v3_readout_repair
池化同协议 3 seed 差（avg-max）	+1.17 (SE 1.03; 未舍入 $21.7767 - 20.6033 = 1.1733$)	台账 §13.8
过程自由度 Δ_{proc} ($\alpha = 0$ / +0.3)	3.46 / 3.45	v7_etf_readout/proc_sensiti
门控红利 (C100/mp)	-5.89 $\rightarrow$ +2.90	recipe_simple_cnn_mp.csv
门控红利 (ResNet-18/Exp3)	-4.36 $\rightarrow$ -1.14	recipe_robust_resnet18_exp3
α 估计器（6 组：4 浅 2 深）	R^2 0.827~0.978	v5_full_recipe/recipe*.csv
Dithering 增益 (C100 / C10)	+2.84 / +6.53	extension5_dithering_vgg11/
跨实现尾部差	5.55 ($z = 9.4$; $26.58 - 21.03$, 3 对 6 个 run)	台账 §14.6
同协议方差 / 混协议方差	± 0.392 / ± 2.561	台账 §13.10

B 低位量化机理的跨数据集平行对照

正文第 3 节 H1-H3 的机理量取自 CIFAR-10 侧；下表把 CIFAR-100 侧的对应量平行列出。两侧由同一脚本、同一协议产出（固定 $\alpha = +0.3$ ），唯一差别是数据集与主干权重。（ α 固定为 +0.3，故表中“clean”指 $\alpha = 0$ 的未量化基线。）

出处: outputs/extension5_dithering_vgg11/ 与 outputs_cifar100/extension5_dithering_vgg11/ 下的 group_a_bits_scan.csv ((a)(d) 的精度)、activation_stats.csv ((b) 的峰度)、flip_statistics.csv ((c)) 与 group_c_pure_noise.csv ((c) 末行的剂量匹配噪声)。两点读数：机理的定性结论在两个数据集上一致（H1 否决、H2 确认、H3 支持）；而幅度不可跨数据集搬运——同一条“3 bit 比 4 bit 更尖”，在 CIFAR-10 上只是 0.30 个点的代价，在 CIFAR-100 上却是 8.88 个点。

参考文献

- [1] Yu S, Chen P Y. Emerging memory technologies: recent trends and prospects[J]. IEEE Solid-State Circuits Magazine, 2016, 8(2): 43-56.

表 6: 低位量化机理的量: CIFAR-10 与 CIFAR-100 的平行对照

量	条件	CIFAR-10	CIFAR-100
<i>(a)</i> 精度增益 (<i>VGG-11</i>)			
4 bit – 8 bit	—	+6.53	+2.84
<i>(b)</i> 分类器输入峰度 (<i>H2</i>)			
	clean	1.486	2.541
	8 bit	0.110	0.847
	4 bit	0.214	0.980
	3 bit	0.384	1.023
	2 bit	0.069	0.088
<i>(c)</i> 样本级翻转 (<i>H1</i> , <i>VGG-11</i> , 4 bit 相对 8 bit)			
4 bit 救回 / 杀死	计数 (比值)	860 / 207 (4.15:1)	655 / 371 (1.77:1)
4 bit 净增	计数	+653	+284
8 bit + 最优剂量噪声	高斯 / 均匀 (净增)	+7 / -19	-20 / -9
剂量匹配的纯噪声	高斯 / 均匀	-2.45 / -1.87	-3.12 / -2.48
<i>(d)</i> 架构对照 (<i>H3</i>): 4 bit – 8 bit			
ResNet-18 (0 MaxPool)	—	+0.39	-0.21
SimpleCNN (2 MaxPool)	—	-13.68	-14.71

- [2] Ankit A, El Hajj I, Chalamalasetti S R, et al. PUMA: a programmable ultra-efficient memristor-based accelerator for machine learning inference[C]//ASPLOS. Providence: ACM, 2019: 715–731.
- [3] Zhu M, Liu Y, Wang Z, et al. Nonlinearity-aware training for accurate and robust compute-in-memory neural networks[J]. IEEE TCAD, 2022, 41(11): 3961–3973.
- [4] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//CVPR. Salt Lake City: IEEE, 2018: 2704–2713.
- [5] Wannamaker R A, Lipshitz S P, Vanderkooy J, et al. A theory of nonsubtractive dither[J]. IEEE Transactions on Signal Processing, 2000, 48(2): 499–516.
- [6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. Las Vegas: IEEE, 2016: 770–778.
- [7] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//ICLR. San Diego: ICLR, 2015: 1–14.
- [8] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.
- [9] Kumar A, Raghunathan A, Jones R, et al. Fine-tuning can distort pretrained features and underperform out-of-distribution[C]//International Conference on Learning Representations. 2022. arXiv:2202.10054.
- [10] Xiao Z, Naik V B, Lim J H, et al. Adapting magnetoresistive memory devices for accurate and on-chip-training-free in-memory computing[J]. Science Advances, 2024, 10(38): eadp3710.

- [11] Rabby G, Auer S. When Graph-JEPA learns the wrong thing: diagnosing and repairing category-conditional collapse[R]. 2026. arXiv:2608.20516.
- [12] Reblitz-Richardson O. When probing accuracy saturates, fragility resolves: a complementary metric for LLM pre-training analysis[R]. 2026. arXiv:2606.11375.
- [13] Wang D, Shelhamer E, Liu S, et al. Tent: fully test-time adaptation by entropy minimization[C]//International Conference on Learning Representations. 2021. arXiv:2006.10726.
- [14] Liang J, Hu D, Feng J. Do we really need to access the source data? Source hypothesis transfer for unsupervised domain adaptation[C]//International Conference on Machine Learning. 2020: 6028–6039. arXiv:2002.08546.