

存算一体芯片逐层非线性失真： 机制、边界与读出层修复

——技术报告与内部归档（六阶段全记录）

黄奕皓

中国科学院大学计算机科学与技术，北京

huangyihao24@mails.ucas.ac.cn

归档版本 v1.0-archive, 2026 年 9 月

摘要

本报告是存算一体芯片非线性失真项目的完整技术归档，覆盖六个研究阶段的全部结论、失败记录、方法学制度与工程推演。与面向期刊的论文版本相比，本报告额外保留三类材料：**(a) 研究历程**——三次“先归因、后被自己否认”的完整链条；**(b) 工程落地推演**——把结论映射到真实 CIM 数字后端的三档判定；**(c) 可复现性手册与方法论制度**——使后来者能重建每一个数字，并知道哪些比较是无效的。

核心科学结论为：在逐层三次多项式非线性失真下，网络在灾难尾 ($\alpha = +0.3$) 损失的是读出的可解码性而非表征中的信息（探针 headroom +20.12 个百分点，同一探针在加性高斯噪声下仅 +7.00）；据此，冻结全部模拟权重、只重训最后的线性层，即可以 1/15~1/30 的训练成本在尾部超过所有全网络鲁棒训练配方（三主干：28.09/15.98/6.22 $\rightarrow$ 43.31/47.79/26.82）；而训练端的四条补救路径全部失效。架构端的池化密度是与之正交的零成本杠杆（+14.38 个百分点），其保护主要来自降维。

本报告同时记录一条对同领域有直接约束力的方法学结论：**跨训练实现比较精度数字会得到不可移植的结果**——同一份权重在两条评估路径下读数逐位相同，而两个训练脚本产出的权重稳定相差 5.55 个百分点，该差异经三次干预实验仍未归因，按已知未知记录。

关键词：存算一体；非线性失真；读出瓶颈；有效秩；鲁棒性杠杆；测量纪律；技术归档

目录

1	阅读指南	3
2	问题、口径与产物	3
2.1	失真模型	3
2.2	度量口径与自检	3
2.3	数据集、主干与产物布局	3
3	六阶段的技术内容	4
3.1	阶段划分	4
3.2	第一、二阶段：任务层结果与三项优化（CIFAR-10）	4
3.3	失真有多大破坏力，往哪里累积	6
3.4	灾难尾丢的不是信息，而是读出的可解码性	7

目录	2
3.5 修复：冻结主干、只重训线性读出	7
3.6 训练端的四条路径为什么全部失效	7
3.7 损伤的形态：维度丢失，不是类间距缩小	8
3.8 第二个杠杆：池化密度	8
3.9 两个杠杆的叠加与在线估计	8
3.10 门控的边界	9
3.11 失真与量化的联合作用	10
4 研究历程：三次”先归因、后被自己否认”	10
4.1 第一次：把处理效应误读成噪声（ ± 3.15 混协议）	11
4.2 第二次：把脚本差异误读成采样粒度	11
4.3 第三次：把序列位置误读成消耗数	11
4.4 三次翻案的共同点与制度沉淀	12
5 工程落地推演	13
5.1 场景设定	13
5.2 三档判定	13
5.3 唯一的硬约束	13
5.4 风险清单（不是结论）	14
5.5 没做的事	14
6 可复现性手册	14
6.1 环境	14
6.2 复现一个数字（三条命令）	15
6.3 重新出图	15
6.4 读文档顺序	15
7 局限、停车场与下一步	16
7.1 局限（每条导致一个由本文发现引出的问题未决）	16
7.2 停车场（只登记不执行）	17
7.3 下一阶段的入场券与判据	17
7.4 已明确排除、不应重走的方向	17
8 结论	18

1 阅读指南

你想知道什么	读哪里	页数估计
项目做出来的核心结论	第 3 节（六阶段技术内容）	5
某个方法为什么有效	第 3.4 节（机制链）	3
当初怎么走弯路的	第 4 节（三次翻案）	3
能不能落到硬件上	第 5 节（工程推演）	3
怎么复现一个数字	第 6 节（三条命令）	2
还有什么没做	第 7 节（停车场与入场券）	3

本报告的性质：它是一份归档，不是一份投稿论文。因此它刻意保留了负面结果、被否证的假说、以及三次失败的归因尝试——这些材料的价值在于让后来者不必重走。所有数字均可追溯到一个具体文件或命令输出；无法追溯的陈述一律不写入。

2 问题、口径与产物

2.1 失真模型

模拟域乘累加的输入侧失真建模为逐样本归一化后的三次多项式：

$$y = \alpha \hat{x}^3 + (1 - \alpha) \hat{x}, \quad \hat{x} = \frac{x}{\|x\|_\infty}, \quad (1)$$

$\hat{x}$ 按 batch 维逐样本做无穷范数归一化，避免样本间串扰；失真通过前向钩子挂在每一个 `Conv2d` 与 `Linear` 算子的输入侧，逐层注入，每层可以有自己的 α （除特别说明外，扫描时同一个 α 施加到所有层）。 $\alpha > 0$ 时中段被压低， $\alpha < 0$ 时中段被抬高。

2.2 度量口径与自检

全阶段统一四个标量指标：

指标	定义
<code>clean</code>	$\alpha = 0$ 时的测试精度
<code>drop@0.3</code>	<code>clean</code> 减去 $\alpha = +0.3$ 时的精度
<code>mid_band</code>	$\alpha \in \{-0.2, -0.1, +0.1, +0.2\}$ 四点的平均精度
<code>mean7</code>	$\{-0.3, -0.2, -0.1, 0, +0.1, +0.2, +0.3\}$ 七点的平均精度

评估协议：全量测试集（10000 张）、best 权重、纯推理。每个实验的强度扫描文件里 $\alpha = 0$ 的行必须等于同目录 `metrics.json` 的 `best_test_acc`（容差 0.01）。该自检记在全局台账 `results_master.csv` 的 `pairing_check` 列，当前状态为 **152 行数据、0 FAIL**（58 行 PASS / 94 行 n/a；n/a 者为复用扫描与读出适配行，本就没有可配对的 `metrics.json`）。

2.3 数据集、主干与产物布局

数据集：CIFAR-10（10 类）与 CIFAR-100（100 类）[8]。主干四个，参数量随类别数变化（见表 1）。

产物目录按数据集分离：`outputs/`（CIFAR-10）与 `outputs_cifar100/`（CIFAR-100）；全局台账由 `build_ledger.py` 只读扫描重建，不修改任何既有产物。

表 1: 主干、参数量与设计角色

主干	参数量 (C10 / C100)	Conv	MaxPool	残差	设计角色
SimpleCNN	242 474 / 254 084	4	2	无	浅层基线
SimpleCNN+3×MP	242 474 / 254 084	4	5	无	架构杠杆对照 (参数量不变)
VGG-11	9 231 114 / 9 277 284	8	5	无	深度变量
ResNet-18	11 173 962 / 11 220 132	17	0	有	残差变量




图 1: 任务 1: 三个架构的非线性敏感性 (CIFAR-10)。 $\alpha = +0.3$ 时 SimpleCNN / VGG-11 / ResNet-18 分别跌 29.82 / 53.10 / 75.01 个百分点。数据: outputs/task1_*/alpha_sensitivity.csv。

3 六阶段的技术内容

3.1 阶段划分

阶段	主题	产出
一	敏感性、感知训练、架构增强、三项拓展	破坏力与方向性; NAT 的架构依赖; Exp2 方案
二	外推边界、Dithering 机理、深层迁移	NAT 是分布内属性; Dithering 机理判决; 方案可迁移
三	台账统一与四条新结论	读出瓶颈律与读出适配方法; 训练端四条负结果
四	读出端 vs 训练端的分解	在线 α 估计与路由; 架构杠杆的独立发现
五	完整配方、池化成因、跨数据集复现	池化保护的排除线; 事前预登记复现
六	定律化与落地	秩-恢复曲线; 深层门控边界; 工程推演; 测量纪律

3.2 第一、二阶段：任务层结果与三项优化 (CIFAR-10)

前两阶段以 CIFAR-10 为主线，对应赛题的三项任务与三项拓展，以及评审意见带来的三项优化。它们的完整数值见竞赛版文档，此处给出归档要点。

任务 1: 正向失真的破坏力是负向的 3.4 倍 (以 SimpleCNN 上 $|\alpha| = 0.3$ 计); 误差从浅层向深层累积, fc 层的输出与干净输出的余弦相似度仅 0.895; 残差连接是误差放大器——ResNet-18 的跌幅 (75.01) 远重于 VGG-11 (53.10) 与 SimpleCNN (29.82)。

任务 2: 非线性感知训练在纯前馈网络上有效 (Scratch 策略 +9.15 / +8.04), 但残差网络在极限正向失效甚至退化 (-1.44); 效果与注入点数量负相关 (5 $\rightarrow$ 9 $\rightarrow$ 18)。中等失真上仍

表 2: 任务 2 与任务 3 的关键读数 (CIFAR-10, $\alpha = +0.3$, %)

任务	配置	SimpleCNN	VGG-11	ResNet-18
任务 2	clean (基线)	55.08	36.70	17.08
	NAT-Scratch	64.23 (+9.15)	44.74 (+8.04)	15.64 (−1.44)
	NAT-Finetune	56.08 (+1.00)	39.96 (+3.26)	19.89 (+2.81)
任务 3	Exp1 (+ 残差校准)	63.63	—	—
	Exp2 (+ 分层加权)	68.76	—	—
	Exp3 (+ 非对称采样)	69.14	—	—




图 2: 拓展 2: 非线性失真与加性高斯噪声的对照 (CIFAR-10)。三种架构上的排序完全不同, ResNet-18 上两者完全反转。数据: outputs/extension2_*/.../{gaussian,nonlinearity}_sensitivity.csv。

然有效 (ResNet-18 在 $\alpha = -0.2$ 上 +18.84)。

任务 3: 叠加残差校准模块与分层加权采样后, SimpleCNN 的 $\alpha = +0.3$ 达 **68.76%**。消融显示分层加权是贡献最大的单项 (+5.13), 非对称采样边际贡献仅 +0.38; 三个配置的干净精度 (87.19 / 87.37 / 87.59) 全部高于未增强的干净模型 (84.90) ——残差校准模块兼具正则化作用、不引入干净精度代价。

拓展 1-3: 脆弱性随深度与残差连接递增; 非线性失真与高斯噪声的鲁棒性不可跨域迁移 (SimpleCNN 对高斯更脆弱 37.02 vs 55.08, ResNet-18 则反之 57.15 vs 17.08); 量化与非线性的联合作用呈三分格局——SimpleCNN 超加性恶化 (4bit $\Delta = -7.23$)、VGG-11 次加性即 Dithering ($\Delta = +7.82$)、ResNet-18 地板效应 ($\Delta = +1.05$)。

优化二 (Dithering 机理) 的关键结论在本节之后的”失真与量化的联合作用”中给出; 其核心是否决了第一阶段给出的”随机共振”解释与”ADC 前注噪”建议 (等剂量注噪的增益约为零), 机理改写为”离散化分布重塑 + MaxPool 架构载体”。

优化一 (外推边界) 与优化三 (深层迁移) 的要点: 非线性感知训练的增益严格限定在训练分布内——正侧在 $\alpha \approx 0.4$ 处归零 (+0.77) 并反转为劣势 ($\alpha = +0.5$ 时 −10.77), 而负侧随外推距离不降反升 ($\alpha = -0.6$ 处 +8.22); 架构容差窗口随深度单调收窄 (SimpleCNN 约 $[-0.35, +0.25]$ 、VGG-11 约 $[-0.25, +0.2]$ 、ResNet-18 约 $[-0.15, +0.15]$)。Exp2 方案可完整迁移到深层: VGG-11 在 15 个扫描点上全胜三条基线 (相对干净模型平均 +10.22), ResNet-18 全程无败; $\alpha = +0.3$ 的增益为 +13.55 / +3.04; 两架构的干净精度 (91.27 / 93.27) 均为四组权重中最高。多点校准 (5/8 处) 修复了 SimpleCNN 单点版本 (1 处) 在负侧外推输给 NAT-Scratch 最多 12.58 个百分点的短板。




图 3: 拓展 3/优化二: Dithering 增益的架构依赖 (CIFAR-10, $\alpha = +0.3$)。增益与 MaxPool 密度同向, 但要足够密——2 个 MaxPool 的 SimpleCNN 是负增益, 0 个的 ResNet-18 无效应。数据: outputs/extension5_dithering_vgg11/arch_dithering_summary.csv。




图 4: 优化三: 增强方案向深层主干迁移 (CIFAR-10)。灰色虚线为同架构干净模型, 橙色为 Exp2 方案。VGG-11 上 Exp2 在全部 15 个扫描点上都优于三条基线; ResNet-18 上全程无败, 但正侧强失真区的绝对精度仍然很低。数据: outputs/extension6_deep_robust/alpha_wide_scan_deep_robust.csv。

3.3 失真有多大破坏力, 往哪里累积

$\alpha = +0.3$ 时 SimpleCNN 从 59.99 掉到 28.09、VGG-11 从 67.09 掉到 16.92、ResNet-18 从 72.09 掉到 2.70。按容量排序, 干净精度越高、跌幅越大, 这条反相关关系在同数据集内跨容量单调。

”3.4 倍不对称” 这个常被引用的数字不是常数: CIFAR-10/SimpleCNN/ $|\alpha| = 0.3$ 上是 3.4, CIFAR-100 同模型上只有 1.87。跨条件稳定成立的只有方向。

把”最脆弱的位置”分成注入位置与观测位置后, 一个反直觉结果出现: 单层注入探针中最敏感的是中间层卷积 (conv2 跌幅 -12.43、conv3 -7.56), 而 fc 单点注入只有 -0.68。全 5 层同时注入的跌幅 31.90 远超线性累加的 23.33 (超加性 -8.57)。fc 是误差的汇聚与观测点, 不是注入敏感点。




图 5: 失真的方向性与容量依赖 (CIFAR-100)。三个主干在七点上的扫描；正侧跌落显著大于负侧，且随容量与深度单调放大。数据: `outputs_cifar100/task1_*/alpha_sensitivity.csv`。

表 3: 读出适配 vs 全网络鲁棒训练 (CIFAR-100, $\alpha = +0.3$, 精度%)

方法	训练成本	SimpleCNN	VGG-11	ResNet-18
干净模型 (不处理)	—	28.09	16.92	2.70
读出适配 (24ep, 3 seed)	12~30 min	43.31±0.16	47.79±3.18	26.82±3.40
全网络鲁棒训练 (最好)	1~6.5 h	26.57	24.69	6.22

3.4 灾难尾丢的不是信息，而是读出的可解码性

这是全项目的枢纽结论。图 6 用探针把它测出来。

$\alpha = +0.3$ 时探针达 47.89%、自带头 27.76%，headroom **20.12**； $\alpha = +0.4$ 时 30.41、+0.5 时 30.38。失真越强 headroom 越大。

对照通路的判别力：同一套探针在加性高斯噪声 $\sigma = 0.3$ 下 headroom 只有 7.00。随机扰动与确定性系统误差在”信息还剩多少”这个量上清楚地分开。

3.5 修复：冻结主干、只重训线性读出

读出适配在三个主干上一致超过”全网络重训”整类配方，可训练参数只占 5.04%/0.55%，训练时间低 1~2 个数量级。代价是干净精度下降 3.19~6.67 个百分点。

必要的自我校验：单点读出适配 (只对 $\alpha = +0.3$ 拟合) 确实是再分配——该点 +24.70 但干净精度 -20.36、 $\alpha = -0.3$ 掉 25.71，七点均值反而低于基线。起作用的是**分布式版本** ($\alpha \sim U[\pm 0.3]$ 上训练)，它在每个扫描点都不显著劣化。同一层参数、两种训练方式给出质上不同的结果。

3.6 训练端的路径为什么全部失效

四条独立路径：采样预算分配 (三种轮廓，最好 26.13)、 α 空间对抗训练 (24.32, -1.71)、课程式采样 (21.78, -4.25)、训练范围外推至 ± 0.5 (20.48, -5.55)。基准 (均匀采样) 为 26.03。没有一条超过基准。




图 6: 探针 headroom: 灾难尾的标签信息仍然线性可达。在同一冻结主干的末端特征上, 线性探针 (实心) 与模型自带分类头 (空心) 的精度; 7 个 α 点, CIFAR-100 全量测试集、best 权重、单种子。 $\alpha = +0.3$ 时相差 20.12 个百分点; 同样的探针在加性高斯噪声 $\sigma = 0.3$ 下只有 7.00。数据: outputs_cifar100/v3_probe_info_death/probe_results.csv。

最强的一条证据是范围外推: 模型已在 ± 0.5 上训练过, 测试 $\alpha = +0.5$ 时仍只有 2.71%, 同期负侧 -0.5 有 31.19% (差 28.5 个百分点)。正侧尾部不是采样覆盖问题, 而是结构性的不可训练区。

3.7 损伤的形态: 维度丢失, 不是类间距缩小

$\alpha = +0.3$ 时有效秩下降 20.6% / 33.3% / 58.7% (三个主干); 负侧同强度只降 2.0%。关键在于: 正侧失真下 **Fisher** 判别比反而升高——类间可分性没有变差, 丢失的是**维度**。这与幅度统计一致: $\alpha > 0$ 把深层特征的幅度向中段压缩 (fc 与 conv1 的 L2 范数比从 0.45 降到 0.23), 端点不变而中段被压低。

这解释了“信息还在但训练救不回”的表面矛盾: 信息仍存在于剩余维度里, 但这些维度在主干参数的可达域之外。

3.8 第二个杠杆: 池化密度

$\alpha = +0.3$ 从 28.09 提升到 42.47 (干净训练)、26.03 到 41.55 (鲁棒训练; 两侧同为逐层独立采样, 同 seed 配对, 增益 +15.52), 七点均值提升 4.5~4.9 个百分点, 干净精度不降。

机制: 保护主要来自降维。三个候选解释被逐一排除:

三条排除后, 唯一显著差异是空间元素数从 **256** 降到 **16**。同协议 3 种子对照: $5 \times \max$ 的 drop@0.3 为 20.60 ± 1.54 、 $5 \times \text{avg}$ 为 21.78 ± 0.91 , 差 +1.17 (标准误 1.03, $z \approx 1.1$) $\rightarrow$ “降维: 非均值聚合”的定量比例不予裁决, 只给方向: 保护主要来自降维。

3.9 两个杠杆的叠加与在线估计

架构杠杆与读出杠杆在尾部近似正交可叠加: ‘ $5 \times \text{MaxPool}$ 主干 + readout-NAT’ 的 $\alpha = +0.3$ 达 **49.12** (比架构单独 +6.65、比读出单独 +5.74)。




图 7: 读出适配跨三个主干一致抬升尾部 (CIFAR-100, 3 个种子的逐点均值)。实线为 readout-NAT (主干全冻结, 可训练参数占全模型 5.04%/0.55%) , 虚线为各模型自带头。数据: outputs_cifar100/v3_readout_repair/*ep24*.csv。




图 8: 训练端的补救路径在 $\alpha = +0.3$ 上全部不优于均匀采样基准 (CIFAR-100 / SimpleCNN)。数据: outputs_cifar100/v3_methods/*/alpha_sensitivity.csv。

失真强度可由读出特征的岭回归在线恢复: 四个主干 $\times$ 数据集组合上 R^2 0.827~0.935、MAE 0.036~0.061。

3.10 门控的边界

CIFAR-100/mp 上鲁棒头的干净代价 -5.89、门控收回 +2.90; 但把深层主干加进来后, 代价落进此前空白的 2~5 个百分点区间 (VGG-11 -3.45、ResNet-18 -4.36), 红利却没有跟着变大 (+0.68 与 -1.14)。

原因: ResNet-18 的自带头在负侧是崩的 ($\alpha = -0.2$ 只有 10.27%)。软门控按 $w = |\hat{\alpha}|/0.3$ 插值, 在 $\alpha = -0.2$ 处 $w \approx 0.67$, 三分之一权重的坏头把 45.64 拖到 39.21。

门控有效需要两个前提同时成立: 鲁棒头干净代价足够大; 两个头在整个 α 轴上都不能崩。两前提无法做成装前的量化自检——两种候选定义在已有 7 个点上都不分离红利的符号 (VGG-11 的最小精度只有 15.73 却红利为正; CIFAR-10/mp 主干 43 的最小精度有 69.23 却红利为




图 9: 正侧失真使末端特征的有效秩塌陷，负侧几乎不动。纵轴为按各模型 $\alpha = 0$ 归一化的有效秩 $\exp(-\sum p_i \ln p_i)$ ；特征维数分别为 128 / 512 / 512。数据：outputs_cifar100/v5_rank_collapse/rank_stats*.csv。

表 4: 池化保护的三个候选解释与排除依据

候选解释	检验	结论
池化”吸收”了失真	归一化三次映射与 max 是否可交换	在池化输入（post-ReLU，非负）上精确可交换（ $\max \Delta = 0.000e+00$ ），但可交换却非成因
质量向恒等区集中	5-pool 与 2-pool 的易感度 S 与不变区占比	5-pool 的 S 反而更高（conv4: 0.1527 vs 0.1134），不变区占比不变
max 的选择性	换成 top-2 池化（与 f_α 不可交换）	保护与 max 等同（42.98 vs 42.47，单种子）

-0.003)。

3.11 失真与量化的联合作用

VGG-11 上 4bit 量化的精度高于 8bit (CIFAR-100 +2.84、CIFAR-10 +6.53)。三假设判决：**H1 随机去相关否决**（等剂量注噪 -2.45/ -1.87，8bit+ 最优剂量噪声 -0.03；样本级翻转 4bit 为 4.15:1 而噪声条件约 1:1）、**H2 分布重塑确认**（分类器输入峰度 $1.486 \rightarrow 0.110$ ，4bit 恢复到 0.214）、**H3 MaxPool 交互支持（必要条件）**（无 MaxPool 的 ResNet-18 免疫 +0.39，但 2 个 MaxPool 的 SimpleCNN 是 -13.68）。

4 研究历程：三次”先归因、后被自己否认”

本节记录本项目最贵的一课。三次的形态完全一样：一个被当成”噪声”或”实现细节”的差异，被重新命名成一个”效应”，又被实验否认，最后回到未知。




图 10: 秩损失与读出可恢复量 (三点, $r = -0.960$)。恢复率 = 读出适配 @ $\alpha = +0.3$ 的精度 $\div$ 同一文件里原始头 @ $\alpha = 0$ 的精度。三点不足以定曲线形状; 形状提示为”先平后塌”。

4.1 第一次：把处理效应误读成噪声 (± 3.15 混协议)

当时的判断：一组鲁棒训练的 3 个种子, $\alpha = +0.3$ 的读数是 21.41 / 26.73 / 26.95, 标准差记为”尾部种子噪声 ± 3.15 个百分点” (同期干净精度只有 ± 0.51)。据此立下全项目规则：涉及尾部指标的对比必须 ≥ 3 个种子, 单种子尾部差值 < 3 个百分点不构成结论。

问题：这 3 个种子来自两个脚本。

否认：补跑同脚本的第三个种子后, 同协议的尾部标准差只有 ± 0.392 , 而混协议组是 ± 2.561 ——方差被估高约 6 倍。进一步的定量分解显示：混合组里两个数相差 5.32, 与实测的脚本级处理效应 5.52 几乎相等, 也就是说那 2.56 里绝大部分不是随机噪声, 而是两种训练配方之间的系统差。

制度补丁：方差对比必须同脚本、同一采样代码路径。

4.2 第二次：把脚本差异误读成采样粒度

当时的判断：同 seed 下两个脚本的 $\alpha = +0.3$ 相差 4.62 个百分点, 是纯协议标准差的约 11.8 倍。两脚本在数据加载、归一化、优化器、batch、epoch、调度器、增强、钩子机制、采样位置与评估口径上逐项核对一致, 因此判定”目前唯一可辨识的实现差异就是 α 采样粒度 (每批共享 vs 逐层独立)”, 并把它提升为候选定律。

否认：在同一个脚本里只切换粒度：shared 26.55 vs per-layer 26.57, 差 +0.02 ($z = 0.08$); 而同粒度跨脚本差 +5.52 ($z = 9.4$)。效应跟着脚本走, 不跟着粒度走。

制度补丁：涉及跨脚本比较时, 先做一次交叉评估 (把 A 的权重量到 B 的评估路径下), 确认评估侧无差。这条制度立刻在下一个实验中产生了价值。

更深的教训：”逐项排除混杂”这种论证在跨实现比较里不成立。两脚本的 8 项都一致、训练损失逐 epoch 差 ≤ 0.016 , 效应却稳定存在。没查出差异 $\neq$ 没有差异。

4.3 第三次：把序列位置误读成消耗数

当时的判断：交叉评估把差异锁到”权重侧” (见下), 再据 α 采样轨迹把根因定为”随机数流错开”——一个脚本的 shared 模式消耗 5 个随机数、另一个只消耗 1 个, 第 1 个 batch 相同、之后完全错开。

否认：在同一个脚本里把消耗数从 5 改成 1: 26.66 vs 26.55, 差 +0.11。消耗数不是因果。




图 11：池化密度是零训练成本的独立架构杠杆。MaxPool 从 2 个加到 5 个（参数量不变、训练脚本不变）： $\alpha = +0.3$ 从 28.09 到 42.47。虚线为第一阶段 100 epoch 产物，异协议，仅作参考。

表 5：5.55 个百分点差异的三次归因尝试

轮次	归因	结果
1	尾部种子噪声 ± 3.1	否认：三种子来自两脚本；同协议标准差只有 ± 0.39 ，混协议把方差估高约 6 倍
2	α 采样粒度	否认：同脚本切换粒度差 $+0.02$ ($z = 0.08$)，同粒度跨脚本差 $+5.52$ ($z = 9.4$)
3	随机数消耗位置	否认：同脚本把消耗数从 5 改成 1，差 $+0.11$

最终图景：一个脚本训出的鲁棒权重稳定落在 21.03 ± 1.00 （3 个种子，逐 seed 19.67~22.02），另一个脚本的六个 run 全部落在 26.58 ± 0.29 （逐 run 26.03~26.95），两组相差 **5.55** 个百分点 ($z = 9.4$)。组内极紧、组间稳定分离——这正是最令人困惑的地方：同脚本内换种子的流差异只值 ± 1 ，跨脚本却稳定值 5.55。

已排除的解释累计：种子噪声、 α 采样粒度、随机数消耗数、评估路径（8 个权重 $\times$ 2 条路径逐位相同）、训练动力学（逐 epoch 损失差 ≤ 0.016 ）。仍未归因，按已知未知记录。

最终的硬结论：任何精度数字不可跨训练实现移植；部署校准必须与部署训练同实现、同路径。

4.4 三次翻案的共同点与制度沉淀

三次都是用自己的实验推翻自己上一轮的结论。三次的根因按项目内部的总结都是”没做交叉评估”——或者说，在跨实现的比较里，任何没有做干预实验的归因都只是命名，不是因果。

沉淀下来的三条制度：

1. 降级一个数字，必须扫它的整条引用链。含均值、差值、占比这些派生量——它们不带原值，模糊搜索抓不到。这条制度立起来的原因是：一次降级只改了被降级的那一节本身，而它派生出去的数字还在下游活着（其中一处甚至是”同一行内混了两个脚本”）。
2. 方差对比三要求：同脚本 / 已交叉评估 / 未校准的组必须标注。后续补充第四条：跨实现比较前先做消耗数等价检查；且”同脚本 + 交叉评估”不足以让两套跨脚本数字可比。




图 12: 门控红利不随鲁棒头代价单调增长。七个点取自四个主干配置与两个数据集，各 3 个种子。七点 $r = -0.533$ ；去掉 CIFAR-100 远点后 $n = 6$ 时符号反转为 $+0.351$ 。数据: v5_full_recipe/recipe*.csv。

- 判据跑前写死，跑后不改。六个阶段的每个实验都在台账里留了预登记，包括那些最终被否证的。

5 工程落地推演

本节把研究结论映射到真实 CIM 的数字后端。**零实验、全部是推演**；每个数字要么来自仓库里的实测（标出处），要么是本节现算的（标算法）。判定分三档：**可行 / 需改动 / 不可行**。

5.1 场景设定

- 模拟阵列负责卷积与全连接的乘累加，权重**固化在阵列里**（这是 CIM 省功耗的前提）；
- 阵列输出经 ADC 回到数字域；
- 失真发生在模拟域的输入侧，逐层注入（式 (1)）；
- 数字后端（ADC 之后）可以做任意运算，代价是面积、延迟、功耗。

本节不涉及：ADC 位宽、阵列规模、模拟域校准电路。这些在项目数据里没有对应测量。

5.2 三档判定

5.3 唯一的硬约束

读出层必须落在数字域或可重写——这是全部结论里唯一需要硬件配合的地方。它的改动方向与 CIM 的常见架构一致：ADC 之后本来就是数字电路，把最后那一层放在数字域，很多设计本来就这么做。落地的关键问题是”你的 CIM 把哪一层当读出”，而不是”能不能改”。




图 13: 低位量化在池化密集架构上反转成增益 (VGG-11, $\alpha = +0.3$, CIFAR-100)。4bit 时精度最高, 比 8bit 高 2.84 个百分点。数据: `outputs_cifar100/extension5_dithering_vgg11/group_a_bits_scan.csv`。

5.4 风险清单（不是结论）

1. 失真形态的假设。全部收益都是在“逐层、逐样本 max 归一化、三次多项式”下测的。真实芯片的失真未必是这个参数化形式。参考：加性高斯噪声这条对照通路的 headroom 只有 +7.00，比非线性的 +20.12 低得多。
2. ADC 量化与失真的联合。已测：SimpleCNN 上 4bit 是超加性恶化，VGG-11 上是次加性。也就是说“数字域后处理能救多少”要分层看。
3. 跨脚本的采样序列差异必须处理。两个脚本训出的鲁棒权重稳定差 5.55 个百分点，评估路径已验证无辜。落地时两套数字不可混用。

5.5 没做的事

没有硬件实测，也没有 RTL/功耗仿真；没有把“读出层挪到数字域”的具体接口写出来（时序、位宽、与 ADC 的对接）；没有评估在线重训读出在现场是否可行；没有考虑多任务/多模型共享阵列的情形。

6 可复现性手册

6.1 环境

- Python 必须用 conda 环境 `pytorch_env`。直接敲 `python` 在本机解析到别的解释器（没有 torch）。
- 输出重定向到文件时设 `PYTHONIOENCODING=utf-8`，否则会在打印特殊字符（如 R^2 符号）处因编码中断。
- 显存 8GB。训练任务必须严格串行。本项目出过两次事故：并发 4 个带 DataLoader worker 的任务导致 Windows 提交内存耗尽；一次 CUDA 显存不足（两个训练同时跑）。
- `checkpoints/` 与 `*.log` 在 `.gitignore` 中，不进版本库。




图 14: 交叉评估: 差异不在评估路径。8 个权重分别在另一脚本原样导入的评估函数下重扫, 两条路径给出逐位相同的读数; 但两组权重稳定分成两簇。数据: outputs_cifar100/v6_p4e_crosspath/crosspath.csv。

6.2 复现一个数字 (三条命令)

```
# (1) 重建全局台账 (只读扫盘, 不修改任何既有产物)
<python> build_ledger.py
# -> [ledger] 152 rows -> results_master.csv
# -> [ledger] 冒烟过滤 = 5 行 (epochs==1 或 run_id 含 smoke; 产物留盘不动)
# -> [ledger] pairing FAIL = 0

# (2) 看某一行的四个字段 (例: CIFAR-100 / SimpleCNN / clean 基线)
grep "cifar100|simple_cnn|clean|7pt" results_master.csv
# -> clean=59.99 drop_at_0.3=31.9 mid_band_mean=53.5175 pos_0.3=28.09

# (3) 复算派生量 (七点均值), 核对文档里的 mean7
<python> tools/recalc_mean7.py
```

其中 <python> 为 /d/anaconda3/envs/pytorch_env/python (或本机等价路径)。

口径自检: 任意一个 run 的强度扫描文件里 $\alpha = 0$ 那一行, 必须等于同目录训练指标文件的 best_test_acc (容差 0.01)。

6.3 重新出图

```
<python> paper/figures/gen_figures.py # 期刊/技术报告版 (F01-F11)
<python> paper/figures/gen_figures_comp.py # 竞赛版 (C01-C08)
```

两个脚本都只读 CSV, 脚本内不硬编码任何精度数字, 末尾打印关键读数供交叉核对。中文图使用 SimHei 字体, 输出 PDF (矢量) 与 PNG (300 dpi) 两种格式。

6.4 读文档顺序

1. paper/storyline.md——Central Claim 与 Question-Experiment-Finding 映射表;

表 6: 把结论映射到 CIM 数字后端

组件	判定	依据
读出适配 (readout-NAT)	需改动	要求读出层位于数字域、或阵列里那一小块可重写。若读出也被固化在阵列里, 该方法不成立。读出层只占全模型参数的 5.04% (SimpleCNN) / 0.55% (VGG-11), 把它挪出阵列对阵列面积的影响很小
在线 α 估计 (岭回归)	可行	128/512 维点积, 算力占主干前向的 3.8e-4% / 2.4e-4%。真正的代价在面积: 多一份 d 维权重的存储
软门控 (双头插值)	可行 (前提同第一条)	纯数字域逐元素运算, 每次推理约 400 次操作。干净头是冻结不动的那一个, 正好可以烧进 ROM
冻结主干	可行	就是”不训练主干”, 天然符合权重固化
MaxPool 密集主干	设计阶段零成本 / 部署后不可行	它是网络定义的改动, 只能在投片前决定; 好消息是它零训练成本
全网络重训	不可行	阵列里的权重是烧录/固化的; 而且训练端四条路本来就救不了尾部

2. paper/results-outline.md——每个结果子节的 Question / Data / Finding / 1-hop;
3. paper/discussion-notes.md——2-hop 综合、一般原理、局限与未来工作;
4. experiments_ledger.md——逐实验的预登记判据与结果 (最权威的一手台账);
5. results_master.csv——机器可读的全局表;
6. 本报告第 4 节——最应该读的一节。

7 局限、停车场与下一步

7.1 局限 (每条导致一个由本文发现引出的问题未决)

(1) 失真模型是参数化假设, 且无硬件实测。若真实 CIM 的非线性更接近高阶多项式、带温度依赖、或器件间失配有随机成分, headroom 还有多大、读出杠杆是否成立, 无法回答。已知下界来自高斯对照 ($20.12 \rightarrow 7.00$)。

(2) 深层主干是单次训练产物。VGG-11 与 ResNet-18 的主干各只训一次; 读出侧的 3 个种子不含主干训练方差。而深层上已知的方差已经不小 (固定主干换读出种子, 干净精度从 63.54 摆到 67.61)。因此涉及深层的所有差值——包括门控红利 -1.14 ——是否在主干种子方差内无法裁决。

(3) 池化保护的定量分解没有定下来。(avg 与 max 的差值只有 $+1.17$, $z \approx 1.1$ 。)

(4) 秩-恢复关系只有三个点。

(5) 跨实现的 5.55 个百分点差异未归因。已验证无效的路径是换评估路线; 必须动训练循环。

(6) 读出适配要求读出层可写, 且未评估其硬件代价。

表 7: 待办清单

#	想法	成本	备注
0	鲁棒权重为何稳定低 5.55 个百分点? (机制解释)	≥ 2 次训练	已排除 5 项; 最高优先。核心谜题: 同脚本换种子只值 ±1, 跨脚本稳定 5.55 ($z = 9.4$)
1	采样粒度的跨架构复现	—	已取消: 粒度不是杠杆
2	粒度 × 深度的交互	与 #1 合并	前提已失效
3	其他采样粒度定义 (逐 block 独立等)	2~3 次训练	前提已失效
4	粒度对负侧的影响	0 (复用)	降为”数据已到手, 未分析”
5	R^2 上界能否用”池化压掉多少 α 信息”定量解释	0 (复用)	零成本
6	深层主干的重训方差	4 次训练 × 4h	贵, 但能说清深层结论的置信度
7	门控”两头都不崩”能否量化成装前自检	0 (复用)	已判否定 (两种定义都不分离)
8	深层双头为什么绝对值不低	0 (复用)	需先做同口径比较
9	秩-恢复曲线的形状 (”先平后塌”)	需第 4 个模型	再加 1 个模型即可看形状
10	跨数据集/跨架构的粒度复现	—	设计目的已失效, 等 #0 查清后决定

表 8: 建议的入场判据 (需裁决后才能生效)

入场券	判据	成本
#0 的机制解释	前置要求: 必须能解释”为什么同脚本换种子只值 ±1、跨脚本却稳定 5.55”这个量级差; 只给出一个新名字不算 (这条已被证伪三次)。已验证无效的路径: 换评估路径。建议做法: 逐行对齐两个训练循环做二分	≥ 2 次训练
深层主干方差	每个深层主干重训 2 个种子; 拿到后重算深层全部差值的置信区间	≈16 h
池化保护的两成分分解	每组 ≥ 8 个种子, 或换效应量更大的对照 (池化窗口 2×2 vs 4×4)	9~10 h
秩-恢复曲线形状	第 4 个容量档; 判据为四点能否否定”先平后塌”的形状	1 次训练 + 探针

7.2 停车场 (只登记不执行)

7.3 下一阶段的入场券与判据

7.4 已明确排除、不应重走的方向

为避免后来者重复试错, 以下方向在本项目中已被实验否定, 不建议再列为候选:

- 读出训练时混入干净样本以回收干净精度代价——权衡中性, 两档之间非单调;
- 在 ADC 前注入随机噪声以复现 Dithering——等剂量注噪的增益约为零 (假设已否决);
- 通过训练期采样设计 (预算分配 / 对抗 / 课程式 / 范围外推) 提升正侧尾部——四条独立负结果;
- 把”两头都不崩”做成量化自检——两种定义在已有数据上都不分离。

8 结论

1. 在逐层三次多项式非线性失真下，网络在灾难尾损失的是**读出的可解码性**而非表征中的信息（headroom 20.12 个百分点；高斯噪声下仅 7.00）。
2. 据此，冻结全部模拟权重、只重训最后的线性层，可把尾部提升 13~23 个百分点，成本为主干重训的 $1/15 \sim 1/30$ ，并一致超过所有全网络鲁棒训练配方。
3. 训练端四条补救路径全部失效；正侧尾部是结构性不可训练区，其形态是**维度丢失**（有效秩下降 20.6%~58.7%）而非类间距缩小。
4. 架构端的池化密度提供与之正交的零成本杠杆（+14.38 个百分点），其保护主要来自降维；两个杠杆在尾部可叠加。
5. 失真强度可由岭回归在线恢复（ R^2 0.83~0.94），使门控可以逼近 oracle；但门控有效需两个前提同时成立。
6. 工程上，全部结论只依赖一个硬件条件：**读出层位于数字域或可重写**。
7. 测量纪律上，**跨训练实现的精度数字不可移植**——该差异经三次干预实验未归因，按已知未知记录。

参考文献

- [1] Yu S, Chen P Y. Emerging memory technologies: recent trends and prospects[J]. IEEE Solid-State Circuits Magazine, 2016, 8(2): 43–56.
- [2] Ankit A, El Hajj I, Chalamalasetti S R, et al. PUMA: a programmable ultra-efficient memristor-based accelerator for machine learning inference[C]//ASPLOS. Providence: ACM, 2019: 715–731.
- [3] Zhu M, Liu Y, Wang Z, et al. Nonlinearity-aware training for accurate and robust compute-in-memory neural networks[J]. IEEE TCAD, 2022, 41(11): 3961–3973.
- [4] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//CVPR. Salt Lake City: IEEE, 2018: 2704–2713.
- [5] Wannamaker R A, Lipshitz S P, Vanderkooy J, et al. A theory of nonsubtractive dither[J]. IEEE Transactions on Signal Processing, 2000, 48(2): 499–516.
- [6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. Las Vegas: IEEE, 2016: 770–778.
- [7] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//ICLR. San Diego: ICLR, 2015: 1–14.
- [8] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.