存算一体芯片逐层非线性失真：机制、边界与读出层修复

——技术报告与内部归档（六阶段全记录）

黄奕皓

中国科学院大学计算机科学与技术，北京

huangyihao24@mails.ucas.ac.cn

归档版本 v1.0-archive，2026 年 9 月

摘要

本报告是存算一体芯片非线性失真项目的完整技术归档，覆盖六个研究阶段的全部结论、失败记录、方法学制度与工程推演。与面向期刊的论文版本相比，本报告额外保留三类材料：**(a) 研究历程**——三次" 先归因、后被自己否证" 的完整链条；**(b) 工程落地推演**——把结论映射到真实 CIM 数字后端的三档判定；**(c) 可复现性手册与方法论制度**——使后来者能重建每一个数字，并知道哪些比较是无效的。

核心科学结论为：在逐层三次多项式非线性失真下，网络在灾难尾（$\alpha = +0.3$）损失的是**读出的可解码性**而非表征中的信息（oracle-α 探针 headroom +20.26 个百分点，同一探针在加性高斯噪声下仅 +7.50）；据此，冻结全部模拟权重、只重训最后的线性层，即可以约 1/5∼1/16 的主干重训成本在尾部超过所有全网络鲁棒训练配方（三主干：28.09/15.98/6.22 → 43.31/47.79/26.82）；而训练端没有一条补救路径能改善尾部。架构端的池化密度是另一条零成本的独立杠杆（同协议同 seed 配对 +15.52 个百分点），其保护主要来自降维。

本报告同时记录一条方法学观察：**本文观测到**一个同超参、同种子、跨实现稳定 **5.55** 个百分点的差异——同一份权重在两条评估路径下读数逐位相同，而两个训练脚本产出的权重稳定分居两簇。该差异**经三次干预实验仍未归因**；在归因之前，**我们的做法是**不跨实现引用精度数字。这不排除" 某一脚本里还有一个尚未找到的具体差别"，故按已知未知记录，而非上升为普遍律。

关键词：存算一体；非线性失真；读出瓶颈；有效秩；鲁棒性杠杆；测量纪律；技术归档

目录

1 阅读指南 **3**

2 问题、口径与产物 **3**

2.1 失真模型 3

2.2 度量口径与自检 4

2.3 数据集、主干与产物布局 4

3 六阶段的技术内容 **4**

3.1 阶段划分 4

3.2 第一、二阶段：任务层结果与三项优化（CIFAR-10） 5

3.3 失真有多大破坏力，往哪里累积 8

3.4 灾难尾丢的不是信息，而是读出的可解码性 8
3.5 这条探针读数可信吗：一次主动加固 9
3.6 修复：冻结主干、只重训线性读出 11
3.7 训练端的五条路径为什么都没能改善尾部 11
3.8 损伤的形态：维度丢失，不是类间距缩小 13
3.9 第二个杠杆：池化密度 14
3.10 两个杠杆的叠加与在线估计 15
3.11 门控的边界 15
3.12 失真与量化的联合作用 17

4 研究历程：三次”先归因、后被自己否证” 17
4.1 第一次：把处理效应误读成噪声（±3.15 混协议） 18
4.2 第二次：把脚本差异误读成采样粒度 18
4.3 第三次：把序列位置误读成消耗数 18
4.4 三次翻案的共同点与制度沉淀 19

5 第七阶段：归档后的自主迭代 19
5.1 两条加强中心结论的结果 20
5.2 四条判定：三条排除型结论 + 一条限定 20
5.3 方法学产出（本阶段最值钱的部分） 21
5.4 收官补测：三项实验（2026-09-26） 22
5.5 本阶段自我暴露的问题（同样留痕） 23

6 工程落地推演 23
6.1 场景设定 23
6.2 三档判定 23
6.3 唯一的硬约束 23
6.4 风险清单（不是结论） 23
6.5 没做的事 24

7 可复现性手册 24
7.1 环境 24
7.2 复现一个数字（三条命令） 24
7.3 重新出图 25
7.4 读文档顺序 25

8 局限、停车场与下一步 25
8.1 局限（每条导致一个由本文发现引出的问题未决） 25
8.2 停车场（只登记不执行） 26
8.3 下一阶段的入场券与判据 27
8.4 已明确排除、不应重走的方向 27

9 结论 27

1 阅读指南

你想知道什么	读哪里	节数估计
项目做出来的核心结论	第 3 节（六阶段技术内容）	5
某个方法为什么有效	第 3.4 节（机制链）	3
当初怎么走弯路的	第 4 节（三次翻案）	3
能不能落到硬件上	第 6 节（工程推演）	3
怎么复现一个数字	第 7 节（三条命令）	2
还有什么没做	第 8 节（停车场与入场券）	3

本报告的性质：它是一份*归档*，不是一份投稿论文。因此它刻意保留了负面结果、被否证的假说、以及三次失败的归因尝试——这些材料的价值在于让后来者不必重走。所有数字均可追溯到一个具体文件或命令输出；无法追溯的陈述一律不写入。

定位说明（2026-09-24 补，详见 `docs/POSITIONING.md`）：本项目的核心方法——冻结主干、只重训最后的线性层——**不是一个新方法**，它是迁移学习里的 linear probing；而「预训练特征好、偏移大时线性探针可胜过全量微调」是一条有理论与十数据集实证支撑的已知结论 [9]。**本项目的贡献是**：把它搬到一个新场景（模拟域非理想性），并给出该场景特有的**上界**（探针 headroom 与可恢复量）、**机制**（有效秩塌陷、同强度下正侧 Fisher 反高于负侧）、**边界**（门控两前提 + 读出层须在数字域），外加一个先行工作里没有对应物的**正交架构杠杆**（池化降维）。在 CIM 领域，「冻结阵列 + 数字域补偿」已有先例（例如用器件特定的电导漂移查找表配合自适应量化，在**不做片上训练**的前提下达到软件基线精度 [14]），但形态是**标量或查找表级**校正；本项目动的是整个读出层，代价更大（要求读出层可重写）。本报告同时**主动记录**了本项目最依赖的测量手段（线性探针）正被文献警示可能虚假饱和 [12]，以及对应的加固方案。

与测试时适配（TTA）/ 无源域适应（source-free DA）的关系：与本工作最接近的是这一支，它已确立「冻结主干、只更新极少数参数」是分布偏移下的有效范式——**Tent** 冻结全部主干、只更新批归一化的仿射参数 [10]；**SHOT** 冻结源模型的分类器、只学目标域的特征提取器，且不需要访问源数据 [11]；**Kumar 等**进一步证明预训练特征良好而偏移较大时线性探针可优于全量微调，并给出机制：微调在学头的同时会扭曲底层特征 [9]。**本文与 SHOT 共享" 只动极少量参数、也不需要源数据" 的取向，但动的对象正好相反**——本文冻结的是特征（主干物理上不可重训），更新的是分类头。**本文与这三条的差异有三点**：① **偏移的性质不同**——TTA/DA 处理的是数据分布偏移，本文的失真是**确定性的、逐层累积的、输入相关的系统误差**，换一批测试数据不会让它消失；② **可动参数的范围与性质不同**——TTA 的" 只动少数参数" 是一种设计选择（主干在原理上仍可训练），而 CIM 里模拟权重**因硬件原因物理上不可重训**，冻结不是选择而是约束；③ **给出的量不同**——上述工作报告的是准确率，本文给出该约束下的**可恢复量上界、损伤的几何形态**与**代价的定量权衡**。

2 问题、口径与产物

2.1 失真模型

模拟域乘累加的输入侧失真建模为逐样本归一化后的三次多项式：

$$y = \alpha\,\hat{x}^3 + (1-\alpha)\,\hat{x}, \qquad \hat{x} = \frac{x}{\|x\|_\infty}, \tag{1}$$

表 1: 主干、参数量与设计角色

主干	参数量（C10 / C100）	Conv	MaxPool	残差	设计角色
SimpleCNN	242 474 / 254 084	4	2	无	浅层基线
SimpleCNN+3×MaxPool	242 474 / 254 084	4	5	无	架构杠杆对照（参数量不变）
Wide-CNN†	1 353 258 / 1 399 428	4	2	无	秩-恢复第 4 点
VGG-11	9 231 114 / 9 277 284	8	5	无	深度变量
ResNet-18	11 173 962 / 11 220 132	17	0	有	残差变量

† 与 SimpleCNN 的差异有**两个变量**：容量（1.40M 对 0.25M）与**第二次下采样位置**（SimpleCNN 的 conv4 在 16×16、本主干在 8×8），后者是 MACs 约束下的取舍。

参数量口径：本表为**主干本体，不含**各实验配方里的 **特征校准模块**（`FeatureCalibration`）。**含**校准模块时，VGG-11 与 ResNet-18 分别为 9 889 796（9.89 M）与 11 919 332（11.92 M），第 4 个容量档为 1 662 340（1.66 M）——复现者按模型定义实例化得到的是后者。

$\hat{x}$ 按 batch 维逐样本做无穷范数归一化，避免样本间串扰；失真通过前向钩子挂在每一个 `Conv2d` 与 `Linear` 算子的输入侧，逐层注入，每层可以有自己的 α（除特别说明外，扫描时同一个 α 施加到所有层）。$\alpha > 0$ 时中段被压低，$\alpha < 0$ 时中段被抬高。

2.2 度量口径与自检

全阶段统一四个标量指标：

指标	定义
`clean`	$\alpha = 0$ 时的测试精度
`drop@0.3`	`clean` 减去 $\alpha = +0.3$ 时的精度
`mid_band`	$\alpha \in \{-0.2, -0.1, +0.1, +0.2\}$ 四点的平均精度
`mean7`	$\{-0.3, -0.2, -0.1, 0, +0.1, +0.2, +0.3\}$ 七点的平均精度

评估协议：全量测试集（10 000 张）、best 权重、纯推理。每个实验的强度扫描文件里 $\alpha = 0$ 的行必须等于同目录 `metrics.json` 的 `best_test_acc`（容差 0.01）。该自检记在全局台账 `results_master.csv` 的 `pairing_check` 列，当前状态为 **152 行数据、0 FAIL**（58 行 PASS / 94 行 `n/a`；`n/a` 者为复用扫描与读出适配行，本就没有可配对的 `metrics.json`）。

2.3 数据集、主干与产物布局

数据集：CIFAR-10（10 类）与 CIFAR-100（100 类） [8]。主干五个，参数量随类别数变化（见 表 1）。

产物目录按数据集分离：`outputs/`（CIFAR-10）与 `outputs_cifar100/`（CIFAR-100）；全局台账由 `build_ledger.py` 只读扫盘重建，不修改任何既有产物。

3 六阶段的技术内容

3.1 阶段划分

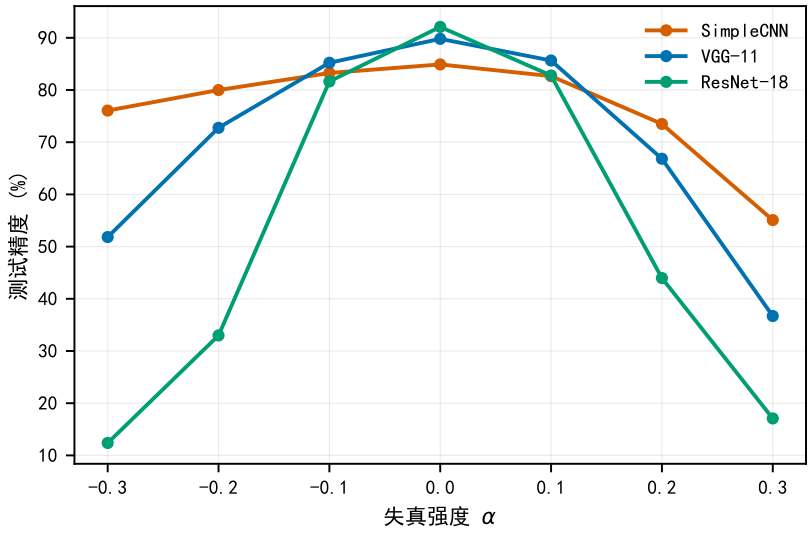


图 1：任务 1：三个架构的非线性敏感性（CIFAR-10）。$\alpha = +0.3$ 时 SimpleCNN / VGG-11 / ResNet-18 分别跌 29.82 / 53.10 / 75.01 个百分点。数据：`outputs/task1_*/alpha_sensitivity.csv`。

阶段	主题	产出
一	敏感性、感知训练、架构增强、三项拓展	破坏力与方向性；NAT 的架构依赖；Exp2 方案
二	外推边界、Dithering 机理、深层迁移	NAT 是分布内属性；Dithering 机理判决；方案可迁移
三	台账统一与四条新结论	**读出瓶颈律**与读出适配方法；训练端四条负结果
四	读出端 vs 训练端的分解	在线 α 估计与路由；架构杠杆的独立发现
五	完整配方、池化成因、跨数据集复现	池化保护的排除线；事前预登记复现
六	定律化与落地	秩-恢复曲线；深层门控边界；工程推演；测量纪律
七	归档后的自主迭代	容量非瓶颈（六种读出对照）；headroom 上界抬高；三条排除型判定；判据前提自检回溯审计；**收官三补**（LP-FT / 秩-恢复第 4 点 / ReLU 非负性）

3.2 第一、二阶段：任务层结果与三项优化（CIFAR-10）

前两阶段以 CIFAR-10 为主线，对应赛题的三项任务与三项拓展，以及评审意见带来的三项优化。它们的完整数值见竞赛版文档，此处给出归档要点；这一阶段的四张主图是 图 1、图 2、图 3 与 图 4。

> **口径注（实现归属）：**本节以及第 4 节引用的**第一、二阶段数值**（任务 1–3、拓展 1–6）来自 `task1` / `task2_nat.py` / `task3_robust.py` / `task_extension*.py` 这一条实现线；而本报告其余各节（第三 ~ 六阶段）的数值来自 `v3_methods_simplecnn.py` / `v3_readout_repair.py` / `v5_*` 等另一条实现线。**两条实现线之间的精度数字不可直接相减或并列比较**——它们之间存在一个稳定的实现级偏移（第 4 节记录为 5.55 个百分点，机制未明，按已知未知归档）。本节内部逐项自洽，但与后文各节之间**只作定性对照，不作定量对比**。

任务 1：正向失真的破坏力是负向的 3.4 倍（以 SimpleCNN 上 $|\alpha| = 0.3$ 计）；误差从浅层向深层累积，fc 层的输出与干净输出的余弦相似度仅 0.895；残差连接是误差放大器——ResNet-18 的跌幅（75.01）远重于 VGG-11（53.10）与 SimpleCNN（29.82）。

任务 2：非线性感知训练在纯前馈网络上有效（Scratch 策略 +9.15 / +8.04），但残差网络在极限正向下失效甚至退化（−1.44）；效果与注入点数量负相关（5 → 9 → 18）。中等失真上仍然有效（ResNet-18 在 $\alpha = -0.2$ 上 +18.84）。

表 2： 任务 2 与任务 3 的关键读数（CIFAR-10，$\alpha = +0.3$，%）

任务	配置	SimpleCNN	VGG-11	ResNet-18
任务 2	clean（基线）	55.08	36.70	17.08
	NAT-Scratch	**64.23**（+9.15）	**44.74**（+8.04）	15.64（**−1.44**）
	NAT-Finetune	56.08（+1.00）	39.96（+3.26）	**19.89**（+2.81）
任务 3	Exp1（+ 残差校准）	63.63	—	—
	Exp2（+ 分层加权）	**68.76**	—	—
	Exp3（+ 非对称采样）	69.14	—	—

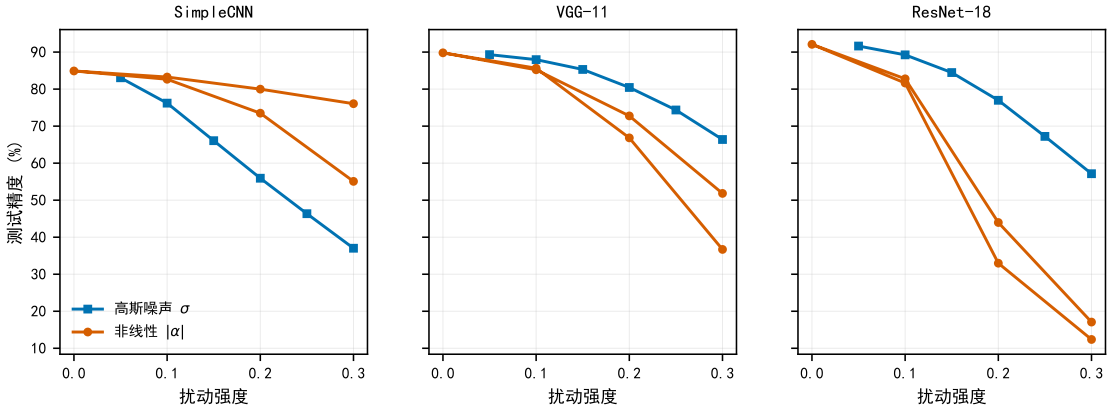


图 2： 拓展 2：非线性失真与加性高斯噪声的对照（CIFAR-10）。三种架构上的排序完全不同，ResNet-18 上两者完全反转。数据：`outputs/extension2_*/.../{gaussian,nonlinearity}_sensitivity.csv`。

任务 3： 叠加残差校准模块与分层加权采样后，SimpleCNN 的 $\alpha = +0.3$ 达 **68.76%**。消融显示分层加权是贡献最大的单项（+5.13），非对称采样边际贡献仅 +0.38；三个配置的干净精度（87.19 / 87.37 / 87.59）全部高于未增强的干净模型（84.90）——残差校准模块兼具正则化作用、不引入干净精度代价。

拓展 1–3： 脆弱性随深度与残差连接递增；非线性失真与高斯噪声的鲁棒性**不可跨域迁移**（SimpleCNN 对高斯更脆弱 37.02 vs 55.08，ResNet-18 则反之 57.15 vs 17.08）；量化与非线性的联合作用呈**三分格局**——SimpleCNN 超加性恶化（4bit $\Delta = -7.23$）、VGG-11 次加性即 Dithering（$\Delta = +7.82$）、ResNet-18 地板效应（$\Delta = +1.05$）。

【第三阶段的细化：L3 两通路机制】上段”不可跨域迁移”在第三阶段被两步修订，此处补入归档（这是本项目最早确立的三条定律之一）。

①迁移层面——”零迁移”是架构依赖的。把一条通路训好的权重拿到另一条通路上扫，测扰动敏感性的变化幅度 $\max|\Delta_\sigma|$（>1.2 判非零）：SimpleCNN 1.16（Exp2 vs 原始）、SimpleCNN 2.43（NAT vs clean）、**VGG-11 5.26（Exp2 vs clean，零迁移被打破）**、ResNet-18 1.41。值得注意的是，给 SimpleCNN 加 3 个 MaxPool 反而把迁移**从 2.43 降到 0.98** ——说明 MaxPool 密度不是迁移的成因。

②训练层面——不是零迁移，而是单向强干扰。同一 harness 上的 2×2（是否注入 α × 是否注入 σ）：

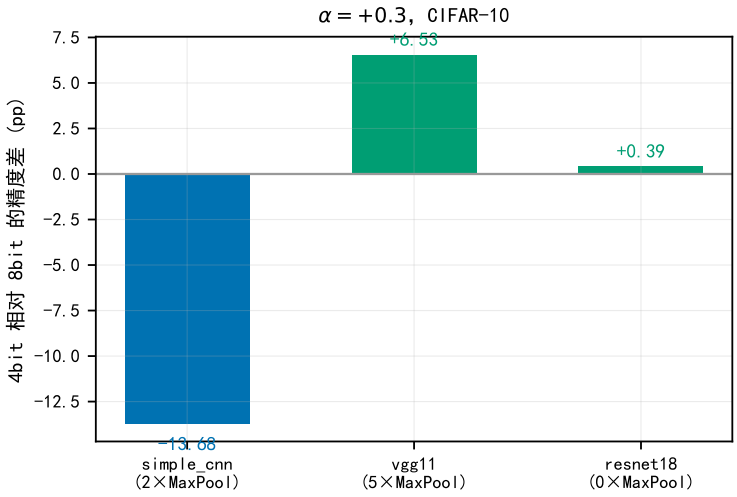


图 3: 拓展 3/优化二：Dithering 增益的架构依赖（CIFAR-10，$\alpha = +0.3$）。增益与 MaxPool 密度同向，但要足够密——2 个 MaxPool 的 SimpleCNN 是负增益，0 个的 ResNet-18 无效应。数据：`outputs/extension5_dithering_vgg11/arch_dithering_summary.csv`。

训练条件	clean	$\alpha = +0.3$	$\sigma = 0.30$	双扰动最坏点均值
无训练（clean 模型）	59.99	28.09	3.98	16.04
α-only	60.85	26.03	4.40	15.22
σ-only	55.79	22.01	**27.19**	**24.60**
$\alpha + \sigma$（联合）	55.20	15.27	31.31	23.29

α 训练对 σ 几乎零收益（4.40 vs 3.98）；但 σ 训练使 α 侧从 28.09 掉到 22.01（-6.08，对 clean 模型），联合训练进一步掉到 15.27（对只做 α 训练的 26.03 再低 -10.76）。**双扰动并存时的最优配方是 σ-only，不是联合训练**——joint 里的 α 注入是净负担（σ 侧仅多拿 4.12，却付出 α 侧 -10.76）。⇒ 正确表述是「**迁移近正交，但训练端存在单向强干扰**（$\sigma \to \alpha$ 有代价、$\alpha \to \sigma$ 无收益）」。

数字出处:上表三行取自 `outputs_cifar100/v3_methods/` 的 `gauss_uniform` / `joint_uniform` / `budget_uniform` 三份 `alpha_sensitivity.csv`（逐位可核）。迁移幅度表见第 3 节与 论文 `v3.md` §8 勘误 12。

优化二（Dithering 机理）的关键结论在本节之后的" 失真与量化的联合作用" 中给出；其核心是**否决了第一阶段给出的" 随机共振" 解释与"ADC 前注噪" 建议**（等剂量注噪的增益约为零），机理改写为" 离散化分布重塑 + MaxPool 架构载体"。

优化一（外推边界）与优化三（深层迁移）的要点：非线性感知训练的增益**严格限定在训练分布内**——正侧在 $\alpha \approx 0.4$ 处归零（+0.77）并反转为劣势（$\alpha = +0.5$ 时 -10.77），而负侧随外推距离不降反升（$\alpha = -0.6$ 处 +8.22）；架构容差窗口随深度单调收窄（SimpleCNN 约 $[-0.35, +0.25]$、VGG-11 约 $[-0.25, +0.2]$、ResNet-18 约 $[-0.15, +0.15]$）。Exp2 方案可完整迁移到深层：VGG-11 在 15 个扫描点上全胜三条基线（相对干净模型平均 +10.22），ResNet-18 全程无败；$\alpha = +0.3$ 的增益为 +13.55 / +3.04；两架构的干净精度（91.27 / 93.27）均为四组权重中最高。多点校准（5/8 处）修复了 SimpleCNN 单点版本（1 处）在负侧外推输给 NAT-Scratch 最多 12.58 个百分点的短板。

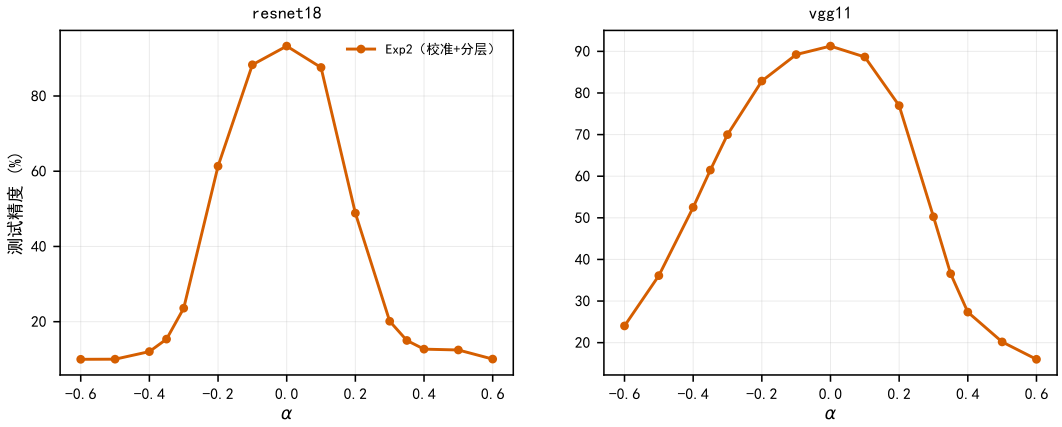


图 4：优化三：增强方案向深层主干迁移（CIFAR-10）。灰色虚线为同架构干净模型，橙色为 Exp2 方案。VGG-11 上 Exp2 在全部 15 个扫描点上都优于三条基线；ResNet-18 上全程无败，但正侧强失真区的绝对精度仍然很低。数据：`outputs/extension6_deep_robust/alpha_wide_scan_deep_robust.csv`。

3.3 失真有多大破坏力，往哪里累积

图 5 给出失真的方向性与容量依赖。

$\alpha = +0.3$ 时 SimpleCNN 从 59.99 掉到 28.09、VGG-11 从 67.09 掉到 16.92、ResNet-18 从 72.09 掉到 2.70。按容量排序，干净精度越高、跌幅越大，这条反相关关系在同数据集内跨容量单调。

”3.4 倍不对称” 这个常被引用的数字**不是常数**：CIFAR-10/SimpleCNN/$|\alpha| = 0.3$ 上是 3.4，CIFAR-100 同模型上只有 1.87。它的适用域还很窄——CIFAR-100 的三个主干依次为 1.87 / 1.18 / 1.01，CIFAR-10 的三个主干为 3.4 / 1.40 / **0.94：方向随深度衰减，并在最深的主干上（CIFAR-10/ResNet-18）反号**。

把” 最脆弱的位置” 分成**注入位置**与**观测位置**后，一个反直觉结果出现：单层注入探针中最敏感的是中间层卷积（conv2 跌幅 −12.43、conv3 −7.56），而 fc 单点注入只有 −0.68。全 5 层同时注入的跌幅 31.90 远超线性累加的 23.33 （超加性 −8.57）。fc 是误差的**汇聚与观测点**，不是注入敏感点。

3.4 灾难尾丢的不是信息，而是读出的可解码性

这是全项目的枢纽结论。图 6 用探针把它测出来。

$\alpha = +0.3$ 时探针达 48.35%、原始头 28.09%，headroom **20.26** 个百分点 [1]；$\alpha = +0.4$ 时 30.90、+0.5 时 30.82。headroom 随失真增强先放大、后趋于平坦（$+0.3 \to +0.4$ 增幅最大，$+0.4 \to +0.5$ 微降 0.08——不是单调上升）。

口径标注（必读）：该探针**逐 α 条件训练**——它在每个测试点的失真特征上重新拟合线性头（源文件 `ra_onprotocol_main.csv` 的 `probe_same_cond` 列，与之并列的 `probe_clean_train` 列则只在干净特征上训练）。因此 headroom 是 **oracle-α** 诊断量：它回答的是” 若已知失真强度、且读出可自由重训，线性解码还能恢复多少”，**不是可部署读数**——不知道 α 时的实际读出读数是 43.31 （见第 3 节的读出适配）。作为对照，只在干净特征上训练的探针在 $\alpha = +0.3$ 上只有 18.1，低于原始头（28.09）。

[1]两项均取自**全量测试集**（10 000 张），与项目的规范口径逐位一致（$\alpha = +0.3$ 的 28.09 等于 `task1` 同名行；$\alpha = 0$ 的 59.99 等于 `metrics.json` 的 `best_test_acc`）。早期版本曾用 8000 样本子集，给出 27.76 / 59.60 与 +20.12；第七阶段 M0c 已在同一设备（CUDA）上重跑全量口径并替换，全案见 `docs/IMPL_AUDIT.md` 与台账 §16.0。

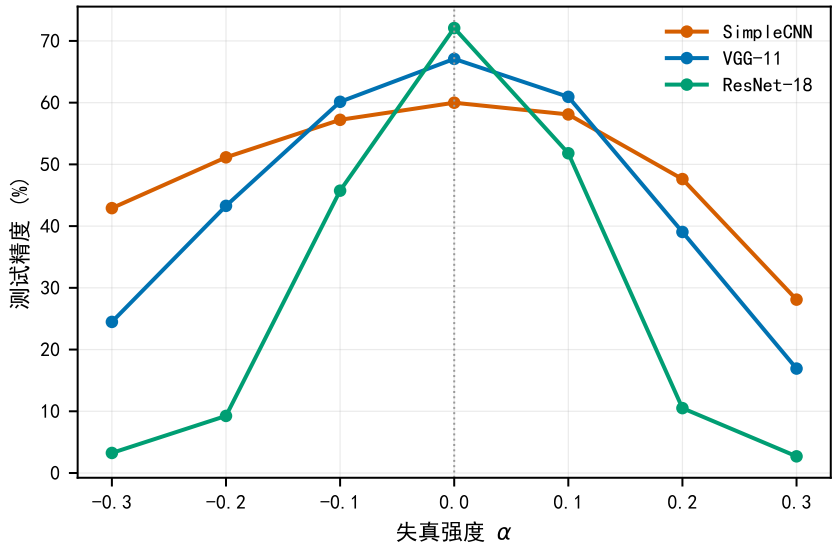


图 5: 失真的方向性与容量依赖（CIFAR-100）。三个主干在七点上的扫描；正侧跌落大于负侧（该方向在 SimpleCNN 与 VGG-11 上明显，在 ResNet-18 上几乎消失：两侧跌幅 69.39 对 68.84），且随容量与深度单调放大。数据：`outputs_cifar100/task1_*/alpha_sensitivity.csv`。

对照通路的判别力：同一套探针在加性高斯噪声 $\sigma = 0.3$ 下 headroom 只有 7.50。随机扰动与确定性系统误差在" 信息还剩多少" 这个量上清楚地分开。

3.5 这条探针读数可信吗：一次主动加固

上面那个 headroom 是**单点**探针读数，而线性探针近年正受到系统质疑：**探针精度饱和并不意味着信息在场，探针失灵也不意味着信息不在场**。已有工作报告过**探针精度 0.871、有效秩 18∼47 全部健康**的表征，在检索任务上却只恢复了 14.4 bit 中的 **0.00** bit [12]。本报告因此做了一组主动加固，四路对照如下。

对照一：随机标签。 把探针的训练标签打乱后重训。9 个条件全部落在 $[0.85, 1.11]\%$，而 CIFAR-100 的随机水平是 1.0%，**最大偏离 0.15 个百分点**。⇒ 探针管线没有泄漏。

对照二：fragility（激活噪声下的临界崩塌点）。 单点精度之外再取一个读数：给评估侧的激活加噪，测" 探针精度跌到半程时的噪声水平" σ^*。该指标及其用法取自已有工作 [13]——它报告的正是" 探针精度持平时，fragility 仍能给出结构化回答"，本文借用它作第二条独立读数。（噪声只加在**评估**侧——训练侧也加噪测的是解码器的抗噪补偿能力，是另一个量。）结果：正侧 σ^* 从 clean 的 **0.4188** 一路降到 $\alpha = +0.5$ 的 **0.1221**（−71%；只有 $\alpha = +0.1$ 一点略高于 clean，0.4273，此后严格单调下降）。**但在同一 $|\alpha| = 0.3$ 上，正负两侧几乎一样：**σ^* 为 **0.3230** 与 **0.3310**，相对 clean 分别是 **−22.9**% 与 **−21.0**%（约 1.1 : 1）。（负侧只测到 −0.3——产物里没有 $\alpha = -0.4/-0.5$ 两档，所以" 负侧平缓" 是**未测**，不是测出来。）⇒ **第二条读数在最关心的那一点上没有复现 headroom 的不对称：**同一 $|\alpha| = 0.3$ 处，headroom 是 20.26 对 4.76（4.3 : 1），而 fragility 只有 1.1 : 1。两条读数**一致的地方只有" 失真使读出更脆" 这个方向；" 正侧特别脆" 这件事对指标敏感**——这是本文对这条加固论证的**限定**，要判定 fragility 在大失真处是否也分正负，须把负侧测到 −0.5。

一个必须避开的陷阱（我们在本项目内实测到了它）。 σ^* 的**单位**是关键：若用**绝对**噪声水平，会得出**符号相反**的结论：

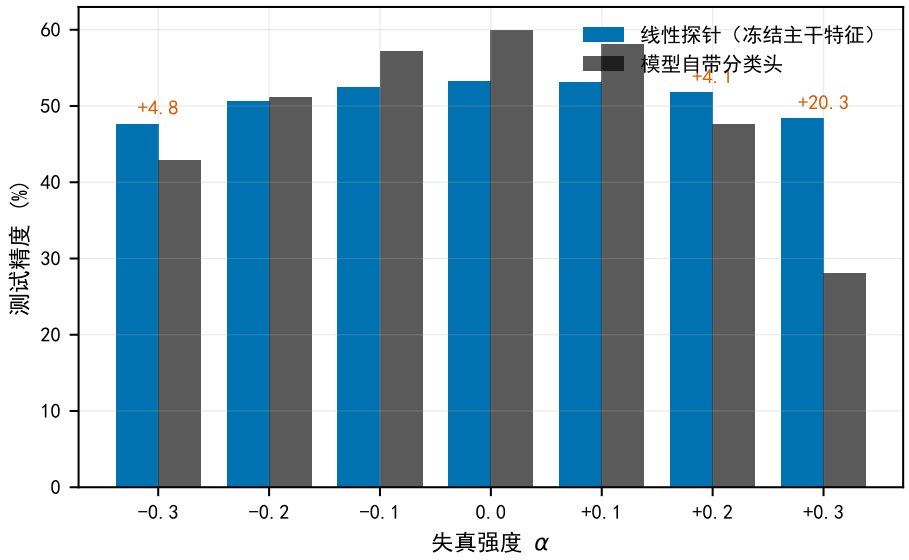


图 6：探针 headroom：灾难尾的标签信息仍然线性可达。在同一冻结主干的末端特征上，线性探针（实心）与**原始头**（空心，即模型自带的分类头，产物里的 `a_original_fc`）的精度；7 个 α 点，CIFAR-100 **全量测试集**（10 000 张）、best 权重、单种子。$\alpha = +0.3$ 时相差 20.26 个百分点；同样的探针在加性高斯噪声 $\sigma = 0.3$ 下只有 7.50。数据：`outputs_cifar100/v7_probe_audit/ra_onprotocol_main.csv`。

α	激活 RMS	绝对 σ^* vs clean	**RMS 归一** σ^* vs clean
clean	2.166	—	—
-0.3	**4.055**（1.87×）	+48%（**显得更鲁棒**）	−21%（**更脆弱**）
$+0.3$	0.914（0.42×）	−67%（更脆弱）	−23%（更脆弱）

原因：$\alpha < 0$ 把深层激活的幅度**抬高到 1.87 倍**，固定绝对噪声相对就更”小”，于是失真组**虚假地显得更鲁棒**。归一化到该条件自身的 RMS 之后符号才正确。⇒ **负侧的结论完全依赖这一步归一化。这一陷阱并非本文首见：**[13] 自己就把它列为该指标的适用条件（跨层比较须用 RMS 归一化的临界噪声，层内比较才用原始值），本文在本场景下**独立复现**了它——而且这里尺度差达 1.87×，所以这一步在本文里是**判决性的**，不是可选项。（出处：`v7_probe_audit/c2_fragility.csv` 的 `critical_noise_abs` 与 `critical_sigma_rms_norm` 两列，”vs clean” 以该文件的 clean 行为基准。）

对照三与四：划分与不相交性。 换 decoder 的随机种子与训练/测试划分（5 个划分 + 3 次 bootstrap）：读数稳定，划分间标准差 0.17 ∼ 0.47、bootstrap ≤ 0.38，单条件总标准差 0.56 ∼ 1.33（总极差 ≤ 3.42）。更强的一项是把探针的训练与评估都放在**与主干训练集完全不相交**的样本上：$\alpha = +0.3$ 的 headroom 为 **+16.23**，即规范口径 +20.26 的 **80%**。

小结。 四路对照**都未能否证** headroom；其中**只有对照二（fragility）提供了第二条独立读数，**而它只与 headroom 在”方向”上一致（见上）。**headroom 这个结论在更严的口径下存活，但幅度会缩水到约八成。**我们把它作为中心结论的**下界：**即使在”探针从没见过的样本上训练”这一最严设定下，$\alpha = +0.3$ 处仍有一个约 16 个百分点的可解码性缺口。（出处：`outputs_cifar100/v7_probe_audit/` 下的 `c1_random_label.csv`、`c2_fragility.csv`、`c3_decoder_split.csv`、`c4_private_split.csv` 与 `c5_private_decompose_agg.csv`。）

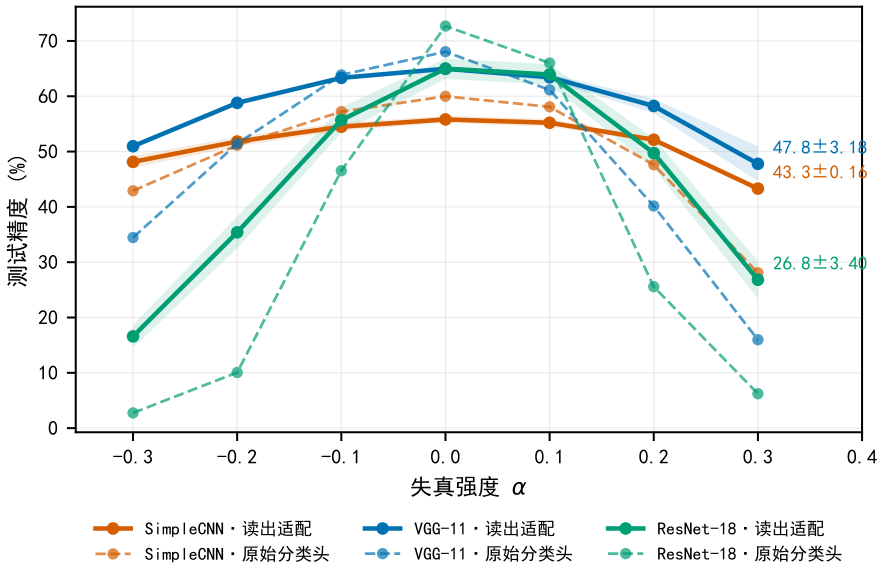


图 7: 读出适配跨三个主干一致抬升尾部（CIFAR-100，3 个种子的逐点均值）。实线为**读出适配**（readout-NAT，主干全冻结，可训练参数占全模型 5.04%/0.55%），虚线为各模型的原始头。数据：`outputs_cifar100/v3_readout_repair/*ep24*.csv`。

3.6 修复：冻结主干、只重训线性读出

图 7 给出读出适配在三个主干上的逐点读数。

读出适配在三个主干上一致超过”全网络重训”整类配方，可训练参数只占 5.04%/0.55%，训练成本**逐主干配对**为 1/5、1/16、1/13（读出 12 / 25 / 30 min 对全网络 1 / 6.5 / 6.5 h），约低一个数量级。代价是干净精度下降 3.08∼7.69 个百分点（$\alpha = 0$ 处：读出适配的三 seed 均值为 55.81 / 64.97 / 65.00，对各自主干的原始头 59.99 / 68.05 / 72.69）。

必要的自我校验：单点读出适配（只对 $\alpha = +0.3$ 拟合）确实是再分配——该点 +24.70 但干净精度 −20.36、$\alpha = -0.3$ 掉 25.71，七点均值反而低于基线。起作用的是**分布式**版本（$\alpha \sim U[\pm 0.3]$ 上训练），它在每个扫描点都不显著劣化。同一层参数、两种训练方式给出质上不同的结果。

这条结论不只有探针读数背书：冻结主干、只重训一个线性头，在 $\alpha = +0.3$ 上**实际达到 43.31**（SimpleCNN，3 seed，24 ep 协议；同期原始头 28.09）——那是一个**真实可部署的分类器**，不是仅用于测量的探针。同口径的 **oracle-α** 探针读数为 48.35，即部署物取到了上界的 **89.6%**（43.31/48.35）。注意分母是 **oracle-α** 口径（假定失真强度已知），因此这个比例**不是**”部署时可以达到 89.6%”的意思。

3.7 训练端的五条路径为什么都没能改善尾部

前四条路径的读数见 图 8（第五条 LP-FT 见下文 表 4）。

前四条独立路径：采样预算分配（三种轮廓，最好 26.13，+0.10）、α 空间对抗训练（24.32，−1.71）、课程式采样（21.78，−4.25）、训练范围外推至 ±0.5（20.48，−5.55）。基准（均匀采样）为 26.03。按本文自订的单种子门槛（尾部差值小于 3 个百分点不作为结论），其中只有课程式与外推两条可记为显著劣于基准（−4.25 / −5.55），对抗训练的 −1.71 落在门槛内、记为**不可分辨**，预算分配的 +0.10 与基准同级。**前四条都没有改善尾部。**

最强的一条证据是范围外推：**模型已在 ±0.5 上训练过**，测试 $\alpha = +0.5$ 时仍只有 2.71%，同期负侧 −0.5 有 31.19%（差 28.5 个百分点）。正侧尾部不是采样覆盖问题，而是**结构性的不可训练区**。

表 3: 读出适配 vs 全网络鲁棒训练（CIFAR-100，$\alpha = +0.3$，精度%）

方法	训练成本	SimpleCNN	VGG-11	ResNet-18
原始头（同主干）	—	28.09	15.98	6.22
读出适配（24ep，3 seed）	**12∼30 min**	**43.31**±0.16	**47.79**±3.18	**26.82**±3.40
全网络鲁棒训练（最好）	1∼6.5 h	29.89	24.69	6.22

表注（口径）：第一行为各读出实验所依附主干的**原始头**（`v3_readout_repair` 的 `a_original_fc` 行在 $\alpha = +0.3$ 的读数；SimpleCNN 的该主干即 `task1` 权重，故与台账逐位一致）。**第三行**为各架构上最好的全网络鲁棒训练配方（SimpleCNN 取该主干在全网络下的最优结果 **29.89**；**同协议 3 seed 的 v3 路径逐层独立 NAT 均值是 26.57，低于 29.89，故本行取 29.89**；VGG-11 与 ResNet-18 取 200 ep 的 Exp3，24.69 / 6.22）。注意 **ResNet-18 的第三行与该列第一行是同一块主干**——全网络配方并没有改善它的原始头。（`task1` 主干的 16.92 / 2.70 属另一批权重，不参与本表逐列比较。）**第二行的 ± 是" 读出种子" 口径**（固定该主干、只换 3 个读出种子）；换成" 主干种子" 口径（读出侧固定 seed 42、3 个主干种子）后，深层尾部均值为 VGG-11 46.82 ± 0.25、ResNet-18 22.91 ± 2.61——后者低于本表的 26.82。两组口径**只有一格重合**，是同一张 3×3 表的两条不同边缘，**不可相减或互替**。

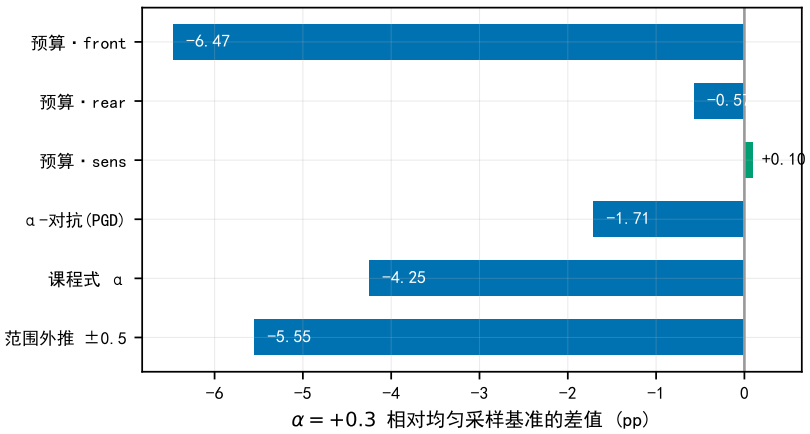


图 8: 训练端的补救路径在 $\alpha = +0.3$ 上没有一条**显著**优于均匀采样基准（CIFAR-100 / SimpleCNN）。数据：`outputs_cifar100/v3_methods/*/alpha_sensitivity.csv`。

第五条动的是主干本身：先训读出、再解冻微调（LP-FT）。前四条都在" 冻结主干、只改采样分布" 的框架内。第五条先按上文读出适配把线性头训好（LP），再**解冻主干**与该头联合微调（FT）——这是分布偏移场景下被证明优于全量微调的配方（ [9]；原理是先把头训好再解冻，避免随机初始化的头在早期用大梯度破坏预训练特征）。判据在跑前写死：$\alpha = +0.3$ 上相对**同一次运行内**的纯读出适配提升 ≥ 3 pp 即成立。结果如表 4：**三个主干一致大幅下降——不是" 没有提升"，而是" 净损伤"。**

口径提醒（必读）：表 4 的" 纯读出" 列取自**同一次运行的 LP 臂（单 seed）**，与 表 3 的" 读出适配"（**3 seed 均值**）**同名但不同源、不可互替**。ResNet-18 那一格 20.79 对 26.82 的 6.03 个百分点里，约 4.6 来自" 单 seed 对 3 seed 均值"、约 1.5 来自脚本内的 RNG 路径差。**本表的判据是同一次运行内的前后对比，不受此影响。**

机制比数字更有信息量：FT 阶段**训练精度一路上涨**（SimpleCNN 88.9%、VGG-11 96.9%，在混合 α 的训练分布上），说明模型在训练分布上确实变好了；而**各 α 的测试读数全线变差、且尾部降幅远大于干净精度降幅**（VGG-11：−33.83 对 −10.38）。⇒ **在失真分布上微调破坏了预训练特征**——这正是 LP-FT 论文在分布偏移场景下要避免、而在失真场景下没有被避免的现象。⇒ **它支持" 训练端做的事越少越好"，不构成对既有结论的修正**；同时把前四条的" 无效" 升级为" 动到主干会主动变坏"。

表 4: 第五条路径（解冻主干微调）在三个主干上都显著劣于纯读出适配

主干	纯读出 @+0.3	LP-FT @+0.3	尾部变化
SimpleCNN	43.40	31.55	−11.85
VGG-11（Exp2）	47.92	14.09	−33.83
ResNet-18（Exp3）	20.79	7.91	−12.88

两臂在同一次运行内、同一评估路径下测量；读出侧 seed 42。LP 24 ep / lr 10^{-2}，FT 30 ep / lr 10^{-3}。**FT 的 batch 在 ResNet-18 一臂为 128、另两臂为 512**——512 是为" 冻结主干前向 / 从头训练" 选的，做**全模型反传**时该主干实测 > 13 min/epoch，故改小；这是**修配置**（lr 与 ep 保持预登记值），但读者应知道**这一格与另两格不同源**。数据：`outputs_cifar100/v7_m8c_lpft/`。

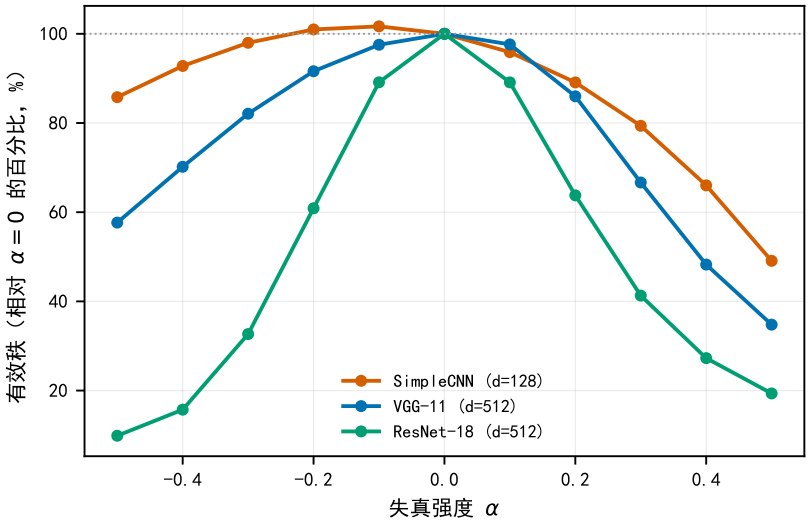


图 9: 正侧失真使末端特征的有效秩塌陷；负侧的形态随主干而异（SimpleCNN 几乎不动，VGG-11 与 ResNet-18 两侧都塌，ResNet-18 的负侧更甚）。纵轴为按各模型 $\alpha = 0$ 归一化的有效秩 $\exp(-\sum p_i \ln p_i)$；特征维数分别为 128 / 512 / 512。数据：`outputs_cifar100/v5_rank_collapse/rank_stats*.csv`。

3.8 损伤的形态：维度丢失，不是类间距缩小

图 9 给出有效秩的塌陷形态，图 10 把秩损失与可恢复量配对。

$\alpha = +0.3$ 时有效秩下降 20.6% / 33.3% / 58.7%（三个主干）；负侧同强度下降 **2.0% / 17.9% / 67.3%**——**" 负侧几乎不动" 只在浅层的 SimpleCNN 上成立，而 ResNet-18 的负侧（67.3%）比正侧（58.7%）掉得更多，其 +0.3 与 −0.3 精度也同样是两侧都崩（2.70 / 3.25）。⇒ 秩塌陷解释" 正侧特殊" 这条链，只在秩塌陷本身不对称的主干上才连得起来。**

关键在于**浅层主干上：同强度下正侧的 Fisher 判别比反而高于负侧**——类间可分性没有变差，丢失的是**维度**。这与幅度统计一致：$\alpha > 0$ 把深层特征的幅度向中段压缩（fc 与 conv1 的 L2 范数比从 0.45 降到 0.23），端点不变而中段被压低。

这解释了" 信息还在但训练救不回" 的表面矛盾：信息仍存在于剩余维度里，但这些维度在主干参数的可达域之外。

秩损失 19.9% / 20.6% / 33.3% / 58.7% 对应恢复率 68.2% / 72.2% / 70.2% / 36.9%（$r = -0.934$），**整体趋势成立；" 秩塌陷即不可恢复"** 不成立——ResNet-18 掉了 58.7% 的秩，读出仍拿回 36.9%。

第 4 个容量档（Wide-CNN：1.40M 参数，MACs 为 VGG-11 的 0.87 倍）的干净精度 65.97% 正好落在 SimpleCNN（59.99）与 VGG-11（68.05）之间，**但它的秩损失 19.9% 与 SimpleCNN**

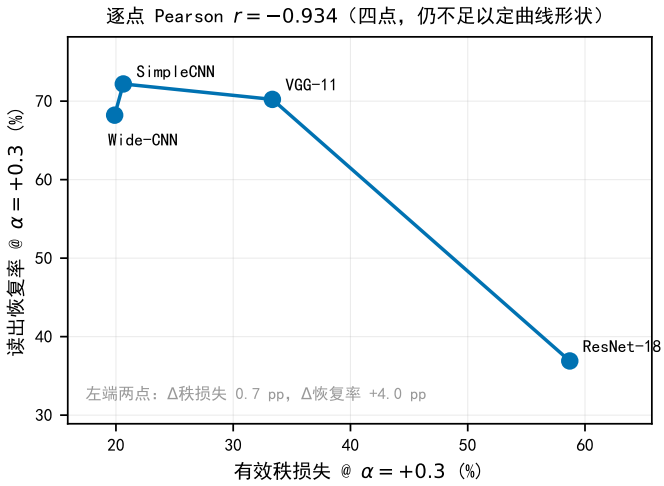


图 10： 秩损失与读出可恢复量（四点，$r = -0.934$）。恢复率 = 读出适配 @$\alpha = +0.3$ 的精度 ÷ 同一文件里原始头 @$\alpha = 0$ 的精度。四点**已不是单调关系**：最左两点秩损失只差 0.7 个百分点，恢复率却差 4.0 个百分点。**四点仍不足以定曲线形状**；形状提示为" 先平后塌"。数据：`rank_stats*.csv` 与 `v3_readout_repair/*ep24*.csv`。

的 20.6% 几乎重合，没有落进中间段。⇒ 按预登记判据，**四点仍不足以判定曲线形状**——" 先平后塌" 仍只是提示。

补测顺带得到一条比判据本身更重要的发现：最左两点秩损失只差 **0.7** 个百分点，恢复率却相差 **4.0** 个百分点（72.2 − 68.2），**超过本文自订的 3 个百分点分辨门槛**，且两点出自同一读出流程、同一秩统计口径、同为 3 seed。⇒ **秩损失不是恢复率的唯一决定因素**，存在秩损失之外的变量。（须写明的代价：Wide-CNN 与前三点的差异**不纯是容量**，它还含" 第二次下采样位置" 这一个变量，是 MACs 约束下的取舍。）

3.9 第二个杠杆：池化密度

图 11 给出这个零训练成本的杠杆。

5 个 MaxPool 的那一支以下简称 **mp 主干**（表 1 的 SimpleCNN+3×MaxPool）。$\alpha = +0.3$ 从 28.09 提升到 42.47（干净训练）、26.03 到 41.55（鲁棒训练；两侧同为逐层独立采样，同 seed 配对，增益 +15.52），七点均值提升 **3.6∼4.9** 个百分点——**区间两端是两种口径，不可当成同一个量**：下界 3.6 取自干净臂的 **3 seed 均值**（52.88 对基线 49.29）；上界 4.9 取自同协议配对的 NAT 臂（54.09 对 49.24），为**单 seed**。干净精度不降。

机制：保护主要来自降维。四个候选解释被逐一检验，其中三个被排除、一个判为不可分辨：

第四条（ReLU 非负性）是唯一没被排除的，但也没能证实。表 5 的前三条都没有排掉一个更基本的原因：ReLU 把池化输入限制在**非负域**，而在那里归一化三次映射与 max 精确可交换（第一行实测）。若保护来源于这个非负性，**削弱非负性的激活应当让保护变弱**。实测（SimpleCNN，2× 与 5× 两种池化密度 × 两种激活，每格 3 seed）：池化保护 P = (2-pool 的 drop) − (5-pool 的 drop)，得 $P(\text{ReLU}) = +11.81$、$P(\text{GELU}) = +14.71$，差 -2.91，落在预登记 ± 4（2σ）带内 ⇒ **判为不可分辨，既不判成立也不判否证**。更关键的是**方向本身不稳定**：单 seed 时 +2.57（与假说同向），3 seed 时 −2.91（**反向**）。**这不是" 接近显著"，而是" 这个量级的效应在本协议下判不了"**——其噪声主要来自 2×max 一侧（种子标准差 3.03 / 2.89，而 5×max 一侧只有 1.54 / 0.26，**相差一个量级**）。

三条排除后，唯一显著差异是**空间元素数从 256 降到 16**。同协议 3 种子对照：5×max 的

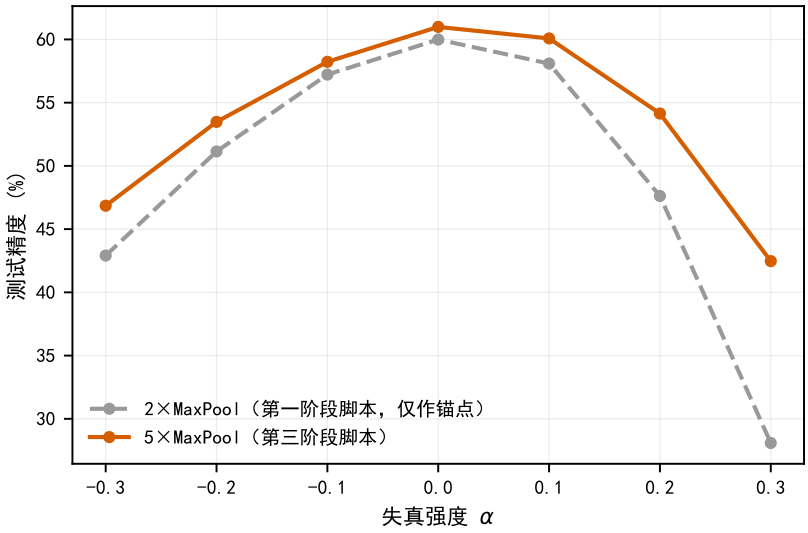


图 11：池化密度是零训练成本的独立架构杠杆。MaxPool 从 2 个加到 5 个（参数量不变）：$\alpha = +0.3$ 从 28.09 到 42.47。虚线为**第一阶段脚本**的产物：它与实线出自**不同训练脚本**（本项目实测跨脚本的精度数字不可直接比较），故属异协议、仅作锚点，不与实线并列比较。**注意：**28.09 → 42.47 **这一对数是横跨这两条曲线的，引用它须注明其跨协议性**；同协议同 seed 配对的读数是 26.03 → 41.55（+15.52），应优先引用后者。数据：`outputs_cifar100/v3_methods/simple_cnn_mp_clean_uniform/alpha_sensitivity.csv` 与 `task1_simplecnn/alpha_sensitivity.csv`。

`drop@0.3` 为 20.60 ± 1.54、5×avg 为 21.78 ± 0.91，差 +1.17（标准误 1.03，$z \approx 1.1$）→ **”降维：非均值聚合”的定量比例不予裁决**，只给方向：**保护主要来自降维。若还要继续追这两条，预算应花在 2×max 的更多种子上**（5×max 一侧的种子方差已经小一个量级，加种子收益低）。

3.10 两个杠杆的叠加与在线估计

架构杠杆与读出杠杆在尾部**可以同时受益，但显著次可加、不是相加：**mp 主干 + 读出适配的 $\alpha = +0.3$ 达 **49.12**（相对基线 28.09 即 +21.03），而两个手段单独的增益之和是 +29.67（架构 +14.38 与读出 +15.29 分别取自同批**单 seed** 产物的 42.47 与 43.38）——**合起来只拿到约七成，损失约三成**。本段四个数（28.09 / 42.47 / 43.38 / 49.12）**全部为单 seed 口径**（连续均匀 α、24 ep、20k 样本，同 v3 路径）；13 点离散 α、3 seed 的 v5 口径给出同样的次可加结论。

失真强度可由读出特征的岭回归在线恢复：四个主干 × 数据集组合上 R^2 **0.827∼0.978**（**浅层四个组合** 0.827 ∼ 0.935、**深层两个组合** 0.95 ∼ 0.98）、MAE **0.036∼0.061**。**主干越深、估计越准：**VGG-11（Exp2 主干）$R^2 =$ **0.9516** / MAE 0.0324，ResNet-18（Exp3 主干）$R^2 =$ **0.9778** / MAE 0.0219（出处：`v5_full_recipe/recipe_robust_*.csv` 的 `ridge_R2` / `ridge_MAE` 两列）。

3.11 门控的边界

图 12 给出门控红利与鲁棒头代价的关系。

CIFAR-100 的 mp 主干上，**鲁棒头**（即读出适配头，此处沿用产物列名 `acc_robust_head`）的干净代价 −5.89、门控收回 +2.90；但把深层主干加进来后，代价落进此前空白的 2∼5 个百分点区间（VGG-11 −3.45、ResNet-18 −4.36），**红利却没有跟着变大**（+0.68 与 **−1.14**）。

原因：ResNet-18 的原始头在负侧是崩的（$\alpha = -0.2$ 只有 10.27%）。软门控按 $w = |\hat{\alpha}|/0.3$ 插值，在 $\alpha = -0.2$ 处 $w \approx 0.67$，三分之一权重的坏头把 45.64 拖到 39.21。

表 5: 池化保护的四个候选解释与检验结果

候选解释	检验	结论
池化”吸收”了失真	归一化三次映射与 max 是否可交换	在池化输入（post-ReLU，非负）上**精确可交换**（$\max\|\Delta\| = 0.000\text{e+}00$），但可交换却非成因
质量向恒等区集中	5-pool 与 2-pool 的易感度 S 与不变区占比	5-pool 的 S **反而更高**（conv4：0.1527 vs 0.1134），不变区占比不变
max 的选择性	换成 top-2 池化（与 f_α 不可交换）	保护与 max 等同（42.98 vs 42.47，单种子）
ReLU 的非负性	换成 GELU（破坏非负性）后保护是否变弱	$P(\text{ReLU}) = +11.81$ 对 $P(\text{GELU}) = +14.71$（SimpleCNN，两种池化密度 × 3 seed），差 -2.91，落在预登记 ± 4 带内，**方向还随种子翻转 ⇒ 不可分辨**

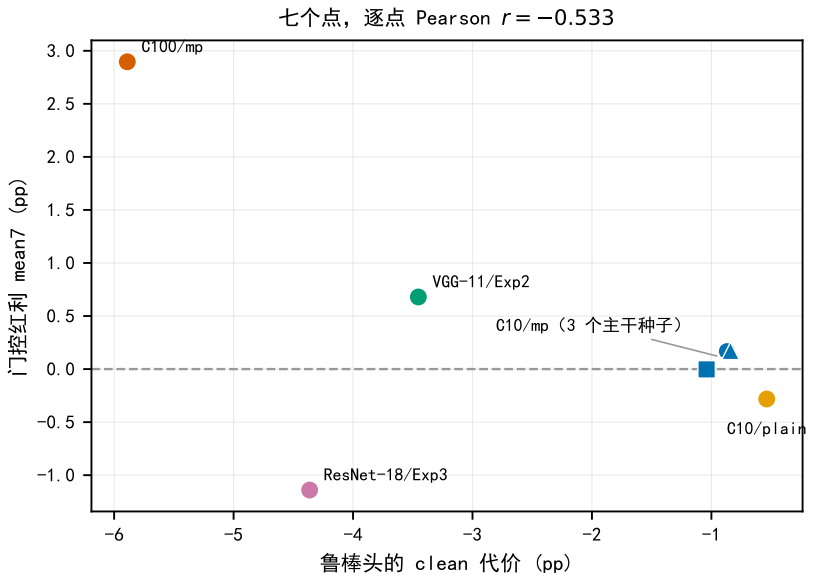


图 12: 门控红利不随鲁棒头代价单调增长。七个点取自四个主干配置与两个数据集，各 3 个种子。七点 $r = -0.533$；去掉 CIFAR-100 远点后 $n = 6$ 时符号反转为 $+0.351$。数据：`v5_full_recipe/recipe*.csv`。

门控有效需要两个前提同时成立：①鲁棒头干净代价足够大；②两个头在整个 α 轴上都不能崩。两前提**无法**做成装前的量化自检——两种候选定义在已有 7 个点上都不分离红利的符号（VGG-11 的最小精度只有 15.73 却红利为正；CIFAR-10 的 mp 主干（主干种子 43）的最小精度有 69.23 却红利为 -0.003）。

为什么它只能”弱支配”：一个机制级的回答。上面那条”跨数据集未复现”是经验事实；它后来有了一个**机制级**的解释，而这个解释同时把那个主张**永久关闭**了。

两个头的错误是否互补可以直接测：取两个头在**同一批样本**上的 0/1 错误指示向量，算它们的 ϕ 相关。**只有当两头的错误负相关时，插值才可能”集成”出比两头都好的结果**（$\phi = 0$ 即相互独立）。实测（7 个 α 点 × 3 个种子 = 每个数据集 21 格；下面的范围是**按 α 点做 3 seed 平均后**的逐点极值）：ϕ 的范围在 CIFAR-100 上是 $+0.594 \sim +0.706$、CIFAR-10 上是 $+0.519 \sim +0.830$；”两头都错”的格数相对独立基线为 $1.50 \sim 1.98$ 倍与 $2.76 \sim 6.58$ 倍。⇒ **ϕ 在两个数据集上都是强正**——两个头的错误**正相关**，它们在同一批样本上**一起错，「插值即集成」所依赖的互补性在两个数据集上都不存在**。

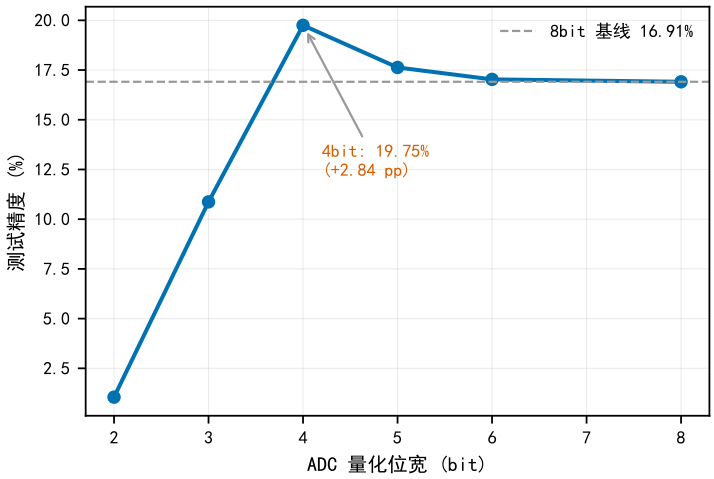


图 13：低位量化在池化密集架构上反转成增益（VGG-11，$\alpha = +0.3$，CIFAR-100）。4bit 时精度最高，比 8bit 高 2.84 个百分点。数据：`outputs_cifar100/extension5_dithering_vgg11/group_a_bits_scan.csv`。

由此两条：①那个机制是被**否证**，不是” 未能分辨”——本项目因此把「插值即集成」**永久关闭**；②收益的上界由此可解释：没有互补性可利用，插值的增益注定有限（实测” 软门控减 oracle” 的极差，CIFAR-100 为 1.60 pp、CIFAR-10 只有 0.71 pp）。但要分清：**被关闭的是机制解释，不是那个效应本身**——CIFAR-100 上软门控确有若干点超过两个头，那个效应仍然存在、也仍未被完全解释；本段只说明了**它的上界为什么不高**，没有说明**它为什么不为零**。

（出处：`outputs_cifar100/v7_gate_mechanism/gate_errors.csv`。该诊断含一条恒等自检：soft − oracle = (rescue − hurt) × 100，通过。）

3.12 失真与量化的联合作用

图 13 给出低位量化的反转。

VGG-11 上 4bit 量化的精度**高于** 8bit（CIFAR-100 +2.84、CIFAR-10 +6.53）。三假设判决（**以下机理数字全部取自 CIFAR-10 侧的** `outputs/extension5_dithering_vgg11/`——该目录才是当时跑机理分析的完整批量；CIFAR-100 侧的对应量见段末）：**H1 随机去相关否决**（等剂量注噪 −2.45/ − 1.87，8bit+ 最优剂量噪声 −0.03；样本级翻转 4bit 为 4.15:1 而噪声条件约 1:1）、**H2 分布重塑确认**（分类器输入峰度 1.486 → 0.110，4bit 恢复到 0.214）、**H3 MaxPool 交互支持（必要条件）**（无 MaxPool 的 ResNet-18 免疫 +0.39，但 2 个 MaxPool 的 SimpleCNN 是 −13.68）。

CIFAR-100 侧的平行读数（同批统计，见 `outputs_cifar100/extension5_dithering_vgg11/`）：峰度 2.541 → 0.847，4bit 恢复到 0.980；翻转 4bit 为 655:371（1.77:1），噪声条件同样接近 1:1；ResNet-18 的 4bit 减 8bit 增益为 −0.21、SimpleCNN 为 −14.71。**三条判决在两个数据集上同向**（H2 的” 峰度恢复” 在 CIFAR-100 上幅度较小），这本身是一条跨数据集稳健性证据。

4 研究历程：三次” 先归因、后被自己否证”

本节记录本项目最贵的一课。三次的形态完全一样：一个被当成” 噪声” 或” 实现细节” 的差异，被重新命名成一个” 效应”，又被实验否证，最后回到未知。

表 6: 5.55 个百分点差异的三次归因尝试

轮次	归因	结果
1	尾部**种子噪声** ±3.1	否证：三种子来自两脚本；同协议标准差只有 ±0.39，混协议把标准差估高约 6 倍
2	α 采样**粒度**	否证：同脚本切换粒度差 +0.02（$z = 0.08$），同粒度跨脚本差 +5.52（$z = 9.4$）
3	随机数**消耗位置**	否证：同脚本把消耗数从 5 改成 1，差 +0.11

4.1 第一次：把处理效应误读成噪声（±3.15 混协议）

当时的判断：一组鲁棒训练的 3 个种子，$\alpha = +0.3$ 的读数是 21.41 / 26.73 / 26.95，标准差记为” 尾部种子噪声 ±3.15 个百分点”（同期干净精度只有 ±0.51）。据此立下全项目规则：涉及尾部指标的对比必须 ≥ 3 个种子，单种子尾部差值 < 3 个百分点不构成结论。

问题：这 3 个种子来自**两个脚本**。

否证：补跑同脚本的第三个种子后，同协议的尾部标准差只有 ±0.392，而混协议组是 ±2.561——**标准差被估高约 6 倍**。进一步的定量分解显示：混合组里两个数相差 5.32，与实测的脚本级处理效应 5.52 几乎相等，也就是说 **那 2.56 里绝大部分不是随机噪声，而是两种训练配方之间的系统差**。

制度补丁：散布对比必须同脚本、同一采样代码路径。

4.2 第二次：把脚本差异误读成采样粒度

当时的判断：同 seed 下两个脚本的 $\alpha = +0.3$ 相差 4.62 个百分点，是纯协议标准差的约 11.8 倍。两脚本在数据加载、归一化、优化器、batch、epoch、调度器、增强、钩子机制、采样位置与评估口径上*逐项核对一致*，因此判定” 目前唯一可辨识的实现差异就是 α 采样粒度（每批共享 vs 逐层独立）”，并把它提升为候选定律。

否证：在**同一个脚本里只切换粒度**：shared 26.55 vs per-layer 26.57，差 +0.02（$z = 0.08$）；而**同粒度跨脚本**差 +5.52（$z = 9.4$）。**效应跟着脚本走，不跟着粒度走。**

制度补丁：涉及跨脚本比较时，**先做一次交叉评估**（把 A 的权重量到 B 的评估路径下），确认评估侧无差。这条制度立刻在下一个实验中产生了价值。

更深的教训：” 逐项排除混杂” 这种论证在跨实现比较里不成立。两脚本的 8 项都一致、训练损失逐 epoch 差 ≤ 0.016，效应却稳定存在。**没查出差异 $\neq$ 没有差异**。

4.3 第三次：把序列位置误读成消耗数

图 14 给出这次翻案的证据链。

当时的判断：交叉评估把差异锁到” 权重侧”（见下），再据 α 采样轨迹把根因定为” 随机数流错开”——一个脚本的 shared 模式消耗 5 个随机数、另一个只消耗 1 个，第 1 个 batch 相同、之后完全错开。

否证：在**同一个脚本里**把消耗数从 5 改成 1：26.66 vs 26.55，差 +0.11。**消耗数不是因果。**

最终图景：一个脚本训出的鲁棒权重稳定落在 $\mathbf{21.03 \pm 1.00}$（3 个种子，逐 seed 19.67∼22.02），另一个脚本的**六个** run 全部落在 $\mathbf{26.58 \pm 0.29}$（逐 run 26.03∼26.95），两组相差 **5.55** 个百分点（$z = 9.4$）。**组内极紧、组间稳定分离**——这正是最令人困惑的地方：同脚本内换种子的流差异只值 ±1，跨脚本却稳定值 5.55。

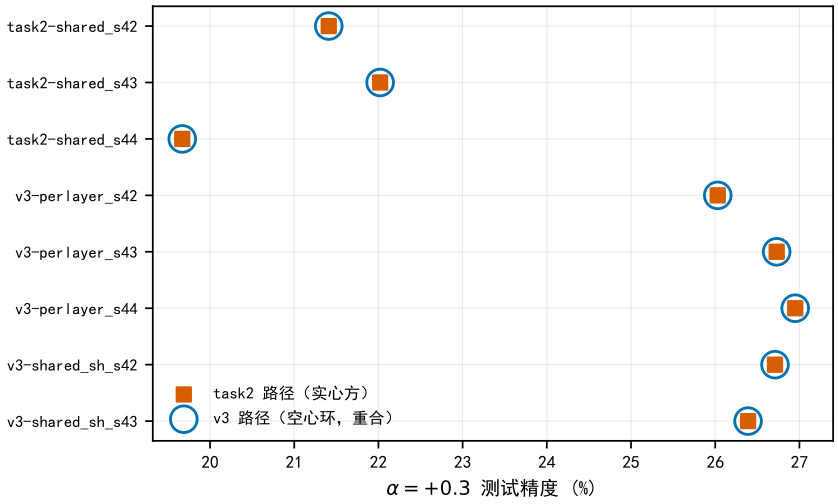


图 14: 交叉评估：差异不在评估路径。8 个权重分别在另一脚本原样导入的评估函数下重扫，两条路径给出**逐位相同**的读数；但两组权重稳定分成两簇。数据：`outputs_cifar100/v6_p4e_crosspath/crosspath.csv`。

已排除的解释累计：种子噪声、α 采样粒度、随机数消耗数、评估路径（8 个权重 $\times$ 2 条路径逐位相同）、训练动力学（逐 epoch 损失差 ≤ 0.016）。**仍未归因，按已知未知记录。**

最终的结论（限定形式）：本文观测到一个同超参、同种子、跨实现稳定 5.55 个百分点的差异，经三次干预实验仍未归因。在归因之前，**我们的做法是**不跨实现引用精度数字，部署校准与部署训练保持同实现、同路径。**这不排除”某一脚本里还有一个尚未找到的具体差别”**——把一个未定位的差异直接命名为”实现层普遍不可移植”，证据不足。

4.4 三次翻案的共同点与制度沉淀

三次都是**用自己的实验推翻自己上一轮的结论**。三次的根因按项目内部的总结都是”**没做交叉评估**”——或者说，**在跨实现的比较里，任何没有做干预实验的归因都只是命名，不是因果。**

沉淀下来的三条制度：

1. **降级一个数字，必须扫它的整条引用链。**含均值、差值、占比这些**派生量**——它们不带原值，模糊搜索抓不到。这条制度立起来的原因是：一次降级只改了被降级的那一节本身，而它派生出去的数字还在下游活着（其中一处甚至是”同一行内混了两个脚本”）。
2. **散布对比三要求：**同脚本 / 已交叉评估 / 未校准的组必须标注。后续补充第四条：跨实现比较前先做消耗数等价检查；且”同脚本 + 交叉评估”**不足以**让两套跨脚本数字可比。
3. **判据跑前写死，跑后不改。**六个阶段的每个实验都在台账里留了预登记，包括那些最终被否证的。

5 第七阶段：归档后的自主迭代

归档（tag `v1.0-archive`）之后又进行了一轮自主迭代。本节记录它的产出——分两类：**加强结论的**，与**排除解释的**。末尾补记收官阶段的三项实验（LP-FT / 秩-恢复第 4 点 / ReLU 非负性）。详细台账见 `experiments_ledger.md` §16。

5.1 两条加强中心结论的结果

(1) 容量不是这里的瓶颈。此前所有读出都是**线性**的，所以" 瓶颈在读出" 有一个明显的反驳：也许瓶颈只是在线性。为排除它，在同一批冻结特征上比较六种读出（$\alpha = +0.3$，CIFAR-100，$n_{\text{train}} = 8000$）：

读出	精度（%）
线性头（torch，同族公平锚）	**51.47**
强正则逻辑回归（$C = 0.01$）	49.23
sklearn 逻辑回归（跨优化器参考臂）	48.25
两层 MLP（$128 \to 256 \to 100$）	48.62
瓶颈 MLP（$128 \to 32 \to 100$）	43.38
k-NN（$k = 20$）	38.12

三种非线性读出**没有一个超过线性头**（相对线性头 51.47：k-NN 38.12 即 −13.35、瓶颈 MLP 43.38 即 −8.09、两层 MLP 48.62 即 −2.85）。前两者的差距远超本轮立的可分辨门槛（$\Delta_{\text{proc}} = 3.45$ pp，见下）；**两层 MLP 只差 2.85，落在门槛内、按本文自订规则不可裁决**，方向上仍劣于线性头。而且**参数越多反而越差**——典型过拟合序。⇒ 「信息仍线性可达」从" 只测过线性" 升级为「**测过 k-NN 与两种 MLP 之后，线性头仍是最优读出**」。

(2) headroom 是下界，而且可以抬高。把探针的训练样本从 8000 加到 50000（训练集全量）：

	探针（n=8000）	探针（n=50000）	冻结头
clean	53.56	**59.00**	59.99
$\alpha = +0.3$	48.35	**55.72**	28.09
headroom @+0.3	+20.26	**+27.63**	—

且仍未饱和（等宽对数斜率比 $r = 0.96/0.61$，判据要求 ≤ 0.5）。按" 不相交划分" 校正后约 +25.4（$= 27.63 - 2.19$；其中 2.19 pp 是" 探针训练集与主干训练集 **不相交**" 这一口径在 $\alpha = +0.3$ 上比分布内低的量，出自台账 §16.0a 的三臂对照，此处按同口径移用到 n=50000 档）。

这条观测的含义比数字本身重要：+20.26 不是表征的某个固定属性，它是" 探针只喂了 8000 个样本" 下的读数。⇒ **headroom 是读出训练方式的函数**——与下面那条" 过程自由度" 是同一件事的两个侧面。**读出这一层不是免费的。**

5.2 四条判定：三条排除型结论 + 一条限定

方向	判决
ETF / 原型读出	**无增益**。三种原型或 ETF 正则读出均未超过线性头
神经坍缩（NC）几何	**未能构成稳健排除**。类均值夹角偏离与模长变异系数在**以全局均值为中心**的口径下正侧 5/5 上升（即**远离** ETF）；但换成**不做中心化**的口径，模长变异系数只有 1/5 上升——**两版给出不同的判决分支**。⇒ 该几何量对预处理敏感，「正侧 Fisher 反而高于负侧」这条异常**未能由它稳健地排除**
" 少样本即可恢复全表示"	**不成立**。读出样本量曲线在 500~50000 上单调上升且**未饱和**，需数千量级样本
门控两前提的装前自检	**不分离**。两种候选量化定义在已有的 7 个点上都分不开红利的符号

排除型结论的价值在于：它们各自堵死一个替代解释。尤其第一条——原来" 读出瓶颈" 可以被反驳为" 你只测了线性头"，现在这个反驳不成立了。**第二条（NC 几何）在本轮审计后不再作排除用：**它两版判决不同、对预处理敏感，此处如实记为" 未能构成稳健排除"——**这条降级本身就是信息：**它说明该几何量在本配置下不具备判决力，因此不能拿它去否证别的解释。

5.3 方法学产出（本阶段最值钱的部分）

(a) 三级可分辨性。「跨实现不可移植」是一个已知未知，无法直接当门槛用。但它旁边两级**可测**的散布，合起来给出一个可操作的尺度：

层级	变的是什么	实测幅度
①种子噪声	同一过程重复；**两类种子须分开**	尾部：**读出种子** $\pm 0.16 \sim 3.40$、**主干种子** $\pm 0.25 \sim 2.61$；clean $\pm 0.07 \sim 1.85$
②过程自由度	**同数据、同特征、同架构，只换拟合过程**	**3.45 pp**
③跨实现	同超参同种子，实现不同	5.55 pp（未归因）

第②级是这样测的：同一批冻结特征、同一个线性头，只换六种拟合过程（sklearn lbfgs / saga；torch Adam 50/150/400 轮；SGD+ 动量 150 轮）。结果极差 **3.45∼3.46 pp**。

一个反直觉的细节：$\alpha = 0$ 的最大值与最小值**都来自同一个优化器的不同轮数**（Adam 50 轮最高 56.31、Adam 400 轮最低 52.85），该点上" 训多久" 的跨度（3.46）覆盖全距。$\alpha = +0.3$ 上要打一点折扣：极值跨了两个因子（最高仍是 Adam 50 轮的 51.57，最低是 SGD+ 动量 150 轮的 48.12），轮数跨度 3.02、同轮数的优化器跨度 2.25——前者仍更大，但不独占。⇒ **过程自由度的主要来源是" 训多久" 而不是" 用哪个"**；这条在 $\alpha = 0$ 上最干净，且只在本文测过的**这一个特征集与头规模**上成立，属**提示性**结论。

⇒ 由此立一条规则：**任何" 读出类" 效应（换头、加正则、改容量）的可分辨门槛，必须同时以 Δ_{proc} 为参照，不能只用种子噪声**——种子噪声测的是" 同一过程重复"，Δ_{proc} 测的是" 换一个过程"，**后者才是接收端口真正面对的不确定性**。

(b) 两条口径陷阱（都是本轮内实测触发的，不是转引文献）。

陷阱	不做会怎样	为什么会
不做 **RMS 归一化**	负侧结论**反号**	$\alpha < 0$ 把深层激活抬到 1.87 倍，固定绝对噪声相对更" 小"，失真组虚假显得更鲁棒
不做**中心化**	判决从分支②变③	NC 的定义是" 以全局均值为中心" 的单纯形框架；不去均值则度量的是别的几何量

(c) 两个工具（把纪律固化，不靠记性）。

- `tools/check_papers.py`：提交前检查（markdown 残留 + 编译两遍 + 数错误 + 数未定义引用）。**本阶段在 `.tex` 里混写 markdown 踩了 8 次，其中 7 次由它拦下**——手动检查已被证明不可靠（有两次是" 修完以为干净了、实际还有"）。
- `docs/DERIVED_VALUES.md`：派生值登记表。均值、差值、比值这类数字**不以字面形式存在于任何产物文件里**，复核的人必须知道算式才复得出来。该表登记它们的文件/行/列/合成方式。

(d) 一次对存量判据的「前提自检」回溯审计。本阶段先撞出两次同形缺陷（§16.5a、§16.7），据此立了一条要求：**凡拿某个量当参照或判据依据的，都要补该量的前提自检**。制度立起来之后的第一件事，是拿它**回头扫存量**：扫 **30** 条显式预登记判据，得 **8 条同类缺陷（命中率 27%）**，其中 **5 条足以翻转判决、3 条已由实测确认翻转**。**一条时间上的观察**：8 条缺陷**全部落在 §4∼§13** 这一段（早期阶段），§14 及以后一条都没有——不是" 后来的判据写得好"，而是**制度立起来之后，同类缺陷在当场就被抓了**。**顺带发现：无**——本次未发现任何" 实验结论本身" 的问题，**全部 8 条都是判据写法问题**，不是执行或数据问题。（出处：台账 §16.8；本节无新产物文件。）

5.4 收官补测：三项实验（2026-09-26）

M4 收工之后还有一段 GPU 空窗，补跑了三项此前排在队尾的实验。**三项都不需要修改既有结论**，其中一项把已有的表述改得更准。详细台账见 §16.9 / §16.10 / §16.11，正文细节已并入上文对应各节。

实验	判决	一句话
M8c LP-FT	**阴性（强）**	先训读出、再解冻主干微调，**三个主干一致大幅下降**（−11.85 / −33.83 / −12.88）。机制：FT 阶段训练精度涨到 88.9% / 96.9%，而各 α 测试全线变差、尾部降幅远大于干净降幅 ⇒ **微调破坏了预训练特征**。这正是 LP-FT 论文在分布偏移下要避免的现象，**在失真场景下没有被避免**。⇒ 支持" 训练端做的事越少越好"
M5 秩-恢复第 4 点	**仍不足以判定形状**	新增 Wide-CNN 容量档（1.40M 参数 / 133.3M MACs），干净精度 65.97% 居中，**但秩损失 19.9% 与 SimpleCNN 的 20.6% 几乎重合**，没有落进中间段。**顺带发现比判据更重要**：秩损失只差 0.7 pp、恢复率却差 4.0 pp ⇒ **秩损失不是恢复率的唯一决定因素**
M14b ReLU 非负性	**不可分辨**	把 ReLU 换成 GELU：$P(\text{ReLU}) = +11.81$、$P(\text{GELU}) = +14.71$，差 -2.91，落在预登记 ± 4 带内。**方向还随种子翻转**（单 seed +2.57、3 seed −2.91）⇒ **不是" 接近显著"，是" 判不了"**

这一轮的附带产出（比三条判决本身更值得记）：

1. **一个新的、可执行的下一个问题**。M5 把" 秩损失预测可恢复量" 这条从一个**开放搜索**变成了一次**有对照的检验**——我们已知道两个主干在几乎相同的秩损失下相差 4.0 pp，那么找出它们**除秩损失之外还差什么**，答案就在里面。
2. **噪声来源被定位**。M14b 补 seed 后看出：2×max 的种子标准差（3.03 / 2.89）比 5×max（1.54 / 0.26）**大一个量级**。⇒ 若要真正裁决非负性假说，预算应花在 2×max 的更多种子上。
3. **一条负面方法学经验**。全模型反传叠加" 每 batch 注册失真 hook" 会让训练慢 7 倍（实测 $> 13\,\text{min/epoch}$，而该主干从头训练是 105 s/epoch），实验一度被迫中止。⇒ 微调类实验要单独配 batch 与 hook 策略，不要复用" 冻结主干前向 / 浅层训练" 的配置。

5.5 本阶段自我暴露的问题（同样留痕）

问题	处置
探针 headline 曾是 8000 子集口径	台账 §6 登记过、但没传播进论文。重跑全量口径并替换，扫了 5 个文件 49 处数字
一处数字**全仓库无出处**	追查 `12.76` 时发现它不存在，原句还把两个不同基线的数并进一个区间。登记为勘误 12
四处 Fisher 措辞**丢了比较对象**	” 正侧升高” 不成立（正侧内部只有 +0.1 升），且**可被本文自己的表格否证**。全部改为带比较对象的写法
读出适配的**命名会骗人**	`s4{2,3,4}` 三个文件其实是**同一个主干**变读出种子。新主干改用 `bs<seed>` 区分，并加” 原头读数 = 主干 metrics” 的核验
摘要与贡献列表落后于正文	正文加了四块内容后外围文档没跟上。**这是” 扫引用链” 在文档层的同类问题**

6 工程落地推演

本节把研究结论映射到真实 CIM 的数字后端。**零实验、全部是推演**；每个数字要么来自仓库里的实测（标出处），要么是本节现算的（标算法）。判定分三档：**可行** / **需改动** / **不可行**。

6.1 场景设定

- 模拟阵列负责卷积与全连接的乘累加，权重**固化在阵列里**（这是 CIM 省功耗的前提）；
- 阵列输出经 ADC 回到数字域；
- 失真发生在模拟域的输入侧，逐层注入（式 (1)）；
- 数字后端（ADC 之后）可以做任意运算，代价是面积、延迟、功耗。

本节不涉及：ADC 位宽、阵列规模、模拟域校准电路。这些在项目数据里没有对应测量。

6.2 三档判定

6.3 唯一的硬约束

读出层必须落在数字域或可重写——这是全部结论里唯一需要硬件配合的地方。它的改动方向与 CIM 的常见架构一致：ADC 之后本来就是数字电路，把最后那一层放在数字域，很多设计本来就这么做。**落地的关键问题是” 你的 CIM 把哪一层当读出”，而不是” 能不能改”。**

6.4 风险清单（不是结论）

1. **失真形态的假设**。全部收益都是在” 逐层、逐样本 max 归一化、三次多项式” 下测的。真实芯片的失真未必是这个参数化形式。参考：加性高斯噪声这条对照通路的 headroom 只有 +7.50，比非线性的 +20.26 低得多。
2. **ADC 量化与失真的联合**。已测：SimpleCNN 上 4bit 是超加性恶化，VGG-11 上是次加性。也就是说” 数字域后处理能救多少” 要**分层看**。
3. **跨脚本的采样序列差异必须处理**。两个脚本训出的鲁棒权重稳定差 5.55 个百分点，评估路径已验证无辜。**落地时两套数字不可混用**。

表 7: 把结论映射到 CIM 数字后端

组件	判定	依据
读出适配	**需改动**	要求读出层位于数字域、或阵列里那一小块可重写。若读出也被固化在阵列里，该方法不成立。读出层只占全模型参数的 **5.04%**（SimpleCNN）/ **0.55%**（VGG-11），把它挪出阵列对阵列面积的影响很小
在线 α 估计（岭回归）	**可行**	128/512 维点积，算力占主干前向的 **3.8e-4%** / 2.4e-4%。真正的代价在面积：多一份 d 维权重的存储
软门控（双头插值）	**可行**（前提同第一条）	纯数字域逐元素运算，每次推理约 **400** 次操作。原始头是冻结不动的那一个，正好可以烧进 ROM
冻结主干	**可行**	就是" 不训练主干"，天然符合权重固化
MaxPool 密集主干	**设计阶段零成本 / 部署后不可行**	它是网络定义的改动，只能在投片前决定；好消息是它零训练成本
全网络重训	**不可行**	阵列里的权重是烧录/固化的；而且训练端五条路本来就救不了尾部

6.5 没做的事

没有硬件实测，也没有 RTL/功耗仿真；没有把" 读出层挪到数字域" 的具体接口写出来（时序、位宽、与 ADC 的对接）；没有评估在线重训读出在现场是否可行；没有考虑多任务/多模型共享阵列的情形。

7 可复现性手册

7.1 环境

- Python 必须用 conda 环境 `pytorch_env`。直接敲 `python` 在本机解析到别的解释器（没有 torch）。
- 输出重定向到文件时设 `PYTHONIOENCODING=utf-8`，否则会在打印特殊字符（如 R^2 符号）处因编码中断。
- 显存 8GB。**训练任务必须严格串行。**本项目出过两次事故：并发 4 个带 DataLoader worker 的任务导致 Windows 提交内存耗尽；一次 CUDA 显存不足（两个训练同时跑）。
- `checkpoints/` 与 `*.log` 在 `.gitignore` 中，不进版本库。

7.2 复现一个数字（三条命令）

```
# (1) 重建全局台账（只读扫盘，不修改任何既有产物）
<python> build_ledger.py
# -> [ledger] 152 rows -> results_master.csv
# -> [ledger] 冒烟过滤 = 5 行（epochs==1 或 run_id 含 smoke；产物留盘不动）
# -> [ledger] pairing FAIL = 0

# (2) 看某一行的四个字段（例：CIFAR-100 / SimpleCNN / clean 基线）
grep "cifar100|simple_cnn|clean|7pt" results_master.csv
```

```
# -> clean=59.99 drop_at_0.3=31.9 mid_band_mean=53.5175 pos_0.3=28.09

# (3) 复算派生量（七点均值），核对文档里的 mean7
<python> tools/recalc_mean7.py
```

其中 <python> 为 /d/anaconda3/envs/pytorch_env/python（或本机等价路径）。

口径自检：任意一个 run 的强度扫描文件里 $\alpha = 0$ 那一行，必须等于同目录训练指标文件的 best_test_acc（容差 0.01）。

7.3 重新出图

```
<python> paper/figures/gen_figures.py # 期刊/技术报告版（F01-F11）
<python> paper/figures/gen_figures_comp.py # 竞赛版（C01-C08）
```

两个脚本都**只读 CSV**，脚本内不硬编码任何精度数字，末尾打印关键读数供交叉核对。中文图使用 SimHei 字体，输出 PDF（矢量）与 PNG（300 dpi）两种格式。

7.4 读文档顺序

1. paper/storyline.md——Central Claim 与 Question–Experiment–Finding 映射表；
2. paper/results-outline.md——每个结果子节的 Question / Data / Finding / 1-hop；
3. paper/discussion-notes.md——2-hop 综合、一般原理、局限与未来工作；
4. experiments_ledger.md——逐实验的预登记判据与结果（最权威的一手台账）；
5. results_master.csv——机器可读的全局表；
6. 本报告第 4 节——最应该读的一节。

8 局限、停车场与下一步

8.1 局限（每条导致一个由本文发现引出的问题未决）

(1) 失真模型是参数化假设，且无硬件实测。若真实 CIM 的非线性更接近高阶多项式、带温度依赖、或器件间失配有随机成分，headroom 还有多大、读出杠杆是否成立，**无法回答**。已知下界来自高斯对照（20.26 → 7.50）。

(2) 深层差值的可裁决性（已补测，原判断部分保留）。原写" 深层主干是单次训练产物…… 涉及深层的所有差值是否在主干种子方差内无法裁决"。现每个深层主干已补训到 3 个种子（读出侧固定 seed 42）。尾部（$\alpha = +0.3$）的**主干级**标准差为 VGG-11 0.25、ResNet-18 2.61，**均小于对应的读出级标准差**（3.18 / 3.40）——即此前印出的 ± 值没有低估总不确定度。读出适配线上的深层差值因此可以裁决（须写明在已测主干上成立）；而门控红利 −1.14 仍落在主干级散布 2.61 之内，**这一条仍然不可裁决**——理由从" 没有测" 变成了" 测了，方差确实盖得住它"。

(3) 池化保护的机制分解没有定下来。两个子问题都没有结论：**①定量分解**——avg 与 max 的差值只有 +1.17，$z \approx 1.1$；**②非负性**——换成 GELU 后保护之差为 −2.91，落在预登记 ±4 带内，**且方向随种子翻转**（单 seed +2.57、3 seed −2.91），只能记为不可分辨。

(4) 秩-恢复关系仍不足以定形状，且秩损失不是唯一决定因素。第 4 个容量档已补齐，但它与 SimpleCNN 的秩损失几乎重合（19.9% 对 20.6%），没有落进中间段，故曲线形状仍未判定；

同时它暴露出**秩损失相同的主干恢复率可差 4.0 个百分点**（> 3 pp 分辨门槛）⇒ **秩损失之外还有一个变量，本文未识别**。

(5) 跨实现的 5.55 个百分点差异未归因。已验证无效的路径是换评估路线；必须动训练循环。

(6) 读出适配要求读出层可写，且未评估其硬件代价。

(7) 读出适配只在 $|\alpha| \le 0.3$ 的窗口内评估过。全部读出产物的 α 网格都是 ± 0.3 七个点（`v3_readout_repair/*.csv` 的表头逐字如此），**没有一份覆盖** $\pm 0.4/\pm 0.5$。而原始头恰在那两处跌到 12.32 / 6.09，探针 headroom 反而最大（+30.90 / +30.82）——**读出杠杆在更远的尾部还能捞回多少，由现有数据无法回答**，而那里正是工程上最需要这个杠杆的地方。

(8) 架构杠杆只在含池化的主干上验证过。「池化密度是独立杠杆」的证据全部来自 SimpleCNN 家族（MaxPool 2 个 $\to$ 5 个）；而本项目用的 ResNet-18 已按 CIFAR 适配去掉初始 MaxPool，其 `maxpool_count` 为 0（`outputs_cifar100/extension5_dithering_vgg11/arch_dithering_summary.csv`）——**对本身不含池化的架构（含注意力主干），这条建议没有对应的旋钮**，本文给不出替代方案；而第 6 节把它排在落地顺序的第一步。

(9) 证据全部来自 CIFAR 上的小型卷积主干。参数量跨度只有 0.25 M∼11.2 M，架构形态**全部是 ReLU + 卷积/池化堆叠**（无注意力、无归一化型主干）。**「先测 headroom、再决定修哪里」这套测量顺序能否外推到注意力架构与更大规模，本文未验证**；而第 6 节的推演没有限定架构。

(10) 探针是 oracle-α 读数，缺一条与部署同构的读出臂。探针逐 α 训练（见第 3 节的口径标注），因此 headroom 度量的是" 已知失真强度时还能恢复多少"。一条用 α 混合数据训练的（与部署同构的）读出臂**尚未产出**（脚本与预登记判据已就绪，受资源限制未执行）；在它落定之前，**headroom 与部署可达之间的缺口有多大，无法回答**。

(11) 低位量化与读出适配从未组合测量。「低位量化在池化密集架构上反转为增益」的证据取自**未施加读出适配**的原始头，且固定在 $\alpha = +0.3$。两条杠杆（量化与读出适配）从未落在同一份产物上，**它们的收益是可加、还是互相挤占同一个补偿机制，本文无法判定**。

8.2 停车场（只登记不执行）

表 8: 待办清单

#	想法	成本	备注
0	**鲁棒权重为何稳定低 5.55 个百分点?**（机制解释）	≥ 2 次训练	已排除 5 项；**最高优先**。核心谜题：同脚本换种子只值 ± 1，跨脚本稳定 5.55（$z = 9.4$）
1	采样粒度的跨架构复现	—	**已取消**：粒度不是杠杆
2	粒度 × 深度的交互	与 #1 合并	前提已失效
3	其他采样粒度定义（逐 block 独立等）	2∼3 次训练	前提已失效
4	粒度对负侧的影响	0（复用）	降为" 数据已到手，未分析"
5	R^2 上界能否用" 池化压掉多少 α 信息" 定量解释	0（复用）	零成本
6	深层主干的重训散布	4 次训练 × 4h	贵，但能说清深层结论的置信度
7	门控" 两头都不崩" 能否量化成装前自检	0（复用）	**已判否定**（两种定义都不分离）
8	深层双头为什么绝对值不低	0（复用）	需先做同口径比较
9	秩-恢复曲线的形状（" 先平后塌"）	需第 4 个模型	再加 1 个模型即可看形状
10	跨数据集/跨架构的粒度复现	—	设计目的已失效，等 #0 查清后决定

8.3 下一阶段的入场券与判据

表 9: 建议的入场判据（需裁决后才能生效）

入场券	判据	成本
#0 的机制解释	**前置要求**：必须能解释” 为什么同脚本换种子只值 ±1、跨脚本却稳定 5.55” 这个量级差；**只给出一个新名字不算**（这条已被证伪三次）。已验证无效的路径：换评估路径。建议做法：逐行对齐两个训练循环做二分	≥ 2 次训练
深层主干散布	**已兑现（M4）**：主干级标准差 VGG-11 0.25、ResNet-18 2.61，均小于读出级，深层差值因此可以裁决	已收工
池化保护的两成分分解	每组 ≥ 8 个种子，**或**换效应量更大的对照（池化窗口 2×2 vs 4×4）。**补充（M14b 实测）**：同一批数据还带出一条预算指引——噪声集中在 $2\times$max 一侧（种子标准差差一个量级），追加种子应投在那里	9∼10 h
秩-恢复曲线形状	**已测（M5）**：第 4 点与 SimpleCNN 的秩损失几乎重合（19.9% 对 20.6%），故**形状仍定不了**，判为” 仍不足以判定”。**但这次补测引出一个更值得做的问题**——找出秩损失之外那个变量	已收工

8.4 已明确排除、不应重走的方向

为避免后来者重复试错，以下方向在本项目中已被实验否证，**不建议再列为候选：**

- 读出训练时混入干净样本以回收干净精度代价——权衡中性，两档之间非单调；
- 在 ADC 前注入随机噪声以复现 Dithering——等剂量注噪的增益约为零（假设已否决）；
- 通过训练期采样设计（预算分配 / 对抗 / 课程式 / 范围外推）提升正侧尾部——四条独立负结果（无一改善，其中两条显著劣于基准、一条落在单种子门槛内、一条与基准同级）；
- 先训读出、再解冻主干微调（LP-FT）——**不但无效，三个主干一致大幅下降**（-11.85 / -33.83 / -12.88），机制是微调破坏预训练特征；
- 把” 两头都不崩” 做成量化自检——两种定义在已有数据上都不分离。

9 结论

1. 在逐层三次多项式非线性失真下，网络在灾难尾损失的是**读出的可解码性**而非表征中的信息（oracle-α 探针 headroom 20.26 个百分点；高斯噪声下仅 7.50）。
2. 据此，冻结全部模拟权重、只重训最后的线性层，可把尾部提升 +15.2 ∼ +31.8 个百分点（CIFAR-100，24 ep/20k，各 3 seed），成本约为主干重训的 1/5∼1/16（逐主干配对：读出 12 / 25 / 30 min 对全网络 1 / 6.5 / 6.5 h），并一致超过所有全网络鲁棒训练配方。
3. 训练端的五条补救路径没有一条改善尾部（前四条中两条显著劣于基准、一条落在单种子门槛内、一条与基准同级；**第五条解冻主干微调反而主动破坏**，三主干 $-11.85/-33.83/-12.88$）；正侧尾部是结构性不可训练区，其形态是**维度丢失**（有效秩下降 20.6%∼58.7%）而非类间距缩小。

4. 架构端的池化密度提供另一条零成本的独立杠杆（同协议同 seed 配对 +15.52 个百分点），其保护主要来自降维；两个杠杆在尾部可以同时受益，但**显著次可加、不独立相加**。
5. 失真强度可由岭回归在线恢复（R^2 0.827∼0.978），使门控可以逼近 oracle；但门控有效需两个前提同时成立。
6. 工程上，全部结论只依赖一个硬件条件：**读出层位于数字域或可重写**。
7. **测量纪律上**：本文观测到一个跨训练实现稳定 5.55 个百分点的差异，经三次干预实验**仍未归因**；在归因之前，**我们的做法是**不跨实现引用精度数字。该差异按已知未知记录——**未排除"某一脚本里还有未被找到的具体差别"**。

参考文献

[1] Yu S, Chen P Y. Emerging memory technologies: recent trends and prospects[J]. IEEE Solid-State Circuits Magazine, 2016, 8(2): 43–56.

[2] Ankit A, El Hajj I, Chalamalasetti S R, et al. PUMA: a programmable ultra-efficient memristor-based accelerator for machine learning inference[C]//ASPLOS. Providence: ACM, 2019: 715–731.

[3] Bhattacharjee A, Bhatnagar L, Kim Y, et al. NEAT: nonlinearity aware training for accurate, energy-efficient, and robust implementation of neural networks on 1T-1R crossbars[J]. IEEE TCAD, 2022, 41(8): 2625–2637.

[4] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//CVPR. Salt Lake City: IEEE, 2018: 2704–2713.

[5] Wannamaker R A, Lipshitz S P, Vanderkooy J, et al. A theory of nonsubtractive dither[J]. IEEE Transactions on Signal Processing, 2000, 48(2): 499–516.

[6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. Las Vegas: IEEE, 2016: 770–778.

[7] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//ICLR. San Diego: ICLR, 2015: 1–14.

[8] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.

[9] Kumar A, Raghunathan A, Jones R, et al. Fine-tuning can distort pretrained features and underperform out-of-distribution[C]//ICLR. 2022. arXiv:2202.10054.

[10] Wang D, Shelhamer E, Liu S, et al. Tent: fully test-time adaptation by entropy minimization[C]//International Conference on Learning Representations. 2021. arXiv:2006.10726.

[11] Liang J, Hu D, Feng J. Do we really need to access the source data? Source hypothesis transfer for unsupervised domain adaptation[C]//International Conference on Machine Learning. 2020: 6028–6039. arXiv:2002.08546.

[12] Rabby G, Auer S. When Graph-JEPA learns the wrong thing: diagnosing and repairing category-conditional collapse[R]. 2026. arXiv:2608.20516.

[13] Reblitz-Richardson O. When probing accuracy saturates, fragility resolves: a complementary metric for LLM pre-training analysis[R]. 2026. arXiv:2606.11375.

[14] Xiao Z, Naik V B, Lim J H, et al. Adapting magnetoresistive memory devices for accurate and on-chip-training-free in-memory computing[J]. Science Advances, 2024, 10(38): eadp3710.