

存算一体芯片逐层非线性失真： 机制、边界与读出层修复

——技术报告与内部归档（六阶段全记录）

黄奕皓

中国科学院大学计算机科学与技术，北京

huangyihao24@mails.ucas.ac.cn

归档版本 v1.0-archive, 2026 年 9 月

摘要

本报告是存算一体芯片非线性失真项目的完整技术归档，覆盖六个研究阶段的全部结论、失败记录、方法学制度与工程推演。与面向期刊的论文版本相比，本报告额外保留三类材料：**(a) 研究历程**——三次“先归因、后被自己否认”的完整链条；**(b) 工程落地推演**——把结论映射到真实 CIM 数字后端的三档判定；**(c) 可复现性手册与方法论制度**——使后来者能重建每一个数字，并知道哪些比较是无效的。

核心科学结论为：在逐层三次多项式非线性失真下，网络在灾难尾（ $\alpha = +0.3$ ）损失的是读出的可解码性而非表征中的信息（oracle- α 探针 headroom +20.26 个百分点，同一探针在加性高斯噪声下仅 +7.50）；据此，冻结全部模拟权重、只重训最后的线性层，即可以约 $1/5 \sim 1/16$ 的主干重训成本在尾部超过所有全网络鲁棒训练配方（三主干：28.09/15.98/6.22 $\rightarrow$ 43.31/47.79/26.82）；而训练端没有一条补救路径能改善尾部。架构端的池化密度是另一条零成本的独立杠杆（同协议同 seed 配对 +15.52 个百分点），其保护主要来自降维。

本报告同时记录一条方法学观察：本文观测到一个同超参、同种子、跨实现稳定 **5.55** 个百分点的差异——同一份权重在两条评估路径下读数逐位相同，而两个训练脚本产出的权重稳定分居两簇。该差异经三次干预实验仍未归因；在归因之前，我们的做法是不跨实现引用精度数字。这不排除“某一脚本里还有一个尚未找到的具体差别”，故按已知未知记录，而非上升为普遍律。

关键词：存算一体；非线性失真；读出瓶颈；有效秩；鲁棒性杠杆；测量纪律；技术归档

目录

1	阅读指南	3
2	问题、口径与产物	3
2.1	失真模型	3
2.2	度量口径与自检	4
2.3	数据集、主干与产物布局	4
3	六阶段的技术内容	4
3.1	阶段划分	4
3.2	第一、二阶段：任务层结果与三项优化（CIFAR-10）	5
3.3	失真有多大破坏力，往哪里累积	8

3.4	灾难尾丢的不是信息，而是读出的可解码性	8
3.5	修复：冻结主干、只重训线性读出	9
3.6	训练端的五条路径为什么都没能改善尾部	9
3.7	损伤的形态：维度丢失，不是类间距缩小	10
3.8	第二个杠杆：池化密度	11
3.9	两个杠杆的叠加与在线估计	12
3.10	门控的边界	13
3.11	失真与量化的联合作用	14
4	研究历程：三次”先归因、后被自己否认”	15
4.1	第一次：把处理效应误读成噪声（ ± 3.15 混协议）	15
4.2	第二次：把脚本差异误读成采样粒度	16
4.3	第三次：把序列位置误读成消耗数	16
4.4	三次翻案的共同点与制度沉淀	17
5	第七阶段：归档后的自主迭代	17
5.1	两条加强中心结论的结果	18
5.2	四条判定：三条排除型结论 + 一条限定	19
5.3	方法学产出（本阶段最值钱的部分）	19
5.4	收官补测：三项实验（2026-09-26）	20
5.5	本阶段自我暴露的问题（同样留痕）	21
6	工程落地推演	21
6.1	场景设定	21
6.2	三档判定	21
6.3	唯一的硬约束	21
6.4	风险清单（不是结论）	22
6.5	没做的事	22
7	可复现性手册	22
7.1	环境	22
7.2	复现一个数字（三条命令）	23
7.3	重新出图	23
7.4	读文档顺序	23
8	局限、停车场与下一步	23
8.1	局限（每条导致一个由本文发现引出的问题未决）	23
8.2	停车场（只登记不执行）	24
8.3	下一阶段的入场券与判据	24
8.4	已明确排除、不应重走的方向	24
9	结论	25

1 阅读指南

你想知道什么	读哪里	节数估计
项目做出来的核心结论	第 3 节（六阶段技术内容）	5
某个方法为什么有效	第 3.4 节（机制链）	3
当初怎么走弯路的	第 4 节（三次翻案）	3
能不能落到硬件上	第 6 节（工程推演）	3
怎么复现一个数字	第 7 节（三条命令）	2
还有什么没做	第 8 节（停车场与入场券）	3

本报告的性质：它是一份归档，不是一份投稿论文。因此它刻意保留了负面结果、被否证的假说、以及三次失败的归因尝试——这些材料的价值在于让后来者不必重走。所有数字均可追溯到一个具体文件或命令输出；无法追溯的陈述一律不写入。

定位说明（2026-09-24 补，详见 docs/POSITIONING.md）：本项目的核心方法——冻结主干、只重训最后的线性层——**不是一个新方法**，它是迁移学习里的 linear probing；而「预训练特征好、偏移大时线性探针可胜过全量微调」是一条有理论与十数据集实证支撑的已知结论 [9]。**本项目的贡献是：**把它搬到一个新场景（模拟域非理想性），并给出该场景特有的**上界**（探针 headroom 与可恢复量）、**机制**（有效秩塌陷、同强度下正侧 Fisher 反高于负侧）、**边界**（门控两前提 + 读出层须在数字域），外加一个先行工作里没有对应物的**正交架构杠杆**（池化降维）。在 CIM 领域，「冻结阵列 + 数字域补偿」已有先例（例如用器件特定的电导漂移查找表配合自适应量化，在**不做片上训练**的前提下达到软件基线精度 [13]），但形态是**标量或查找表级校正**；本项目动的是整个读出层，代价更大（要求读出层可重写）。本报告同时**主动记录**了本项目最依赖的测量手段（线性探针）正被文献警示可能虚假饱和 [12]，以及对应的加固方案。

与测试时适配（TTA）/ 无源域适应（source-free DA）的关系：与本工作最接近的是这一支，它已确立「冻结主干、只更新极少数参数」是分布偏移下的有效范式——**Tent** 冻结全部主干、只更新批归一化的仿射参数 [10]；**SHOT** 冻结源模型的分类器、只学目标域的特征提取器，且不需要访问源数据 [11]；**Kumar** 等进一步证明预训练特征良好而偏移较大时线性探针可优于全量微调，并给出机制：微调在学头的同时会扭曲底层特征 [9]。**本文与 SHOT 共享”只动极少量参数、也不需要源数据”的取向，但动的对象正好相反——**本文冻结的是特征（主干物理上不可重训），更新的是分类头。**本文与这三条的差异有三点：**① **偏移的性质不同——**TTA/DA 处理的是数据分布偏移，本文的失真是确定性的、逐层累积的、输入相关的系统误差，换一批测试数据不会让它消失；② **可动参数的范围与性质不同——**TTA 的”只动少数参数”是一种设计选择（主干在原理上仍可训练），而 CIM 里模拟权重因硬件原因物理上不可重训，冻结不是选择而是约束；③ **给出的量不同——**上述工作报告的是准确率，本文给出该约束下的可恢复量上界、损伤的几何形态与代价的定量权衡。

2 问题、口径与产物

2.1 失真模型

模拟域乘累加的输入侧失真建模为逐样本归一化后的三次多项式：

$$y = \alpha \hat{x}^3 + (1 - \alpha) \hat{x}, \quad \hat{x} = \frac{x}{\|x\|_\infty}, \quad (1)$$

表 1: 主干、参数量与设计角色

主干	参数量 (C10 / C100)	Conv	MaxPool	残差	设计角色
SimpleCNN	242 474 / 254 084	4	2	无	浅层基线
SimpleCNN+3×MaxPool	242 474 / 254 084	4	5	无	架构杠杆对照 (参数量不变)
Wide-CNN [†]	1 353 258 / 1 399 428	4	2	无	秩-恢复第 4 点
VGG-11	9 231 114 / 9 277 284	8	5	无	深度变量
ResNet-18	11 173 962 / 11 220 132	17	0	有	残差变量

[†] 与 SimpleCNN 的差异有两个变量: 容量 (1.40M 对 0.25M) 与第二次下采样位置 (SimpleCNN 的 conv4 在 16×16 、本主干在 8×8)，后者是 MACs 约束下的取舍。

$\hat{x}$ 按 batch 维逐样本做无穷范数归一化，避免样本间串扰；失真通过前向钩子挂在每一个 Conv2d 与 Linear 算子的输入侧，逐层注入，每层可以有自己的 α (除特别说明外，扫描时同一个 α 施加到所有层)。 $\alpha > 0$ 时中段被压低， $\alpha < 0$ 时中段被抬高。

2.2 度量口径与自检

全阶段统一四个标量指标：

指标	定义
clean	$\alpha = 0$ 时的测试精度
drop@0.3	clean 减去 $\alpha = +0.3$ 时的精度
mid_band	$\alpha \in \{-0.2, -0.1, +0.1, +0.2\}$ 四点的平均精度
mean7	$\{-0.3, -0.2, -0.1, 0, +0.1, +0.2, +0.3\}$ 七点的平均精度

评估协议：全量测试集 (10 000 张)、best 权重、纯推理。每个实验的强度扫描文件里 $\alpha = 0$ 的行必须等于同目录 metrics.json 的 best_test_acc (容差 0.01)。该自检记在全局台账 results_master.csv 的 pairing_check 列，当前状态为 **152 行数据、0 FAIL** (58 行 PASS / 94 行 n/a；n/a 者为复用扫描与读出适配行，本就没有可配对的 metrics.json)。

2.3 数据集、主干与产物布局

数据集：CIFAR-10 (10 类) 与 CIFAR-100 (100 类) [8]。主干五个，参数量随类别数变化 (见表 1)。

产物目录按数据集分离：outputs/ (CIFAR-10) 与 outputs_cifar100/ (CIFAR-100)；全局台账由 build_ledger.py 只读扫盘重建，不修改任何既有产物。

3 六阶段的技术内容

3.1 阶段划分




图 1: 任务 1: 三个架构的非线性敏感性 (CIFAR-10)。 $\alpha = +0.3$ 时 SimpleCNN / VGG-11 / ResNet-18 分别跌 29.82 / 53.10 / 75.01 个百分点。数据: outputs/task1_*/alpha_sensitivity.csv。

阶段	主题	产出
一	敏感性、感知训练、架构增强、三项拓展	破坏力与方向性; NAT 的架构依赖; Exp2 方案
二	外推边界、Dithering 机理、深层迁移	NAT 是分布内属性; Dithering 机理判决; 方案可迁移
三	台账统一与四条新结论	读出瓶颈律与读出适配方法; 训练端四条负结果
四	读出端 vs 训练端的分解	在线 α 估计与路由; 架构杠杆的独立发现
五	完整配方、池化成因、跨数据集复现	池化保护的排除线; 事前预登记复现
六	定律化与落地	秩-恢复曲线; 深层门控边界; 工程推演; 测量纪律
七	归档后的自主迭代	容量非瓶颈 (六种读出对照); headroom 上界抬高; 三条排除型判定; 判据前提自检回溯审计; 收官三补 (LP-FT / 秩-恢复第 4 点 / ReLU 非负性)

3.2 第一、二阶段：任务层结果与三项优化（CIFAR-10）

前两阶段以 CIFAR-10 为主线，对应赛题的三项任务与三项拓展，以及评审意见带来的三项优化。它们的完整数值见竞赛版文档，此处给出归档要点。

口径注（实现归属）：本节以及第 4 节引用的第一、二阶段数值（任务 1-3、拓展 1-6）来自 task1 / task2_nat.py / task3_robust.py / task_extension*.py 这一条实现线；而本报告其余各节（第三～六阶段）的数值来自 v3_methods_simplecnn.py / v3_readout_repair.py / v5_* 等另一条实现线。两条实现线之间的精度数字不可直接相减或并列比较——它们之间存在一个稳定的实现级偏移（第 4 节记录为 5.55 个百分点，机制未明，按已知未知归档）。本节内部逐项自洽，但与后文各节之间只作定性对照，不作定量对比。

任务 1：正向失真的破坏力是负向的 3.4 倍（以 SimpleCNN 上 $|\alpha| = 0.3$ 计）；误差从浅层向深层累积，fc 层的输出与干净输出的余弦相似度仅 0.895；残差连接是误差放大器——ResNet-18 的跌幅（75.01）远重于 VGG-11（53.10）与 SimpleCNN（29.82）。

任务 2：非线性感知训练在纯前馈网络上有效（Scratch 策略 +9.15 / +8.04），但残差网络在极限正向下失效甚至退化（-1.44）；效果与注入点数量负相关（5 $\rightarrow$ 9 $\rightarrow$ 18）。中等失真上仍然有效（ResNet-18 在 $\alpha = -0.2$ 上 +18.84）。

表 2: 任务 2 与任务 3 的关键读数 (CIFAR-10, $\alpha = +0.3$, %)

任务	配置	SimpleCNN	VGG-11	ResNet-18
任务 2	clean (基线)	55.08	36.70	17.08
	NAT-Scratch	64.23 (+9.15)	44.74 (+8.04)	15.64 (−1.44)
	NAT-Finetune	56.08 (+1.00)	39.96 (+3.26)	19.89 (+2.81)
任务 3	Exp1 (+ 残差校准)	63.63	—	—
	Exp2 (+ 分层加权)	68.76	—	—
	Exp3 (+ 非对称采样)	69.14	—	—




图 2: 拓展 2: 非线性失真与加性高斯噪声的对照 (CIFAR-10)。三种架构上的排序完全不同, ResNet-18 上两者完全反转。数据: outputs/extension2_*/.../{gaussian,nonlinearity}_sensitivity.csv。

任务 3: 叠加残差校准模块与分层加权采样后, SimpleCNN 的 $\alpha = +0.3$ 达 **68.76%**。消融显示分层加权是贡献最大的单项 (+5.13), 非对称采样边际贡献仅 +0.38; 三个配置的干净精度 (87.19 / 87.37 / 87.59) 全部高于未增强的干净模型 (84.90) ——残差校准模块兼具正则化作用、不引入干净精度代价。

拓展 1-3: 脆弱性随深度与残差连接递增; 非线性失真与高斯噪声的鲁棒性不可跨域迁移 (SimpleCNN 对高斯更脆弱 37.02 vs 55.08, ResNet-18 则反之 57.15 vs 17.08); 量化与非线性的联合作用呈三分格局——SimpleCNN 超加性恶化 (4bit $\Delta = -7.23$)、VGG-11 次加性即 Dithering ($\Delta = +7.82$)、ResNet-18 地板效应 ($\Delta = +1.05$)。

【第三阶段的细化: L3 两通路机制】上段”不可跨域迁移”在第三阶段被两步修订, 此处补入归档 (这是本项目最早确立的三条定律之一)。

①迁移层面——”零迁移”是架构依赖的。把一条通路训好的权重拿到另一条通路上扫, 测扰动敏感性的变化幅度 $\max |\Delta_\sigma|$ (>1.2 判非零): SimpleCNN 1.16 (Exp2 vs 原始)、SimpleCNN 2.43 (NAT vs clean)、**VGG-11 5.26 (Exp2 vs clean, 零迁移被打破)**、ResNet-18 1.41。值得注意的是, 给 SimpleCNN 加 3 个 MaxPool 反而把迁移从 **2.43 降到 0.98** ——说明 MaxPool 密度不是迁移的成因。

②训练层面——不是零迁移, 而是单向强干扰。同一 harness 上的 2×2 (是否注入 $\alpha \times$ 是否注入 σ):




图 3: 拓展 3/优化二: Dithering 增益的架构依赖 (CIFAR-10, $\alpha = +0.3$)。增益与 MaxPool 密度同向, 但要足够密——2 个 MaxPool 的 SimpleCNN 是负增益, 0 个的 ResNet-18 无效应。数据: outputs/extension5_dithering_vgg11/arch_dithering_summary.csv。

训练条件	clean	$\alpha = +0.3$	$\sigma = 0.30$	双扰动最坏点均值
无训练 (clean 模型)	59.99	28.09	3.98	16.04
α -only	60.85	26.03	4.40	15.22
σ -only	55.79	22.01	27.19	24.60
$\alpha + \sigma$ (联合)	55.20	15.27	31.31	23.29

α 训练对 σ 几乎零收益 (4.40 vs 3.98); 但 σ 训练使 α 侧从 28.09 掉到 22.01 (−6.08, 对 clean 模型), 联合训练进一步掉到 15.27 (对只做 α 训练的 26.03 再低 −10.76)。双扰动并存时的最优配方是 σ -only, 不是联合训练——joint 里的 α 注入是净负担 (σ 侧仅多拿 4.12, 却付出 α 侧 −10.76)。⇒ 正确表述是「迁移近正交, 但训练端存在单向强干扰 ($\sigma \rightarrow \alpha$ 有代价、 $\alpha \rightarrow \sigma$ 无收益)」。

数字出处: 上表三行取自 outputs_cifar100/v3_methods/ 的 gauss_uniform / joint_uniform / budget_uniform 三份 alpha_sensitivity.csv (逐位可核)。迁移幅度表见第 3 节与 论文 v3.md §8 勘误 12。

优化二 (Dithering 机理) 的关键结论在本节之后的“失真与量化的联合作用”中给出; 其核心是否决了第一阶段给出的“随机共振”解释与“ADC 前注噪”建议 (等剂量注噪的增益约为零), 机理改写为“离散化分布重塑 + MaxPool 架构载体”。

优化一 (外推边界) 与优化三 (深层迁移) 的要点: 非线性感知训练的增益严格限定在训练分布内——正侧在 $\alpha \approx 0.4$ 处归零 (+0.77) 并反转劣势 ($\alpha = +0.5$ 时 −10.77), 而负侧随外推距离不降反升 ($\alpha = -0.6$ 处 +8.22); 架构容差窗口随深度单调收窄 (SimpleCNN 约 $[-0.35, +0.25]$ 、VGG-11 约 $[-0.25, +0.2]$ 、ResNet-18 约 $[-0.15, +0.15]$)。Exp2 方案可完整迁移到深层: VGG-11 在 15 个扫描点上全胜三条基线 (相对干净模型平均 +10.22), ResNet-18 全程无败; $\alpha = +0.3$ 的增益为 +13.55 / +3.04; 两架构的干净精度 (91.27 / 93.27) 均为四组权重中最高。多点校准 (5/8 处) 修复了 SimpleCNN 单点版本 (1 处) 在负侧外推输给 NAT-Scratch 最多 12.58 个百分点的短板。




图 4: 优化三: 增强方案向深层主干迁移 (CIFAR-10)。灰色虚线为同架构干净模型, 橙色为 Exp2 方案。VGG-11 上 Exp2 在全部 15 个扫描点上都优于三条基线; ResNet-18 上全程无败, 但正侧强失真区的绝对精度仍然很低。数据: outputs/extension6_deep_robust/alpha_wide_scan_deep_robust.csv。

3.3 失真有多大破坏力, 往哪里累积

$\alpha = +0.3$ 时 SimpleCNN 从 59.99 掉到 28.09、VGG-11 从 67.09 掉到 16.92、ResNet-18 从 72.09 掉到 2.70。按容量排序, 干净精度越高、跌幅越大, 这条反相关关系在同数据集内跨容量单调。

“3.4 倍不对称” 这个常被引用的数字不是常数: CIFAR-10/SimpleCNN/ $|\alpha| = 0.3$ 上是 3.4, CIFAR-100 同模型上只有 1.87。它的适用域还很窄——CIFAR-100 的三个主干依次为 1.87 / 1.18 / 1.01, CIFAR-10 的三个主干为 3.4 / 1.40 / **0.94**: 方向随深度衰减, 并在最深的主干上 (CIFAR-10/ResNet-18) 反号。

把“最脆弱的位置”分成注入位置与观测位置后, 一个反直觉结果出现: 单层注入探针中最敏感的是中间层卷积 (conv2 跌幅 -12.43、conv3 -7.56), 而 fc 单点注入只有 -0.68。全 5 层同时注入的跌幅 31.90 远超线性累加的 23.33 (超加性 -8.57)。fc 是误差的汇聚与观测点, 不是注入敏感点。

3.4 灾难尾丢的不是信息, 而是读出的可解码性

这是全项目的枢纽结论。图 6 用探针把它测出来。

$\alpha = +0.3$ 时探针达 48.35%、原始头 28.09%, headroom **20.26¹**; $\alpha = +0.4$ 时 30.90、+0.5 时 30.82。headroom 随失真增强先放大、后趋于平坦 (+0.3 $\rightarrow$ +0.4 增幅最大, +0.4 $\rightarrow$ +0.5 微降 0.08——不是单调上升)。

口径标注 (必读): 该探针逐 α 条件训练——它在每个测试点的失真特征上重新拟合线性头 (源文件 ra_onprotocol_main.csv 的 probe_same_cond 列, 与之并列的 probe_clean_train 列则只在干净特征上训练)。因此 headroom 是 **oracle- α** 诊断量: 它回答的是“若已知失真强度、且读出可自由重训, 线性解码还能恢复多少”, 不是可部署读数——不知道 α 时的实际读出读数是 43.31 (见第 3 节的读出适配)。作为对照, 只在干净特征上训练的探针在 $\alpha = +0.3$ 上只有 18.1, 低于原始头 (28.09)。

¹两项均取自全量测试集 (10000 张), 与项目的规范口径逐位一致 ($\alpha = +0.3$ 的 28.09 等于 task1 同名行; $\alpha = 0$ 的 59.99 等于 metrics.json 的 best_test_acc)。早期版本曾用 8000 样本子集, 给出 27.76 / 59.60 与 +20.12; 第七阶段 M0c 已在同一设备 (CUDA) 上重跑全量口径并替换, 全案见 docs/IMPL_AUDIT.md 与台账 §16.0。




图 5: 失真的方向性与容量依赖 (CIFAR-100)。三个主干在七点上的扫描；正侧跌落大于负侧（该方向在 SimpleCNN 与 VGG-11 上明显，在 ResNet-18 上几乎消失：两侧跌幅 69.39 对 68.84），且随容量与深度单调放大。数据：outputs_cifar100/task1_*/alpha_sensitivity.csv。

对照通路的判别力：同一套探针在加性高斯噪声 $\sigma = 0.3$ 下 headroom 只有 7.50。随机扰动与确定性系统误差在“信息还剩多少”这个量上清楚地分开。

3.5 修复：冻结主干、只重训线性读出

读出适配在三个主干上一致超过“全网络重训”整类配方，可训练参数只占 5.04%/0.55%，训练成本逐主干配对为 1/5、1/16、1/13（读出 12 / 25 / 30 min 对全网络 1 / 6.5 / 6.5 h），约低一个数量级。代价是干净精度下降 3.08~7.69 个百分点（ $\alpha = 0$ 处：读出适配的三 seed 均值为 55.81 / 64.97 / 65.00，对各自主干的原始头 59.99 / 68.05 / 72.69）。

必要的自我校验：单点读出适配（只对 $\alpha = +0.3$ 拟合）确实是再分配——该点 +24.70 但干净精度 -20.36、 $\alpha = -0.3$ 掉 25.71，七点均值反而低于基线。起作用的是分布式版本（ $\alpha \sim U[\pm 0.3]$ 上训练），它在每个扫描点都不显著劣化。同一层参数、两种训练方式给出质上不同的结果。

这条结论不只有探针读数背书：冻结主干、只重训一个线性头，在 $\alpha = +0.3$ 上实际达到 **43.31**（SimpleCNN, 3 seed, 24 ep 协议；同期原始头 28.09）——那是一个真实可部署的分类器，不是仅用于测量的探针。同口径的 **oracle- α** 探针读数为 48.35，即部署物取到了上界的 **89.6%**（43.31/48.35）。注意分母是 **oracle- α** 口径（假定失真强度已知），因此这个比例不是“部署时可以达到 89.6%”的意思。

3.6 训练端的五条路径为什么都没能改善尾部

前四条独立路径：采样预算分配（三种轮廓，最好 26.13，+0.10）、 α 空间对抗训练（24.32，-1.71）、课程式采样（21.78，-4.25）、训练范围外推至 ± 0.5 （20.48，-5.55）。基准（均匀采样）为 26.03。按本文自订的单种子门槛（尾部差值小于 3 个百分点不作为结论），其中只有课程式与外推两条可记为显著劣于基准（-4.25 / -5.55），对抗训练的 -1.71 落在门槛内、记为不可分辨，预算分配的 +0.10 与基准同级。前四条都没有改善尾部。

最强的一条证据是范围外推：**模型已在 ± 0.5 上训练过**，测试 $\alpha = +0.5$ 时仍只有 2.71%，同期负侧 -0.5 有 31.19%（差 28.5 个百分点）。正侧尾部不是采样覆盖问题，而是结构性的不可训




图 6: 探针 headroom: 灾难尾的标签信息仍然线性可达。在同一冻结主干的末端特征上, 线性探针 (实心) 与原始头 (空心, 即模型自带的分类头, 产物里的 `a_original_fc`) 的精度; 7 个 α 点, CIFAR-100 全量测试集 (10000 张)、best 权重、单种子。 $\alpha = +0.3$ 时相差 20.26 个百分点; 同样的探针在加性高斯噪声 $\sigma = 0.3$ 下只有 7.50。数据: `outputs_cifar100/v7_probe_audit/ra_onprotocol_main.csv`。

练区。

第五条动的是主干本身: 先训读出、再解冻微调 (LP-FT)。前四条都在“冻结主干、只改采样分布”的框架内。第五条先按上文读出适配把线性头训好 (LP), 再解冻主干与该头联合微调 (FT)——这是分布偏移场景下被证明优于全量微调的配方 ([9]; 原理是先把头训好再解冻, 避免随机初始化的头在早期用大梯度破坏预训练特征)。判据在跑前写死: $\alpha = +0.3$ 上相对同一次运行内的纯读出适配提升 ≥ 3 pp 即成立。结果如表 4: 三个主干一致大幅下降——不是“没有提升”, 而是“净损伤”。

机制比数字更有信息量: FT 阶段训练精度一路上涨 (SimpleCNN 88.9%、VGG-11 96.9%, 在混合 α 的训练分布上), 说明模型在训练分布上确实变好了; 而各 α 的测试读数全线变差、且尾部降幅远大于干净精度降幅 (VGG-11: -33.83 对 -10.38)。 $\Rightarrow$ 在失真分布上微调破坏了预训练特征——这正是 LP-FT 论文在分布偏移场景下要避免、而在失真场景下没有被避免的现象。 $\Rightarrow$ 它支持“训练端做的事越少越好”, 不构成对既有结论的修正; 同时把前四条的“无效”升级为“动到主干会主动变坏”。

3.7 损伤的形态: 维度丢失, 不是类间距缩小

$\alpha = +0.3$ 时有效秩下降 20.6% / 33.3% / 58.7% (三个主干); 负侧同强度下降 2.0% / 17.9% / 67.3%——“负侧几乎不动”只在浅层的 SimpleCNN 上成立, 而 ResNet-18 的负侧 (67.3%) 比正侧 (58.7%) 掉得更多, 其 +0.3 与 -0.3 精度也同样是两侧都崩 (2.70 / 3.25)。 $\Rightarrow$ 秩塌陷解释“正侧特殊”这条链, 只在秩塌陷本身不对称的主干上才连得起来。

关键在于浅层主干上: 同强度下正侧的 Fisher 判别比反而高于负侧——类间可分性没有变差, 丢失的是维度。这与幅度统计一致: $\alpha > 0$ 把深层特征的幅度向中段压缩 (fc 与 conv1 的 L2 范数比从 0.45 降到 0.23), 端点不变而中段被压低。

这解释了“信息还在但训练救不回”的表面矛盾: 信息仍存在于剩余维度里, 但这些维度在主干参数的可达域之外。




图 7: 读出适配跨三个主干一致抬升尾部 (CIFAR-100, 3 个种子的逐点均值)。实线为读出适配 (readout-NAT, 主干全冻结, 可训练参数占全模型 5.04%/0.55%), 虚线为各模型的原始头。数据: outputs_cifar100/v3_readout_repair/*ep24*.csv。

秩损失 19.9% / 20.6% / 33.3% / 58.7% 对应恢复率 68.2% / 72.2% / 70.2% / 36.9% ($r = -0.934$), 整体趋势成立; 反向不成立——ResNet-18 掉了 58.7% 的秩, 读出仍拿回 36.9%。

第 4 个容量档 (Wide-CNN: 1.40M 参数, MACs 为 VGG-11 的 0.87 倍) 的干净精度 65.97% 正好落在 SimpleCNN (59.99) 与 VGG-11 (68.05) 之间, 但它的秩损失 19.9% 与 SimpleCNN 的 20.6% 几乎重合, 没有落进中间段。⇒ 按预登记判据, 四点仍不足以判定曲线形状——“先平后塌”仍只是提示。

补测顺带得到一条比判据本身更重要的发现: 最左两点秩损失只差 0.7 个百分点, 恢复率却相差 4.0 个百分点 ($72.2 - 68.2$), 超过本文自订的 3 个百分点分辨门槛, 且两点出自同一读出流程、同一秩统计口径、同为 3 seed。⇒ 秩损失不是恢复率的唯一决定因素, 存在秩损失之外的变量。(须写明的代价: Wide-CNN 与前三点的差异不纯是容量, 它还含“第二次下采样位置”这一个变量, 是 MACs 约束下的取舍。)

3.8 第二个杠杆: 池化密度

5 个 MaxPool 的那一支以下简称 **mp** 主干 (表 1 的 SimpleCNN+3×MaxPool)。 $\alpha = +0.3$ 从 28.09 提升到 42.47 (干净训练)、26.03 到 41.55 (鲁棒训练; 两侧同为逐层独立采样, 同 seed 配对, 增益 +15.52), 七点均值提升 4.5~4.9 个百分点, 干净精度不降。

机制: 保护主要来自降维。四个候选解释被逐一检验, 其中三个被排除、一个判为不可分辨:

第四条 (ReLU 非负性) 是唯一没被排除的, 但也没能证实。表 5 的前三条都没有排掉一个更基本的原因: ReLU 把池化输入限制在非负域, 而在那里归一化三次映射与 max 精确可交换 (第一行实测)。若保护来源于这个非负性, 削弱非负性的激活应当让保护变弱。实测 (SimpleCNN, 2× 与 5× 两种池化密度 × 两种激活, 每格 3 seed): 池化保护 $P = (2\text{-pool 的 drop}) - (5\text{-pool 的 drop})$, 得 $P(\text{ReLU}) = +11.81$ 、 $P(\text{GELU}) = +14.71$, 差 -2.91, 落在预登记 $\pm 4 (2\sigma)$ 带内 ⇒ 判为不可分辨, 既不判成立也不判否定。更关键的是方向本身不稳定: 单 seed 时 +2.57 (与假说同向), 3 seed 时 -2.91 (反向)。这不是“接近显著”, 而是“这个量级的效应在本协议下判不了”——其噪声主要来自 2×max 一侧 (种子标准差 3.03 / 2.89, 而 5×max 一侧只有 1.54 / 0.26, 相差一个

表 3: 读出适配 vs 全网络鲁棒训练 (CIFAR-100, $\alpha = +0.3$, 精度%)

方法	训练成本	SimpleCNN	VGG-11	ResNet-18
原始头 (同主干)	—	28.09	15.98	6.22
读出适配 (24ep, 3 seed)	12~30 min	43.31 $\pm$ 0.16	47.79 $\pm$ 3.18	26.82 $\pm$ 3.40
全网络鲁棒训练 (最好)	1~6.5 h	29.89	24.69	6.22

表注(口径): 第一行为各读出实验所依附主干的原始头(v3_readout_repair的a_original_fc行在 $\alpha = +0.3$ 的读数; SimpleCNN 的该主干即 task1 权重, 故与台账逐位一致)。第三行为各架构上最好的全网络鲁棒训练配方 (SimpleCNN 取该主干在全网络下的最优结果 29.89; 同协议 3 seed 的 v3 路径逐层独立 NAT 均值是 26.57, 低于 29.89, 故本行取 29.89; VGG-11 与 ResNet-18 取 200ep 的 Exp3, 24.69 / 6.22)。注意 ResNet-18 的第三行与该列第一行是同一块主干——全网络配方并没有改善它的原始头。(task1 主干的 16.92 / 2.70 属另一批权重, 不参与本表逐列比较。)第二行的 $\pm$ 是”读出种子”口径(固定该主干、只换 3 个读出种子); 换成”主干种子”口径(读出侧固定 seed 42、3 个主干种子)后, 深层尾部均值为 VGG-11 46.82 $\pm$ 0.25、ResNet-18 22.91 $\pm$ 2.61——后者低于本表的 26.82。两组口径只有一格重合, 是同一张 3 $\times$ 3 表的两条不同边缘, 不可相减或互替。




图 8: 训练端的补救路径在 $\alpha = +0.3$ 上没有一条显著优于均匀采样基准 (CIFAR-100 / SimpleCNN)。数据: outputs_cifar100/v3_methods/*/alpha_sensitivity.csv。

量级)。

三条排除后, 唯一显著差异是空间元素数从 256 降到 16。同协议 3 种子对照: $5 \times \max$ 的 drop@0.3 为 20.60 ± 1.54 、 $5 \times \text{avg}$ 为 21.78 ± 0.91 , 差 +1.17 (标准误 1.03, $z \approx 1.1$) $\rightarrow$ ”降维: 非均值聚合”的定量比例不予裁决, 只给方向: 保护主要来自降维。若还要继续追这两条, 预算应花在 $2 \times \max$ 的更多种子上 ($5 \times \max$ 一侧的种子方差已经小一个量级, 加种子收益低)。

3.9 两个杠杆的叠加与在线估计

架构杠杆与读出杠杆在尾部可以同时受益, 但显著次可加、不是相加: mp 主干 + 读出适配的 $\alpha = +0.3$ 达 49.12 (相对基线 28.09 即 +21.03), 而两个手段单独的增益之和是 +29.67 (架构 +14.38 与读出 +15.29 分别取自同批单 seed 产物的 42.47 与 43.38)——合起来只拿到约七成, 损失约三成。本段四个数 (28.09 / 42.47 / 43.38 / 49.12) 全部为单 seed 口径 (连续均匀 α 、24ep、20k 样本, 同 v3 路径); 13 点离散 α 、3 seed 的 v5 口径给出同样的次可加结论。

失真强度可由读出特征的岭回归在线恢复: 四个主干 $\times$ 数据集组合上 R^2 0.827~0.935、MAE 0.036~0.061。

表 4: 第五条路径（解冻主干微调）在三个主干上都显著劣于纯读出适配

主干	纯读出 @+0.3	LP-FT @+0.3	尾部变化
SimpleCNN	43.40	31.55	-11.85
VGG-11 (Exp2)	47.92	14.09	-33.83
ResNet-18 (Exp3)	20.79	7.91	-12.88

两臂在同一次运行内、同一评估路径下测量；读出侧 seed 42。LP 24ep / lr 10^{-2} ，FT 30ep / lr 10^{-3} 。数据：
outputs_cifar100/v7_m8c_lpft/。




图 9: 正侧失真使末端特征的有效秩塌陷；负侧的形态随主干而异（SimpleCNN 几乎不动，VGG-11 与 ResNet-18 两侧都塌，ResNet-18 的负侧更甚）。纵轴为按各模型 $\alpha = 0$ 归一化的有效秩 $\exp(-\sum p_i \ln p_i)$ ；特征维数分别为 128 / 512 / 512。数据：outputs_cifar100/v5_rank_collapse/rank_stats*.csv。

3.10 门控的边界

CIFAR-100 的 mp 主干上，鲁棒头（即读出适配头，此处沿用产物列名 acc_robust_head）的干净代价 -5.89、门控收回 +2.90；但把深层主干加进来后，代价落进此前空白的 2~5 个百分点区间（VGG-11 -3.45、ResNet-18 -4.36），红利却没有跟着变大（+0.68 与 -1.14）。

原因：ResNet-18 的原始头在负侧是崩的（ $\alpha = -0.2$ 只有 10.27%）。软门控按 $w = |\hat{\alpha}|/0.3$ 插值，在 $\alpha = -0.2$ 处 $w \approx 0.67$ ，三分之一权重的坏头把 45.64 拖到 39.21。

门控有效需要两个前提同时成立：①鲁棒头干净代价足够大；②两个头在整个 α 轴上都不能崩。两前提无法做成装前的量化自检——两种候选定义在已有 7 个点上都不分离红利的符号（VGG-11 的最小精度只有 15.73 却红利为正；CIFAR-10 的 mp 主干（主干种子 43）的最小精度有 69.23 却红利为 -0.003）。

为什么它只能“弱支配”：一个机制级的回答。上面那条“跨数据集未复现”是经验事实；它后来有了一个机制级的解释，而这个解释同时把那个主张永久关闭了。

两个头的错误是否互补可以直接测：取两个头在同一批样本上的 0/1 错误指示向量，算它们的 ϕ 相关。只有当两头的错误负相关时，插值才可能“集成”出比两头都好的结果（ $\phi = 0$ 即相互独立）。实测（7 个 α 点 $\times$ 3 个种子 = 每个数据集 21 格；下面的范围是按 α 点做 3 seed 平均后的逐点极值）： ϕ 的范围在 CIFAR-100 上是 +0.594 ~ +0.706、CIFAR-10 上是 +0.519 ~ +0.830；“两头都错”的格数相对独立基线为 1.50 ~ 1.98 倍与 2.76 ~ 6.58 倍。 $\Rightarrow \phi$ 在两个数据集上都是强正——两个头的错误正相关，它们在同一批样本上一起错，「插值即集成」所依赖的互补性在两




图 10: 秩损失与读出可恢复量 (四点, $r = -0.934$)。恢复率 = 读出适配 @ $\alpha = +0.3$ 的精度 $\div$ 同一文件里原始头 @ $\alpha = 0$ 的精度。四点已不是单调关系: 最左两点秩损失只差 0.7 个百分点, 恢复率却差 4.0 个百分点。四点仍不足以定曲线形状: 形状提示为”先平后塌”。

表 5: 池化保护的四个候选解释与检验结果

候选解释	检验	结论
池化”吸收”了失真	归一化三次映射与 max 是否可交换	在池化输入 (post-ReLU, 非负) 上 精确可交换 ($\max \Delta = 0.000\text{e}+00$), 但可交换却非成因
质量向恒等区集中	5-pool 与 2-pool 的易感度 S 与不变区占比	5-pool 的 S 反而更高 (conv4: 0.1527 vs 0.1134), 不变区占比不变
max 的选择性	换成 top-2 池化 (与 f_α 不可交换)	保护与 max 等同 (42.98 vs 42.47, 单种子)
ReLU 的非负性	换成 GELU (破坏非负性) 后保护是否变弱	$P(\text{ReLU}) = +11.81$ 对 $P(\text{GELU}) = +14.71$ (SimpleCNN, 两种池化密度 $\times 3$ seed), 差 -2.91 , 落在预登记 ± 4 带内, 方向还随种子翻转 $\Rightarrow$ 不可分辨

个数据集上都不存在。

由此两条: ①那个机制是被**否认**, 不是”未能分辨”——本项目因此把「插值即集成」**永久关闭**; ②收益的上界由此可解释: 没有互补性可利用, 插值的增益注定有限 (实测”软门控减 oracle”的极差, CIFAR-100 为 1.60 pp、CIFAR-10 只有 0.71 pp)。但要分清: **被关闭的是机制解释, 不是那个效应本身**——CIFAR-100 上软门控确有若干点超过两个头, 那个效应仍然存在、也仍未被完全解释; 本段只说明了它的上界为什么不高, 没有说明它为什么不为零。

(出处: outputs_cifar100/v7_gate_mechanism/gate_errors.csv. 该诊断含一条恒等自检: $\text{soft} - \text{oracle} = (\text{rescue} - \text{hurt}) \times 100$, 通过。)

3.11 失真与量化的联合作用

VGG-11 上 4bit 量化的精度高于 8bit (CIFAR-100 +2.84、CIFAR-10 +6.53)。三假设判决 (以下机理数字全部取自 **CIFAR-10** 侧的 outputs/extension5_dithering_vgg11/——该目录才是当时跑机理分析的完整批量; CIFAR-100 侧的对应量见段末): **H1 随机去相关否决** (等剂量注噪 $-2.45/-1.87$, 8bit+ 最优剂量噪声 -0.03 ; 样本级翻转 4bit 为 4.15:1 而噪声条件约 1:1)、




图 11: 池化密度是零训练成本的独立架构杠杆。MaxPool 从 2 个加到 5 个（参数量不变、训练脚本不变）： $\alpha = +0.3$ 从 28.09 到 42.47。虚线为第一阶段脚本的产物：它与实线出自不同训练脚本（本项目实测跨脚本的精度数字不可直接比较），故属异协议、仅作参考，不与实线并列比较。

H2 分布重塑确认（分类器输入峰度 $1.486 \rightarrow 0.110$, 4bit 恢复到 0.214）、**H3 MaxPool 交互支持（必要条件）**（无 MaxPool 的 ResNet-18 免疫 $+0.39$, 但 2 个 MaxPool 的 SimpleCNN 是 -13.68 ）。

CIFAR-100 侧的平行读数（同批统计, 见 `outputs_cifar100/extension5_dithering_vgg11/`）：峰度 $2.541 \rightarrow 0.847$, 4bit 恢复到 0.980；翻转 4bit 为 655:371 (1.77:1)，噪声条件同样接近 1:1；ResNet-18 的 4bit 减 8bit 增益为 -0.21 、SimpleCNN 为 -14.71 。三条判决在两个数据集上同向（H2 的”峰度恢复”在 CIFAR-100 上幅度较小），这本身是一条跨数据集稳健性证据。

4 研究历程：三次”先归因、后被自己否认”

本节记录本项目最贵的一课。三次的形态完全一样：一个被当成”噪声”或”实现细节”的差异，被重新命名成一个”效应”，又被实验否认，最后回到未知。

4.1 第一次：把处理效应误读成噪声（ ± 3.15 混协议）

当时的判断：一组鲁棒训练的 3 个种子， $\alpha = +0.3$ 的读数是 21.41 / 26.73 / 26.95，标准差记为”尾部种子噪声 ± 3.15 个百分点”（同期干净精度只有 ± 0.51 ）。据此立下全项目规则：涉及尾部指标的对比必须 ≥ 3 个种子，单种子尾部差值 < 3 个百分点不构成结论。

问题：这 3 个种子来自两个脚本。

否认：补跑同脚本的第三个种子后，同协议的尾部标准差只有 ± 0.392 ，而混协议组是 ± 2.561 ——标准差被估高约 6 倍。进一步的定量分解显示：混合组里两个数相差 5.32，与实测的脚本级处理效应 5.52 几乎相等，也就是说那 2.56 里绝大部分不是随机噪声，而是两种训练配方之间的系统差。

制度补丁：散布对比必须同脚本、同一采样代码路径。




图 12: 门控红利不随鲁棒头代价单调增长。七个点取自四个主干配置与两个数据集，各 3 个种子。七点 $r = -0.533$; 去掉 CIFAR-100 远点后 $n = 6$ 时符号反转为 $+0.351$ 。数据: v5_full_recipe/recipe*.csv。

表 6: 5.55 个百分点差异的三次归因尝试

轮次	归因	结果
1	尾部种子噪声 ± 3.1	否认: 三种子来自两脚本; 同协议标准差只有 ± 0.39 , 混协议把标准差估高约 6 倍
2	α 采样粒度	否认: 同脚本切换粒度差 $+0.02$ ($z = 0.08$), 同粒度跨脚本差 $+5.52$ ($z = 9.4$)
3	随机数消耗位置	否认: 同脚本把消耗数从 5 改成 1, 差 $+0.11$

4.2 第二次：把脚本差异误读成采样粒度

当时的判断: 同 seed 下两个脚本的 $\alpha = +0.3$ 相差 4.62 个百分点, 是纯协议标准差的约 11.8 倍。两脚本在数据加载、归一化、优化器、batch、epoch、调度器、增强、钩子机制、采样位置与评估口径上逐项核对一致, 因此判定”目前唯一可辨识的实现差异就是 α 采样粒度 (每批共享 vs 逐层独立)”, 并把它提升为候选定律。

否认: 在同一个脚本里只切换粒度: shared 26.55 vs per-layer 26.57, 差 $+0.02$ ($z = 0.08$); 而同粒度跨脚本差 $+5.52$ ($z = 9.4$)。效应跟着脚本走, 不跟着粒度走。

制度补丁: 涉及跨脚本比较时, 先做一次交叉评估 (把 A 的权重量到 B 的评估路径下), 确认评估侧无差。这条制度立刻在下一个实验中产生了价值。

更深的教训: ”逐项排除混杂”这种论证在跨实现比较里不成立。两脚本的 8 项都一致、训练损失逐 epoch 差 ≤ 0.016 , 效应却稳定存在。没出差异 $\neq$ 没有差异。

4.3 第三次：把序列位置误读成消耗数

当时的判断: 交叉评估把差异锁到”权重侧” (见下), 再据 α 采样轨迹把根因定为”随机数流错开”——一个脚本的 shared 模式消耗 5 个随机数、另一个只消耗 1 个, 第 1 个 batch 相同、之后完全错开。

否认: 在同一个脚本里把消耗数从 5 改成 1: 26.66 vs 26.55, 差 $+0.11$ 。消耗数不是因果。




图 13: 低位量化在池化密集架构上反转成增益 (VGG-11, $\alpha = +0.3$, CIFAR-100)。4bit 时精度最高, 比 8bit 高 2.84 个百分点。数据: `outputs_cifar100/extension5_dithering_vgg11/group_a_bits_scan.csv`。

最终图景: 一个脚本训出的鲁棒权重稳定落在 21.03 ± 1.00 (3 个种子, 逐 seed 19.67~22.02), 另一个脚本的六个 run 全部落在 26.58 ± 0.29 (逐 run 26.03~26.95), 两组相差 **5.55** 个百分点 ($z = 9.4$)。组内极紧、组间稳定分离——这正是最令人困惑的地方: 同脚本内换种子的流差异只值 ± 1 , 跨脚本却稳定值 5.55。

已排除的解释累计: 种子噪声、 α 采样粒度、随机数消耗数、评估路径 (8 个权重 $\times$ 2 条路径逐位相同)、训练动力学 (逐 epoch 损失差 ≤ 0.016)。仍未归因, 按已知未知记录。

最终的结论 (限定形式): 本文观测到一个同超参、同种子、跨实现稳定 **5.55** 个百分点的差异, 经三次干预实验仍未归因。在归因之前, 我们的做法是不跨实现引用精度数字, 部署校准与部署训练保持同实现、同路径。这不排除”某一脚本里还有一个尚未找到的具体差别”——把一个未定位的差异直接命名为”实现层普遍不可移植”, 证据不足。

4.4 三次翻案的共同点与制度沉淀

三次都是用自己的实验推翻自己上一轮的结论。三次的根因按项目内部的总结都是”没做交叉评估”——或者说, 在跨实现的比较里, 任何没有做干预实验的归因都只是命名, 不是因果。

沉淀下来的三条制度:

1. 降级一个数字, 必须扫它的整条引用链。含均值、差值、占比这些派生量——它们不带原值, 模糊搜索抓不到。这条制度立起来的原因是: 一次降级只改了被降级的那一节本身, 而它派生出去的数字还在下游活着 (其中一处甚至是”同一行内混了两个脚本”)。
2. 散布对比三要求: 同脚本 / 已交叉评估 / 未校准的组必须标注。后续补充第四条: 跨实现比较前先做消耗数等价检查; 且”同脚本 + 交叉评估”不足以让两套跨脚本数字可比。
3. 判据跑前写死, 跑后不改。六个阶段的每个实验都在台账里留了预登记, 包括那些最终被否证的。

5 第七阶段：归档后的自主迭代

归档 (tag v1.0-archive) 之后又进行了一轮自主迭代。本节记录它的产出——分两类: **加强结论的**, 与**排除解释的**。末尾补记收官阶段的三项实验 (LP-FT / 秩-恢复第 4 点 / ReLU 非负性)。详细台账见 `experiments_ledger.md` §16。




图 14: 交叉评估：差异不在评估路径。8 个权重分别在另一脚本原样导入的评估函数下重扫，两条路径给出逐位相同的读数；但两组权重稳定分成两簇。数据：outputs_cifar100/v6_p4e_crosspath/crosspath.csv。

5.1 两条加强中心结论的结果

(1) 容量不是这里的瓶颈。此前所有读出都是线性的，所以”瓶颈在读出”有一个明显的反驳：也许瓶颈只是在线性。为排除它，在同一批冻结特征上比较六种读出 ($\alpha = +0.3$, CIFAR-100, $n_{\text{train}} = 8000$):

读出	精度 (%)
线性头 (torch, 同族公平锚)	51.47
强正则逻辑回归 ($C = 0.01$)	49.23
sklearn 逻辑回归 (跨优化器参考臂)	48.25
两层 MLP (128 $\rightarrow$ 256 $\rightarrow$ 100)	48.62
瓶颈 MLP (128 $\rightarrow$ 32 $\rightarrow$ 100)	43.38
k-NN ($k = 20$)	38.12

三种非线性读出没有一个超过线性头（相对线性头 51.47: k-NN 38.12 即 -13.35 、瓶颈 MLP 43.38 即 -8.09 、两层 MLP 48.62 即 -2.85 ）。前两者的差距远超本轮立的可分辨门槛 ($\Delta_{\text{proc}} = 3.45$ pp, 见下)；两层 MLP 只差 2.85，落在门槛内、按本文自订规则不可裁决，方向上仍劣于线性头。而且参数越多反而越差——典型过拟合序。 $\Rightarrow$ 「信息仍线性可达」从”只测过线性”升级为「测过 k-NN 与两种 MLP 之后，线性头仍是最优读出」。

(2) headroom 是下界，而且可以抬高。把探针的训练样本从 8000 加到 50000（训练集全量）:

	探针 ($n=8000$)	探针 ($n=50000$)	冻结头
clean	53.56	59.00	59.99
$\alpha = +0.3$	48.35	55.72	28.09
headroom @+0.3	+20.26	+27.63	—

且仍未饱和（等宽对数斜率比 $r = 0.96/0.61$ ，判据要求 ≤ 0.5 ）。按”不相交划分”校正后约 +25.4 ($= 27.63 - 2.19$; 其中 2.19 pp 是”探针训练集与主干训练集不相交”这一口径在 $\alpha = +0.3$ 上比分布内低的量，出自台账 §16.0a 的三臂对照，此处按同口径移用到 $n=50000$ 档)。

这条观测的含义比数字本身重要： $+20.26$ 不是表征的某个固定属性，它是” 探针只喂了 8000 个样本” 下的读数。 $\Rightarrow$ **headroom** 是读出训练方式的函数——与下面那条” 过程自由度” 是同一件事的两个侧面。读出这一层不是免费的。

5.2 四条判定：三条排除型结论 + 一条限定

方向	判决
ETF / 原型读出 神经坍缩 (NC) 几何	无增益。三种原型或 ETF 正则读出均未超过线性头 未能构成稳健排除。类均值夹角偏离与模长变异系数在以全局 均值为中心的口径下正侧 5/5 上升（即远离 ETF）；但换成不 做中心化的口径，模长变异系数只有 1/5 上升——两版给出不 同的判决分支。 $\Rightarrow$ 该几何量对预处理敏感，「正侧 Fisher 反而 高于负侧」这条异常未能由它稳健地排除
” 少样本即可恢复全表示”	不成立。读出样本量曲线在 500~50000 上单调上升且未饱和， 需数千量级样本
门控两前提的装前自检	不分离。两种候选量化定义在已有的 7 个点上都分不开红利的 符号

排除型结论的价值在于：它们各自堵死一个替代解释。尤其第一条——原来” 读出瓶颈” 可以被反驳为” 你只测了线性头”，现在这个反驳不成立了。第二条 (NC 几何) 在本轮审计后不再作排除用：它两版判决不同、对预处理敏感，此处如实记为” 未能构成稳健排除”——这条降级本身就是信息：它说明该几何量在本配置下不具备判决力，因此不能拿它去否定别的解释。

5.3 方法学产出（本阶段最值钱的部分）

(a) 三级可分辨性。「跨实现不可移植」是一个已知未知，无法直接当门槛用。但它旁边两级可测的散布，合起来给出一个可操作的尺度：

层级	变的是什么	实测幅度
①种子噪声	同一过程重复	尾部 $\pm 0.25 \sim 3.40$; clean $\pm 0.07 \sim 1.85$
②过程自由度	同数据、同特征、同架构，只换拟合过程	3.45 pp
③跨实现	同超参同种子，实现不同	5.55 pp (未归因)

第②级是这样测的：同一批冻结特征、同一个线性头，只换六种拟合过程 (sklearn lbfgs / saga; torch Adam 50/150/400 轮; SGD+ 动量 150 轮)。结果极差 **3.45~3.46 pp**。

一个反直觉的细节： $\alpha = 0$ 的最大值与最小值都来自同一个优化器的不同轮数 (Adam 50 轮最高 56.31、Adam 400 轮最低 52.85)，该点上” 训多久” 的跨度 (3.46) 覆盖全距。 $\alpha = +0.3$ 上要打一点折扣：极值跨了两个因子 (最高仍是 Adam 50 轮的 51.57，最低是 SGD+ 动量 150 轮的 48.12)，轮数跨度 3.02、同轮数的优化器跨度 2.25——前者仍更大，但不独占。 $\Rightarrow$ 过程自由度的主要来源是” 训多久” 而不是” 用哪个”；这条在 $\alpha = 0$ 上最干净，且只在本文测过的这一个特征集与头规模上成立，属提示性结论。

$\Rightarrow$ 由此立一条规则：任何” 读出类” 效应 (换头、加正则、改容量) 的可分辨门槛，必须同时以 Δ_{proc} 为参照，不能只用种子噪声——种子噪声测的是” 同一过程重复”， Δ_{proc} 测的是” 换一个过程”，后者才是接收端口真正面对的不确定性。

(b) 两条口径陷阱 (都是本轮内实测触发的，不是转引文献)。

陷阱	不做会怎样	为什么会
不做 RMS 归一化	负侧结论反号	$\alpha < 0$ 把深层激活抬到 1.87 倍，固定绝对噪声相对更”小”，失真组虚假显得更鲁棒
不做中心化	判决从分支②变③	NC 的定义是”以全局均值为中心”的单纯形框架；不去均值则度量的是别的几何量

(c) 两个工具（把纪律固化，不靠记性）。

- tools/check_papers.py: 提交前检查（markdown 残留 + 编译两遍 + 数错误 + 数未定义引用）。本阶段在 .tex 里混写 markdown 踩了 8 次，其中 7 次由它拦下——手动检查已被证明不可靠（有两次是”修完以为干净了、实际还有”）。
- docs/DERIVED_VALUES.md: 派生值登记表。均值、差值、比值这类数字不以字面形式存在于任何产物文件里，复核的人必须知道算式才复得出来。该表登记它们的文件/行/列/合成方式。

(d) 一次对存量判据的「前提自检」回溯审计。本阶段先撞出两次同形缺陷 (§16.5a、§16.7)，据此立了一条要求：凡拿某个量当参照或判据依据的，都要补该量的前提自检。制度立起来之后的第一件事，是拿它回头扫存量：扫 30 条显式预登记判据，得 8 条同类缺陷（命中率 27%），其中 5 条足以翻转判决、3 条已由实测确认翻转。一条时间上的观察：8 条缺陷全部落在 §4~§13 这一段（早期阶段），§14 及以后一条都没有——不是”后来的判据写得更好”，而是制度立起来之后，同类缺陷在当场就被抓了。顺带发现：无——本次未发现任何”实验结论本身”的问题，全部 8 条都是判据写法问题，不是执行或数据问题。（出处：台账 §16.8；本节无新产物文件。）

5.4 收官补测：三项实验（2026-09-26）

M4 收工之后还有一段 GPU 空窗，补跑了三项此前排在队尾的实验。三项都不需要修改既有结论，其中一项把已有的表述改得更准。详细台账见 §16.9 / §16.10 / §16.11，正文细节已并入上文对应各节。

实验	判决	一句话
M8c LP-FT	阴性（强）	先训读出、再解冻主干微调，三个主干一致大幅下降（-11.85 / -33.83 / -12.88）。机制：FT 阶段训练精度涨到 88.9% / 96.9%，而各 α 测试全线变差、尾部降幅远大于干净降幅 $\Rightarrow$ 微调破坏了预训练特征。这正是 LP-FT 论文在分布偏移下要避免的现象，在失真场景下没有被避免。 $\Rightarrow$ 支持”训练端做的事越少越好”
M5 秩-恢复第 4 点	仍不足以判定形状	新增 Wide-CNN 容量档（1.40M 参数 / 133.3M MACs），干净精度 65.97% 居中，但秩损失 19.9% 与 SimpleCNN 的 20.6% 几乎重合，没有落进中间段。顺带发现比判据更重要：秩损失只差 0.7 pp、恢复率却差 4.0 pp $\Rightarrow$ 秩损失不是恢复率的唯一决定因素
M14b ReLU 非负性	不可分辨	把 ReLU 换成 GELU：P(ReLU) = +11.81、P(GELU) = +14.71，差 -2.91，落在预登记 ± 4 带内。方向还随种子翻转（单 seed +2.57、3 seed -2.91） $\Rightarrow$ 不是”接近显著”，是”判不了”

这一轮的附带产出（比三条判决本身更值得记）：

1. 一个新的、可执行的下一个问题。M5 把”秩损失预测可恢复量”这条从一个开放搜索变成了一次有对照的检验——我们已知道两个主干在几乎相同的秩损失下相差 4.0 pp，那么找出它们除秩损失之外还差什么，答案就在里面。
2. 噪声来源被定位。M14b 补 seed 后看出：2×max 的种子标准差 (3.03 / 2.89) 比 5×max (1.54 / 0.26) 大一个量级。⇒ 若要真正裁决非负性假说，预算应花在 2×max 的更多种子上。
3. 一条负面方法学经验。全模型反传叠加”每 batch 注册失真 hook”会让训练慢 7 倍（实测 > 13 min/epoch，而该主干从头训练是 105 s/epoch），实验一度被迫中止。⇒ 微调类实验要单独配 batch 与 hook 策略，不要复用”冻结主干前向 / 浅层训练”的配置。

5.5 本阶段自我暴露的问题（同样留痕）

问题	处置
探针 headline 曾是 8000 子集口径 一处数字全仓库无出处	台账 §6 登记过、但没传播进论文。重跑全量口径并替换，扫了 5 个文件 49 处数字 追查 12.76 时发现它不存在，原句还把两个不同基线的数并进一个区间。登记为勘误 12
四处 Fisher 措辞丢了比较对象 读出适配的命名会骗人	”正侧升高”不成立（正侧内部只有 +0.1 升），且可被本文自己的表格否定。全部改为带比较对象的写法 s4{2,3,4} 三个文件其实是同一个主干变读出种子。新主干改用 bs<seed> 区分，并加”原头读数 = 主干 metrics”的核验
摘要与贡献列表落后于正文	正文加了四块内容后外围文档没跟上。这是”扫引用链”在文档层的同类问题

6 工程落地推演

本节把研究结论映射到真实 CIM 的数字后端。零实验、全部是推演；每个数字要么来自仓库里的实测（标出处），要么是本节现算的（标算法）。判定分三档：可行 / 需改动 / 不可行。

6.1 场景设定

- 模拟阵列负责卷积与全连接的乘累加，权重固化在阵列里（这是 CIM 省功耗的前提）；
- 阵列输出经 ADC 回到数字域；
- 失真发生在模拟域的输入侧，逐层注入（式 (1)）；
- 数字后端（ADC 之后）可以做任意运算，代价是面积、延迟、功耗。

本节不涉及：ADC 位宽、阵列规模、模拟域校准电路。这些在项目数据里没有对应测量。

6.2 三档判定

6.3 唯一的硬约束

读出层必须落在数字域或可重写——这是全部结论里唯一需要硬件配合的地方。它的改动方向与 CIM 的常见架构一致：ADC 之后本来就是数字电路，把最后一层放在数字域，很多设计本来就这么做。落地的关键问题是”你的 CIM 把哪一层当读出”，而不是”能不能改”。

表 7: 把结论映射到 CIM 数字后端

组件	判定	依据
读出适配	需改动	要求读出层位于数字域、或阵列里那一小块可重写。若读出也被固化在阵列里，该方法不成立。读出层只占全模型参数的 5.04% (SimpleCNN) / 0.55% (VGG-11)，把它挪出阵列对阵列面积的影响很小
在线 α 估计 (岭回归)	可行	128/512 维点积，算力占主干前向的 3.8e-4% / 2.4e-4%。真正的代价在面积：多一份 d 维权重的存储
软门控 (双头插值)	可行 (前提同第一条)	纯数字域逐元素运算，每次推理约 400 次操作。原始头是冻结不动的那一个，正好可以烧进 ROM
冻结主干	可行	就是”不训练主干”，天然符合权重固化
MaxPool 密集主干	设计阶段零成本 / 部署后不可行	它是网络定义的改动，只能在投片前决定；好消息是它零训练成本
全网络重训	不可行	阵列里的权重是烧录/固化的；而且训练端五条路本来就救不了尾部

6.4 风险清单 (不是结论)

1. 失真形态的假设。全部收益都是在”逐层、逐样本 max 归一化、三次多项式”下测的。真实芯片的失真未必是这个参数化形式。参考：加性高斯噪声这条对照通路的 headroom 只有 +7.50，比非线性的 +20.26 低得多。
2. ADC 量化与失真的联合。已测：SimpleCNN 上 4bit 是超加性恶化，VGG-11 上是次加性。也就是说”数字域后处理能救多少”要分层看。
3. 跨脚本的采样序列差异必须处理。两个脚本训出的鲁棒权重稳定差 5.55 个百分点，评估路径已验证无辜。落地时两套数字不可混用。

6.5 没做的事

没有硬件实测，也没有 RTL/功耗仿真；没有把”读出层挪到数字域”的具体接口写出来（时序、位宽、与 ADC 的对接）；没有评估在线重训读出在现场是否可行；没有考虑多任务/多模型共享阵列的情形。

7 可复现性手册

7.1 环境

- Python 必须用 conda 环境 `pytorch_env`。直接敲 `python` 在本机解析到别的解释器（没有 torch）。
- 输出重定向到文件时设 `PYTHONIOENCODING=utf-8`，否则会在打印特殊字符（如 R^2 符号）处因编码中断。
- 显存 8GB。训练任务必须严格串行。本项目出过两次事故：并发 4 个带 DataLoader worker 的任务导致 Windows 提交内存耗尽；一次 CUDA 显存不足（两个训练同时跑）。
- checkpoints/ 与 *.log 在 .gitignore 中，不进版本库。

7.2 复现一个数字（三条命令）

```
# (1) 重建全局台账（只读扫盘，不修改任何既有产物）
<python> build_ledger.py
# -> [ledger] 152 rows -> results_master.csv
# -> [ledger] 冒烟过滤 = 5 行 (epochs==1 或 run_id 含 smoke; 产物留盘不动)
# -> [ledger] pairing FAIL = 0

# (2) 看某一行的四个字段（例：CIFAR-100 / SimpleCNN / clean 基线）
grep "cifar100|simple_cnn|clean|7pt" results_master.csv
# -> clean=59.99 drop_at_0.3=31.9 mid_band_mean=53.5175 pos_0.3=28.09

# (3) 复算派生量（七点均值），核对文档里的 mean7
<python> tools/recalc_mean7.py
```

其中 <python> 为 /d/anaconda3/envs/pytorch_env/python（或本机等价路径）。

口径自检：任意一个 run 的强度扫描文件里 $\alpha = 0$ 那一行，必须等于同目录训练指标文件的 best_test_acc（容差 0.01）。

7.3 重新出图

```
<python> paper/figures/gen_figures.py # 期刊/技术报告版 (F01-F11)
<python> paper/figures/gen_figures_comp.py # 竞赛版 (C01-C08)
```

两个脚本都只读 CSV，脚本内不硬编码任何精度数字，末尾打印关键读数供交叉核对。中文图使用 SimHei 字体，输出 PDF（矢量）与 PNG（300 dpi）两种格式。

7.4 读文档顺序

1. paper/storyline.md——Central Claim 与 Question-Experiment-Finding 映射表；
2. paper/results-outline.md——每个结果子节的 Question / Data / Finding / 1-hop；
3. paper/discussion-notes.md——2-hop 综合、一般原理、局限与未来工作；
4. experiments_ledger.md——逐实验的预登记判据与结果（最权威的一手台账）；
5. results_master.csv——机器可读的全局表；
6. 本报告第 4 节——最应该读的一节。

8 局限、停车场与下一步

8.1 局限（每条导致一个由本文发现引出的问题未决）

(1) 失真模型是参数化假设，且无硬件实测。若真实 CIM 的非线性更接近高阶多项式、带温度依赖、或器件间失配有随机成分，headroom 还有多大、读出杠杆是否成立，无法回答。已知下界来自高斯对照（20.26 $\rightarrow$ 7.50）。

(2) 深层差值的可裁决性（已补测，原判断部分保留）。原写“深层主干是单次训练产物……涉及深层的所有差值是否在主干种子方差内无法裁决”。现每个深层主干已补训到 3 个种子（读出侧固定 seed 42）。尾部（ $\alpha = +0.3$ ）的主干级标准差为 VGG-11 0.25、ResNet-18 2.61，均小

于对应的读出级标准差 (3.18 / 3.40) ——即此前印出的 $\pm$ 值没有低估总不确定度。读出适配线上的深层差值因此可以裁决 (须写明在已测主干上成立); 而门控红利 -1.14 仍落在主干级散布 2.61 之内, 这一条仍然不可裁决——理由从“没有测”变成了“测了, 方差确实盖得住它”。

(3) 池化保护的机制分解没有定下来。两个子问题都没有结论: ①定量分解——avg 与 max 的差值只有 +1.17, $z \approx 1.1$; ②非负性——换成 GELU 后保护之差为 -2.91, 落在预登记 ± 4 带内, 且方向随种子翻转 (单 seed +2.57、3 seed -2.91), 只能记为不可分辨。

(4) 秩-恢复关系仍不足以定形状, 且秩损失不是唯一决定因素。第 4 个容量档已补齐, 但它与 SimpleCNN 的秩损失几乎重合 (19.9% 对 20.6%), 没有落进中间段, 故曲线形状仍未判定; 同时它暴露出秩损失相同的主干恢复率可差 4.0 个百分点 (> 3 pp 分辨门槛) $\Rightarrow$ 秩损失之外还有一个变量, 本文未识别。

(5) 跨实现的 5.55 个百分点差异未归因。已验证无效的路径是换评估路线; 必须动训练循环。

(6) 读出适配要求读出层可写, 且未评估其硬件代价。

(7) 读出适配只在 $|\alpha| \leq 0.3$ 的窗口内评估过。全部读出产物的 α 网格都是 ± 0.3 七个点 (v3_readout_repair/*.csv 的表头逐字如此), 没有一份覆盖 $\pm 0.4 / \pm 0.5$ 。而原始头恰在那两处跌到 12.32 / 6.09, 探针 headroom 反而最大 (+30.90 / +30.82) ——读出杠杆在更远的尾部还能捞回多少, 由现有数据无法回答, 而那里正是工程上最需要这个杠杆的地方。

(8) 架构杠杆只在含池化的主干上验证过。「池化密度是独立杠杆」的证据全部来自 SimpleCNN 家族 (MaxPool 2 个 $\rightarrow$ 5 个); 而本项目用的 ResNet-18 已按 CIFAR 适配去掉初始 MaxPool, 其 maxpool_count 为 0 (outputs_cifar100/extension5_dithering_vgg11/arch_dithering_summary.csv) ——对本身不含池化的架构 (含注意力主干), 这条建议没有对应的旋钮, 本文给不出替代方案; 而第 6 节把它排在落地顺序的第一步。

(9) 证据全部来自 CIFAR 上的小型卷积主干。参数量跨度只有 0.25 M~11.2 M, 架构形态全部是 ReLU + 卷积/池化堆叠 (无注意力、无归一化型主干)。「先测 headroom、再决定修哪里」这套测量顺序能否外推到注意力架构与更大规模, 本文未验证; 而第 6 节的推演没有限定架构。

(10) 探针是 oracle- α 读数, 缺一条与部署同构的读出臂。探针逐 α 训练 (见第 3 节的口径标注), 因此 headroom 度量的是“已知失真强度时还能恢复多少”。一条用 α 混合数据训练的 (与部署同构的) 读出臂尚未产出 (脚本与预登记判据已就绪, 受资源限制未执行); 在它落定之前, headroom 与部署可达之间的缺口有多大, 无法回答。

(11) 低位量化与读出适配从未组合测量。「低位量化在池化密集架构上反转为增益」的证据取自未施加读出适配的原始头, 且固定在 $\alpha = +0.3$ 。两条杠杆 (量化与读出适配) 从未落在同一份产物上, 它们的收益是可加、还是互相挤占同一个补偿机制, 本文无法判定。

8.2 停车场 (只登记不执行)

8.3 下一阶段的入场券与判据

8.4 已明确排除、不应重走的方向

为避免后来者重复试错, 以下方向在本项目中已被实验否定, 不建议再列为候选:

- 读出训练时混入干净样本以回收干净精度代价——权衡中性, 两档之间非单调;
- 在 ADC 前注入随机噪声以复现 Dithering——等剂量注噪的增益约为零 (假设已否决);
- 通过训练期采样设计 (预算分配 / 对抗 / 课程式 / 范围外推) 提升正侧尾部——四条独立负结果 (无一改善, 其中两条显著劣于基准、一条落在单种子门槛内、一条与基准同级);

表 8: 待办清单

#	想法	成本	备注
0	鲁棒权重为何稳定低 5.55 个百分点? (机制解释)	≥ 2 次训练	已排除 5 项; 最高优先 。核心谜题: 同脚本换种子只值 ± 1 , 跨脚本稳定 5.55 ($z = 9.4$)
1	采样粒度的跨架构复现	—	已取消 : 粒度不是杠杆
2	粒度 $\times$ 深度的交互	与 #1 合并	前提已失效
3	其他采样粒度定义 (逐 block 独立等)	2~3 次训练	前提已失效
4	粒度对负侧的影响	0 (复用)	降为”数据已到手, 未分析”
5	R^2 上界能否用”池化压掉多少 α 信息”定量解释	0 (复用)	零成本
6	深层主干的重训散布	4 次训练 $\times$ 4h	贵, 但能说清深层结论的置信度
7	门控”两头都不崩”能否量化成装前自检	0 (复用)	已判否定 (两种定义都不分离)
8	深层双头为什么绝对值不低	0 (复用)	需先做同口径比较
9	秩-恢复曲线的形状 (”先平后塌”)	需第 4 个模型	再加 1 个模型即可看形状
10	跨数据集/跨架构的粒度复现	—	设计目的已失效, 等 #0 查清后决定

- 先训读出、再解冻主干微调 (LP-FT)——**不但无效, 三个主干一致大幅下降** ($-11.85 / -33.83 / -12.88$), 机制是微调破坏预训练特征;
- 把”两头都不崩”做成量化自检——两种定义在已有数据上都不分离。

9 结论

1. 在逐层三次多项式非线性失真下, 网络在灾难尾损失的是**读出的可解码性**而非表征中的信息 (oracle- α 探针 headroom 20.26 个百分点; 高斯噪声下仅 7.50)。
2. 据此, 冻结全部模拟权重、只重训最后的线性层, 可把尾部提升 $+15.2 \sim +31.8$ 个百分点 (CIFAR-100, 24 ep/20k, 各 3 seed), 成本约为主干重训的 $1/5 \sim 1/16$ (逐主干配对: 读出 12 / 25 / 30 min 对全网络 1 / 6.5 / 6.5 h), 并一致超过所有全网络鲁棒训练配方。
3. 训练端的五条补救路径没有一条改善尾部 (前四条中两条显著劣于基准、一条落在单种子门槛内、一条与基准同级; **第五条解冻主干微调反而主动破坏**, 三主干 $-11.85 / -33.83 / -12.88$); 正侧尾部是结构性不可训练区, 其形态是**维度丢失** (有效秩下降 20.6%~58.7%) 而非类间距缩小。
4. 架构端的池化密度提供另一条零成本的独立杠杆 (同协议同 seed 配对 $+15.52$ 个百分点), 其保护主要来自降维; 两个杠杆在尾部可以同时受益, 但**显著次可加、不独立相加**。
5. 失真强度可由岭回归在线恢复 (R^2 0.83~0.94), 使门控可以逼近 oracle; 但门控有效需两个前提同时成立。
6. 工程上, 全部结论只依赖一个硬件条件: **读出层位于数字域或可重写**。
7. **测量纪律上**: 本文观测到一个跨训练实现稳定 5.55 个百分点的差异, 经三次干预实验仍未归因; 在归因之前, **我们的做法是不跨实现引用精度数字**。该差异按已知未知记录——**未排除”某脚本里还有未被找到的具体差别”**。

表 9: 建议的入场判据（需裁决后才能生效）

入场券	判据	成本
#0 的机制解释	前置要求：必须能解释”为什么同脚本换种子只值 ± 1 、跨脚本却稳定 5.55”这个量级差：只给出一个新名字不算（这条已被证伪三次）。已验证无效的路径：换评估路径。建议做法：逐行对齐两个训练循环做二分	≥ 2 次训练
深层主干散布	已兑现（M4）：主干级标准差 VGG-11 0.25、ResNet-18 2.61，均小于读出级，深层差值因此可以裁决	已收工
池化保护的两成分分解	每组 ≥ 8 个种子，或换效应量更大的对照（池化窗口 2×2 vs 4×4 ）。补充（M14b 实测）：同一批数据还带出一条预算指引——噪声集中在 $2 \times \max$ 一侧（种子标准差差一个量级），追加种子应投在那里	9~10 h
秩-恢复曲线形状	已测（M5）：第 4 点与 SimpleCNN 的秩损失几乎重合（19.9% 对 20.6%），故形状仍定不了，判为”仍不足以判定”。但这次补测引出一个更值得做的问题——找出秩损失之外那个变量	已收工

参考文献

- [1] Yu S, Chen P Y. Emerging memory technologies: recent trends and prospects[J]. IEEE Solid-State Circuits Magazine, 2016, 8(2): 43–56.
- [2] Ankit A, El Hajj I, Chalamalasetti S R, et al. PUMA: a programmable ultra-efficient memristor-based accelerator for machine learning inference[C]//ASPLOS. Providence: ACM, 2019: 715–731.
- [3] Bhattacharjee A, Bhatnagar L, Kim Y, et al. NEAT: nonlinearity aware training for accurate, energy-efficient, and robust implementation of neural networks on 1T-1R crossbars[J]. IEEE TCAD, 2022, 41(8): 2625–2637.
- [4] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//CVPR. Salt Lake City: IEEE, 2018: 2704–2713.
- [5] Wannamaker R A, Lipshitz S P, Vanderkooy J, et al. A theory of nonsubtractive dither[J]. IEEE Transactions on Signal Processing, 2000, 48(2): 499–516.
- [6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. Las Vegas: IEEE, 2016: 770–778.
- [7] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//ICLR. San Diego: ICLR, 2015: 1–14.
- [8] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.
- [9] Kumar A, Raghunathan A, Jones R, et al. Fine-tuning can distort pretrained features and underperform out-of-distribution[C]//ICLR. 2022. arXiv:2202.10054.
- [10] Wang D, Shelhamer E, Liu S, et al. Tent: fully test-time adaptation by entropy minimization[C]//International Conference on Learning Representations. 2021. arXiv:2006.10726.

- [11] Liang J, Hu D, Feng J. Do we really need to access the source data? Source hypothesis transfer for unsupervised domain adaptation[C]//International Conference on Machine Learning. 2020: 6028–6039. arXiv:2002.08546.
- [12] Rabby G, Auer S. When Graph-JEPA learns the wrong thing: diagnosing and repairing category-conditional collapse[R]. 2026. arXiv:2608.20516.
- [13] Xiao Z, Naik V B, Lim J H, et al. Adapting magnetoresistive memory devices for accurate and on-chip-training-free in-memory computing[J]. Science Advances, 2024, 10(38): eadp3710.